你永远不知道一个强迫症能干出什么事情

倪兴程 [1]

2024 年 10 月 18 日

[1]Email: 19975022383@163.com

Todo list

以后压缩映射单开一章放在合适的地方 21
记得写完以后链接过来，并且在写上下确界与极限的时候就把无穷的情况并进去 . . 24
有空证明 27
记得把单调序列的收敛原理放在这里 29
这里有紧集映射的一个定理 75
有时间证明线性空间。 87
改 theo 引用 102
记得证明独立 112
需要再考虑一下是不是 SRS 和 SRSWR 都是这样的 154
回头补方差分析 183
在概率论里完善 Wilcoxon 秩统计量的分布相关理论，然后链接过来 195
没搞懂这里的连续性修正是个什么情况 203
在完成试验设计之后，把多样本位置检验与方差分析部分结合起来 204
记得以后要写多重假设检验的校正问题 211
需要找论文，Patil(1975)，同时需要看统计量的推导过程，为什么单侧检验 219
现在只提供了大样本近似，回头看完论文和原理记得补 219
有机会看看这里平衡与不平衡的不完全区组设计有没有什么区别 220
代码现在是只考虑平衡的 221
有空证明 226
根本没懂原理 229
查资料看 Kendall 的打结是否和 Friedman 一致 230
写完概率论把独立性链接到这里来 232
有机会看看单侧的实际意义，不懂为什么会考虑单侧 233
写完概率论把 Pearson 线性相关系数链接过来。 235

前言

其实这个想法在我大二之初准备全国大学生数学建模竞赛的时候就已经产生。第一次打数模国赛时整篇论文的编排工作由组内成员负责，当时我并不了解 LaTeX 的语法与使用，但由于 IGEM 校园选拔赛要求每位申请数模组的同学提交一篇自己独立完成的数学建模论文，我便开始学习 LaTeX。

本科阶段我曾学习大量数学专业课程，从基础的数学分析、高等代数到后来的随机过程、实变函数与泛函分析。我曾苦于寻找合适的教材（请允许我吐槽一下国内的本科教材，北大版高等代数与华东师大版数学分析简直不是人能看得下去的东西），感谢知乎、csdn 等处各位同学、学长学姐们的分享，我才得以接触到一些适合我的教材。以数学分析为例，我主要以北京大学张筑生教授编写的《数学分析新讲》为学习教材，以苏州大学谢惠民、恽自求等教授编写的《数学分析习题课讲义》为习题册进行查漏补缺，同时也曾阅读复旦大学陈纪修教授、北京大学伍胜健教授编写的《数学分析》，对清华大学于品教授的讲义也曾匆匆一瞥，这些教材都可以称为是国内顶尖的数学分析教材了。可是每本书都有每本书自己的特点，对于任何一本书，以上所列的其他书籍都对其有着一定的补充，曾考虑使用 marginnote 软件将这些书籍整理成一些思维导图，但思来想去还是觉得不如自己动手重新编撰为一本属于自己的教材。首先，思维导图只能援引原著内容，难以进行个性化表述，即使可以，操作与使用起来都有一定的复杂性与不便性；其次，倘若重新整理，内容编排上可按我的个人习惯以及思维过程进行调整，也可引入适当高阶课程中的知识进行更高观点的阐释，不同课程中的交叉部分也很容易集中叙述；同时，LaTeX 的交叉引用（点击即跳转）的功能也十分吸引我；最后，自己编一本书，倘若确实质量不错，也可上传至 Github 或个人主页供后来者一阅。

曾想过在 Bilibili 上录播自己在 SRT 阶段学习到的机器学习、深度学习及生物信息学知识作为分享，同时也可作为自己复习的一手资料，也曾想过利用 csdn、知乎这两个平台发布自己整理的笔记，但终究没有付诸实践，略有遗憾，但我现在做的本科阶段知识的整理，我一定会完成它。

本书打算整理我本科所学的所有数学类课程知识，将伴随着我个人的考研复习进度逐步完成，预计耗时一年半。

倪兴程

2024 年 10 月 18 日于南京农业大学教四楼 B409

目录

前言 ii

第一部分　代数 1

第一章　线性空间 2

1.1　内积空间 2

第二章　矩阵分解 3

2.1　SVD 分解 3

第二部分　分析学 4

第三章　度量空间 5

3.1　度量空间上的点集 5

3.2　度量空间上点集的性质 7

3.3　稠密、稀疏、可分性、有界性 10

3.4　度量空间上的收敛点列 11

3.5　度量空间上的映射 13

3.6　完备的度量空间 15

3.6.1　柯西点列 15

3.6.2　完备度量空间的定义 16

3.6.3　度量空间的完备化定理 17

3.7　完备度量空间的性质 17

3.7.1　子空间的完备性 17

3.7.2　第一型集与第二型集 18

3.7.3　准紧性与全有界性 18

3.8　紧集与紧度量空间 20

3.8.1　紧集的性质 20

3.8.2　紧度量空间的性质 20

3.8.3 紧集的充要条件 21
3.9 压缩映射原理 21

第四章 实数序列 24
4.1 实数序列的上下极限 24
4.1.1 上下极限与聚点的关系 24
4.1.2 上下极限与极限的关系 25
4.1.3 上下极限的大小 26
4.1.4 上下极限的运算 26

第五章 数项级数 28
5.1 正项级数 29
5.1.1 收敛原理 29
5.1.2 比较判别法 29
5.1.3 Cauchy 判别法 30
5.1.4 比值判别法 31
5.1.5 D'Alembert 判别法 32
5.1.6 Cauchy 积分判别法 34
5.1.7 比较尺度问题 36
5.1.8 Raabe 判别法 36
5.1.9 Gauss 判别法 38
5.2 任意项级数 39
5.2.1 条件收敛的判别 39
5.3 收敛级数的性质 42
5.3.1 收敛级数的可结合性 42
5.3.2 绝对收敛级数的性质 43
5.4 级数乘法 47

第六章 函数序列与函数项级数 49
6.1 函数序列的收敛 49
6.1.1 逐点收敛 49
6.1.2 一致收敛 50
6.2 函数项级数的收敛 51
6.2.1 逐点收敛 51
6.2.2 一致收敛 51
6.3 极限函数的分析性质 54
6.3.1 连续性 54
6.3.2 定积分 55
6.3.3 微分 55

第七章 Lebesgue 积分 **56**
7.1 外测度 56
7.1.1 外测度的定义 56
7.1.2 外测度的性质 57
7.1.3 区间的外测度 58
7.2 可测集的定义与性质 58
7.3 可测集类 62
7.4 可测函数 64
7.4.1 可测函数的定义 64
7.4.2 可测函数的性质 65
7.4.3 可测函数与简单函数 67
7.4.4 叶戈罗夫定理 68
7.4.5 可测函数与连续函数的关系 68
7.5 积分论 69

第八章 赋范线性空间 **70**
8.1 范数 70
8.2 赋范线性空间作为线性空间的性质 72
8.2.1 基与维数 72
8.2.2 直和 72
8.2.3 有限维赋范线性空间的性质 72
8.3 Banach 空间 75
8.3.1 无限维 Banach 空间的基 76
8.4 Hilbert 空间 76
8.4.1 内积与范数的关系 77

第九章 常见度量空间与赋范线性空间 **79**
9.1 $\mathbb{R}^n$ 79
9.1.1 $\mathbb{R}^n$ 上的距离 79
9.2 $\mathbb{C}^n$ 80
9.2.1 $\mathbb{C}^n$ 上的距离 80
9.3 l^p 80
9.3.1 l^p 上的距离 81
9.4 l^∞ 81
9.4.1 l^∞ 上的距离 81
9.5 s 82
9.5.1 s 上的距离 82
9.6 S 82
9.6.1 S 上的距离 82

9.7 $C[a,b]$ 82
9.7.1 $C[a,b]$ 上的距离 83
9.8 L^p 83
9.8.1 L^p 上的距离 83
9.9 L^∞ 83
9.9.1 L^∞ 上的距离 83

第十章 Banach 空间上的有界线性算子 84
10.1 线性算子 84
10.1.1 线性算子的定义 84
10.1.2 线性算子的连续性 84
10.1.3 线性算子的有界性 85
10.1.4 线性算子有界与连续的关系 85
10.2 有界线性算子空间 86
10.2.1 有界线性算子空间的范数 86
10.2.2 有界线性算子空间中的依算子范数收敛 87
10.2.3 有界线性算子空间中的强收敛 88
10.2.4 有界线性算子空间的完备性 88
10.2.5 有界线性算子的乘法 89
10.3 Banach 空间上有界线性算子的四大定理 90
10.3.1 开映射定理 90

第三部分 概率论 91

第十一章 大数定律与中心极限定理 92
11.1 连续性校正 92
11.1.1 使用原因 92
11.1.2 具体方法 93

第四部分 不等式 94

第十二章 不等式 95
12.1 Cauchy 不等式 95
12.1.1 实数域上的 Cauchy 不等式 95
12.1.2 复数域上的 Cauchy 不等式 95
12.1.3 内积导出的 Cauchy-Schiwarz 不等式 96
12.2 Young's 不等式 96
12.2.1 一般形式 96

12.3 Holder 不等式 97
12.3.1 离散形式的 Holder 不等式 97
12.4 Minkowski 不等式 97
12.4.1 离散形式的 Minkowski 不等式 97

第五部分 统计学 99

第十三章 正态分布与三大抽样分布 100
13.1 多维正态分布 100
13.1.1 多维正态分布的定义 100
13.1.2 多维正态分布的性质 101

第十四章 something 103
14.1 Delta method 103
14.2 主成分分析 103

第十五章 方差分析 104
15.1 固定效应下的单因子方差分析 105
15.1.1 统计模型 105
15.1.2 统计假设 105
15.1.3 偏差平方和的分解 106
15.1.4 检验统计量 107
15.1.5 统计量的分布 110
15.1.6 方差分析表 110
15.1.7 参数估计 110
15.2 多重假设检验 111
15.2.1 对比 112
15.2.2 正交对比 113
15.2.3 Duncan 多重比较法 115
15.2.4 Scheffe 多重比较法 117
15.3 随机效应下的单因子方差分析 117
15.3.1 统计模型 118
15.3.2 统计假设 118
15.3.3 方差分析 118
15.3.4 方差分析表 120
15.3.5 参数估计 120
15.4 可加效应下的两因子方差分析 121
15.4.1 统计模型 121
15.4.2 统计假设 122

15.4.3 偏差平方和的分解 122
15.4.4 检验统计量 125
15.4.5 统计量的分布 127
15.4.6 方差分析表 127
15.4.7 参数估计 128
15.4.8 多重比较问题 129
15.4.9 等重复试验情形 129
15.5 交互效应下的两因子方差分析 130
15.5.1 统计模型 130
15.5.2 统计假设 131
15.5.3 偏差平方和的分解 131
15.5.4 检验统计量 133
15.5.5 统计量的分布 133
15.5.6 方差分析表 134
15.5.7 参数估计 134
15.6 随机效应下的两因子方差分析 135
15.6.1 统计模型 135
15.6.2 统计假设 135
15.6.3 方差分析 135
15.6.4 方差分析表 137
15.6.5 参数估计 137
15.7 混合模型下的两因子方差分析 138
15.7.1 统计模型 138
15.7.2 统计假设 139
15.7.3 方差分析 139
15.7.4 方差分析表 140
15.7.5 多重比较比较问题 140
15.7.6 参数估计 140
15.8 部分实施问题 141
15.8.1 正交拉丁方设计 141

第六部分 试验设计 **146**

第十六章 试验设计基本概念 **147**

第七部分 抽样调查 **148**

符号说明 **149**

第十七章 抽样调查基本概念 151
17.1 抽样调查的目的 151
17.2 目标群体、源群体、研究群体 151
17.3 抽样设计 152
17.4 抽样框架 152
17.5 抽样调查随机性的来源 153
17.5.1 基于模型的方法 153
17.5.2 基于设计的方法 153
17.6 概率抽样概述 153
17.6.1 样本概率 153
17.6.2 入样概率与抽样权重 153

第十八章 简单随机抽样 154
18.1 SRS 的参数估计 154
18.1.1 SRS 总体均值 μ 的估计 155
18.1.2 SRS 总体总数 τ 的估计 155
18.1.3 SRS 总体方差 σ^2 的估计 157
18.2 SRS 阳性率问题 157
18.2.1 总体均值 p 的估计 157
18.2.2 总体方差 σ^2 的估计 158
18.2.3 总体方差 σ^2 与总体均值 p 的关系 158
18.3 SRSWR 的参数估计 158
18.3.1 SRSWR 总体总数 τ 的估计 159
18.4 样本容量的选择 160
18.4.1 总体均值样本容量公式 160
18.4.2 总体阳性率样本容量公式 161
18.5 简单随机抽样适用条件 162

第十九章 回归估计与比例估计 163
19.1 辅助变量 163
19.1.1 辅助变量选择要求 163
19.1.2 辅助变量与待估参数的相关性 163
19.2 估计量 165
19.2.1 回归估计量 165
19.2.2 比例估计量 165
19.3 偏差 165
19.3.1 回归估计的偏差 165
19.3.2 比例估计的偏差 165
19.4 均方误差 167

19.4.1 回归估计量的均方误差 167
19.4.2 比例估计量的均方误差 168
19.5 方差 168
19.5.1 回归估计的方差 168
19.5.2 比例估计的方差 169
19.6 置信区间 171
19.6.1 回归估计的置信区间 171
19.6.2 比例估计的置信区间 171
19.7 比例估计样本容量的选择 171
19.8 回归估计、比例估计与 HT 估计的比较 171

第二十章 标记重捕法 172
20.1 假设 172
20.2 总体总数 t 的估计 173
20.2.1 点估计 173
20.2.2 区间估计 174

第二十一章 分层抽样 178
21.1 参数估计 179
21.1.1 亚群体特征的估计 179
21.1.2 总体总量 $\hat{\tau}$ 的估计 179
21.1.3 总体均值 $\hat{\mu}$ 的估计 180
21.1.4 估计的性质 180
21.1.5 群体比例问题 181
21.2 估计方法思考 181
21.3 分配原则 182
21.3.1 比例分配 182
21.3.2 最优分配 184
21.4 后分层 187
21.4.1 参数估计 187
21.5 样本容量 188

第二十二章 整群抽样 189

第八部分 非参数统计学 191

第二十三章 单样本位置检验 192
23.1 广义符号检验 192
23.2 Wilcoxon 符号秩检验 194

23.3 中位数的点估计与置信区间 196
23.4 符号检验与 Wilcoxon 符号秩检验的比较 197

第二十四章 两样本位置检验 198
24.1 目的 198
24.2 Brown-Mood 中位数检验 198
24.3 Wilcoxon 秩和检验 200
24.4 Brown-Mood 中位数检验与 Wilcoxon 秩和检验的比较 201
24.5 成对数据差异性检验 201
24.5.1 连续型数据 202
24.5.2 01 型数据的 McNemar 检验 202

第二十五章 多样本位置检验 204
25.1 目的 204
25.2 本章各方法的简单总结 204
25.3 Kruskal-Wallis 检验 204
25.4 Jonckheere-Terpstra 检验 207
25.5 Friedman 秩和检验 210
25.6 Page 检验 213
25.7 Cochran 检验 218
25.8 Durbin 检验 220

第二十六章 Something else 224
26.1 Cox-Stuart 趋势检验 224
26.2 游程检验 225
26.3 分类评分结果一致性判断 229
26.3.1 Cohen's Kappa 系数 229
26.3.2 Kendall 协同系数检验 230
26.4 列联表独立性问题 232
26.4.1 Pearson 近似检验 232
26.4.2 低维列联表的 Fisher 精确检验 233
26.5 似然比检验 234

第二十七章 单调关联性 235
27.1 单调关联性的零假设与备择假设 235
27.2 本章各方法的简单总结 235
27.3 Spearman 秩关联检验 236
27.4 Kendall τ 关联检验 237
27.5 Goodman-Kruskal's γ 关联检验 238
27.6 Sumers' d 关联检验 239

附录 **240**
.1 R 语言函数详解 240
.1.1 wilcox.test 240

后记 **241**

第一部分

代数

Chapter 1

线性空间

1.1 内积空间

内积空间的定义

定义 1.1. 设 X 为实（复）数域 K 上的线性空间。若 X 中任意一堆元素 x, y 都对应于 K 中的一个数，记为 (x, y)，满足：

1. 线性性：$(\alpha x + \beta y, z) = \alpha(x, z) + \beta(y, z)$，这里 $z \in X$。
2. 对称性：当 K 为实数域时，$(x, y) = (y, x)$；当 K 为复数域时，$(x, y) = \overline{(y, x)}$。
3. 非负性：$(x, x) \geqslant 0$，等号成立当且仅当 $x = \mathbf{0}$。

那么就称 X 为实（复）内积空间 *(inner product space)*，称 (x, y) 为元素 x, y 的内积 *(inner product)*。

Chapter 2

矩阵分解

2.1 SVD 分解

定理 2.1. 设 $A \in \mathbb{R}^{n\times n}$，则 AA^T 是半正定矩阵。

证明. 设 λ_i, $i = 1, 2, \ldots, r$ 是矩阵 AA^T 的特征值，ξ_i 是对应的特征向量，则：

$$
\begin{aligned}
AA^T\xi_i &= \lambda_i\xi_i \\
\xi_i^T AA^T\xi_i &= \lambda_i\xi_i^T\xi_i \\
||A^T\xi_i||^2 &= \lambda_i||\xi_i||^2
\end{aligned}
$$

由于左式非负，所以右式非负，而 $||\xi_i||^2$ 非负，因此 λ_i 非负，即 AA^T 是半正定矩阵。 □

下给出奇异值 (singular value) 的定义：

定义 2.1. 设 $A \in \mathbb{R}^{n\times n}$，设 AA^T 的正特征值为 λ_i, $i = 1, 2, \ldots, r$，则称 $\delta_i = \sqrt{\lambda_i}$ 为矩阵 A 的奇异值。

第二部分

分析学

Chapter 3

度量空间

定义 3.1. 设 X 为一个非空集合。若对于 $\forall\, x, y \in X$，都 $\exists\, \rho(x,y) \in \mathbb{R}$ 与 x, y 对应，且满足以下三个条件（即距离公理）：

1. 非负性：$\rho(x,y) \geqslant 0$，等号成立当且仅当 $x = y$。
2. 对称性：$\rho(x,y) = \rho(y,x)$。
3. 三角不等式：$\rho(x,y) \leqslant \rho(x,z) + \rho(z,y)$, $\forall\, z \in X$。

则称 ρ 是 X 上的一个距离，X 是以 ρ 为距离的度量空间 *(metric space)*，记为 (X,ρ)。度量空间中的元素又称之为点。

3.1 度量空间上的点集

本节首先定义邻域的概念，然后由邻域得到内点、界点、外点、聚点、孤立点的定义，再由这五个点得到开核、导集、边界、闭包的定义，从而进一步讨论开集、闭集以及子空间。

邻域的定义

定义 3.2. 度量空间 (X,ρ) 中的点集

$$\{P \in X : \rho(P, P_0) < \delta\} \qquad (\delta > 0)$$

被称之为点 P_0 的 δ邻域 *(neighbourhood)*[1]，记为 $U(P_0,\delta)$。

上式定义的邻域也称为开邻域。若在上式中取小于等于号，则称之为闭邻域，用 $\bar{U}(P,\delta)$ 表示。下面如果不作特殊说明，涉及到邻域时都指开邻域。

[1]此处的邻域不再具有 $\mathbb{R}^n$ 中那样的球形几何直观。

内、外、界点定义

定义 3.3. (X,ρ) 是一个度量空间，$E\subset X$。若对于点 $P\in X$，存在 $U(P)\subset E$，则称点 P 为 E 的内点 *(interior point)*。

定义 3.4. (X,ρ) 是一个度量空间，$E\subset X$。若点 $P\in X$ 为 E^c 的内点，则称点 P 为 E 的外点 *(exterior point)*。

定义 3.5. (X,ρ) 是一个度量空间，$E\subset X$。若对于点 $P\in X$，它的任意邻域中都既有 E 中的点，又有 E^c 中的点，则称点 P 为 E 的界点 *(boundary point)*。

聚点与孤立点定义

定义 3.6. (X,ρ) 是一个度量空间，$E\subset X$。若点 $P\in X$ 满足以下任一条件：

1. P 的任何邻域内都存在无穷个 E 中的点。
2. P 的任何邻域内都存在一个 E 中异于 P 的点。
3. E 中有一个极限为 P 的点列（极限的定义参考定义 *3.23*）。

则 P 是 E 的一个聚点 *(limit point)*。

这三个条件实际上是等价的：

证明. (1) $\to$ (2) 显然，(3) $\to$ (1) 显然，下证 (2) $\to$ (3)。取 $\delta_n=min\{\rho(P_n,P),\frac{1}{n}\}$，在 $U(P,\delta_n)$ 中至少有一点 P_n，$P_n\in E$ 且 $P_n\neq P$，显然 $\{P_n\}\to P$。 □

定义 3.7. (X,ρ) 是一个度量空间，$E\subset X$。若点 $P\in E$ 但不是 E 的聚点，即存在 P 的邻域 $U(P)$，使得 $E\cap U(P)=\{P\}$，则称 P 为 E 的孤立点 *(isolated point)*。

开核、导集、边界、闭包的定义

定义 3.8. (X,ρ) 是一个度量空间，$E\subset X$。E 的全体内点所组成的集合称为 E 的内核 *(interior)*，记为 $\mathring{E}$。

定义 3.9. (X,ρ) 是一个度量空间，$E\subset X$。E 的全体聚点所组成的集合称为 E 的导集 *(derived set)*，记为 E'。

定义 3.10. (X,ρ) 是一个度量空间，$E\subset X$。E 的全体界点所组成的集合称为 E 的边界 *(boarder)*，记为 ∂E。

定义 3.11. (X,ρ) 是一个度量空间，$E\subset X$。$E\cup E'$ 称为 E 的闭包 *(closure)*，记为 $\overline{E}$。

开集、闭集的定义

定义 3.12. (X,ρ) 是一个度量空间，$E\subset X$。若 $E=\mathring{E}$，则称 E 是一个开集 *(open set)*。

定义 3.13. (X,ρ) 是一个度量空间，$E\subset X$。若 $E'\subset E$，则称 E 是一个闭集 *(closed set)*。

子空间

定义 3.14. (X, ρ_X) 是一个度量空间。若 $E \subset X$，且在 E 上定义距离 ρ_E 使得 E 中任意点对 x, y 之间的距离 $\rho_E(x, y) = \rho_X(x, y)$，则称 E 是 X 的一个子空间 *(subspace)*。

定义 3.15. 若 E 是度量空间 (X, ρ) 的一个子空间，且 E 是一个开集，则称 E 是 X 的一个开子空间 *(open subspace)*。

定义 3.16. 若 E 是度量空间 (X, ρ) 的一个子空间，且 E 是一个闭集，则称 E 是 X 的一个闭子空间 *(closed subspace)*。

3.2 度量空间上点集的性质

邻域的性质

性质. (X, ρ) 是一个度量空间，$P \in X$，则有：

1. $\forall\, \delta > 0,\ P \in U(P, \delta)$。
2. $\forall\, \delta_1, \delta_2 > 0,\ \exists\, \delta_3 > 0,\ U(P, \delta_3) \subset U(P, \delta_1) \cap U(P, \delta_2)$。
3. $\forall\, P_0 \in X,\ P_0 \neq P,\ \exists\, U(P), U(P_0),\ U(P) \cap U(P_0) = \varnothing$。
4. $\forall\, P_0 \in U(P),\ \exists\, U(P_0) \subset U(P)$，即开邻域是开集。
5. $\forall\, P_0 \in \left(\bar{U}(P)\right)',\ P_0 \in \bar{U}(P_0)$，即闭邻域是闭集。

证明. (2) 取 $\delta_3 < min(\delta_1, \delta_2)$。(3) 取 $\delta \in (0, \frac{\rho(P, P_0)}{2})$。

(4) 要使得 $U(P_0) \subset U(P)$，则 $\forall\, x \in U(P_0),\ \rho(x, P) < \delta_P$，而 $\rho(x, P) < \rho(x, P_0) + \rho(P_0, P) < \delta_{P_0} + \rho(P_0, P)$，故只要使 $\delta_{P_0} + \rho(P_0, P) < \delta_P$ 即可。

(5) 对于 $\forall\, P_0 \in \left(\bar{U}(P)\right)'$，$\exists\, \bar{U}(P)$ 中的点列 $\{P_n\} \to P_0$。若 $P_0 \notin \bar{U}(P)$，则 $\rho(P_0, P) > \delta_P$。取 $\varepsilon = \rho(P_0, P) - \delta_P$，则必然 $\exists\, N \in \mathbb{N}^+$，当 $n > N$ 时，有 $\rho(P_n, P_0) < \varepsilon$，那么 $\rho(P_n, P) > \delta_P$，即 $P_n \notin U(P)$，矛盾。因此 $P_0 \in \bar{U}(P)$。由 P_0 的任意性，闭邻域是闭集。 □

内外界聚孤立五点的性质

定理 3.1. (X, ρ) 是一个度量空间，$E \subset X$。E 的界点不是聚点就是孤立点。

证明. 若 P 是 E 的一个界点，则它的任意邻域中都既有 E 中的点，又有 E^c 中的点。若它的任意邻域中都只含有有限个 E 中的点，则一定存在一个邻域，使得只有自身属于 E，那么它是一个孤立点；若它的任意邻域中都含有无限个 E 中的点，由聚点定义，它是一个聚点。 □

关于内外界聚孤立五点的总结

$$\text{度量空间}(X,\rho)\text{中的点与 } E \text{ 的关系可分为} \begin{cases} \text{内点} \\ \text{界点} \\ \text{外点} \end{cases} \quad \text{或} \begin{cases} \text{聚点} \\ \text{孤立点} \\ \text{外点} \end{cases}$$

开核、导集、边界、闭包的性质

定理 3.2. (X,ρ) 是一个度量空间，$E \subset X$。$(\mathring{E})^c = \overline{E^c}$。

证明. $\overline{E^c} = E^c \cup (E^c)'$。

对 $\forall\, P \in \overline{E^c} \cap \mathring{E}$，应有 $P \in (E^c)'$，即 P 的任意邻域中都有 E^c 中的点，而这与 $P \in \mathring{E}$ 矛盾，由 P 的任意性有 $\overline{E^c} \cap \mathring{E} = \varnothing$，即 $\overline{E^c} \subset (\mathring{E})^c$；

对 $\forall\, P \in (\mathring{E})^c$，应有 $P \in (\mathring{E^c}) \cup \partial E$。若 $P \in (\mathring{E^c})$，显然 $P \in (\mathring{E^c}) \subset E^c \subset \overline{E^c}$；若 $P \in \partial E$，要么 $P \in E$，要么 $P \notin E$，如果此时 $P \in E$，则由界点定义它必然是 E^c 的聚点，即 $P \in \overline{E^c}$；如果此时 $P \notin E$，则 $P \in E^c$，即 $P \in \overline{E^c}$。由 P 的任意性有 $(\mathring{E})^c \subset \overline{E^c}$。

综上 $(\mathring{E})^c = \overline{E^c}$。 □

定理 3.3. (X,ρ) 是一个度量空间，$E \subset X$。$\partial E = \partial E^c$。

证明. 由定义直接可得。 □

定理 3.4. (X,ρ) 是一个度量空间，$E \subset X$。$\overline{\overline{E}} = \overline{E}$。

证明. $\overline{\overline{E}} = \overline{E} \cup (\overline{E})'$，由定理 3.8，$\overline{E}$ 是闭集，因此 $(\overline{E})' \subset \overline{E}$，即 $\overline{\overline{E}} = \overline{E}$。 □

定理 3.5. (X,ρ) 是一个度量空间，$A \cup B \subset X$。若 $A \subset B$，则 $\mathring{A} \subset \mathring{B}$，$A' \subset B'$，$\overline{A} \subset \overline{B}$。

证明. 由内点、聚点的定义直接可得。 □

定理 3.6. (X,ρ) 是一个度量空间，$A \cup B \subset X$。$(A \cup B)' = A' \cup B'$。

证明. $A \subset (A \cup B)$，$B \subset (A \cup B)$，由定理 3.5可知，$A' \subset (A \cup B)'$，$B' \subset (A \cup B)'$，因此 $A' \cup B' \subset (A \cup B)'$。

另一方面，对 $\forall\, P \in (A \cup B)'$，应有 $P \in A' \cup B'$。否则就有 $P \notin A'$ 且 $P \notin B'$，因此存在 $U_1(P)$ 和 $U_2(P)$ 使得 $U_1(P)$ 中不含除了 P 以外的 A 中的点、$U_2(P)$ 中不含除了 P 以外的 B 中的点，由邻域的性质，存在 $U_3(P)$ 使得其内不含除了 P 以外 $A \cup B$ 中的点，而这与 $P \in (A \cup B)'$ 矛盾。由 P 的任意性有 $(A \cup B)' \subset A' \cup B'$。

综上 $(A \cup B)' = A' \cup B'$。 □

定理 3.7. (X,ρ) 是一个度量空间，$A \cup B \subset X$。$\overline{A \cup B} = \overline{A} \cup \overline{B}$。

证明. 由定理 3.6：

$$\overline{A}\cup\overline{B}=A\cup A'\cup B\cup B'=(A\cup B)\cup(A'\cup B')=(A\cup B)\cup(A\cup B)'=\overline{A\cup B}\qquad\square$$

定理 3.8. (X,ρ) 是一个度量空间，$E\subset X$。$\mathring{E}$ 是开集，E' 和 $\overline{E}$ 都是闭集。

证明. (1)$\mathring{E}$ 是开集：对 $\forall\, P\in\mathring{E}$，存在 $U(P)\subset E$，对 $\forall\, Q\in U(P)$，存在 $U(Q)\subset U(P)\subset E$，因此 $Q\in\mathring{E}$，即存在 $U(P)\subset\mathring{E}$，P 是 $\mathring{E}$ 的内点。由 P 的任意性，$\mathring{E}$ 是开集。

(2)E' 是闭集：对 $\forall\ P\in(E')'$，由聚点定义，任意 $U(P)$ 中都含有 E' 中的点，取 $\forall\ Q\in U(P)\cap E'$，任意 $U(Q)$ 都含 E 中的点，而 $Q\in U(P)$，由邻域的性质，存在 $U(Q)\subset U(P)$，因此任意 $U(P)$ 中都含有 E 中的点，即 P 是 E 的聚点，$P\in E'$。由 P 的任意性与 P 的选取方式，E' 是闭集。

(3)$\overline{E}$ 是闭集：$\overline{E}=E\cup E'$，由定理 3.6，$(\overline{E})'=E'\cup(E')'$，显然 $E'\subset\overline{E}$，而 E' 是闭集，$(E')'\subset E'\subset\overline{E}$。因此，$(\overline{E})'\subset\overline{E}$，即 $\overline{E}$ 是闭集。 $\square$

开集、闭集的性质

定理 3.9. 对于度量空间 (X,ρ)，X 和 $\varnothing$ 是唯二既开又闭的集合。

开集与闭集的互补性

定理 3.10. (X,ρ) 是一个度量空间，$E\subset X$。若 E 是开集，则 E^c 是闭集；若 E 是闭集，则 E^c 是开集。

证明. E 是开集：$\forall\, P\in(E^c)'$，应有 $P\notin E$，即 P 不会是 E 的内点。否则由内点定义，存在 $U(P)$ 使得 $U(P)\subset E$，即 $U(P)$ 中不含 E^c 中的点，这与点 $P\in(E^c)'$ 矛盾。由 P 的任意性有 $E'\subset E$，即 E^c 是闭集。

E 是闭集：$\forall\, P\in E^c$，应有 P 是 E^c 的一个内点。否则任意 $U(P)$ 中都存在 E 中的点，则 P 应该是 E 的一个聚点，而此时 $P\in E^c$，与 E 是闭集矛盾。由 P 的任意性有 $E^c=(\mathring{E^c})$，即 E^c 是开集。 $\square$

开集与闭集的交与并

定理 3.11. (X,ρ) 是一个度量空间。*(1)* 任意个开集的并是开集；*(2)* 有限个开集的交是开集；*(3)* 任意个闭集的交是闭集；*(4)* 有限个闭集的并是闭集。

证明. (1) 对于在任意个开集的并集中的点 P，P 必属于其中一个开集，因而存在一个邻域 $U(P)$ 使得其中的点都在那个开集中，进而 $U(P)$ 都在任意个开集的并集中，即 P 是任意个开集的并集的内点。由 P 的任意性，任意个开集的并集是开集。[2]

[2]这里使用纯文字说明是因为考虑该定理对不可数个集合也成立，当集合不可数的时候是无法给集合编号的。

(2) 设这有限个开集为 $A_i, i=1,2,\ldots,n$。对 $\forall\, P \in \bigcap\limits_{i=1}^{n} A_i$，则 P 是所有 A_i 的内点，因此存在 $U_i(P) \subset A_i$，由邻域的性质，存在 $U(P)$ 使得 $\forall\, Q \in U(P)$ 满足 $U(P) \subset \bigcap\limits_{i=1}^{n} U_i(P) \subset \bigcap\limits_{i=1}^{n} A_i$，因此 P 是 $\bigcap\limits_{i=1}^{n} A_i$ 的内点。由 P 的任意性，$\bigcap\limits_{i=1}^{n} A_i$ 是开集。

(3)(4) 可由定理 3.10以及德摩根公式在 (1)(2) 的基础上直接得出。 □

3.3 稠密、稀疏、可分性、有界性

稠密

定义 3.17. (X,ρ) 是一个度量空间，$A \cup B \subset X$。若 $A \subset \overline{B}$，则称 B 在 A 中稠密 *(dense)*。

稠密性等价定义

定理 3.12. (X,ρ) 是一个度量空间，$A \cup B \subset X$。以下四个命题等价：

1. B 在 A 中稠密。
2. 对于 $\forall\, x \in A$，x 的任意邻域中都存在 B 中的点。
3. 对于 $\forall\, x \in A$，B 中存在一个点列 $\{x_n\}$ 收敛于 x（点列收敛的定义参考定义 *3.23*）。
4. 对于 $\forall\, \varepsilon > 0$，$B$ 中每个点的 ε 开球邻域的并包含了 A。

证明. (1) $\to$ (2) 因为 $\overline{B} = B \cup B'$，所以若 $x \in A$，则 $x \in B$ 或 $x \in B'$，此时显然 (2) 成立。

(2) $\to$ (3) 显然。（点列中元素可重复出现）

(3) $\to$ (4) 若此时 (4) 不成立，即存在 $x \in A$ 对于某个 ε，满足条件 x 不在任何 B 中点的 ε 开球邻域内，则存在 $U(x)$ 使得 $U(x)$ 中不含 B 中的点，那么 (3) 也不可能成立，矛盾。

(4) $\to$ (1) 对于 $\forall\, x \in A$，如果 $x \notin \overline{B}$，那么存在 $U(x,\delta)$ 使得 $U(x,\delta)$ 中不含 B 中的点，记 x 与 B 中点之间的最小距离为 ρ，此时只要取 $\varepsilon < \rho$，x 就不在那些邻域的并集中了，矛盾。由 x 的任意性，$A \subset \overline{B}$。 □

稀疏集

定义 3.18. (X,ρ) 是一个度量空间，A 是 X 的一个子集。若 A 在 X 的任何一个非空开集中均不稠密，则称 A 为 X 中的稀疏集 *(nowhere dense set)*。

稀疏集等价定义

下述定理中的邻域既可以是开邻域也可以是闭邻域：

定理 3.13. 度量空间 (X,ρ) 的子集 A 为稀疏集的充分必要条件是：对 $\forall\, x \in X$ 和 x 的任意邻域 $U(x)$，存在一个包含于邻域 $U(x)$ 的邻域 $U(y)$ 使得：

$$A \cap U(y) = \varnothing$$

证明. 充分性:假设此时 A 在 X 中的某非空开集 B 中稠密,则 $B \subset \overline{A}$。任取 $x \in B$,则 $x \in \overline{A}$。如果此时存在包含于 $U(x)$ 的 $U(y)$ 使得题目条件成立，则 $y \notin \overline{A}$，这与 $U(y) \subset U(x) \subset B$ 矛盾。

必要性：若 A 是稀疏集，则 A 在 $U(x)$ 中不稠密。由稠密的等价定义 (2)，$\exists\ y \in U(x)$, $\exists\, U(y) \subset U(x)$ 使得 $A \cap U(y) = \varnothing$。 □

可分性

定义 3.19. (X, ρ) 是一个度量空间，$A \subset X$。若存在可列集 $B \subset X$ 使得 B 在 A 中稠密，则称 A 是可分的 *(separable)*。若 X 中存在一个在 X 中稠密的可列子集，则称 X 是可分的度量空间。

有界性

定义 3.20. (X, ρ) 是一个度量空间，$E \subset X$。定义

$$\delta_E = \sup_{x,y \in E} \rho(x, y)$$

为点集 E 的直径 *(diameter)*。

定义 3.21. (X, ρ) 是一个度量空间，$E \subset X$。若 $\delta_E < +\infty$，则称 E 是 (X, ρ) 中的有界集 *(bounded set)*。

有界集的等价定义

定义 3.22. (X, ρ) 是一个度量空间，$E \subset X$。如果 E 包含在 X 中某个点的闭邻域或开邻域内，则称 E 是 (X, ρ) 中的有界集。

二者的等价性很直观：

证明. (1) $\to$ (2)：任取 $x \in X$，取 $\delta = \delta_E$ 构造闭邻域 $U(x, \delta)$ 或取 $\delta = \delta_E + \varepsilon (\forall\, \varepsilon > 0)$ 构造开邻域 $U(x, \delta)$。

(2) $\to$ (1)：设关于该点的开邻域或闭邻域半径为 δ，显然 $\delta_E \leqslant 2\delta$。 □

3.4 度量空间上的收敛点列

定义 3.23. $\{x_n\}$ 是度量空间 (X, ρ) 中的一个点列 *(sequence of points)*，如果对于 $\forall\, \varepsilon > 0$，$\exists\, N \in \mathbb{N}^+$，当 $n > N$ 时有：

$$\rho(x_n, x) < \varepsilon$$

则称 $\{x_n\}$ 是度量空间 (X, ρ) 中的收敛点列 *(convergent sequence of points)*，x 是点列 $\{x_n\}$ 的极限 *(limit)*。

收敛点列的性质

极限的唯一性

定理 3.14. $\{x_n\}$ 是度量空间 (X,ρ) 中的一个收敛点列。$\{x_n\}$ 的极限是唯一的。

证明. 假设极限不唯一，$\{x_n\}$ 既收敛到 a 又收敛到 b，则对于 $\forall\,\varepsilon>0$，$\exists\,N_1\in\mathbb{N}^+$，当 $n>N_1$ 时有 $\rho(x_n,a)<\frac{\varepsilon}{2}$；$\exists\,N_2\in\mathbb{N}^+$，当 $n>N_2$ 时有 $\rho(x_n,b)<\frac{\varepsilon}{2}$。取 $N=max\{N1,N2\}$，则当 $n>N$ 时，有

$$\rho(a,b)\leqslant\rho(a,x_n)+\rho(x_n,b)<\varepsilon$$

即 $a=b$。 □

有界性

定理 3.15. $\{x_n\}$ 是度量空间 (X,ρ) 中的一个收敛点列。对 $\forall\,y\in X$，数列 $\{\rho(x_n,y)\}$ 有界。

证明. 设 $\{x_n\}\to x$，由距离的定义：

$$\rho(x_n,y)\leqslant\rho(x_n,x)+\rho(x,y)$$

由于 $\{x_n\}$ 收敛，所以对 $\varepsilon=1$：

$$\exists\,N\in\mathbb{N}^+,\ \forall\,n>N,\ \rho(x_n,x)<\varepsilon=1$$

取 $K=\max\{\rho(x_1,x),\rho(x_2,x),\ldots,\rho(x_N,x),1\}$，则有：

$$\forall\,n\in\mathbb{N}^+,\ \rho(x_n,y)\leqslant K+\rho(x,y)$$

即数列 $\{\rho(x_n,y)\}$ 有界。 □

推论 3.1. $\{x_n\}$ 是度量空间 (X,ρ) 中的一个收敛点列。若将其看作点集，则 $\{x_n\}$ 是有界点集。

证明. 任取 $y\in X$，数列 $\{\rho(x_n,y)\}$ 有界，即 $\exists\,\delta>0$，$\forall\,n\in\mathbb{N}^+$，$\rho(x_n,y)<\delta$，则 $\{x_n\}\subset U(y,\delta)$。 □

子列的收敛性

定义 3.24. $\{x_n\}$ 是度量空间 (X,ρ) 中的一个点列，而

$$n_1<n_1<\cdots<n_k<n_{k+1}<\cdots$$

是一串严格递增的自然数，则

$$x_{n_1}<x_{n_2}<\cdots<x_{n_k}<x_{n_{k+1}}<\cdots$$

也形成一个 (X,ρ) 中的点列，我们把 $\{x_{n_k}\}$ 称之为点列 $\{x_n\}$ 的一个子列 *(subsequence)*。

定理 3.16. $\{x_n\}$ 是度量空间 (X,ρ) 中的一个收敛点列，则它的任何子列 $\{x_{n_k}\}$ 都收敛，并且与 $\{x_n\}$ 有同样的极限。反之，若 $\{x_n\}$ 的任何子列都收敛，则 $\{x_n\}$ 本身也收敛。

证明. (1) 设 $\{x_n\}$ 的极限为 x，则对于 $\forall\,\varepsilon>0$，$\exists\,N\in\mathbb{N}^+$，当 $n>N$ 时有

$$\rho(x_n,x)<\varepsilon$$

当 $k>N$ 时就有 $n_k\geqslant k>N$，也就有

$$\rho(x_{n_k},x)<\varepsilon$$

(2)$\{x_n\}$ 也是它自己的一个子列。 □

3.5 度量空间上的映射

定义 3.25. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间。若对于 $\forall\,x\in X$，都 $\exists\,y\in Y$ 与之对应，则称这个对应是一个 X 到 Y 的*映射 (mapping)*，用符号 T 表示。

单射、满射、双射

定义 3.26. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的映射。如果对于 $\forall\,y\in Tx$，只有唯一的 x 使得 $Tx=y$，那么称映射 T 为*单射 (injective function)*。

定义 3.27. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的映射。如果对于 $\forall\,y\in Y$，都存在 X 中的 x 使得 $Tx=y$，那么称映射 T 为*满射 (surjective function)*。

定义 3.28. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的映射。如果 T 既是单射，又是满射，则称之为*双射 (bijective function)*。

逆映射

定义 3.29. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的双射。则对于 $\forall\,y\in Y$，都存在唯一的 $x\in X$ 使得 $Tx=y$，此时可以得到一个新的映射，它将 Y 映成 X，称这个映射为 T 的*逆映射 (inverse mapping)*。

定理 3.17. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的映射。T 存在逆映射的充要条件是 T 是一个双射。

复合映射

定义 3.30. (X,ρ_X)、(Y,ρ_Y) 和 (Z,ρ_z) 都是度量空间，T_1 是一个 X 到 Y 的映射，T_2 是一个 Y 到 Z 的映射。定义映射 T_3 满足 $T_3x=T_2(T_1x)$，其中 $x\in X$，则称映射 T_3 是映射 T_1 和映射 T_2 的*复合映射 (composite mapping)*。

复合映射的概念也可以推广到多个映射的复合。

等距映射

定义 3.31. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的双射。若对于 $\forall\, x,y\in X$，有 $\rho_X(x,y)=\rho_Y(Tx,Ty)$，则称 T 是 X 到 Y 上的等距映射 *(isometry)*。如果存在一个 X 到 Y 上的等距映射，则称 X 和 Y 等距 *(isometric)*。

映射的连续性

定义 3.32. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的映射，$x_0\in X$。若对于 $\forall\,\varepsilon>0$，$\exists\,\delta>0$，使得对 X 中一切满足条件 $\rho(x_0,x)<\delta$ 的 x，都有 $\rho_Y(Tx_0,Tx)<\varepsilon$，则称 T 在 x_0 处是连续的 *(continuous)*。

邻域式定义

定义 3.33. T 在 x_0 处连续：对 Tx_0 的任意 ε 邻域 U，必有 x_0 的某个 δ 邻域 V 使得 $TV\subset U$。

点列式定义

定理 3.18. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的映射，那么 T 在 $x_0\in X$ 处连续的充分必要条件为：当 $x_n\to x_0$ 时，$Tx_n\to Tx_0$。

证明. 必要性显然。

充分性：若此时 T 在 x_0 不连续，那么 $\exists\,\varepsilon>0$，$\forall\,\delta>0$，都存在满足条件 $\rho_X(x_0,x)<\delta$ 的点 x 使得 $\rho_Y(Tx_0,Tx)\geqslant\varepsilon$，因此可取一个点列 $\{x_n\}$，满足 $\rho_X(x_0,x_n)<\frac{1}{n}$。注意到此时满足 $x_n\to x$ 但不满足 $Tx_n\to Tx_0$，矛盾。 □

连续映射的定义

定义 3.34. T 是一个 (X,ρ_X) 到 (Y,ρ_Y) 的映射，若 T 在 X 的每一点都连续，则称 T 是 X 上的连续映射 *(continuous mapping)*。

连续映射的拓扑式等价定义

定义 3.35. (X,ρ_X) 和 (Y,ρ_Y) 都是度量空间，T 是一个 X 到 Y 的映射，称集合

$$\{x\in X: Tx\in E\subset Y\}$$

为集合 E 在映射 T 下的原像 *(preimage)*。

定理 3.19. 度量空间 (X,ρ_X) 到 (Y,ρ_Y) 上的映射 T 是 X 上连续映射的充要条件为：

1. Y 中任意开集 E 的原像 $T^{-1}E$ 是 X 中的开集。
2. Y 中任意闭集 E 的原像 $T^{-1}E$ 是 X 中的闭集。

证明. (1) 必要性：设 T 是连续映射，$M \subset Y$ 是一个开集，如果 $T^{-1}M = \varnothing$，则 $T^{-1}M$ 是开集；若 $T^{-1}M \neq \varnothing$，取 $\forall\, x \in T^{-1}M$，令 $Tx = y$，则 $y \in M$，因为 M 是开集，所以存在 y 的 ε 邻域 U，使得 $U \subset M$，由 T 的连续性，存在 x 的 δ 邻域 V，使得 $TV \subset I$，因此 $V \subset T^{-1}U \subset T^{-1}M$，即 x 是 $T^{-1}M$ 的内点。由 x 的任意性，$T^{-1}M$ 是 X 中的开集。

充分性：对 $\forall\, x \in X$ 及 Tx 的任意 ε 邻域 U，由邻域的性质，U 是一个开集，因此 $T^{-1}U$ 是 X 中的开集。因为 x 是 $T^{-1}U$ 的内点，所以存在 x 的某个 δ 邻域 V，使得 $V \subset T^{-1}U$，因此 $TV \subset U$，即 T 在 x 处连续。由 x 的任意性，T 是 X 上的连续映射。

(2) 由 $T^{-1}(M^c) = (T^{-1}M)^c$，利用 (1) 易证 (2)。 □

同胚映射

定义 3.36. (X, ρ_X) 和 (Y, ρ_Y) 都是度量空间，T 是一个 X 到 Y 的双射。若 T 和 T^{-1} 都是连续映射，则称 T 是 X 到 Y 上的同胚映射 *(homeomorphism mapping)*。如果存在一个 X 到 Y 上的同胚映射，则称 X 和 Y 同胚 *(homeomorphic)*。

3.6 完备的度量空间

3.6.1 柯西点列

定义 3.37. (X, ρ) 是一个度量空间，$\{x_n\}$ 是 X 中的点列。若对于 $\forall\, \varepsilon > 0$，$\exists\, N \in \mathbb{N}^+$，当 $n, m > N$ 时，有：

$$\rho(x_n, x_m) < \varepsilon$$

则称点列 $\{x_n\}$ 是一个柯西点列 *(Cauchy sequence)* 或基本点列 *(foundamental sequence)*。

柯西点列的性质

定理 3.20. (X, ρ_X) 是一个度量空间，$\{x_n\}$ 是 X 中的收敛点列，则 $\{x_n\}$ 是一个柯西点列。

证明. 令 $n < m$。因为 $\{x_n\}$ 是 X 中的收敛点列，假设其极限为 x，则对于 $\forall\, \varepsilon > 0$，$\exists\, N_1 \in \mathbb{N}^+$，当 $n > N_1$ 时有 $\rho(x_n, x) < \frac{\varepsilon}{2}$；$\exists\, N_2 \in \mathbb{N}^+$，当 $m > N_2$ 时有 $\rho(x_m, x) < \frac{\varepsilon}{2}$。取 $N = max\{N_1, N_2\}$，则当 $n > N$ 时，有

$$\rho(x_n, x_m) \leqslant \rho(x_n, x) + \rho(x_m, x) < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon$$

即点列 $\{x_n\}$ 是一个柯西点列。 □

该定理的逆命题不正确，考虑有理数集按绝对值距离构成的度量空间中的柯西点列。

定理 3.21. (X, ρ) 是一个度量空间，$\{x_n\}$ 是 X 中的柯西点列。若它的一个子列 $\{x_{n_k}\}$ 收敛，则其本身也收敛，并且极限相同。

证明. 设 $\{x_{n_k}\}$ 极限为 x，则

$$\rho(x_n, x) \leqslant \rho(x_n, x_{n_k}) + \rho(x_{n_k}, x)$$

对 $\forall\, \varepsilon > 0$，因为 x_{n_k} 收敛于 x，所以 $\exists\, N_1 \in \mathbb{N}^+$，使得当 $k > N_1$ 时，有 $\rho(x_{n_k}, x) < \frac{\varepsilon}{2}$。又因 $\{x_n\}$ 是 X 中的柯西点列，因此 $\exists\, N_2 \in \mathbb{N}^+$，使得当 $n, k > N_2$ 时，有 $\rho(x_n, x_{n_k}) < \frac{\varepsilon}{2}$。取 $N = max\{N_1, N_2\}$，当 $n, k > N$ 时，即有

$$\rho(x_n, x) \leqslant \rho(x_n, x_{n_k}) + \rho(x_{n_k}, x) < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon \qquad \square$$

定理 3.22. 度量空间中的任何柯西点列都是有界的。

证明. 设 (X, ρ) 是一个度量空间，$\{x_n\}$ 是 X 中的柯西点列，则对于 $\forall\, \varepsilon > 0$，$\exists\, N \in \mathbb{N}^+$，当 $n, m > N$ 时，有：

$$\rho(x_n, x_m) < \varepsilon$$

取 $m = N + 1$，令 $\alpha = \max\limits_{i=1,2,\ldots,N} \rho(x_m, x_i)$，$\delta = max\{\varepsilon, \alpha\}$，则 $\{x_n\}$ 中的所有点都在闭邻域 $U(x_m, \delta)$ 中。由定义 3.22，$\{x_n\}$ 有界。 $\square$

3.6.2 完备度量空间的定义

定义 3.38. (X, ρ) 是一个度量空间。若 X 中的任意柯西点列 $\{x_n\}$ 都收敛到 X 中的某一点，则称 X 是一个完备的 *(complete)*度量空间。

完备度量空间的等价定义

下列定理是 Cantor's Intersection Theorem 的一个变体：

定理 3.23 (闭球套定理)**.** (X, ρ) 是一个度量空间。X 完备的充分必要条件为对任何满足下列条件的一列闭邻域 $\{E_n = \overline{U}(x_n, \delta_n)\}$：

1. $E_1 \supset E_2 \supset \cdots \supset E_n \supset \cdots$
2. $\{\delta_n\} \to 0$

X 中都存在唯一的 x 满足 $x \in \bigcap\limits_{n \in \mathbb{N}^+} E_n$。

证明. 充分性：任取 X 中的一个柯西点列 $\{x_n\}$。由柯西点列的定义，$\{x_n\}$ 存在一个子列 $\{x_{n_k}\}$，满足：

$$\rho(x_{n_k}, x_{n_{k+1}}) < \frac{1}{2^k}$$

取闭邻域列：

$$\{E_k = \bar{U}(x_{n_k}, \frac{1}{2^{k-1}})\}$$

显然：

$$\forall\, y \in E_{k+1},\ \rho(y, x_{n_k}) \leqslant \rho(y, x_{n_{k+1}}) + \rho(x_{n_{k+1}}, x_{n_k}) < \frac{1}{2^k} + \frac{1}{2^k} = \frac{1}{2^{k-1}}$$

所以 $E_k \supset E_{k+1}$。由题目条件，此时存在唯一的 $x \in X$ 满足 $x \in E_k$, $\forall\ k \in \mathbb{N}^+$。下证 $\{x_n\} \to x$。

$$\rho(x_n, x) \leqslant \rho(x_n, x_{n_k}) + \rho(x_{n_k}, x) \leqslant \rho(x_n, x_{n_k}) + \frac{1}{2^{k-1}}$$

因为 $\{x_n\}$ 是一个柯西点列，因此当 n 和 k 足够大时，上式右端两项均趋于 0。因此 $\{x_n\} \to x$。由 $\{x_n\}$ 的任意性，X 是一个完备的度量空间。

必要性中的存在性：在每个 E_n 中取一点 y_n 构成点列 $\{y_n\}$。设 $m > n$，因为 $E_m \subset E_n$，所以 $y_m \in E_n$，于是有：

$$\rho(y_n, y_m) \leqslant 2\delta_n \to 0$$

因此 $\{y_n\}$ 是一个柯西点列。因为 X 完备，所以 $\{y_n\} \to x \in X$。对 $\forall\ n_0 \in \mathbb{N}^+$，当 $n > n_0$ 时，$y_n \in E_n \subset E_{n_0}$。又因为闭邻域 E_{n_0} 是闭集，因此 $x \in E_{n_0}$。由 n_0 的任意性，$x \in E_n$, $\forall\ n \in \mathbb{N}^+$。

必要性中的唯一性：若还有一点 y 满足上述条件，则：

$$\rho(x, y) \leqslant \rho(x, x_n) + \rho(x_n, y) \to 0$$

唯一性显然得证。 □

3.6.3 度量空间的完备化定理

定理 3.24. (X, ρ_X) 是一个度量空间，则一定存在一个完备度量空间 (Y, ρ_Y)，使得 X 与 Y 的一个稠密子空间等距同构，并且 Y 在等距同构的意义下是唯一的[3]。

证明太复杂，不提供。

3.7 完备度量空间的性质

3.7.1 子空间的完备性

定理 3.25. 完备度量空间 (X, ρ_X) 的子空间 M 是完备度量空间的充要条件为 M 是 X 中的一个闭子空间。

证明. 必要性：因为 M 是完备子空间，则对于 $\forall\ x \in M'$，存在 M 中的一个收敛点列 $\{x_n\} \to x$。因为收敛点列也是柯西点列，而此时柯西点列在 M 中收敛，所以 $x \in M$。由 x 的任意性，$M' \subset M$，故 M 是一个闭集，即 M 是 X 的一个闭子空间。

充分性：任取 $\{x_n\}$ 为 M 中的一个柯西点列，那么它也是 X 中的柯西点列，因此 $\exists\ x \in X$ 使得 $\{x_n\} \to x$，即 x 是 M 的一个聚点。又因 M 是 X 的一个闭子空间，所以 $x \in M$，即柯西点列 $\{x_n\}$ 收敛于 M 中的一点。由 $\{x_n\}$ 的任意性，M 是完备的度量空间。 □

[3]这里的唯一性是指，如果存在另一个完备度量空间 (Z, ρ_Z) 使得 X 与 Z 的一个稠密子空间等距同构，则 Y 与 Z 等距同构。

3.7.2 第一型集与第二型集

定义 3.39. 设 A 是度量空间 (X,ρ) 的子集。若 A 可表示为至多可列个稀疏集的并，则称 A 是第一型集 *(set of first category)*。反之则为第二型集 *(set of second category)*。

定理 3.26. 任何完备的度量空间都是第二型集。

证明. 假设不成立，即存在完备的度量空间 X 使得 X 是第一型集。也就是说 $X=\bigcup\limits_{i=1}^{\infty}F_i$，其中 F_i, $\forall\, i\in\mathbb{N}^+$ 是稀疏集。因为 F_1 是稀疏集，因此 $\exists\, x_1\in X$，使得闭邻域 $U(x_1,r_1)$ 中不含 F_1 中的点。对于闭邻域 $U(x_1,r_1)$，由于 F_2 是稀疏集，因此 $\exists\, x_2\in U(x_1,r_2)$，使得闭邻域 $U(x_2,r_2)$ 中不含 F_1 中的点。如此重复下去，实际上可以取 $r_n\in(0,\frac{1}{n})$，便可以得到一个闭集套：

$$U(x_1,r_1)\supset U(x_2,r_2)\supset\cdots\supset U(x_n,r_n)\supset\cdots$$

由完备度量空间的闭集套定理，存在一个点 $x\in U(x_n,r_n)$, $\forall\, n\in\mathbb{N}^+$。而由闭集套的取法，$x\notin X$，矛盾。 □

3.7.3 准紧性与全有界性

准紧性的定义

定义 3.40. (X,ρ) 是一个度量空间，A 是 X 的一个子集。如果 A 的每个点列都有一个收敛子列收敛于 X 中的某一点，则称 A 是准紧集 *(precompact set)*。

准紧集的性质

性质. 准紧集的子集也是准紧集。

全有界集的定义

定义 3.41. (X,ρ) 是一个度量空间，A 和 B 都是 X 的子集，ε 是一个给定的正数。如果对于 $\forall\, x\in A$，都 $\exists\, y\in B$，使得 $\rho(x,y)<\varepsilon$，则称 B 是 A 的一个 ε-网。即：以 B 中的点为中心，ε 为半径的所有开邻域的并包含了 A。

定义 3.42. (X,ρ) 是一个度量空间，A 是 X 的子集。如果对于 $\forall\,\varepsilon>0$，X 中总存在 A 的 ε-网，且该 ε-网只有有限个点，则称 A 是全有界集 *(totally bounded set)*。

全有界集的性质

性质. 全有界集具有如下性质：

(1) 任何有限集都是全有界集。

(2) 全有界集的子集也是全有界集。

(3) 设 A 是一个全有界集，则对 $\forall\,\varepsilon>0$，总存在 A 的一个有限子集成为 A 的一个 ε-网。

(4) 全有界集有界且可分。

证明. (1)(2) 是显然的。

(3) 因为 A 是一个全有界集，所以对 $\forall\,\varepsilon>0$，存在一个 A 的 $\frac{\varepsilon}{2}$-网 $\{x_1,x_2,\ldots,x_n\}$。依次取 $a_i\in A$ 使得 $a_i\in U(x_i,\frac{\varepsilon}{2})$, $i=1,2,\ldots,n$，则 $\{a_1,a_2,\ldots,a_n\}$ 即构成 A 的一个 ε-网：

$$\forall\,a\in U(x_i,\frac{\varepsilon}{2}),\ \rho(a,a_i)\leqslant\rho(a,x_i)+\rho(x_i,a_i)<\frac{\varepsilon}{2}+\frac{\varepsilon}{2}=\varepsilon,\ i=1,2,\ldots,n$$

(4) 设 (X,ρ) 是给定的度量空间，A 是一个全有界集。由全有界集定义，A 应有一个 1-网 $\{x_1,x_2,\ldots,x_n\}$。则：

$$\forall\,a\in A,\ \exists\,x_k\in\{x_1,x_2,\ldots,x_n\},\ \rho(a,x_k)<1$$

故（下式中 x_k 是与 a 对应的那个点）：

$$\forall\,a\in A,\ \rho(a,x_1)\leqslant\rho(a,x_k)+\rho(x_k,x_1)<1+\max_{k=1,2,\ldots,n}\rho(x_k,x_1)$$

记 $\max\limits_{k=1,2,\ldots,n}\rho(x_k,x_1)=K$，则 $\forall\,a\in A,\ a\in U(x_1,1+K)$，所以 A 是有界的。

因为 A 是一个全有界集，所以对 $\forall\,\varepsilon=\frac{1}{n},\ n\in\mathbb{N}^+$，$X$ 中都存在 A 的一个只含有限个点的 ε-网 B_n。记：

$$B=\bigcup_{n=1}^{+\infty}B_n$$

显然 B 是可列的。对 $\forall\,x\in A,\ \exists\,x_n\in B_n\subset B,\ \rho(x,x_n)<\frac{1}{n},\ \forall\,n\in\mathbb{N}^+$。因此点列 $\{x_n\}$ 收敛于 x。由 x 的任意性和稠密性的等价命题 3，B 在 A 中稠密。综上，A 是可分的。 □

准紧性与全有界性的关系

以下定理说明了完备度量空间中准紧性与全有界性的关系，即二者在完备度量空间中是等价的：

定理 3.27. (X,ρ) 是一个度量空间。

(1) 如果 $A\subset X$ 准紧，则 A 全有界。

(2) 如果 X 是完备的，则当 A 全有界时，A 也必定准紧。

证明. (1) 如果 A 不是全有界集，则 $\exists\,\varepsilon>0$，使得 A 没有只有有限点的 ε-网。任取 $x_1\in A$，则 $\exists\,x_2\in A$ 使得 $\rho(x_1,x_2)\geqslant\varepsilon$，否则 $\{x_1\}$ 就是 A 的一个 ε-网。同理，$\exists\,x_3\in A$ 使得 $\rho(x_3,x_j)\geqslant\varepsilon,\ j=1,2$，否则 $\{x_1,x_2\}$ 就是 A 的一个 ε-网。重复这一步骤就得到点列 $\{x_n\}$，当 $m\neq n$ 时，$\rho(x_m,x_n)\geqslant\varepsilon$。由柯西收敛准则 $\{x_n\}$ 显然没有收敛的子列，这与 A 的准紧性矛盾。

(2) 任取 A 中的点列 $\{x_n\}$。如果 $\{x_n\}$ 中只有有限个互不相同的元素，则 $\{x_n\}$ 显然有收敛的子列。如果 $\{x_n\}$ 中有无限个互不相同的元素，记这些元素构成的集合为 B_0。由全有界集性质 (2)，B_0 也是全有界集。由全有界集性质 (3)，B_0 中存在有限个元素使得以它们为球心，$\frac{1}{2}$ 为半径的开邻域的并包含 B_0，显然 B_0 中至少存在一个点 y_1 使得以它为半径，$\frac{1}{2}$ 为半径的开邻域包含了无穷多个 A 中的点。记被 y_1 包含的这无穷多个点构成的集合为 B_1，显然 B_1 的直径小于 1。因为 B_1 是 B_0 的子集，所以 B_1 也是全有界的，重复上述论证，则存在 $B_2\subset B_1$，使得 B_2 中含有 B_1 无穷多个元素且 B_2 的直径小于 $\frac{1}{2}$。依次类推，可以得到一系列集合满足如下条件：

1. $B_1 \supset B_2 \supset \cdots \supset B_n \supset \cdots$。

2. B_n 的直径小于 $\frac{1}{2^{n-1}}$。

3. 每个 B_n 中都含有 $\{x_n\}$ 中无限个元素。

取 $x_{n_k} \in B_k,\ n_{k+1} > n_k,\ k \in \mathbb{N}^+$，便得到 $\{x_n\}$ 的一个子列 $\{x_{n_k}\}$。显然 $\{x_{n_k}\}$ 是一个基本点列：

$$\forall\, p > q,\ x_{n_p} \in B_p \subset B_q,\ \rho(x_{n_p}, x_{n_q}) < \frac{1}{2^{q-1}} \to 0$$

因为 X 完备，所以 $\{x_{n_k}\}$ 在 X 中收敛。由 $\{x_n\}$ 的任意性，A 准紧。 □

推论 3.2. 度量空间中的准紧集是有界且可分的。

定理 3.28. (X, ρ) 是完备的度量空间，$A \subset X$。A 为准紧集的充分必要条件是对 $\forall\, \varepsilon > 0$，$A$ 都有准紧的 ε-网。

证明. (1) 必要性：A 就是它自身的准紧的 ε-网。

(2) 充分性：若对 $\forall\, \varepsilon > 0$，$A$ 都有准紧的 ε-网 B。因为 B 准紧，同时 X 完备，所以 B 全有界，即 B 有只有有限个元素的 ε-网 $C = \{c_1, c_2, \ldots, c_n\}$。则：

$$\forall\, a \in A,\ \rho(a, c_i) \leqslant \rho(a, b) + \rho(b, c_i),\ \forall\, i = 1, 2, \ldots, n$$

可以选取 c_i 使得 $\rho(a, b) < \varepsilon,\ \rho(b, c_i) < \varepsilon$（先选择 b，再根据 b 即可选得 c_i）。也就是说，$\forall\, a \in A,\ \exists\, c_i \in \{c_1, c_2, \ldots, c_n\},\ \rho(a, c_i) < 2\varepsilon$。以 $\{c_1, c_2, \ldots, c_n\}$ 中的点为中心，2ε 为半径构成的 2ε-网必然是 A 的一个 2ε-网。由 ε 的任意性，A 全有界。又因为 X 是完备的，所以 A 准紧。 □

3.8 紧集与紧度量空间

定义 3.43. (X, ρ) 是一个度量空间，A 是 X 的一个子集。如果 A 的每个点列都有一个收敛子列收敛于 A 中的某一点，则称 A 是紧集 *(compact set)*。若 X 是紧集，则称 X 是紧度量空间 *(compact metric space)*。

3.8.1 紧集的性质

定理 3.29. 度量空间中的紧集是有界且可分的。

证明. 因为准紧集是有界可分的，且紧集必然是准紧集，所以紧集也是有界可分的。 □

3.8.2 紧度量空间的性质

完备性

定理 3.30. 任一度量空间中的紧集都是完备的。紧度量空间是完备度量空间。

证明. 由紧集定义立刻可得出紧集上任意柯西点列存在收敛的子列，进而柯西点列收敛。 □

定理 3.31. (X,ρ) 是一个度量空间，$\{E_n\}$ 是 X 中的一列非空紧集，满足：

$$E_1 \supset E_2 \supset \cdots \supset E_n \supset \ldots$$

则 $\bigcap\limits_{n=1}^{+\infty} E_n \neq \varnothing$。

证明. 在每个 E_n 中选择一点 x_n，构成序列 $\{x_n\}$。因为 $\forall\ n \in \mathbb{N}^+$，$x_n \in E_n \subset E_1$，又 E_1 是紧集，所以 $\{x_n\}$ 存在子列 $\{x_{n_k}\} \to x_0 \in E_1$。对 $\forall\ n \in \mathbb{N}^+$，当 $n_k > n$ 时，有 $x_{n_k} \in E_{n_k} \subset E_n$，又因收敛点列必为柯西点列、$E_n$ 完备，所以 $x_0 \in E_n$。由 n 的任意性，$x_0 \in \bigcap\limits_{n=1}^{+\infty} E_n$，所以 $\bigcap\limits_{n=1}^{+\infty} E_n \neq \varnothing$。 □

3.8.3 紧集的充要条件

有限覆盖

定义 3.44. (X,ρ) 是一个度量空间，A 是 X 的子集，$\{G_i\}_{i\in I}$（其中 I 是一个指标集）是 X 中某些开集组成的集族。如果：

$$A \subset \bigcup_{i\in I} G_i$$

则称 $\{G_i\}_{i\in I}$ 为 A 的开覆盖 *(open cover)*。如果 I 是有限集，则称 $\{G_i\}_{i\in I}$ 为 A 的有限开覆盖 *(finite open cover)*。

定理 3.32. 度量空间 (X,ρ) 的子集 A 是紧集的充分必要条件是从 A 的任一开覆盖 $\{G_i\}_{i\in I}$ 中必可选出一个有限子覆盖。

证明. □

3.9 压缩映射原理

以后压缩映射一章放在合适的方

不动点的定义

定义 3.45. 若点 φ 在映射 T 的作用下满足 $T\varphi = \varphi$，则称 φ 是映射 T 的一个。

压缩映射的定义

定义 3.46. (X,ρ) 是一个度量空间，T 是 X 到 X 的一个映射，如果存在一个数 $\alpha, 0 \leqslant \alpha < 1$，使得对任意的 $x, y \in X$，有：

$$\rho(Tx, Ty) \leqslant \alpha\rho(x, y)$$

则称 T 是。

压缩映射原理

定理 3.33. (X,ρ) 是一个完备的度量空间，T 是 X 上的一个压缩映射，那么 T 有且只有一个不动点。

证明. (1) 存在性：任取 $x_0 \in X$，令 $x_n = T^n x_0$，由此产生一个点列 $\{x_n\}$。下面我们来证明这个点列是一个柯西点列，它的极限就是一个不动点。

$$\begin{aligned}\rho(x_{m+1},x_m) &= \rho(Tx_m,Tx_{m-1}) \leqslant \alpha\rho(x_m,x_{m+1})\\ &= \cdots\\ &= \alpha^{m-1}\rho(Tx_1,Tx_0) \leqslant \alpha^m\rho(x_1,x_0)\end{aligned}$$

取 $n > m$，由距离的三角不等式：

$$\begin{aligned}\rho(x_m,x_n) &\leqslant \rho(x_{m+1},x_n) + \cdots + \rho(x_{n-1},x_n)\\ &\leqslant (\alpha^m + \alpha^{m+1} + \cdots + \alpha^{n-1})\rho(x_0,x_1)\\ &= \alpha^m\frac{1-\alpha^{n-m}}{1-\alpha}\rho(x_0,x_1)\\ &< \frac{\alpha^m}{1-\alpha}\rho(x_0,x_1)\end{aligned}$$

因为 $0 \leqslant \alpha < 1$，所以当 m 足够大的时候，$\rho(x_m,x_n) \to 0$，即 $\{x_n\}$ 是 X 中的柯西点列。又因为 X 完备，所以 $\{x_n\} \to x \in X$。由三角不等式：

$$\rho(x,Tx) \leqslant \rho(x,x_m) + \rho(x_m,Tx) \leqslant \rho(x,x_m) + \alpha\rho(x_{m-1},x)$$

当 $m \to +\infty$ 时上式右端趋于 0，因此 $\rho(x,Tx) = 0$，即 $Tx = x$，T 存在一个不动点。

(2) 唯一性：假设 T 还有一个不动点 y，则

$$\rho(x,y) = \rho(Tx,Ty) \leqslant \alpha\rho(x,y)$$

因为 $0 \leqslant \alpha < 1$，所以 $\rho(x,y) = 0$，即 $x = y$，唯一性得证。 □

压缩映射原理有一个推广：

定理 3.34. T 是完备度量空间 X 到自身的映射，如果存在常数 α 及自然数 n_0，$0 \leqslant \alpha < 1$，使得对任意 $x,y \in X$，有：

$$\rho(T^{n_0}x,T^{n_0}y) \leqslant \alpha\rho(x,y)$$

那么 T 在 X 中有且只有一个不动点。

证明. 存在性：T^{n_0} 满足压缩映射原理的条件，因此 T^{n_0} 有且只有一个不动点 x_0。下证 x_0 也是 T 在 X 中唯一的不动点。因为

$$T^{n_0}(Tx_0) = T^{n_0+1}x_0 = T(T^{n_0}x_0) = Tx_0$$

所以 Tx_0 是 T^{n_0} 的一个不动点，由不动点的唯一性，$Tx_0 = x_0$，所以 x_0 是 T 的一个不动点。

唯一性：若 T 存在另一个不动点 x_1，则

$$T^{n_0}x_1 = T^{n_0-1}Tx_1 = T^{n_0-1}x_1 = x_1$$

即 x_1 也是 T^{n_0} 的一个不动点，由不动点的唯一性，$x_0 = x_1$。 □

Chapter 4

实数序列

4.1 实数序列的上下极限

定义

定义 4.1. 对于实数序列 $\{x_n\}$，我们将

$$\underline{\lim}\, x_n = \lim_{n\to+\infty} \inf_{k\geqslant n} x_k = \sup_n \inf_{k\geqslant n} x_k$$

$$\overline{\lim}\, x_n = \lim_{n\to+\infty} \sup_{k\geqslant n} x_k = \inf_n \sup_{k\geqslant n} x_k$$

分别称之为 $\{x_n\}$ 的下极限 *(lower limit)*和上极限 *(upper limit)*。

我们知道不是所有实数序列都有极限，但任意实数序列在 $\overline{\mathbb{R}}$ 中都有上下极限。不难注意到：

$$\inf_{k\geqslant n} x_k, \quad \sup_{k\geqslant n} x_k$$

分别为单调递增序列与单调递减序列，而单调序列在 $\overline{\mathbb{R}}$ 中都存在极限、上下确界。

写完以后链接，并且在写上下与极限的时候无穷的情况并

4.1.1 上下极限与聚点的关系

聚点介于上下极限之间

定理 4.1. 实数序列 $\{x_n\}$ 的任何聚点 ξ 都介于 $\eta = \underline{\lim}\, x_n$ 和 $\zeta = \overline{\lim}\, x_n$ 之间。

证明. 任取实数序列的一个聚点 ξ，由聚点定义可知，$\{x_n\}$ 中存在一个子列 $\{x_{n_k}\}$ 满足：

$$\lim_{k\to+\infty} x_{n_k} = \xi$$

令：

$$y_k = \inf_{n\geqslant k} x_n, \quad z_k = \sup_{n\geqslant k} x_n$$

显然有：

$$y_k \leqslant x_{n_k} \leqslant z_k$$

因为 $n_k \geqslant k$，所以对上式取极限即为：

$$\eta \leqslant \xi \leqslant \zeta$$

□

上下极限也是聚点

定理 4.2. 实数序列 $\{x_n\}$ 的下极限 $\eta = \underline{\lim}\, x_n$ 和上极限 $\zeta = \overline{\lim}\, x_n$ 是其自身的两个聚点。

证明. 下给出下极限的证明，上极限可类似得出。

若 $\{x_n\}$ 下方无界，则存在子列 $\{x_{n_k}\}$ 使得：

$$\lim_{k\to+\infty} x_{n_k} = -\infty$$

于是 $-\infty$ 成为实数序列 $\{x_n\}$ 的一个聚点。

当 $\{x_n\}$ 下方有界时，记：

$$y_k = \inf_{n\geqslant k} x_n$$

由下确界的定义可知，存在 x_{n_k} 满足：

$$y_k \leqslant x_{n_k} \leqslant y_k + \frac{1}{k}$$

对上式取极限即为：

$$\lim_{k\to+\infty} x_{n_k} = \lim_{k\to+\infty} y_k = \eta = \underline{\lim}\, x_n$$

□

4.1.2 上下极限与极限的关系

定理 4.3. 设 $\{x_n\}$ 是实数序列，则以下三条陈述互相等价：

1. $\underline{\lim}\, x_n = \overline{\lim}\, x_n = \xi$；
2. $\lim\limits_{n\to+\infty} x_n = \xi$；
3. $\{x_n\}$ 只有一个聚点。

证明. (2) → (3) 和 (3) → (1) 是显然的，下证 (1) → (2)。

令：

$$y_n = \inf_{k\geqslant n} x_k, \quad z_n = \sup_{k\geqslant n} x_k$$

则显然有：

$$y_n \leqslant x_n \leqslant z_n$$

又因为：

$$\lim_{n\to+\infty} y_n = \lim_{n\to+\infty} z_n = \xi$$

由夹逼定理可得：

$$\lim_{n\to+\infty} x_n = \xi$$

□

4.1.3 上下极限的大小

定理 4.4. 设 $\{x_n\}$ 是实数序列，

1. 如果 $\underline{\lim}\, x_n > \lambda$，则 $\exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ x_n > \lambda$。
2. 如果 $\underline{\lim}\, x_n < \rho$，则 $\forall\, N \in \mathbb{N}^+,\ \exists\, n > N,\ x_n < \rho$。
3. 如果 $\overline{\lim}\, x_n < \rho$，则 $\exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ x_n < \rho$。
4. 如果 $\overline{\lim}\, x_n > \lambda$，则 $\forall\, N \in \mathbb{N}^+,\ \exists\, n > N,\ x_n > \lambda$。

证明是容易的，利用上下极限定义中的 sup 和 inf 即可。同时从 $\mathbb{R}$ 的紧性来讲的话，上面这个定理也是很容易记住的。

4.1.4 上下极限的运算

定理 4.5. 设 $\{u_n\}$ 和 $\{v_n\}$ 都是实数序列，则只要以下各式等号或不等号两侧的式子都有意义，则式子成立。

1. 上下极限的加法运算：

$$\begin{aligned}
\underline{\lim}\, u_n + \underline{\lim}\, v_n &\leqslant \underline{\lim}(u_n + v_n) \\
&\leqslant \begin{cases} \overline{\lim}\, u_n + \underline{\lim}\, v_k \\ \underline{\lim}\, u_n + \overline{\lim}\, v_k \end{cases} \\
&\leqslant \overline{\lim}(u_n + v_n) \\
&\leqslant \overline{\lim}\, u_n + \overline{\lim}\, v_n
\end{aligned}$$

2. 上下极限的减法运算：

$$\begin{aligned}
-\underline{\lim}\, u_n &= \overline{\lim}(-u_n) \\
-\overline{\lim}\, u_n &= \underline{\lim}(-u_n)
\end{aligned}$$

3. 上下极限的乘法运算：

$$\begin{aligned}
\underline{\lim}\, u_n \cdot \underline{\lim}\, v_n &\leqslant \underline{\lim}(u_n \cdot v_n) \\
&\leqslant \begin{cases} \overline{\lim}\, u_n \cdot \underline{\lim}\, v_k \\ \underline{\lim}\, u_n \cdot \overline{\lim}\, v_k \end{cases} \\
&\leqslant \overline{\lim}(u_n \cdot v_n) \\
&\leqslant \overline{\lim}\, u_n \cdot \overline{\lim}\, v_n
\end{aligned}$$

4. 上下极限的分式运算（$\underline{\lim}\, u_n > 0$）：

$$\frac{1}{\underline{\lim}\, u_n} = \overline{\lim}\, \frac{1}{u_n}$$
$$\frac{1}{\overline{\lim}\, u_n} = \underline{\lim}\, \frac{1}{u_n}$$

5. 上下极限与极限混合的加法运算（$\lim\limits_{n\to+\infty} u_n = u$）：

$$\underline{\lim}(u_n + v_n) = u + \underline{\lim}\, v_n$$
$$\overline{\lim}(u_n + v_n) = u + \overline{\lim}\, v_n$$

6. 上下极限与极限混合的乘法运算（$\lim\limits_{n\to+\infty} u_n = u > 0,\ v_n \geqslant 0,\ \forall\, n \in \mathbb{N}^+$）：

$$\underline{\lim}(u_n \cdot v_n) = u \cdot \underline{\lim}\, v_n$$
$$\overline{\lim}(u_n \cdot v_n) = u \cdot \overline{\lim}\, v_n$$

7. 上下极限的不等式性（$u_n \leqslant v_n$）：

$$\underline{\lim}\, u_n \leqslant \underline{\lim}\, v_n$$
$$\overline{\lim}\, u_n \leqslant \overline{\lim}\, v_n$$

有空证明

Chapter 5

数项级数

定义 5.1. 设 $a_n \in \mathbb{R}$, $\forall\, n \in \mathbb{N}^+$。我们把记号：

$$\sum_{n=1}^{+\infty} a_n = a_1 + a_2 + \cdots + a_n + \cdots$$

称为以 $a_1, a_2, \ldots, a_n, \ldots$ 为项的*级数 (series)*。把 $\{S_n\}$：

$$S_n = \sum_{i=1}^{n} a_i$$

称为级数 $\sum\limits_{n=1}^{+\infty} a_n$ 的*部分和序列 (sequence of partial sums)*。如果 $\{S_n\}$ 收敛，则称级数 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛，同时将级数的值记为 $\{S_n\}$ 的极限。

本章的目的即为讨论确定级数 $\sum\limits_{n=1}^{+\infty} a_n$ 敛散性的方法。

级数与序列的关系

级数和序列其实是相通的。我们通过部分和序列来定义级数的敛散性与级数的和，反过来，关于序列极限的问题也可以转化为级数的相应问题。具体来讲：

1. 序列 $\{a_n\}$ 的敛散性与级数 $a_1 + \sum\limits_{i=1}^{+\infty}(a_{i+1} - a_i)$ 的敛散性相同。

2. 序列 $\{a_n\} \to a$ 可以转化为级数 $a_1 + \sum\limits_{i=1}^{+\infty}(a_{i+1} - a_i) = a$。

级数的柯西收敛原理

可根据序列的 Cauchy 收敛原理给出如下级数的 Cauchy 收敛原理：

定理 5.1. 级数 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛的充分必要条件为：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ |\sum_{i=n}^{m} a_i| < \varepsilon$$

绝对收敛与条件收敛

我们注意到，当级数 $\sum\limits_{n=1}^{+\infty}|a_n|$ 收敛时，级数 $\sum\limits_{n=1}^{+\infty}a_n$ 必定也收敛，这点可以由级数的 Cauchy 收敛原理及绝对值的三角不等式来证明。因此：

定义 5.2. 对级数的收敛做如下划分：

(1) 如果级数 $\sum\limits_{n=1}^{+\infty}|a_n|$ 收敛，则称级数 $\sum\limits_{n=1}^{+\infty}a_n$ 绝对收敛 *(absolute convergence)*。

(2) 如果级数 $\sum\limits_{n=1}^{+\infty}|a_n|$ 发散，但级数 $\sum\limits_{n=1}^{+\infty}a_n$ 收敛，则称级数 $\sum\limits_{n=1}^{+\infty}a_n$ 条件收敛 *(conditional convergence)*。

如果一个级数的各项都是非负的，那么显然它的敛散性会更好讨论一点。故我们首先来讨论各项都非负的级数的敛散性问题，再去讨论任意项级数的敛散性问题。

在此之前先给出一个很容易证得的定理：

定理 5.2. 级数的运算满足线性性。

5.1 正项级数

定义 5.3. 如果级数 $\sum\limits_{n=1}^{+\infty}a_n$ 的每一项都是非负数，则称该级数为正项级数 *(positive series)*。

5.1.1 收敛原理

显然正项级数的部分和序列是单调递增序列。由单调序列的收敛原理，有如下定理：

记得把单调序列收敛原理放在这

定理 5.3. 正项级数 $\sum\limits_{n=1}^{+\infty}a_n$ 收敛的充分必要条件为它的部分和序列 $\{S_n\}$ 有上界。

5.1.2 比较判别法

以下方法我们称之为比较判别法 (comparison test)。

一般形式

定理 5.4. 设 $\sum\limits_{n=1}^{+\infty}a_n$ 和 $\sum\limits_{n=1}^{+\infty}b_n$ 都是正项级数。

1. 若 $\sum\limits_{n=1}^{+\infty}b_n$ 收敛，且 $\exists\, N\in\mathbb{N}^+,\ \forall\, n>N,\ a_n\leqslant cb_n,\ c\in[0,+\infty)$，那么 $\sum\limits_{n=1}^{+\infty}a_n$ 也收敛。

2. 若 $\sum\limits_{n=1}^{+\infty}b_n$ 发散，且 $\exists\, N\in\mathbb{N}^+,\ \forall\, n>N,\ a_n\geqslant cb_n,\ c\in(0,+\infty]$，那么 $\sum\limits_{n=1}^{+\infty}a_n$ 也发散。

证明. (1) 若条件得到满足，则：

$$\begin{aligned}\sum_{n=1}^{+\infty} a_n &= \sum_{n=1}^{N} a_n + \sum_{n=N+1}^{+\infty} a_n \\ &\leqslant \sum_{n=1}^{N} a_n + \sum_{n=N+1}^{+\infty} cb_n \\ &\leqslant \sum_{n=1}^{N} a_n + \sum_{n=1}^{+\infty} cb_n \\ &= \sum_{n=1}^{N} a_n + c\sum_{n=1}^{+\infty} b_n\end{aligned}$$

显然 $\sum\limits_{n=1}^{+\infty} a_n$ 有上界，因此收敛。

(2) 若此时 a_n 收敛，则：

$$\exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ b_n \leqslant \frac{1}{c}a_n,\ \frac{1}{c} \in [0, +\infty)$$

$\sum\limits_{n=1}^{+\infty} b_n$ 就应该收敛，矛盾。 □

极限形式

定理 5.5. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 和 $\sum\limits_{n=1}^{+\infty} b_n$ 都是正项级数。且有：

$$\lim \frac{a_n}{b_n} = \gamma,\ 0 \leqslant \gamma \leqslant +\infty$$

1. 若 $\sum\limits_{n=1}^{+\infty} b_n$ 收敛且 $\gamma < +\infty$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。
2. 若 $\sum\limits_{n=1}^{+\infty} b_n$ 发散且 $\gamma > 0$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

证明. (1) 若条件得到满足，取 $\varepsilon < +\infty$，则 $\exists\, N \in \mathbb{N}^+,\ \forall\, n > N, a_n < (\gamma + \varepsilon)b_n$。

(2) 若条件得到满足，取 $\varepsilon < \frac{\gamma}{2}$，则 $\exists\, N \in \mathbb{N}^+,\ \forall\, n > N, a_n > (\gamma - \varepsilon)b_n$。 □

5.1.3 Cauchy 判别法

以下定理我们称之为 Cauchy's根式判别法 (root test)。该判别法的实质其实就是将 $\sum\limits_{n=1}^{+\infty} a_n$ 与 $\sum\limits_{n=1}^{+\infty} r^n$ 作比较。当 $r < 1$ 时，由收敛准则易证 $\sum\limits_{n=1}^{+\infty} r^n$ 收敛。

一般形式

定理 5.6. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是正项级数。

1. 若 $\exists\, r < 1,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ \sqrt[n]{a_n} < r$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛[1]。

2. 若对于无穷个 n 有 $\sqrt[n]{a_n} \geqslant 1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

证明. (1) 若条件满足，则 $\forall\, n > N,\ a_n < r^n$。由比较判别法，$\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

(2) 由条件，$S_n - S_{n-1}$ 不趋向于 0，那么 $\{S_n\}$ 也就不收敛。 □

上下极限形式

定理 5.7. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是正项级数。且：

$$\overline{\lim}\ \sqrt[n]{a_n} = q$$

1. 若 $q < 1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 若 $q > 1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

极限形式

定理 5.8. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是正项级数。且：

$$\lim\ \sqrt[n]{a_n} = q$$

1. 若 $q < 1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 若 $q > 1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

5.1.4 比值判别法

定义 5.4. 对于级数 $\sum\limits_{n=1}^{+\infty} a_n$，如果 $\exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ a_n > 0$，则称该级数为*严格正项级数 (strictly positive series)*。

针对严格正项级数的敛散性问题，有如下的比值判别法 (ratio test)。

定理 5.9. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 和 $\sum\limits_{n=1}^{+\infty} b_n$ 是严格正项级数。

1. 若 $\sum\limits_{n=1}^{+\infty} b_n$ 收敛，且 $\exists\, N \in \mathbb{N}^+$，当 $n > N$ 时满足：

$$\frac{a_{n+1}}{a_n} \leqslant \frac{b_{n+1}}{b_n}$$

[1] 思考能否去掉 r，直接写 $\sqrt[n]{a_n} < 1$。

则 $\sum\limits_{n=1}^{+\infty} a_n$ 也收敛。

2. 若 $\sum\limits_{n=1}^{+\infty} b_n$ 发散，且 $\exists\, N \in \mathbb{N}^+$，当 $n > N$ 时满足：

$$\frac{a_{n+1}}{a_n} \geqslant \frac{b_{n+1}}{b_n}$$

则 $\sum\limits_{n=1}^{+\infty} a_n$ 也发散。

证明. (1) 由题目条件可得：

$$\frac{a_{N+2}}{a_{N+1}} \leqslant \frac{b_{N+2}}{b_{N+1}},\ \frac{a_{N+3}}{a_{N+2}} \leqslant \frac{b_{N+3}}{b_{N+2}},\ \cdots,\ \frac{a_{n+1}}{a_n} \leqslant \frac{b_{n+1}}{b_n}$$

作乘法即可得：

$$\frac{a_{n+1}}{a_{N+1}} \leqslant \frac{b_{n+1}}{b_{N+1}}$$

即：

$$a_{n+1} \leqslant \frac{a_{N+1}}{b_{N+1}} b_{n+1},\ \forall\, n > N$$

由比较判别法即可得出 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

(2) 类似 (1)。 □

5.1.5 D'Alembert 判别法

以下定理我们称之为 D'Alembert 判别法。该判别法的实质其实就是将 $\sum\limits_{n=1}^{+\infty} a_n$ 与 $\sum\limits_{n=1}^{+\infty} r^n$ 作比较。当 $r < 1$ 时，由收敛准则易证 $\sum\limits_{n=1}^{+\infty} r^n$ 收敛。

一般形式

定理 5.10. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是严格正项级数。

1. 若 $\exists\, r < 1,\ \exists\, N \in \mathbb{N}^+$，当 $n > N$ 时满足：

$$\frac{a_{n+1}}{a_n} < r$$

则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 若 $\exists\, N \in \mathbb{N}^+$，当 $n > N$ 满足[2]：

$$\frac{a_{n+1}}{a_n} \geqslant 1$$

则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

[2] 思考能否像柯西根式判别法一样写成对无穷个 n 都成立。

上下极限形式

定理 5.11. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是严格正项级数。

1. 如果：
$$\overline{\lim}\,\frac{a_{n+1}}{a_n} < 1$$
则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 如果：
$$\underline{\lim}\,\frac{a_{n+1}}{a_n} > 1$$
则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

极限形式

定理 5.12. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是严格正项级数。且：
$$\lim\,\frac{a_{n+1}}{a_n} = q$$

1. 若 $q < 1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 若 $q > 1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

D'Alembert 判别法与 Cauchy 根式判别法的比较

定理 5.13. *(1)* $\overline{\lim}\,\frac{a_{n+1}}{a_n} < 1 \Rightarrow \overline{\lim}\,\sqrt[n]{a_n} < 1$；*(2)* $\underline{\lim}\,\frac{a_{n+1}}{a_n} > 1 \Rightarrow \overline{\lim}\,\sqrt[n]{a_n} > 1$。即能用 *D'Alembert* 判别法判别的，一定也能用 *Cauchy* 根式判别法判别。

证明. 只需利用下列关系：
$$\begin{aligned}\underline{\lim}\,\frac{a_{n+1}}{a_n} &\leqslant \underline{\lim}\,\sqrt[n]{a_n}\\ &\leqslant \overline{\lim}\,\sqrt[n]{a_n}\\ &\leqslant \overline{\lim}\,\frac{a_{n+1}}{a_n}\end{aligned}$$
下给出证明。

(1) 设：
$$\overline{\lim}\,\frac{a_{n+1}}{a_n} = \xi$$
取 $\lambda > \xi$，则 $\exists\, N \in \mathbb{N}^+,\ \forall\, n > N$，使得：
$$\frac{a_{n+1}}{a_n} < \lambda$$

即有：

$$\begin{aligned}\sqrt[n]{a_n} &= \sqrt[n]{\frac{a_n}{a_{n-1}}\frac{a_{n-1}}{a_{n-2}}\cdots\frac{a_{N+2}}{a_{N+1}}a_{N+1}}\\ &< \sqrt[n]{\lambda^{n-N-1}a_{N+1}}\\ &= \lambda^{1-\frac{N-1}{n}}\sqrt[n]{a_{N+1}}\end{aligned}$$

于是有：

$$\overline{\lim}\ \sqrt[n]{a_n} \leqslant \lim_{n\to+\infty}\lambda^{1-\frac{N-1}{n}}\sqrt[n]{a_{N+1}} = \lambda$$

可以取 $\lambda \to \xi$，就有：

$$\overline{\lim}\ \sqrt[n]{a_n} \leqslant \xi = \overline{\lim}\,\frac{a_{n+1}}{a_n}$$

(2) 设：

$$\underline{\lim}\,\frac{a_{n+1}}{a_n} = \xi$$

取 $\lambda < \xi$，则 $\exists\, N \in \mathbb{N}^+,\ \forall\, n > N$，使得：

$$\frac{a_{n+1}}{a_n} > \lambda$$

即有：

$$\begin{aligned}\sqrt[n]{a_n} &= \sqrt[n]{\frac{a_n}{a_{n-1}}\frac{a_{n-1}}{a_{n-2}}\cdots\frac{a_{N+2}}{a_{N+1}}a_{N+1}}\\ &> \sqrt[n]{\lambda^{n-N-1}a_{N+1}}\\ &= \lambda^{1-\frac{N-1}{n}}\sqrt[n]{a_{N+1}}\end{aligned}$$

于是有：

$$\underline{\lim}\ \sqrt[n]{a_n} \geqslant \lim_{n\to+\infty}\lambda^{1-\frac{N-1}{n}}\sqrt[n]{a_{N+1}} = \lambda$$

可以取 $\lambda \to \xi$，就有：

$$\underline{\lim}\ \sqrt[n]{a_n} \geqslant \xi = \underline{\lim}\,\frac{a_{n+1}}{a_n}$$

□

5.1.6 Cauchy 积分判别法

本节介绍 Cauchy's积分判别法 (Integral test)。

引理 5.1. 设 $f(x)$ 在 $[1,+\infty)$ 上非负。记

$$F(x) = \int_1^x f(x)\,\mathrm{d}x$$

则级数 $\sum\limits_{n=1}^{+\infty}[F(n+1)-F(n)]$ 与广义积分 $\int_1^{+\infty} f(x)\,\mathrm{d}x$ 同收敛。

证明. (1) 如果广义积分收敛，则：

$$\begin{aligned}\lim_{n\to+\infty}\sum_{i=1}^{n}[F(i+1)-F(i)] &= \lim_{n\to+\infty}F(n+1)\\ &= \lim_{n\to+\infty}\int_1^{n+1}f(x)\,\mathrm{d}x\\ &= \int_1^{+\infty}f(x)\,\mathrm{d}x\end{aligned}$$

因此级数收敛。

(2) 如果级数收敛，对 $\forall\, H>0$，令 $N=[H]$（取整函数），则：

$$\begin{aligned}\int_1^{+\infty}f(x)\,\mathrm{d}x &= \lim_{H\to+\infty}\int_1^{H}f(x)\,\mathrm{d}x\\ &\leqslant \lim_{H\to+\infty}\int_1^{N+1}f(x)\,\mathrm{d}x\\ &= \lim_{N\to+\infty}\int_1^{N+1}f(x)\,\mathrm{d}x\\ &= \lim_{N\to+\infty}\sum_{n=1}^{N}[F(n+1)-F(n)]\\ &= \sum_{n=1}^{+\infty}[F(n+1)-F(n)]\end{aligned}$$

因此广义积分收敛。 □

定理 5.14. 设 $f(x)$ 在 $[1,+\infty)$ 单调下降且非负，则级数：

$$\sum_{n=1}^{+\infty}f(n)$$

与广义积分：

$$\int_1^{+\infty}f(x)\,\mathrm{d}x$$

同敛态。

证明. (1) 如果广义积分收敛，则级数：

$$\sum_{n=2}^{+\infty}[F(n)-F(n-1)]$$

收敛，由 $f(x)$ 单调下降且非负，有：

$$f(n)\leqslant\int_{n-1}^{n}f(x)\,\mathrm{d}x=F(n)-F(n-1)$$

由比较判别法，级数收敛。

(2) 如果广义积分发散，则级数：

$$\sum_{n=1}^{+\infty}[F(n+1)-F(n)]$$

发散，由 $f(x)$ 单调下降且非负，有：

$$f(n) \geqslant \int_n^{n+1} f(x)\,\mathrm{d}x = F(n+1)-F(n)$$

由比较判别法，级数发散。 □

5.1.7 比较尺度问题

由柯西积分判别法，我们可以很容易地判断以下级数是否收敛：

1. $\sum\limits_{n=1}^{+\infty}\frac{1}{n^p}$。
2. $\sum\limits_{n=2}^{+\infty}\frac{1}{n(\ln n)^p}$。
3. $\sum\limits_{n=3}^{+\infty}\frac{1}{n\ln n(\ln\ln n)^p}$。
4. $\cdots$

上述级数在 $p>1$ 时都收敛，反之发散。

我们会谈论比较尺度的问题，简单来讲就是说对于一个级数的敛散性问题，如果 a 判别法无法判别但 b 判别法可以，那么 b 的比较尺度应该是更加精细的。这个问题局限于判别法，但也不局限于判别法，如何理解呢？D'Alembert 判别法和 Raabe 判别法的背后其实都是比较判别法，方法是一样的，但选取的比较级数不一样，也带来了它们比较尺度的不一样。上面这句话不是很直观，我们来看上面提到的由柯西积分法带来的三个级数（其实不止三个，按照换元积分法的规则，可以利用的级数能够无穷无尽地写下去）。可以看出，越往下写，通项在 n 相同时就会变得越大。也就是说它的尺度会变得更精细，之前无法判断为收敛的现在可以了。

5.1.8 Raabe 判别法

以下定理我们称之为 Raabe 判别法。该判别法的实质其实就是将 $\sum\limits_{n=1}^{+\infty}a_n$ 与 $\sum\limits_{n=1}^{+\infty}\dfrac{1}{n^p}$ 作比较。当 $p>1$ 时，由 Cauchy 积分判别法易证 $\sum\limits_{n=1}^{+\infty}\dfrac{1}{n^p}$ 收敛。

一般形式

定理 5.15. 设 $\sum\limits_{n=1}^{+\infty}a_n$ 是严格正项级数。

1. 如果 $\exists\, q > 1,\ \exists\, N \in \mathbb{N}^+$，使得对 $\forall\, n > N$ 有：

$$n\left(\frac{a_n}{a_{n+1}} - 1\right) \geqslant q$$

则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 如果 $\exists\, N \in \mathbb{N}^+$，使得对 $\forall\, n > N$ 有：

$$n\left(\frac{a_n}{a_{n+1}} - 1\right) \leqslant 1$$

则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

证明. (1) 所给的条件等价于对 $\forall\, n > N$ 有：

$$\frac{a_n}{a_{n+1}} \geqslant 1 + \frac{q}{n}$$

取 $p \in \mathbb{R}$ 满足 $1 < p < q$，取级数 $\sum\limits_{n=1}^{+\infty} \frac{1}{n^p}$，令 $b_n = \frac{1}{n^p}$。当 n 足够大的时候，有：

$$\begin{aligned}\frac{b_n}{b_{n+1}} &= \frac{(n+1)^p}{n^p} \\ &= (1+\frac{1}{n})^p \\ &= 1 + \frac{p}{n} + O(\frac{1}{n^2}) \\ &< 1 + \frac{q}{n} \leqslant \frac{a_n}{a_{n+1}}\end{aligned}$$

由比值判别法可得 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

(2) 所给的条件等价于对 $\forall\, n > N$ 有：

$$\frac{a_n}{a_{n+1}} \leqslant 1 + \frac{1}{n} = \frac{\frac{1}{n}}{\frac{1}{n+1}}$$

由比值判别法可得 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。 □

上下极限形式

定理 5.16. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是严格正项级数。

1. 如果：

$$\underline{\lim}\, n\left(\frac{a_n}{a_{n+1}} - 1\right) > 1$$

则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 如果：

$$\overline{\lim}\, n\left(\frac{a_n}{a_{n+1}}-1\right)<1$$

则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

极限形式

定理 5.17. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是严格正项级数。且：

$$\lim_{n\to+\infty} n\left(\frac{a_n}{a_{n+1}}-1\right)=q$$

1. 若 $q>1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

2. 若 $q<1$，则 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

5.1.9 Gauss 判别法

下面介绍 Gauss 判别法，它可以概括 D'Alembert 判别法与 Raabe 判别法，在比较尺度上能够达到 $\sum\limits_{n=2}^{+\infty} \frac{1}{n(\ln n)^p}$ 的精度。

定理 5.18. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是严格正项级数。若：

$$\frac{a_n}{a_{n+1}}=\lambda+\frac{\mu}{n}+\frac{\nu}{n\ln n}+o(\frac{1}{n\ln n})$$

则：

1. 若 $\lambda>1$，则级数 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛；若 $\lambda<1$，则级数 $\sum\limits_{n=1}^{+\infty} a_n$ 发散；

2. 若 $\lambda=1$, $\mu>1$，则级数 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛；若 $\lambda=1$, $\mu<1$，则级数 $\sum\limits_{n=1}^{+\infty} a_n$ 发散；

3. 若 $\lambda=1$, $\mu=1$, $\nu>1$，则级数 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛；若 $\lambda=1$, $\mu=1$, $\nu<1$，则级数 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。

证明. (1) 可以归结为 D'Alembert 判别法；(2) 可以归结为 Raabe 判别法；

(3) 我们以级数：

$$\sum_{n=2}^{+\infty} b_n=\sum_{n=2}^{+\infty}\frac{1}{n(\ln n)^p}$$

作为比较的尺度。计算可得：

$$
\begin{aligned}
\frac{b_n}{b_{n+1}} &= \frac{(n+1)(\ln(n+1))^p}{n(\ln n)^p} \\
&= \left(1+\frac{1}{n}\right)\left(1+\frac{\ln(1+\frac{1}{n})}{\ln n}\right)^p \\
&= \left(1+\frac{1}{n}\right)\left(1+\frac{\ln(1+\frac{1}{n})}{\ln n}\right)^p \\
&= \left(1+\frac{1}{n}\right)\left(1+\frac{1}{n\ln n}+o(\frac{1}{n\ln n})\right)^p \\
&= 1+\frac{1}{n}+\frac{p}{n\ln n}+o\left(\frac{1}{n\ln n}\right)
\end{aligned}
$$

其中第三行到第四行利用了泰勒展开。

回归原级数，如果 $\lambda=\mu=1,\ \nu>1$，则可以选取 $p\in\mathbb{R}$，使得：

$$1<p<\nu$$

当 n 足够大的时候，就有：

$$\frac{a_n}{a_{n+1}} \geqslant \frac{b_n}{b_{n+1}}$$

此时 $\sum\limits_{n=1}^{+\infty} b_n$ 收敛，由比值判别法，级数 $\sum\limits_{n=1}^{+\infty} a_n$ 收敛。

如果 $\lambda=\mu=1,\ \nu<1$，则可以选取 $p\in\mathbb{R}$，使得：

$$\nu<p<1$$

当 n 足够大的时候，就有：

$$\frac{a_n}{a_{n+1}} \leqslant \frac{b_n}{b_{n+1}}$$

此时 $\sum\limits_{n=1}^{+\infty} b_n$ 发散，由比值判别法，级数 $\sum\limits_{n=1}^{+\infty} a_n$ 发散。 □

5.2 任意项级数

本节讨论任意项级数 (arbitrary series)，即不对各项的正负性做出要求的级数。

5.2.1 条件收敛的判别

Abel 引理

引理 5.2. 设 $\alpha_i,\beta_i,\ i=1,2,\ldots,p$ 是实数，且：

$$B_k=\sum_{i=1}^{k}\beta_i,\ k=1,2,\ldots,p$$

则有：

1. $\sum\limits_{i=1}^{p}\alpha_i\beta_i=\sum\limits_{i=1}^{p-1}(\alpha_i-\alpha_{i+1})B_i+\alpha_pB_p$

2. 如果 $\{\alpha_i\}$ 单调，并且有：

$$|B_k|\leqslant L,\ k=1,2,\ldots,p$$

那么就有：

$$\left|\sum_{i=1}^{p}\alpha_i\beta_i\right|\leqslant L\left(|\alpha_1|+2|\alpha_p|\right)$$

(1) 这个公式又称为阿贝尔变换 (Abel transformation)、分部求和公式 (summation by parts)。之所以被称之为分部求和公式，是因为它可以写为如下形式：

$$\sum_{i=1}^{p}\alpha_i\Delta B_i=\alpha_jB_j\Big|_{j=0}^{p}-\sum_{i=1}^{p-1}B_i\Delta\alpha_i$$

其中：

$$\begin{gathered}a_0=0,\quad B_0=0\\ \Delta B_k=B_k-B_{k-1}=\beta_k,\quad k=1,2,\ldots,p,\\ \Delta\alpha_i=\alpha_{i+1}-\alpha_i,\quad i=1,2,\ldots,p-1\end{gathered}$$

证明. 记 $B_0=0$，于是有：

(1)

$$\begin{aligned}\sum_{i=1}^{p}\alpha_i\beta_i&=\sum_{i=1}^{p}\alpha_i(B_i-B_{i-1})\\&=\sum_{i=1}^{p}\alpha_iB_i-\sum_{i=1}^{p}\alpha_iB_{i-1}\\&=\sum_{i=1}^{p}\alpha_iB_i-\sum_{i=0}^{p-1}\alpha_{i+1}B_i\\&=\sum_{i=1}^{p}\alpha_iB_i-\sum_{i=1}^{p-1}\alpha_{i+1}B_i\\&=\sum_{i=1}^{p-1}(\alpha_i-\alpha_{i+1})B_i+\alpha_pB_p\end{aligned}$$

(2) 下第三行到第四行利用了 $\{\alpha_i\}$ 的单调性。

$$\begin{aligned}\left|\sum_{i=1}^{p}\alpha_i\beta_i\right| &= \left|\sum_{i=1}^{p-1}(\alpha_i-\alpha_{i+1})B_i+\alpha_pB_p\right| \\ &\leqslant \sum_{i=1}^{p-1}|\alpha_i-\alpha_{i+1}|\,|B_i|+|\alpha_p|\,|B_p| \\ &\leqslant L\left(\sum_{i=1}^{p-1}|\alpha_i-\alpha_{i+1}|+|\alpha_p|\right) \\ &= L\left(|\alpha_1-\alpha_p|+|\alpha_p|\right) \\ &\leqslant L\left(|\alpha_1|+2|\alpha_p|\right)\end{aligned}$$

□

Dirichlet 判别法

定理 5.19. 对于级数 $\sum\limits_{n=1}^{+\infty}a_nb_n$，如果：

1. 序列 $\{a_n\}$ 单调收敛于 0；
2. 序列 $\{\sum\limits_{i=1}^{n}b_i\}$ 有界；

那么级数收敛。

证明. 我们来估计：

$$\left|\sum_{i=n+1}^{n+p}a_ib_i\right|$$

令：

$$B_k=\sum_{i=1}^{n+k}b_i$$

因为序列 $\{\sum\limits_{i=1}^{n}b_i\}$ 有界，因此有：

$$\left|\sum_{i=1}^{n}b_i\right|\leqslant L,\ n\in\mathbb{N}^+$$

也就有：

$$|B_k|=\left|\sum_{i=1}^{n+k}b_i-\sum_{i=1}^{n}b_i\right|\leqslant 2L$$

因为 $\{\alpha_i\}$ 单调，于是：

$$\left|\sum_{i=n+1}^{n+p}a_ib_i\right|\leqslant 2L(|\alpha_{n+1}|+2|\alpha_{n+p}|)$$

又因为 $\{\alpha_i\} \to 0$，显然对 $\forall\, \varepsilon > 0$，当 n 足够大时可以有：

$$\left| \sum_{i=n+1}^{n+p} a_i b_i \right| < \varepsilon$$

由 Cauchy 收敛准则，级数 $\sum\limits_{n=1}^{+\infty} a_n b_n$ 收敛。 □

Abel 判别法

定理 5.20. 对于级数 $\sum\limits_{n=1}^{+\infty} a_n b_n$，如果：

1. 序列 $\{a_n\}$ 单调有界；
2. 级数 $\sum\limits_{n=1}^{+\infty} b_n$ 收敛；

那么级数收敛。

证明. 因为 $\{a_n\}$ 单调有界，由实数序列的单调收敛原理，可以设：

$$\lim_{n \to +\infty} a_n = a$$

则序列 $\{a_n - a\}$ 单调趋于 0。又因级数 $\sum\limits_{n=1}^{+\infty} b_n$ 收敛，所以序列 $\{\sum\limits_{i=1}^{n} b_i\}$ 有界。由 Dirichlet 判别法，级数 $\sum\limits_{n=1}^{+\infty} (a_n - a) b_n$ 收敛。又因为级数 $\sum\limits_{n=1}^{+\infty} a b_n$ 收敛，而：

$$\sum_{n=1}^{+\infty} a_n b_n = \sum_{n=1}^{+\infty} [(a_n - a) b_n + a b_n] = \sum_{n=1}^{+\infty} [(a_n - a) b_n] + \sum_{n=1}^{+\infty} a b_n$$

因此级数 $\sum\limits_{n=1}^{+\infty} a_n b_n$ 收敛。 □

Leibniz 判别法

定理 5.21. 设序列 $\{a_n\}$ 单调下降且收敛于 0，则以下级数收敛：

$$\sum_{n=1}^{+\infty} (-1)^{n-1} a_n$$

证明. 使用 Dirichlet 判别法可直接证得。 □

5.3 收敛级数的性质

5.3.1 收敛级数的可结合性

定理 5.22. 设有收敛级数：

$$a_1 + a_2 + \cdots + a_n + \cdots$$

如果把这个级数的若干个相继的项归并为一项，即将该级数变为如下形式：

$$(a_1+a_2+\cdots+a_{n_1})+(a_{n_1+1}+a_{n_1+2}+\cdots+a_{n_2})+\cdots+(a_{n_k+1}+a_{n_k+2}+\cdots+a_{n_{k+1}})+\cdots$$

则结合后的级数仍然收敛，且与原级数有相等的和。

证明. 结合后级数的部分和序列是原级数部分和序列的子列。 □

如果原级数为定号级数（即正项级数或负项级数），逆命题也成立。若不定号，考虑级数：

$$(1-1)+(1-1)+\cdots+(1-1)+\cdots$$

这个级数当然是收敛的，但级数：

$$1-1+1-1+\cdots+(-1)^{n-1}+\cdots$$

显然还是发散的。

5.3.2 绝对收敛级数的性质

可交换性

设 $\sum\limits_{n=1}^{+\infty} a_n$ 是一个级数，我们对其进行重排，即把该序列中的所有项无重复、无遗漏地改变一个顺序重新排出来。用符号表示即为：

$$\alpha_n^{'}=\alpha_{\varphi(n)}$$

其中 φ 是一个从 $\mathbb{N}^+$ 到 $\mathbb{N}^+$ 的双射。

定理 5.23. 若级数 $\sum\limits_{n=1}^{+\infty} a_n$ 绝对收敛，则重排后的级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$ 也绝对收敛，并且二者值相等。

证明. 我们先来讨论正项级数，再来讨论任意项级数：

(1) 正项级数：

设级数 $\sum\limits_{n=1}^{+\infty} a_n$ 为绝对收敛的正项级数，则级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$ 也是一个正项级数。由题目条件，显然可得：

$$\sum_{n=1}^{N} a_n^{'} \leqslant \sum_{n=1}^{+\infty} a_n,\ \forall\, N\in\mathbb{N}^+$$

由正项级数的收敛原理，级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$ 收敛。由极限的不等式性也有：

$$\sum_{n=1}^{+\infty} a_n^{'} \leqslant \sum_{n=1}^{+\infty} a_n$$

反之，可认为级数 $\sum\limits_{n=1}^{+\infty} a_n$ 是由级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$ 重排后的结果，因此也可得到：

$$\sum_{n=1}^{+\infty} a_n \leqslant \sum_{n=1}^{+\infty} a_n^{'}$$

于是：

$$\sum_{n=1}^{+\infty} a_n = \sum_{n=1}^{+\infty} a_n^{'}$$

(2) 任意项级数：设级数 $\sum\limits_{n=1}^{+\infty} a_n$ 为绝对收敛的任意项级数。令：

$$p_n = \frac{|a_n| + a_n}{2},\ q_n = \frac{|a_n| - a_n}{2},\ n \in \mathbb{N}^+$$

显然有：

$$0 \leqslant p_n \leqslant |a_n|,\ 0 \leqslant q_n \leqslant |a_n|,\ n \in \mathbb{N}^+$$

取比较级数 $\sum\limits_{n=1}^{+\infty} |a_n|$，由正项级数的比较判别法，$\sum\limits_{n=1}^{+\infty} p_n$ 与 $\sum\limits_{n=1}^{+\infty} q_n$ 都是正项收敛级数。由 (1)，任意重排后的级数 $\sum\limits_{n=1}^{+\infty} p_n^{'}$ 和 $\sum\limits_{n=1}^{+\infty} q_n^{'}$ 也都收敛，并且有：

$$\sum_{n=1}^{+\infty} p_n^{'} = \sum_{n=1}^{+\infty} p_n, \quad \sum_{n=1}^{+\infty} q_n^{'} = \sum_{n=1}^{+\infty} q_n$$

因此级数：

$$\sum_{n=1}^{+\infty} |a_n^{'}| = \sum_{n=1}^{+\infty} (p_n^{'} - q_n^{'})$$

由级数的线性运算也收敛，即级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$ 绝对收敛，并且有：

$$\begin{aligned}
\sum_{n=1}^{+\infty} a_n^{'} &= \sum_{n=1}^{+\infty} (p_n^{'} - q_n^{'}) \\
&= \sum_{n=1}^{+\infty} p_n^{'} - \sum_{n=1}^{+\infty} q_n^{'} \\
&= \sum_{n=1}^{+\infty} p_n - \sum_{n=1}^{+\infty} q_n \\
&= \sum_{n=1}^{+\infty} (p_n - q_n) \\
&= \sum_{n=1}^{+\infty} a_n
\end{aligned}$$

第一行到第二行利用级数的线性运算，第二行到第三行利用 (1) 的结果，第三行到第四行再次利用级数的线性运算。 □

条件收敛级数并不满足可交换性

定理 5.24. 设 $\sum\limits_{n=1}^{+\infty} a_n$ 是一个条件收敛级数，则对于 $\forall\, \xi \in \overline{\mathbb{R}}$，都存在 $\sum\limits_{n=1}^{+\infty} a_n$ 的一个重排级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$，使：

$$\sum_{n=1}^{+\infty} a_n^{'} = \xi$$

证明. (1) 对于 $\xi \in \mathbb{R}$：

令：

$$p_n = \frac{|a_n| + a_n}{2},\ q_n = \frac{|a_n| - a_n}{2},\ n \in \mathbb{N}^+$$

显然 $\sum\limits_{n=1}^{+\infty} p_n$ 与 $\sum\limits_{n=1}^{+\infty} q_n$ 都是正项级数，并且有：

$$\lim_{n\to+\infty} p_n = \lim_{n\to+\infty} \frac{|a_n| + a_n}{2} = 0$$
$$\lim_{n\to+\infty} q_n = \lim_{n\to+\infty} \frac{|a_n| - a_n}{2} = 0$$
$$\sum_{n=1}^{+\infty} p_n = \sum_{n=1}^{+\infty} \frac{|a_n| + a_n}{2} = \frac{1}{2}\sum_{n=1}^{+\infty} |a_n| + \frac{1}{2}\sum_{n=1}^{+\infty} a_n = +\infty$$
$$\sum_{n=1}^{+\infty} q_n = \sum_{n=1}^{+\infty} \frac{|a_n| - a_n}{2} = \frac{1}{2}\sum_{n=1}^{+\infty} |a_n| - \frac{1}{2}\sum_{n=1}^{+\infty} a_n = +\infty$$

前两个公式可由 Cauchy 收敛准则的必要性推得。接下来来考察序列：

$$a_1, a_2, \cdots, a_n, \cdots$$

令 P_n 表示这个序列中第 n 个非负项，以 Q_n 表示其中第 n 个负项的绝对值。则 $\{P_n\}$ 是 $\{p_n\}$ 去除一部分值为 0 的项后剩下的子序列（去除的是 $a_n \leqslant 0$ 导致 $p_n = 0$ 的项），$\{Q_n\}$ 是 $\{q_n\}$ 去除所有值为 0 的项后剩下的子序列（即 $a_n \geqslant 0$ 导致 $q_n = 0$ 的项）。由 $\{p_n\}$ 和 $\{q_n\}$ 作为实数序列与作为级数项的收敛性，可得到：

$$\lim_{n\to+\infty} P_n = \lim_{n\to+\infty} Q_n = 0$$
$$\sum_{n=1}^{+\infty} P_n = \sum_{n=1}^{+\infty} Q_n = +\infty$$

同时注意到，$\{P_n\}$ 与 $\{-Q_n\}$ 的各项其实都是原本 $\{a_n\}$ 中的某项。我们依次考察 $P_1, P_2, \ldots$ 中的各项，设 P_{m_1} 是第一个满足以下条件的项（存在性由 $\sum\limits_{n=1}^{+\infty} P_n = +\infty$ 保证）：

$$P_1 + P_2 + \cdots + P_{m_1} > \xi$$

再依次考察 $Q_1, Q_2, \ldots$ 中的各项，设 Q_{n_1} 是第一个满足以下条件的项（存在性由 $\sum\limits_{n=1}^{+\infty} Q_n = +\infty$ 保证）：

$$P_1 + P_2 + \cdots + P_{m_1} - Q_1 - Q_2 - \cdots - Q_{n_1} < \xi$$

再考虑考察 $P_{m_1+1}, P_{m_1+2}, \ldots$ 中的各项，设 P_{m_2} 是第一个满足以下条件的项：

$$P_1 + P_2 + \cdots + P_{m_1} - Q_1 - Q_2 - \cdots - Q_{n_1}$$
$$+P_{m_1+1} + P_{m_1+2} + \cdots + P_{m_2} > \xi$$

不断重复下去，我们可以得到 $\sum\limits_{n=1}^{+\infty} a_n$ 的一个重排级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$：

$$P_1 + P_2 + \cdots + P_{m_1} - Q_1 - Q_2 - \cdots - Q_{n_1}$$
$$+P_{m_1+1} + P_{m_1+2} + \cdots + P_{m_2} - Q_{n_1+1} - Q_{n_1+2} - \cdots - Q_{n_2}$$
$$\vdots$$

令 R_k 和 L_k 分别表示级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$ 末项为 P_{m_k} 的部分和与末项为 Q_{n_k} 的部分和，则由：

$$|R_k - \xi| \leqslant P_{m_k},\ k = 2, 3, \ldots,$$
$$|L_k - \xi| \leqslant Q_{n_k},\ k = 1, 2, 3, \ldots,$$

而：

$$\lim_{n\to+\infty} P_{m_k} = \lim_{n\to+\infty} Q_{n_k} = 0$$

所以：

$$\lim_{n\to+\infty} R_k = \lim_{n\to+\infty} L_k = \xi$$

因为级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$ 的任意一个部分和 $S_n^{'}$ 必定介于一对 R_k 和 L_k 之间（因为 P_{m_k} 和 Q_{n_k} 都是取的第一个满足条件的），且随着 n 的增大，可以让 k 也随之增大直至无穷。因此由夹逼定理：

$$\sum_{n=1}^{+\infty} a_n^{'} = \xi$$

(2) 对于 ξ 为正无穷或负无穷的情况，仅对正无穷情况进行讨论，负无穷类似：

任取一个单调上升且趋于无穷的实数数列 $\{\xi_n\}$。沿用 (1) 中的记号。设 P_{m_1} 是第一个满足以下条件的项（存在性由 $\sum\limits_{n=1}^{+\infty} P_n = +\infty$ 保证）：

$$P_1 + P_2 + \cdots + P_{m_1} > \xi_1$$

再依次考察 $Q_1, Q_2, \ldots$ 中的各项，设 Q_{n_1} 是第一个满足以下条件的项（存在性由 $\sum\limits_{n=1}^{+\infty} Q_n = +\infty$ 保证）：

$$P_1 + P_2 + \cdots + P_{m_1} - Q_1 - Q_2 - \cdots - Q_{n_1} < \xi_1$$

再考虑考察 $P_{m_1+1}, P_{m_1+2}, \ldots$ 中的各项，设 P_{m_2} 是第一个满足以下条件的项：

$$P_1 + P_2 + \cdots + P_{m_1} - Q_1 - Q_2 - \cdots - Q_{n_1}$$
$$+P_{m_1+1} + P_{m_1+2} + \cdots + P_{m_2} > \xi_2$$

不断重复下去，我们可以得到 $\sum\limits_{n=1}^{+\infty} a_n$ 的一个重排级数 $\sum\limits_{n=1}^{+\infty} a_n^{'}$：

$$\begin{gathered}P_1+P_2+\cdots+P_{m_1}-Q_1-Q_2-\cdots-Q_{n_1}\\+P_{m_1+1}+P_{m_1+2}+\cdots+P_{m_2}-Q_{n_1+1}-Q_{n_1+2}-\cdots-Q_{n_2}\\\vdots\end{gathered}$$

而这个重排级数显然满足：

$$\sum_{n=1}^{+\infty} a_n^{'}=+\infty$$

□

5.4 级数乘法

本节介绍级数乘法 (series multiplication)。

对于两个无穷级数：

$$\sum_{n=1}^{+\infty} a_n,\quad \sum_{n=1}^{+\infty} b_n$$

它们的乘积可以写作如下形式：

$$\begin{array}{cccc}a_1b_1 & a_1b_2 & a_1b_3 & \cdots\\a_2b_1 & a_2b_2 & a_2b_3 & \cdots\\\vdots & \vdots & \vdots & \\a_ib_1 & a_ib_2 & a_ib_3 & \cdots\\\vdots & \vdots & \vdots & \end{array}$$

这些数可以用很多种方式排成数列。

我们称以下排列方式为三角形排列：

$$a_1b_1, a_1b_2, a_2b_1, a_1b_3, a_2b_2, a_3b_1, a_1b_4\ldots$$

称以下排列方式为正方形排列：

$$a_1b_1, a_1b_2, a_2b_2, a_2b_1, a_1b_3, a_2b_3, a_3b_3\ldots$$

定理 5.25. 如果级数 $\sum\limits_{n=1}^{+\infty} a_n$ 和级数 $\sum\limits_{n=1}^{+\infty} b_n$ 绝对收敛，并且：

$$\sum_{n=1}^{+\infty} a_n=A,\quad \sum_{n=1}^{+\infty} b_n=B$$

则这两个级数的无穷乘积中的元素 a_ib_j 按任意方式排列成的级数都是绝对收敛的，并且其和为 AB。

证明. 设 $a_{i_k}b_{j_k}$, $k \in \mathbb{N}^+$ 是 a_ib_j, $i,j \in \mathbb{N}^+$ 的任意一种排列。把 $i_1, i_2, \ldots, i_n$, $j_1, j_2, \ldots, j_n$ 中最大的记为 N，则：

$$\begin{aligned}\sum_{k=1}^{n}|a_{i_k}b_{j_k}| &\leqslant \sum_{i=1}^{N}|a_i|\sum_{j=1}^{N}|b_j| \\ &\leqslant \sum_{i=1}^{+\infty}|a_i|\sum_{j=1}^{+\infty}|b_j|\end{aligned}$$

由极限的不等式性：

$$\sum_{n=1}^{+\infty}a_{i_k}b_{j_k}$$

绝对收敛。按正方形形式重排该级数可得到：

$$\begin{aligned}\sum_{n=1}^{+\infty}a_{i_k}b_{j_k} &= \lim_{n\to+\infty}\left(\sum_{i=1}^{n}a_i\right)\left(\sum_{i=1}^{n}b_i\right) \\ &= \left(\sum_{i=1}^{+\infty}a_i\right)\left(\sum_{i=1}^{+\infty}b_i\right) \\ &= AB\end{aligned}$$

□

Chapter 6

函数序列与函数项级数

本章讨论各项都是 x 的函数的序列：

$$f_1(x), f_2(x), \cdots, f_n(x), \cdots$$

同时也讨论各项都是 x 的函数的级数：

$$\sum_{n=1}^{+\infty} f_n(x)$$

定义 6.1. 使得函数序列或函数项级数收敛的 x 的集合，被称为序列或级数的收敛域 *(domian of convergence)*。

6.1 函数序列的收敛

6.1.1 逐点收敛

极限函数的定义

定义 6.2. 设 $D \subset \mathbb{R}$。如果函数序列 $\{f_n(x)\}$ 的收敛域包含了 D，那么：

$$\forall\, x \in D,\ \lim_{n\to+\infty} f_n(x) \in \mathbb{R}$$

可以定义一个函数：

$$f(x) = \lim_{n\to+\infty} f_n(x),\ f : D \to \mathbb{R}$$

我们把函数 f 称之为函数序列 $\{f_n(x)\}$ 在集合 D 上的极限函数 *(limit function)*。

函数序列逐点收敛的定义

定义 6.3. 函数序列 $\{f_n(x)\}$ 在集合 E 上逐点收敛 *(pointwise convergence)*于函数 $f(x)$ 是指：

$$\forall\, x \in E,\ \forall\, \varepsilon > 0,\ \exists\, N(x,\varepsilon) \in \mathbb{N}^+,\ \forall\, n > N,\ |f_n(x) - f(x)| < \varepsilon$$

6.1.2 一致收敛

函数序列一致收敛的定义

定义 6.4. 设函数序列 $\{f_n(x)\}$ 在集合 E 上逐点收敛于函数 $f(x)$。如果：

$$\forall\, \varepsilon > 0,\ \exists\, N(\varepsilon) \in \mathbb{N}^+,\ \forall\, n > N,\ \forall\, x \in E,\ |f_n(x) - f(x)| < \varepsilon$$

则称函数序列 $\{f_n(x)\}$ 在集合 E 上一致收敛 *(uniform convergence)* 于函数 $f(x)$，记为：

$$f_n(x) \underset{E}{\rightrightarrows} f(x) \quad (n \to +\infty)$$

函数序列一致收敛的等价叙述

定理 6.1. 设函数序列 $\{f_n(x)\}$ 在集合 E 上逐点收敛于函数 $f(x)$。记：

$$\rho(f_n(x), f(x)) = \sup_{x \in E} |f_n(x) - f(x)|$$

则以下三条陈述等价：

1. 函数序列 $\{f_n(x)\}$ 在集合 E 上一致收敛于函数 $f(x)$。
2. $\lim\limits_{n \to +\infty} \rho(f_n(x), f(x)) = 0$。
3. 对任何序列 $\{x_n\} \subset E$，都有：

$$\lim_{n \to +\infty} [f_n(x_n) - f(x_n)] = 0$$

证明. (1) $\to$ (2) 和 (2) $\to$ (3) 是显然的。下证 (3) $\to$ (1)：

假设 (1) 不成立，则

$$\exists\, \varepsilon > 0,\ \forall\, N(\varepsilon) \in \mathbb{N}^+,\ \exists\, n > N,\ \exists\, x \in E,\ |f_n(x) - f(x)| \geqslant \varepsilon$$

取一个固定地 $\varepsilon > 0$，令 $n_0 = 0$，则 $\exists\, n_k \in \mathbb{N}^+,\ n_k > n_{k-1} + 1$，且 $x_{n_k} \in E$，使得：

$$|f_{n_k}(x_{n_k}) - f(x_{n_k})| \geqslant \varepsilon$$

显然 $\{x_{n_k}\}$ 这个序列不满足 (3) 的条件，矛盾。 □

函数序列一致收敛的柯西原理

以上判别一个函数列是否一致收敛到一个极限函数的方法都需要提前求出极限函数，而以下柯西原理则不需要提前知道极限函数的形式：

定理 6.2. 设函数序列 $\{f_n(x)\}$ 的各项在集合 E 上都有定义，则这个函数序列在 E 上一致收敛于某个极限函数的充要条件是：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ \forall\, x \in E,\ |f_m(x) - f_n(x)| < \varepsilon$$

证明. 必要性：由三角不等式是显然的。

充分性：由条件，对 $\forall\, x \in E$，$f_n(x)$ 构成一个 $\mathbb{R}$ 上的柯西序列，因此可定义一个极限函数：

$$f(x) = \lim_{n\to+\infty} f_n(x),\ \forall\, x \in E$$

同时，由题目条件可得：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ \forall\, p \in \mathbb{N}^+,\ \forall\, x \in E,\ |f_{n+p}(x) - f_n(x)| < \varepsilon$$

在上式中取 $p \to +\infty$ 即可得到：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ \forall\, x \in E,\ |f(x) - f_n(x)| \leqslant \varepsilon$$

即 $\{f_n(x)\}$ 一致收敛于 $f(x)$。 □

6.2 函数项级数的收敛

6.2.1 逐点收敛

函数项级数逐点收敛的定义

定义 6.5. 函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在集合 E 上逐点收敛于函数 $f(x)$ 是指：

$$\forall\, x \in E,\ \forall\, \varepsilon > 0,\ \exists\, N(x,\varepsilon) \in \mathbb{N}^+,\ \forall\, n > N,\ |\sum_{i=1}^{n} f_i(x) - f(x)| < \varepsilon$$

6.2.2 一致收敛

函数项级数一致收敛的定义

定义 6.6. 设函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在集合 E 上逐点收敛于函数 $f(x)$。如果：

$$\forall\, \varepsilon > 0,\ \exists\, N(\varepsilon) \in \mathbb{N}^+,\ \forall\, n > N,\ \forall\, x \in E,\ \left|\sum_{i=1}^{n} f_i(x) - f(x)\right| < \varepsilon$$

则称函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在集合 E 上一致收敛于函数 $f(x)$。

函数项级数一致收敛的柯西原理

定理 6.3. 设函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在集合 E 上有定义，则这个函数序列在 E 上一致收敛于某个极限函数的充要条件是：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ \forall\, x \in E,\ \left|\sum_{i=n+1}^{m} f_i(x)\right| < \varepsilon$$

证明. 必要性：由三角不等式是显然的。

充分性：由条件，对 $\forall\, x \in E$，$\sum\limits_{i=1}^{n} f_i(x)$ 构成一个 $\mathbb{R}$ 上的柯西序列，因此可定义一个极限函数 $f(x)$ 使得：

$$\forall\, x \in E,\ f(x) = \lim_{n\to+\infty} \sum_{i=1}^{n} f_i(x)$$

同时，由题目条件可得：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ \forall\, p \in \mathbb{N}^+,\ \forall\, x \in E,\ \left|\sum_{i=1}^{n+p} f_i(x) - \sum_{i=1}^{n} f_i(x)\right| < \varepsilon$$

在上式中取 $p \to +\infty$ 即可得到：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ \forall\, x \in E,\ |f(x) - \sum_{i=1}^{n} f_i(x)| \leqslant \varepsilon$$

即函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 一致收敛于 $f(x)$。 □

推论 6.1. *若函数项级数 $\sum\limits_{n=1}^{+\infty} |f_n(x)|$ 在集合 E 上一致收敛，则 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在集合 E 上也一致收敛。*

证明. 由三角不等式即可证得。 □

请注意这里没有说二者一致收敛的对象是一样的!!!

函数项级数绝对一致收敛的判别法

定理 6.4 (Weierstrass 判别法)**.** *设函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在集合 E 上有定义。如果存在收敛的正项数项级数 $\sum\limits_{n=1}^{+\infty} x_n$，满足：*

$$\forall\, n \in \mathbb{N}^+,\ \forall\, x \in E,\ |f_n(x)| \leqslant x_n$$

则函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在集合 E 上绝对一致收敛。称正项数项级数 $\sum\limits_{n=1}^{+\infty} x_n$ 为优级数。

证明. 因为数项级数 $\sum\limits_{n=1}^{+\infty} x_n$ 收敛，所以：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ |\sum_{i=n+1}^{m} x_i| = \sum_{i=n+1}^{m} x_i < \varepsilon$$

也就有：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ \forall\, x \in E,\ \sum_{i=n+1}^{m} |f_n(x)| \leqslant \sum_{i=n+1}^{m} x_i < \varepsilon$$

由函数项级数收敛的柯西原理，$\sum\limits_{n=1}^{+\infty} |f_n(x)|$ 一致收敛，即 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 绝对一致收敛。 □

函数项级数条件一致收敛的判别法

定理 6.5 (Dirichlet 判别法). 对函数项级数：

$$\sum_{n=1}^{+\infty} f_n(x)g_n(x), \quad x \in E$$

如果：

1. 函数序列 $\{f_n(x)\}$ 对每个取定的 $x \in E$ 都是单调的，并且该函数序列在 E 上一致地趋于 0；
2. 函数项级数 $\sum\limits_{n=1}^{+\infty} g_n(x)$ 的部分和序列在 E 上一致有界：

$$\forall\, n \in \mathbb{N}^+,\ \forall\, x \in E,\ \left|\sum_{i=1}^{n} g_i(x)\right| \leqslant L$$

则函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)g_n(x)$ 在 E 上条件一致收敛。

证明. 利用 Abel 引理来估计：

$$\left|\sum_{i=n+1}^{m} f_i(x)g_i(x)\right|$$

因为函数项级数 $\sum\limits_{n=1}^{+\infty} g_n(x)$ 的部分和序列在 E 上一致有界，所以：

$$\forall\, n, m \in \mathbb{N}^+,\ m > n,\ \forall\, x \in E,\ \left|\sum_{i=n+1}^{m} g_i(x)\right| \leqslant \left|\sum_{i=1}^{n} g_i(x)\right| + \left|\sum_{i=1}^{m} g_i(x)\right| \leqslant 2L$$

又因函数序列 $\{f_n(x)\}$ 对每个取定的 $x \in E$ 都是单调的，由 Abel 引理：

$$\forall\, n, m \in \mathbb{N}^+,\ m > n,\ \forall\, x \in E,\ \left|\sum_{i=n+1}^{m} f_i(x)g_i(x)\right| \leqslant 2L(|f_{n+1}(x)| + 2|f_m(x)|)$$

因为函数序列 $\{f_n(x)\}$ 在 E 上一致地趋于 0，所以：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n > N,\ \forall\, x \in E,\ |f_n(x)| < \frac{\varepsilon}{6L}$$

于是有：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ \forall\, x \in E,\ \left|\sum_{i=n+1}^{m} f_i(x)g_i(x)\right| < \varepsilon$$

由函数项级数一致收敛的柯西原理，级数 $\sum\limits_{n=1}^{+\infty} f_n(x)g_n(x)$ 在 E 上条件一致收敛。 □

定理 6.6 (Abel 判别法). 对函数项级数：

$$\sum_{n=1}^{+\infty} f_n(x)g_n(x), \quad x \in E$$

如果：

1. 函数序列 $\{f_n(x)\}$ 对每个取定的 $x \in E$ 都是单调的，并且该函数序列在 E 上一致有界；

$$\forall\, n \in \mathbb{N}^+,\ \forall\, x \in E,\ |f_n(x)| \leqslant M$$

2. 函数项级数 $\sum\limits_{n=1}^{+\infty} g_n(x)$ 在 E 上一致收敛：

则函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)g_n(x)$ 在 E 上条件一致收敛。

证明. 因为函数项级数 $\sum\limits_{n=1}^{+\infty} g_n(x)$ 在 E 上一致收敛，则：

$$\forall\, \varepsilon^{'} > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ \left|\sum_{i=n+1}^{m} g_i(x)\right| < \varepsilon^{'}$$

又因函数序列 $\{f_n(x)\}$ 对每个取定的 $x \in E$ 都是单调的，由 Abel 引理：

$$\forall\, x \in E,\ \left|\sum_{i=n+1}^{m} f_i(x)g_i(x)\right| \leqslant 2\varepsilon^{'}(|f_{n+1}(x)| + 2|f_m(x)|) \leqslant 3M\varepsilon^{'}$$

对 $\forall\, \varepsilon > 0$，可以选取 $\varepsilon^{'} > 0$ 使得：

$$3M\varepsilon^{'} < \varepsilon$$

□

6.3 极限函数的分析性质

本节来讨论，一致收敛的函数序列或函数项级数需要满足怎样的条件，才能使得它们的极限函数拥有与它们一样的分析性质。在这里讨论的分析性质为：连续性、定积分、微分。

6.3.1 连续性

极限函数的连续性

定理 6.7. 设函数序列 $\{f_n(x)\}$ 在区间 I 上一致收敛于函数 $f(x)$。当函数序列 $\{f_n(x)\}$ 的每一项在 I 上都连续时，$f(x)$ 在 I 上也连续。

定理 6.8. 设函数项级数 $\sum\limits_{n=1}^{+\infty} f_n(x)$ 在区间 I 上一致收敛于函数 $f(x)$。当函数序列 $\{f_n(x)\}$ 的每一项在 I 上连续时，$f(x)$ 在 I 上也连续。

6.3.2 定积分

逐项积分定理

6.3.3 微分

逐项微分定理

Chapter 7

Lebesgue 积分

本章讨论 Lebesgue 积分。

在前半部分作好定义 Lebesgue 积分的所有准备工作，即讨论 $\mathbb{R}^n$ 上的测度。

测度 (measure)是一种映射，它把集合映射到某一个实数，是一种将几何空间的度量（长度、面积、体积）和其他常见概念（如大小、质量和事件的概率）广义化后产生的概念。

我们的目的是建立一种定义[1]在 $\mathbb{R}^n$ 上的测度，使它满足以下的：

公理 1. *对于 $\mathbb{R}^n$ 上的某一集合族 $\mathcal{F}$（待定义），对于 $\forall\, E \in \mathcal{F}$，$m$（将集合 E 的测度写作 $m(E)$）有如下性质：*

1. *非负性：$m(E) \geqslant 0$。*
2. *可列可加性：若 $E_i \cap E_j = \varnothing$，那么有 $m(\bigcup\limits_{i=1}^{\infty} E_i) = \sum\limits_{i=1}^{\infty} m(E_i)$。*
3. *正则性：单位立方体 $[0,1]^n = (x_1, x_2, \ldots, x_n) \in \mathbb{R}^n$. $\forall\, i \in \mathbb{N}^+$, $x_i \in [0,1]$ 的测度 $m([0,1]^n) = 1$。*

7.1 外测度

7.1.1 外测度的定义

定义 7.1. *设 E 为 $\mathbb{R}^n$ 中的任一点集，E 的 Lebesgue 定义为所有能够覆盖 E 的开区间列的体积总和的下确界。即：*

$$m^*(E) = \inf_{E \subset \bigcup\limits_{i=1}^{\infty} I_i} \sum_{i=1}^{\infty} |I_i|$$

需要注意如下事项：

[1]这里的定义并不是函数的定义域那种含义的定义，可以证明实数直线上存在不可测集合，这里类似于概率空间 $(\Omega, \mathcal{F}, P)$，实数直线是类似样本空间的概念。

1. 必须是无穷多个开区间的体积总和的下确界。如果将定义改为有限个：取 E 为 $[0,1]$ 内的有理数集，若 E 被有限个开区间覆盖，即 $E \subset \bigcup\limits_{i=1}^{n} I_i$，那么 $\bigcup\limits_{i=1}^{n} I_i$ 一定覆盖 $[0,1]$（反证法，有理数集的稠密性），即这种定义下 E 的外测度等于 1。同理，$[0,1]$ 内无理数集的外测度也为 1，由测度公理 (2)，$[0,1]$ 的测度为 2，而由测度公理 (3)，$[0,1]$ 的测度应为 1，矛盾。

2. 定义虽然是无穷多个开区间，但实际仍可以是有限的，因为可以取空集（就比如概率论可列可加性推有限可加性）。

3. 长度总和可以是 $+\infty$。

7.1.2 外测度的性质

外测度有以下三条基本性质：

性质. *1.* $m^*(E) \geqslant 0$，*等号成立当且仅当* $E = \varnothing$。

2. 若 $A \subset B$，*则有* $m^*(A) \leqslant m^*(B)$。

3. $m^*(\bigcup\limits_{i=1}^{\infty} A_i) \leqslant \sum\limits_{i=1}^{\infty} m^*(A_i)$。

证明. (1) 显然成立。

(2) 对于满足条件 $B \subset \bigcup\limits_{i=1}^{\infty} I_i$ 的任意开区间列 $\{I_i,\ i \in \mathbb{N}^+\}$，必然有 $A \subset \bigcup\limits_{i=1}^{\infty} I_i$，又因为 $m^*(A)$ 是长度总和的下确界，那么就有：

$$m^*(A) \leqslant \sum_{i=1}^{\infty} |I_i|$$

由下确界的保号性即可推得：

$$m^*(A) \leqslant \inf_{B \subset \bigcup\limits_{i=1}^{\infty} I_i} \sum_{i=1}^{\infty} |I_i| = m^*(B)$$

(3) 从单个 A_i 开始着手考虑。因为外测度是下确界，对任意 $\varepsilon > 0$ 和每个 $A_n, n \in \mathbb{N}^+$，都存在一个开区间列 $\{I_{n,i},\ i \in \mathbb{N}^+\}$ 使[2]：

$$\sum_{i=1}^{\infty} |I_{n,i}| < m^*(A_n) + \frac{\varepsilon}{2^n},\ A_n \subset \bigcup_{i=1}^{\infty} I_{n,i}$$

那么就有（第一个不等式是因为外测度是下确界，第二个不等式是上式的求和形式）：

$$m^*(\bigcup_{i=1}^{\infty} A_i) \leqslant \sum_{n=1}^{\infty}\sum_{i=1}^{\infty} |I_{n,i}| < \sum_{n=1}^{\infty} m^*(A_n) + \varepsilon$$

由 ε 的任意性，有：

$$m^*(\bigcup_{i=1}^{\infty} A_i) \leqslant \sum_{n=1}^{\infty}\sum_{i=1}^{\infty} |I_{n,i}| \leqslant \sum_{n=1}^{\infty} m^*(A_n)$$ □

[2] $\frac{\varepsilon}{2^n}$ 是一种为了在求和后得到 ε 的常用规范化取法，这是因为 $\sum\limits_{n=1}^{\infty} \frac{1}{2^n} = 1$

7.1.3 区间的外测度

定理 7.1. 区间的外测度就是区间的体积，即 $m^*(I) = |I|$。

从直观上这一点很好理解，如果 $m^*(I) > |I|$，则必然能找到一个体积总和更小的开区间列覆盖 I；如果 $m^*(I) < |I|$，则 I 必然没有被对应的开区间列全覆盖。

证明. (1) 对任意区间 I，必存在一个开区间 I' 使 $I \subset I'$ 且 $|I'| < |I| + \varepsilon$。那么就有（第一个不等式是因为外测度是下确界）：

$$m^*(I) \leqslant |I'| < |I| + \varepsilon$$

由 ε 的任意性，即有：

$$m^*(I) \leqslant |I|$$

(2) 如果 $m^*(I) < |I|$，由外测度定义，必存在一个开区间列 $\{A_i\}$，使 $I \subset \bigcup\limits_{i=1}^{\infty} A_i$ 且 $\sum\limits_{i=1}^{\infty} |A_i| < |I|$，而这是不可能的。 □

7.2 可测集的定义与性质

事情是这样的：我们就非要把外测度变成 Lebesgue 测度。目前为止外测度是不是 Lebesgue 测度呢？由外测度的性质 (1) 和区间的外测度，外测度显然满足公理 1的第一条和第三条，但是在 $\mathbb{R}^n$ 上，人们确实能够证明外测度不具有可数可加性。事实上，$\mathbb{R}^n$ 上的确存在互不相交的一列集合 $\{E_i\}$，使得：

$$m(\bigcup_{i=1}^{\infty} E_i) < \sum_{i=1}^{\infty} m(E_i)$$

因此外测度还不是 Lebesgue 测度。于是我们选择修改外测度的定义域，找到某个定义在 $\mathbb{R}^n$ 上的集合族 $\mathcal{F}$，使得外测度在 $\mathcal{F}$ 上成为 Lebesgue 测度，不在 $\mathcal{F}$ 中的 $\mathbb{R}^n$ 的子集便成为不可测集。

下面给出这个集合族的定义。

定义 7.2 (Caratheodory condition)**.** 设 E 为 $\mathbb{R}^n$ 中的点集，如果对 $\mathbb{R}^n$ 中的任一点集 T，都有：

$$m^*(T) = m^*(T \cap E) + m^*(T \cap E^c)$$

则 $E \in \mathcal{F}$。此时称 E 是 *Lebesgue* 可测的，E 的 *Lebesgue* 测度即为 E 的外测度[3]，记为 $m(E)$。

下面我们来探索这个定义带来的可测集的性质。

定理 7.2. $\varnothing$ 和 $\mathbb{R}^n$ 可测。

[3]此时外测度的性质便成为 Lebesgue 测度的性质了。

证明. 代入定义直接可得。 □

定理 7.3. S 可测的充要条件是 S^c 可测。

证明. 若 S 可测，对 $\forall T \in \mathbb{R}^n$，则有：

$$\begin{aligned} m^*(T) = m^*(T \cap S) + m^*(T \cap S^c) &= m^*[T \cap (S^c)^c] + m^*(T \cap S^c) \\ &= m^*(T \cap S^c) + m^*[T \cap (S^c)^c] \end{aligned}$$

□

引理 7.1. 集合 E 可测的充要条件是对与 $\forall A \subset E, \forall B \subset E^c$，总有：

$$m^*(A \cup B) = m^*(A) + m^*(B)$$

证明. 必要性：对 $\forall A \subset E, \forall B \subset E^c$，取 $T = A \cup B$，因为 E 可测，那么对于这个 T，应有：

$$m^*(A \cup B) = m^*(T) = m^*(T \cap E) + m^*(T \cap E^c) = m^*(A) + m^*(B)$$

充分性：对 $\forall T$，$\exists A \subset E, \exists B \subset E^c$，使得 $T = A \cup B$，那么就有：

$$m^*(T) = m^*(A \cup B) = m^*(A) + m^*(B) = m^*(T \cap E) + m^*(T \cap E^c)$$

由 T 的任意性，E 可测。 □

定理 7.4. 若 S_1, S_2 都可测，则 $S_1 \cup S_2$ 也可测。当 $S_1 \cap S_2 = \varnothing$ 时，对于 $\forall T$ 都有：

$$m^*[T \cap (S_1 \cup S_2)] = m^*(T \cap S_1) + m^*(T \cap S_2)$$

证明. 因为 S_1 可测，对于 $\forall T$ 都有：

$$m^*(T) = m^*(T \cap S_1) + m^*(T \cap S_1^c) \tag{7.1}$$

因为 S_2 可测，对于 $m^*(T \cap S_1^c)$ 有：

$$m^*(T \cap S_1^c) = m^*[(T \cap S_1^c) \cap S_2] + m^*[(T \cap S_1^c) \cap S_2^c] \tag{7.2}$$

将(7.2)式代入(7.1)式，再由德摩根公式，得到：

$$\begin{aligned} m^*(T) &= m^*(T \cap S_1) + m^*[(T \cap S_1^c) \cap S_2] + m^*[(T \cap S_1^c) \cap S_2^c] \\ &= m^*(T \cap S_1) + m^*[(T \cap S_1^c) \cap S_2] + m^*[T \cap (S_1 \cup S_2)^c] \end{aligned}$$

由于 $T \cap S_1 \subset S_1$，$(T \cap S_1^c) \cap S_2 \subset S_1^c$，满足引理 7.1条件，因此上式的前两项可以合并：

$$\begin{aligned} m^*(T \cap S_1) + m^*[(T \cap S_1^c) \cap S_2] &= m^*[(T \cap S_1) \cup (T \cap S_1^c \cap S_2)] \\ &= m^*\{T \cap [S_1 \cup (S_1^c \cap S_2)]\} \\ &= m^*\{T \cap [(S_1 \cup S_1^c) \cap (S_1 \cup S_2)]\} \\ &= m^*[T \cap (S_1 \cup S_2)] \end{aligned}$$

那么就有：

$$m^*(T) = m^*[T \cap (S_1 \cup S_2)] + m^*[T \cap (S_1 \cup S_2)^c]$$

由 T 的任意性，$S_1 \cup S_2$ 可测。

当 $S_1 \cap S_2 = \varnothing$ 时，显然 $S_2 \subset S_1^c$，那么就有 $T \cap S_2 \subset S_1^c$，由引理 7.1：

$$\begin{aligned} m^*[T \cap (S_1 \cup S_2)] &= m^*[(T \cap S_1) \cup (T \cap S_2)] \\ &= m^*(T \cap S_1) + m^*(T \cap S_2) \end{aligned}$$

□

推论 7.1. 设 $S_i (i = 1, 2, \ldots, n)$ 都可测，则 $\bigcup\limits_{i=1}^{n} S_i$ 也可测。当 $S_i \cap S_j = \varnothing$ 时，有：

$$m^*[T \cap (\bigcup_{i=1}^{n} S_i)] = \sum_{i=1}^{n} m^*(T \cap S_i)$$

定理 7.5. 若 S_1, S_2 都可测，则 $S_1 \cap S_2$ 也可测。

证明. $S_1 \cap S_2 = [(S_1 \cap S_2)^c]^c = [S_1^c \cup S_2^c]^c$。 □

推论 7.2. 设 $S_i (i = 1, 2, \ldots, n)$ 都可测，则 $\bigcap\limits_{i=1}^{n} S_i$ 也可测。

定理 7.6. 若 S_1, S_2 都可测，则 $S_1 \backslash S_2$ 也可测。

证明. $S_1 \backslash S_2 = S_1 \cap S_2^c$。 □

定理 7.7. 设 $\{S_i\}$ 是一列互不相交的可测集，则 $\bigcup\limits_{i=1}^{\infty} S_i$ 也可测，并且有：

$$m(\bigcup_{i=1}^{\infty} S_i) = \sum_{i=1}^{\infty} m(S_i)$$

证明. 由推论 7.1，对 $\forall\, n$，$\bigcup\limits_{i=1}^{n} S_i$ 都可测，那么对 $\forall\, T$，就有（第一行到第二行利用外测度性质 (2)，第二行到第三行利用推论 7.1）：

$$\begin{aligned} m^*(T) &= m^*[T \cap (\bigcup_{i=1}^{n} S_i)] + m^*[T \cap (\bigcup_{i=1}^{n} S_i)^c] \\ &\geqslant m^*[T \cap (\bigcup_{i=1}^{n} S_i)] + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c] \\ &= \sum_{i=1}^{n} m^*(T \cap S_i) + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c] \end{aligned}$$

令 $n \to +\infty$，有（第一行到第二行利用极限的不等式性，第二行到第三行利用外测度的性质 (3)）：

$$\begin{aligned} m^*(T) &\geqslant \sum_{i=1}^{n} m^*(T \cap S_i) + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c] \\ &\geqslant \sum_{i=1}^{\infty} m^*(T \cap S_i) + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c] \\ &\geqslant m^*[\bigcup_{i=1}^{\infty} (T \cap S_i)] + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c] \\ &= m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)] + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c] \end{aligned} \tag{7.3}$$

又因：

$$T = [T \cap (\bigcup_{i=1}^{\infty} S_i)] \cup [T \cap (\bigcup_{i=1}^{\infty} S_i)^c]$$

由外测度的性质 (3)，有：

$$m^*(T) \leqslant m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)] + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c]$$

因此：

$$m^*(T) = m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)] + m^*[T \cap (\bigcup_{i=1}^{\infty} S_i)^c]$$

由 T 的任意性，$\bigcup_{i=1}^{\infty} S_i$ 可测。

令 $T = \bigcup_{i=1}^{\infty} S_i$，代入公式 (7.3) 式，则：

$$\begin{aligned} m^*(\bigcup_{i=1}^{\infty} S_i) &\geqslant \sum_{i=1}^{\infty} m^*[(\bigcup_{i=1}^{\infty} S_i) \cap S_i] + m^*[(\bigcup_{i=1}^{\infty} S_i) \cap (\bigcup_{i=1}^{\infty} S_i)^c] \\ &= \sum_{i=1}^{\infty} m^*(S_i) \end{aligned}$$

但是由外测度的性质 (3) 有：

$$m^*(\bigcup_{i=1}^{\infty} S_i) \leqslant \sum_{i=1}^{\infty} m^*(S_i)$$

因此：

$$m^*(\bigcup_{i=1}^{\infty} S_i) = \sum_{i=1}^{\infty} m^*(S_i)$$ □

推论 7.3. 设 $\{S_i\}$ 是一列可测集合，则 $\bigcup_{i=1}^{\infty} S_i$ 也可测。

证明. $\bigcup_{i=1}^{\infty} S_i$ 可被表示为互不相交的可数个集合的并：

$$\bigcup_{i=1}^{\infty} S_i = S_1 \cup (S_2 \backslash S_1) \cup [S_3 \backslash (S_1 \cup S_2)] \cup \cdots$$ □

定理 7.8. 设 $\{S_i\}$ 是一列可测集合，则 $\bigcap_{i=1}^{\infty} S_i$ 也可测。

证明. 由德摩根公式：

$$(\bigcap_{i=1}^{\infty} S_i)^c = \bigcup_{i=1}^{\infty} S_i^c$$ □

做一个总结：

1. $\mathcal{F}$ 中元素的可测性对可列并、可列交、补、差封闭。
2. 定义在 $\mathcal{F}$ 中的外测度满足可列可加性。
3. $\mathcal{F}$ 是 $\mathbb{R}^n$ 上的一个 σ 代数。[4]

[4]定义：一个集合 X 的子集族 $\mathcal{M}$ 被称为一个 σ-代数，当且仅当满足以下三个条件：(1)$X \in \mathcal{F}$；(2) 若 $A \in \mathcal{F}$，则 $A^c \in \mathcal{F}$；(3) 若 $A_1, A_2, A_3, \cdots \in \mathcal{F}$，则 $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$。

7.3 可测集类

在这一节里，我们来讨论 $\mathbb{R}^n$ 上什么样的集合是可测的。先给出以下总结：

1. 外测度为 0 的集合都可测，称为零测集。
2. 零测集的任何子集都可测，并且仍然是零测集。
3. 有限个或可数个零测集的并可测，并且仍然是零测集。
4. 区间都可测，并且测度为其体积。
5. 开集和闭集都可测。
6. Borel 集都可测。

零测集

定义 7.3. 外测度为 0 的集合称之为。

定理 7.9. 零测集都可测。

证明. 任取一个零测集 E，对 $\forall\, T \in \mathbb{R}^n$，有：

$$\begin{aligned} m^*(T) &\geqslant m^*(T \cap E^c) \\ &= 0 + m^*(T \cap E^c) \\ &= m^*(T \cap E) + m^*(T \cap E^c) \end{aligned}$$

又因：

$$T = (T \cap E) \cup (T \cap E^c)$$

由外测度性质 (3)：

$$m^*(T) \leqslant m^*(T \cap E) + m^*(T \cap E^c)$$

因此：

$$m^*(T) \leqslant m^*(T \cap E) + m^*(T \cap E^c)$$

即 E 可测。由 E 的任意性，零测集都可测。 □

定理 7.10. 零测集的任何子集都可测，并且仍然是零测集。

证明. 由外测度性质 (2)，零测集的任何子集的外测度都为 0。 □

定理 7.11. 有限个或可数个零测集的并可测，并且仍然是零测集。

证明. 由外测度的可列可加性直接可得。 □

区间

定理 7.12. 区间都可测，并且 $m(I) = |I|$。

证明. □

开闭集

定理 7.13. 开集闭集都可测。

证明. □

Borel 代数

定义 7.4. 设 Σ 是 $\mathbb{R}^n$ 的一个子集族，则称所有包含 Σ 的 σ 代数的交集为 Σ 产生的 σ 代数。

定义 7.5. 由 $\mathbb{R}^n$ 中全体开集组成的子集类生成的 σ 代数称为，记为 $\mathcal{B}$，其中的元素被称为。

定理 7.14. 博雷尔集都是可测的。

证明. 开集都是可测的。 □

可测集类的通性

定义 7.6. 设集合 G 可表示成一列开集 $\{G_i\}$ 的交集：

$$G = \bigcap_{i=1}^{\infty} G_i$$

则称 G 为 G_δ 型集。

定义 7.7. 设集合 F 可表示成一列闭集 $\{F_i\}$ 的并集：

$$F = \bigcup_{i=1}^{\infty} F_i$$

则称 F 为 F_σ 型集。

定理 7.15. 设 E 是任意可测集，则一定存在 G_δ 型集 G 使 $E \subset G$，且 $m(G \setminus E) = 0$。

证明. (1) 先证对于 $\forall\, \varepsilon > 0$，存在开集 G，使 $E \subset G$，且 $m(G \setminus E) < \varepsilon$。

对于测度有限的集合 E，由测度定义，存在一列开区间 $\{I_i\}$，使得 $E \subset \bigcup_{i=1}^{\infty} I_i$，并且有：

$$\sum_{i=1}^{\infty} |I_i| < m(E) + \varepsilon$$

令 $G = \bigcup_{i=1}^{\infty} I_i$，则 G 是开集，并且 $E \subset G$。同时由外测度性质 (2) 和 (3)：

$$m(E) \leqslant m(G) = \sum_{i=1}^{\infty} m(I_i) = \sum_{i=1}^{\infty} |I_i| < m(E) + \varepsilon$$

因此：

$$m(G \setminus E) = m(G) - m(E) < \varepsilon$$

若 $m(E) = \infty$，则 E 一定可表示为可列个互不相交并且测度有限的可测集的并集，即 $E = \bigcup\limits_{i=1}^{\infty} E_i$。对每个 E_i 应用上面的结果，可找到开集 G_i 使 $E_i \subset G_i$，并且有 $m(G_i) < m(E_i) + \frac{\varepsilon}{2^i}$。令 $G = \bigcup\limits_{i=1}^{\infty} G_i$，则 G 是开集，$E \subset G$，并且有：

$$G \setminus E = \bigcup_{i=1}^{\infty} G_i \setminus \bigcup_{i=1}^{\infty} E_i \subset \bigcup_{i=1}^{\infty} (G_i \setminus E_i)$$
$$m(G \setminus E) \leqslant m\left[\bigcup_{i=1}^{\infty} (G_i \setminus E_i)\right] \leqslant \sum_{i=1}^{\infty} m(G_i \setminus E_i) < \varepsilon$$

(2) 依次取 $\varepsilon = \frac{1}{n}, n \in \mathbb{N}^+$，由 (1) 可知存在开集 G_n 使得 $E \subset G_n$，且 $m(G_n \setminus E) < \frac{1}{n}$。令 $G = \bigcap\limits_{i=1}^{\infty} G_i$，则 G 为 G_δ 型集，$E \subset G$，且有：

$$m(G \setminus E) \leqslant m(G_n \setminus E) < \frac{1}{n}$$

对 $\forall\, n \in \mathbb{N}^+$ 成立，即 $m(G \setminus E) = 0$。 □

定理 7.16. 设 E 是任意可测集，则一定存在 F_σ 型集 F 使 $F \subset E$，且 $m(E \setminus F) = 0$。

证明. 因为 E 可测，所以 E^c 也可测。那么存在 G_δ 型集 G，使得 $E^c \subset G$，且 $m(G \setminus E^c) = 0$。令 $F = G^c$，则显然 F 是一个 F_σ 型集，且有 $F \subset E$，同时有：

$$m(E \setminus F) = m(E \setminus G^c) = m(E \cap G) = m(G \setminus E^c) = 0$$ □

7.4 可测函数

7.4.1 可测函数的定义

定义 7.8. 设 $f(x)$ 是定义在可测集 $E \subset \mathbb{R}^n$ 上的实值函数。如果对 $\forall\, a \in \mathbb{R}$，$E(f > a)$ 都是可测集，则称 $f(x)$ 是定义在 E 上的可测函数 *(measurable function)*。

该定义有如下几个等价定义：

定义 7.9. 设 $f(x)$ 是定义在可测集 $E \subset \mathbb{R}^n$ 上的实值函数。下列任一条件都是 $f(x)$ 在 E 上称为可测函数的充要条件：

1. 对 $\forall\, a \in \mathbb{R}$，$E(f \geqslant a)$ 都是可测集。
2. 对 $\forall\, a \in \mathbb{R}$，$E(f < a)$ 都是可测集。
3. 对 $\forall\, a \in \mathbb{R}$，$E(f \leqslant a)$ 都是可测集。
4. 对 $\forall\, a, b \in \mathbb{R}$, $a < b$，$E(a \leqslant f < b)$ 都是可测集。

证明. (1) 与 (2) 互补，只需证 (1)；(3) 显然成立；(4) 的必要性显然与 (1) 同时成立。因此只需证 (1) 的充要性与 (4) 的充分性。

对于 (1)，只需注意到对 $\forall\, n \in \mathbb{N}^+$，有：

$$E(f \geqslant a) = \bigcap_{n=1}^{\infty} E(f > a - \frac{1}{n})$$
$$E(f > a) = \bigcup_{n=1}^{\infty} E(f \geqslant a + \frac{1}{n})$$

(1) 的必要性可由上第一式推得，(1) 的充分性可由上第二式推得。

对于 (4) 的充分性，只需注意到对 $\forall\, n \in \mathbb{N}^+$，有：

$$E(f \geqslant a) = \bigcup_{n=1}^{\infty} E(a \leqslant f < a + n)$$ □

7.4.2 可测函数的性质

定理 7.17. 设 $f(x)$ 是可测集 $E \subset \mathbb{R}^n$ 上的可测函数，则对于 $a \in \overline{\mathbb{R}}$，$E(f = a)$ 可测。

证明. 只需注意到：

$$E(f = a) = E(f \geqslant a) \setminus E(f > a)$$
$$E(f = +\infty) = \bigcap_{n=1}^{\infty} E(f > n) \quad E(f = -\infty) = \bigcap_{n=1}^{\infty} E(f < -n)$$ □

限制与延拓

定理 7.18. *(1)* 设 $f(x)$ 是可测集 $E \subset \mathbb{R}^n$ 上的可测函数，E_1 是 E 的可测子集，则 $f(x)$ 限制在 E_1 上时也是可测函数。

(2) 设 $f(x)$ 在可测集 $E_i, i = 1, 2, \ldots, n$，$n \in \mathbb{R}$ 上都是可测函数，则 $f(x)$ 延拓在 $E = \bigcup_{i=1}^{n} E_i$ 上时也是可测函数。

证明. (1) 只需注意到：

$$E_1(f > a) = E_1 \cap E(f > a)$$

(2) 只需注意到：

$$E(f > a) = \bigcup_{i=1}^{n} E_i(f > a)$$ □

上下确界与上下极限

定理 7.19. 设 $\{f_n(x)\}$ 是 E 上一列或有限个可测函数，则 $\mu(x) = \inf\limits_n f_n(x)$ 与 $\lambda(x) = \sup\limits_n f_n(x)$ 都是 E 上的可测函数。

证明. 注意到：

$$E(\mu \geqslant a) = \bigcap_{n=1}^{\infty} E(f_n \geqslant a),\ E(\lambda \leqslant a) = \bigcap_{n=1}^{\infty} E(f_n \leqslant a)$$ □

定理 7.20. 设 $\{f_n(x)\}$ 是 E 上一列可测函数，则 $F(x)=\varliminf\limits_{n\to\infty} f_n(x)$ 与 $G(x)=\varlimsup\limits_{n\to\infty} f_n(x)$ 都是 E 上的可测函数。

证明. 注意到：

$$\varliminf_{n\to\infty} f_n(x)=\sup_n(\inf_{m\geqslant n} f_m(x)),\ \varlimsup_{n\to\infty} f_n(x)=\inf_n(\sup_{m\geqslant n} f_m(x))$$

使用上一个定理即可证成。 □

推论 7.4. 设 $\{f_n(x)\}$ 是 E 上一列可测函数，若 $F(x)=\lim\limits_n f_n(x)$ 存在，则 $F(x)$ 是 E 上的可测函数。

这个推论可以稍微推广一下，因为可测性不受一个零测度集的影响，所以 $F(x)=\lim\limits_n f_n(x)$ 几乎处处存在时，$F(x)$ 也是 E 上的可测函数。

四则运算

引理 7.2. 设 $f(x)$ 和 $g(x)$ 为 $E\subset\mathbb{R}^n$ 上可测函数，则 $E(f>g)$ 和 $E(f\geqslant g)$ 都是可测集。

证明. $E(f\geqslant g)=E\setminus E(f<g)$，由 f 和 g 的对称性，显然我们只需要证明 $E(f>g)$ 可测即可。若 $f>g$，则必然存在一个有理数 r 使得 $f>r>g$，由有理数的稠密性，反之结论也成立。令 $\{r_n\}$ 为全体有理数组成的数列，则：

$$E(f>g)=\bigcup_{n=1}^{\infty}[E(f>r_n)\cap E(g<r_n)]$$

显然 $E(f>g)$ 可测。 □

定理 7.21. 设 $f(x)$ 和 $g(x)$ 为 $E\subset\mathbb{R}^n$ 上可测函数，则下列函数若在 E 上有意义，则在 E 上可测：

$$(1)f(x)\pm g(x);\ (2)|f(x)|;\ (3)\frac{1}{f(x)};\ (4)f(x)g(x)$$

证明. (1) 注意到 $E(f\pm g>a)=E(f>a\pm g)$，显然 $a\pm g$ 在 E 上是可测的，由上述引理，$f\pm g$ 可测。

(2) 注意到：

$$E(|f|>a)=\begin{cases}E(f<a)\cup E(f>a), & a>0\\ E\setminus E(f=0), & a=0\\ E, & a<0\end{cases}$$

(3) 注意到：

$$E(\frac{1}{f}>a)=\begin{cases}E(0<f<\frac{1}{a}), & a>0\\ E(0<f<+\infty), & a=0\\ E(f<\frac{1}{a})\cup E(f>0), & a<0\end{cases}$$

(4) 注意到：

$$E(fg>a)=\begin{cases}\{[E(f<0)\cup E(g<0)]\cup[E(f>0)\cup E(g>0)]\}\cap E(|f|>\frac{a}{|g|}), & a>0\\ [E(f<0)\cup E(g<0)]\cup[E(f>0)\cup E(g>0)], & a=0\\ E\setminus\left(\{[E(f<0)\cup E(g>0)]\cup[E(f>0)\cup E(g<0)]\}\cap E(|f|>\frac{-a}{|g|})\right), & a<0\end{cases}$$

(4) 的证明过程中使用到了 (2) 和 (3) 的结论。 □

7.4.3 可测函数与简单函数

简单函数的定义

定义 7.10. 设 $f(x)$ 的定义域 E 可分为有限个互不相交的可测集 $E_i, i=1,2,\ldots,n$，$E=\bigcup\limits_{i=1}^{n}E_i$，使 $f(x)$ 在每个 E_i 上都等于常数 c_i，则称 $f(x)$ 为*简单函数 (simple function)*。

下面一个定理的结论是显然的。

定理 7.22. 简单函数都是可测函数。

可测函数与简单函数的关系

设 $f(x)$ 是定义在 E 上的实值函数，令：

$$f^+(x)=\max\{f(x),0\}=\begin{cases}f(x), & f(x)\geqslant 0\\ 0, & f(x)<0\end{cases}$$

$$f^-(x)=-\min\{f(x),0\}=\begin{cases}-f(x), & f(x)\leqslant 0\\ 0, & f(x)>0\end{cases}$$

称 $f^+(x)$ 和 $f^-(x)$ 分别为 $f(x)$ 的正部和负部。由定理 7.19，若 $f(x)$ 是 E 上的可测函数，则 $f^+(x), f^-(x)$ 也是 E 上的可测函数。

定理 7.23. *(1)* 若 $f(x)$ 在 E 上非负可测，则存在可测简单函数列 $\{\varphi_n(x)\}$，使得对任意 $x\in E$，$\varphi_n(x)\leqslant\varphi_{n+1}(x), k\in\mathbb{N}^+$，且 $\lim\limits_{n\to+\infty}\varphi_n(x)=f(x)$。

(2) 若 $f(x)$ 在 E 上可测，则存在可测简单函数列 $\{\varphi_n(x)\}$，使得对任意 $x\in E$，$\lim\limits_{n\to+\infty}\varphi_n(x)=f(x)$。若 $f(x)$ 在 E 上有界，则上述收敛可以是一致收敛。

证明. (1) 若 $f(x)$ 在 E 上非负可测，对 $\forall\, n\in\mathbb{N}^+$，将 $[0,n]$ 分为 $n2^n$ 份，令：

$$E_{n,j}=E\left(\frac{j-1}{2^n}\leqslant f<\frac{j}{2^n}\right),\quad j=1,2,\ldots,n2^n$$

$$E_n=E(f\geqslant n),\quad n=1,2,\ldots$$

作函数列：

$$\varphi_n(x)=\begin{cases}\frac{j-1}{2^n}, & x\in E_{n,j}\\ k, & x\in E_n\end{cases}\quad j=1,2,\ldots,n2^n;\ n=1,2,\ldots$$

则 $\varphi_n(x)$ 是简单函数，并且有：

$$\varphi_n(x) \leqslant \varphi_{n+1}(x) \leqslant f(x), \quad \forall\, n \in \mathbb{N}^+$$

设 $x \in E$，若 $f(x) < +\infty$，则当 $k > f(x)$ 时有：

$$0 \leqslant f(x) - \varphi_n(x) \leqslant 2^{-n}$$

若 $f(x) = +\infty$，则 $\varphi_n(x) = n,\ n = 1, 2, \ldots$，因此 $\lim\limits_{n\to+\infty} \varphi_n(x) = f(x)$。

(2) 若 $f(x)$ 时 E 上的可测函数，则 $f(x) = f^+(x) - f^-(x)$。由 (1)，存在可测简单函数列 $\{\varphi_n^+(x)\}$ 和 $\{\varphi_n^-(x)\}$，使得对 $\forall\, x \in E$，有：

$$\lim_{n\to+\infty} \varphi_n^+(x) = f^+(x),\ \lim_{n\to+\infty} \varphi_n^-(x) = f^-(x)$$

令 $\varphi_n(x) = \varphi_n^+(x) - \varphi_n^-(x)$，则 $\{\varphi_n(x)\}$ 是可测简单函数列，且对 $\forall\, x \in E$，$\lim\limits_{n\to+\infty} \varphi_n(x) = f(x)$。

若 $f(x)$ 有界，设 $\sup\{|f(x)| : x \in E\} = M$，则由 (1) 的证明过程，当 $n > M$ 时有：

$$\sup\{|f^+(x) - \varphi_n^+(x)| : x \in E\} \leqslant \frac{1}{2^n}$$
$$\sup\{|f^-(x) - \varphi_n^-(x)| : x \in E\} \leqslant \frac{1}{2^n}$$

因此：

$$\begin{aligned}
\sup\{|f(x) - \varphi_n(x)| : x \in E\} &= \sup\{|f^+(x) - f^-(x) - \varphi_n^+(x) + \varphi_n^-(x)| : x \in E\} \\
&\leqslant \sup\{|f^+(x) - \varphi_n^+(x)| + |f^-(x) - \varphi_n^-(x)| : x \in E\} \\
&\leqslant \sup\{|f^+(x) - \varphi_n^+(x)| : x \in E\} + \sup\{|f^-(x) - \varphi_n^-(x)| : x \in E\} \\
&\leqslant \frac{1}{2^{n-1}}
\end{aligned}$$

所以 $\{\varphi_n(x)\}$ 在 E 上一致收敛于 $f(x)$。 □

7.4.4 叶戈罗夫定理

定理 7.24. 设 $m(E) < +\infty$，$\{f_n\}$ 是 E 上一列 *a.e.* 收敛于一个 *a.e.* 有限的函数 f 的可测函数，则对于 $\forall\, \delta > 0$，存在子集 $E_\delta \subset E$，使得 $\{f_n\}$ 在 E_δ 上一致收敛，且 $m(E \setminus E_\delta) < \delta$。

7.4.5 可测函数与连续函数的关系

连续函数都是可测函数

定理 7.25. 可测集 $E \subset \mathbb{R}^n$ 上的连续函数是可测函数。

证明. 任取一个定义在可测集 E 上的连续函数 f，设 $x \in E(f > a)$，则由 f 的连续性，存在 x 的一个邻域 $U(x)$，使得：

$$U(x) \cap E \subset E(f > a)$$

令 $G = \bigcup\limits_{x \in E(f>a)} U(x)$，则：

$$G \cap E = \left(\bigcup_{x \in E(f>a)} U(x) \right) \cap E = \bigcup_{x \in E(f>a)} (U(x) \cap E) \subset E(f > a)$$

反之显然有：

$$E(f > a) \subset G \cap E$$

因此 $E(f > a) = G \cap E$。由于 G 是开集，E 是可测集，所以 $E(f > a)$ 是可测集，因此 f 是 E 上的可测函数。 □

可测函数 a.e. 连续

定理 7.26 (卢津定理)**.** 设 $f(x)$ 是 E 上 *a.e.* 有限的可测函数，则对 $\forall\ \delta > 0$，存在闭子集 $F_\delta \subset E$，使得 $f(x)$ 在 F_δ 上连续，并且 $m(E \setminus F_\delta) < \delta$。

因该定理中函数限制在闭集上连续这一条件有时应用起来不太方便，下给出卢津定理的另一种形式：

定理 7.27. 设 $f(x)$ 是 $E \subset R$ 上 *a.e.* 有限的可测函数，则对 $\forall\ \delta > 0$，存在闭集 $F \subset E$ 及定义在整个 R 上的连续函数 $g(x)$（F 和 $g(x)$ 依赖于 δ），使得在 F 上 $f(x) = g(x)$，并且 $m(E \setminus F) < \delta$。

7.5 积分论

Chapter 8

赋范线性空间

距离空间 X 到实数或复数域上的映射被称之为泛函。

首先来讨论赋范线性空间，然后在此基础上讨论 Banach 空间、Hilbert 空间以及它们上面的线性算子。

8.1 范数

范数的定义

定义 8.1. 设 X 是实或者复线性空间，如果对于 X 中的每个元素 x，都有一个实数与之对应，记为 $||x||$，且满足：

1. 非负性：$||x|| \geqslant 0$，等号成立当且仅当 $x = \mathbf{0}$。
2. 数乘：$||\alpha x|| = |\alpha|\ ||x||$，$\alpha \in \mathbb{C}$ 或 $\mathbb{R}$。
3. 三角不等式：$||x + y|| \leqslant ||x|| + ||y||$。

则称 X 为实或复的赋范线性空间 *(normed linear space)*，$||x||$ 为元素 x 的范数 *(norm)*。

赋范线性空间中的距离

定义 8.2. 对于赋范线性空间 X，我们定义如下距离来衡量 X 中元素 x 和 y 之间的距离：

$$\rho(x, y) = ||x - y||$$

下验证它的确符合距离的定义：

证明. (1) 非负性可由范数的非负性直接验证。

(2) 对称性：$\rho(x, y) = ||x - y|| = |-1|\ ||x - y|| = ||y - x||$。

(3) 三角不等式：$\rho(x, y) = ||x - y|| = ||x - z + z - y|| \leqslant ||x - z|| + ||z - y|| = \rho(x, z) + \rho(z, y)$。 □

赋范线性空间中点列的收敛

赋范线性空间有了距离，自然也就有了点列收敛的概念。

定义 8.3. 赋范线性空间 X 中，若点列 $\{x_n\}$ 收敛于点 x，则称 $\{x_n\}$*依范数收敛 (convergence in norm)*于 x，也称 $\{x_n\}$*强收敛 (strong convergence)*于 x。

范数的性质

范数有如下几个性质：

性质. *(1)* 范数 $||x||$ 是 $x \in X$ 的连续泛函。*(2)* 依范数收敛满足线性运算法则。

证明性质 (1) 成立之前先证明一个不等式。

引理 8.1. 对于赋范线性空间 X，$x, y \in X$，有：

$$|\,||x|| - ||y||\,| \leqslant ||x - y||$$

证明. $||x|| = ||x - y + y|| \leqslant ||x - y|| + ||y||$，即 $||x|| - ||y|| \leqslant ||x - y||$；$||y|| = ||y - x + x|| \leqslant ||x - y|| + ||x||$，即 $-||x - y|| \leqslant ||x|| - ||y||$。

综上，$-||x - y|| \leqslant ||x|| - ||y|| \leqslant ||x - y||$，即 $|\,||x|| - ||y||\,| \leqslant ||x - y||$。 □

下面我们来证明范数的性质：

证明. (1) 由引理 8.1，$|\,||x_n|| - ||x||\,| \leqslant ||x_n - x||$。因此当 $\{x_n\}$ 依范数收敛于 x 时，$||x_n|| \to ||x||$。

(2) 加法运算：设 $\{x_n\}$ 和 $\{y_n\}$ 都是赋范线性空间 X 中的点列，且 $\{x_n\} \to x$，$\{y_n\} \to y$，由范数的三角不等式：

$$||x_n + y_n - (x + y)|| \leqslant ||x_n - x|| + ||y_n - y||$$

立即可得到 $\{x_n + y_n\} \to x + y$。

数乘运算：设数列 $\{a_n\} \to a$，$\{x_n\}$ 是赋范线性空间 X 中的点列，且 $\{x_n\} \to x$，由不等式：

$$\begin{aligned} ||a_n x_n - ax|| &= ||a_n x_n - a_n x + a_n x - ax|| \\ &\leqslant ||a_n x_n - a_n x|| + ||a_n x - ax|| \\ &= |a_n|\,||x_n - x|| + |a_n - a|\,||x|| \end{aligned}$$

由 $|a_n|$ 的有界性、x_n 的收敛性、a_n 的收敛性立即可得 $\{a_n x_n\} \to ax$。 □

8.2 赋范线性空间作为线性空间的性质

8.2.1 基与维数

定义 8.4. 若赋范线性空间 X 中存在 n $(n \geqslant 1)$ 个元素 $e_1, e_2, \ldots, e_n$，使得任意的 $x \in X$ 都能唯一地表示成

$$x = \sum_{i=1}^{n} c_i e_i$$

的形式，则称 $\{e_1, e_2, \ldots, e_n\}$ 是 X 的一组基，称 $\{c_1, c_2, \ldots, c_n\}$ 是 x 在基 $\{e_1, e_2, \ldots, e_n\}$ 下的坐标，称 n 为 X 的维数，称 X 是 n 维赋范线性空间。所有的 n 维赋范线性空间统称为有限维赋范线性空间 *(finite dimensional normed linear space)*，非有限维的赋范线性空间统称为无限维赋范线性空间 *(infinite dimensional normed linear space)*。

8.2.2 直和

定理 8.1. 设 $L_1, L_2, \ldots, L_n$ 都是赋范线性空间，X 是 $L_1, L_2, \ldots, L_n$ 的直和，即：

$$X = L_1 \oplus L_2 \oplus \cdots \oplus L_n$$

可在 X 中定义如下范数：

$$||x|| = ||x_1|| + ||x_2|| + \cdots + ||x_n||$$
$$||x||_1 = \max_i ||x_i||$$
$$||x||_2 = \left(\sum_{i=1}^{n} ||x_i||^2 \right)^{\frac{1}{2}}$$

这里 $x = (x_1, x_2, \ldots, x_n) \in X, x_i \in L_i (i = 1, 2, \ldots, n)$。$X$ 按照这些范数都构成赋范线性空间。

定理 8.2. 如果 $L_1, L_2, \ldots, L_n$ 都是 *Banach* 空间，X 是 $L_1, L_2, \ldots, L_n$ 的直和，则 X 按照定理 *8.1*也成为 *Banach* 空间。

8.2.3 有限维赋范线性空间的性质

等距同构与拓扑同构

定义 8.5. 设 X 和 Y 都是赋范线性空间，如果满足条件：

1. X 和 Y 作为线性空间是同构的。
2. 从 X 到 Y 的同构映射 T 是等距的（同胚的）。

则称 X 和 Y 等距同构 *(isometric isomorphism)*（拓扑同构 *(topological isomorphism)*）。

引理 8.2. 若 X 和 Z 拓扑同构，Y 和 Z 也拓扑同构，则 X 和 Z 拓扑同构。

证明. 由同构的传递性及两个连续函数的复合函数也是连续函数可立即推出。 □

定理 8.3. 任意两个同为实或复的 n 维赋范线性空间必拓扑同构。

证明. 实：由引理 8.2，只需证明任意 n 维赋范线性空间与 $\mathbb{R}^n$ 拓扑同构。

任取一个 n 维赋范线性空间 X。下证 X 和 $\mathbb{R}^n$ 之间存在一个双射。

设 X 是一个实的 n 维赋范线性空间，$\{e_1, e_2, \ldots, e_n\}$ 是 X 的一个基。定义一个映射 $T : \mathbb{R}^n \mapsto X$ 如下（$\xi \in \mathbb{R}^n$）：

$$T\xi = \sum_{i=1}^{n} \xi_i e_i$$

由于 $\{e_1, e_2, \ldots, e_n\}$ 是 X 的一个基，所以 $T\xi$ 的表出方式唯一，即 T 是一个单射。其次对 $\forall\, y \in X$，它必然能由 $\{e_1, e_2, \ldots, e_n\}$ 线性表出，因此有 $\eta = (\eta_1, \eta_2, \ldots, \eta_n) \in \mathbb{R}^n$，使得 $y = \sum\limits_{i=1}^{n} \eta_i e_i = T\eta$，因此 T 是一个满射。

映射 T 保持线性运算是显然的。

综上，X 和 $\mathbb{R}^n$ 作为线性空间是同构的。

下证映射 T 是连续映射：

$$\begin{aligned}
||T\xi - T\eta|| &= ||\sum_{i=1}^{n} (\xi_i - \eta_i) e_i|| \\
&\leqslant \sum_{i=1}^{n} |\xi_i - \eta_i|\, ||e_i|| \\
&\leqslant \left(\sum_{i=1}^{n} |\xi_i - \eta_i|^2 \right)^{\frac{1}{2}} \cdot \left(\sum_{i=1}^{n} ||e_i||^2 \right)^{\frac{1}{2}} \\
&= M \left(\sum_{i=1}^{n} ||e_i||^2 \right)^{\frac{1}{2}}
\end{aligned}$$

由上式，显然 T 是一个连续映射。

下证 T^{-1} 是一个连续映射。

要证 T^{-1} 是一个连续映射，即证 $\forall\, x, y \in X$，有：

$$||T^{-1}x - T^{-1}y|| \leqslant a||x - y||$$

其中 $a \in \mathbb{R}$。

对 $x = \sum\limits_{i=1}^{n} \xi_i e_i \in X$，令：

$$f(\xi_1, \xi_2, \ldots, \xi_n) = ||x||$$

当 $(\xi_1, \xi_2, \ldots, \xi_n)$ 在 $\mathbb{R}^n$ 的单位球面上时，即 $\sum\limits_{i=1}^{n} \xi_i^2 = 1$ 时，有 $||x|| \neq 0$。因为若此时 $||x|| = 0$，则 x 是赋范线性空间 X 的零元，那么也就有 $\sum\limits_{i=1}^{n} \xi_i e_i = \mathbf{0}$。因为 $\sum\limits_{i=1}^{n} \xi_i^2 = 1$，所以 ξ_i 不全为零，即 $\{e_1, e_2, \ldots, e_n\}$ 线性相关。而 $\{e_1, e_2, \ldots, e_n\}$ 是 X 的一组基，是线性无关的。由

此产生矛盾，也就是说此时 $||x|| \neq 0$。又因为单位球面是一个有界闭集（若某个聚点不在单位球面上，那么单位球面上收敛到这个聚点的点列从某项开始也不会在单位球面上，矛盾），定义在其上的连续函数可以取到最小值，所以 $f(\xi_1, \xi_2, \ldots, \xi_n)$ 在单位球面上有正的下确界 m，即 $||x|| \geqslant m$。对 $\forall\, x = (\xi_1, \xi_2, \ldots, \xi_n) \in X$ 进行单位化，即取 x' 满足：

$$x' = \frac{x}{\left(\sum\limits_{i=1}^{n} \xi_i^2\right)^{\frac{1}{2}}}$$

那么就有 $||x'|| \geqslant m$，即：

$$||x|| \geqslant m \left(\sum_{i=1}^{n} \xi_i^2\right)^{\frac{1}{2}}$$

于是：

$$||T^{-1}x|| \leqslant \frac{||x||}{m}$$

因此：

$$||T^{-1}x - T^{-1}y|| \leqslant m||x - y||$$

复：类似，证明与 $\mathbb{C}^n$ 拓扑同构。 □

推论 8.1. *(1) 任一 $n \in \mathbb{N}^+$ 维赋范线性空间都是完备的。(2) 任一赋范线性空间 X 的 $n \in \mathbb{N}^+$ 维子空间都是完备的，从而是闭子空间。*

证明. (1) 取 n 维赋范线性空间 X。因为 X 与 $\mathbb{R}^n$ 是拓扑同构的，那么 X 与 $\mathbb{R}^n$ 之间存在一个双射 $T : X \to \mathbb{R}^n$，且 T 和 T^{-1} 是连续的。任取 X 上的一个柯西点列 $\{x_n\}$，$Tx_n = y_n \in \mathbb{R}^n$。

下证 $\{y_n\}$ 也是一个柯西序列。

即证对 $\forall\, \varepsilon > 0$，$\exists\, N \in \mathbb{N}^+$，当 $n, m > N$ 时，有 $\rho(y_n, y_m) < \varepsilon$。

因为 T 是连续的，所以对上述 ε，$\exists\, \delta > 0$，当 $\rho(x_n, x_m) < \delta$ 时，有 $\rho(y_n, y_m) < \varepsilon$。而 $\{x_n\}$ 是柯西点列，因此对上述 δ，$\exists\, N' \in \mathbb{N}^+$，当 $n, m > N$ 时，有 $\rho(x_n, x_m) < \delta$。所以取 $N = N'$ 即可满足条件。因此 $\{y_n\}$ 是一个柯西序列。

因为 $\mathbb{R}^n$ 是完备的，所以 $\{y_n\} \to y \in \mathbb{R}^n$。那么就有：

$$\lim_{n \to +\infty} T^{-1} y_n = T^{-1} \lim_{n \to +\infty} y_n = T^{-1} y$$

因为 T 是双射，那么 $\exists\, x \in X$ 使得 $x = T^{-1}y$。因为：

$$\lim_{n \to +\infty} T^{-1} y_n = \lim_{n \to +\infty} x_n$$

所以 $\{x_n\} \to x \in X$。由 $\{x_n\}$ 的任意性，X 是完备的。

(2) 完备性由 (1) 可直接得到。因为完备，所以任一柯西点列收敛。因为任一收敛点列都是柯西点列，所以是闭子空间。 □

Riesz 引理

引理 8.3. 设 X_0 是赋范线性空间 X 的真闭子空间，那么对于 $\forall\, \varepsilon > 0$，存在 $x_0 \in X$，满足 $||x_0|| = 1$，且对 $\forall\, x \in X_0$，有：

$$||x_0 - x|| \geqslant 1 - \varepsilon$$

证明. 当 $\varepsilon \geqslant 1$ 时结论是显然的。下证 $\varepsilon < 1$ 时结论成立。

因为 X_0 是 X 的真子空间，所以 $\exists\, x_1 \in X \backslash X_0$，记：

$$d = \inf_{x \in X_0} ||x - x_1||$$

因为 X_0 是闭的，所以 $d > 0$。因为 $\varepsilon < 1$，因此 $\frac{d}{1-\varepsilon} > d$。由下确界的定义，存在 $x_2 \in X_0$，使得：

$$||x_2 - x_1|| < \frac{d}{1-\varepsilon}$$

令 $x_0 = \frac{x_1 - x_2}{||x_1 - x_2||}$，则 $||x_0|| = 1$。对于 $\forall\, x \in X_0$，注意到 $x_2 \in X_0$，因此有 $||x_1 - x_2||x + x_2 \in X_0$，于是有：

$$\begin{aligned}
||x - x_0|| &= ||x - \frac{x_1 - x_2}{||x_1 - x_2||}|| \\
&= \frac{1}{||x_1 - x_2||}||(||x_1 - x_2||x + x_2) - x_1|| \\
&\geqslant \frac{d}{||x_1 - x_2||} \\
&> 1 - \varepsilon
\end{aligned}$$

□

有限维赋范线性空间的判别

定义 8.6. X 是一个赋范线性空间，若 X 的任一有界闭集是紧的，则称 X 是 *局部紧的 (locally compact)*。

定理 8.4. 赋范线性空间 X 是有限维的的充分必要条件为 X 是局部紧的。

证明. 必要性：设 X 是 n 维实赋范线性空间，由定理 8.3，X 与 $\mathbb{R}^n$ 拓扑同构。因此 X 中的有界闭集映成 $\mathbb{R}^n$ 中的有界闭集，反之亦然。而 $\mathbb{R}^n$ 中的有界闭集是紧的，，于是 X 中的任一有界闭集也是紧的。所以 X 是局部紧的。

这里有紧集映
一个定理

充分性：若此时 X 是无限维的。取 $S = \{x : ||x|| = 1\}$ 为 X 的单位球面 □

8.3 Banach 空间

定义 8.7. 完备的赋范线性空间称之为 *Banach 空间 (Banach space)*。

8.3.1 无限维 Banach 空间的基

定义 8.8. 设 X 是一个无限维的 *Banach* 空间，X 中的点列 $\{e_n\}$ 如果满足：X 中的任一元素 x 可唯一地表示成

$$x = \sum_{n=1}^{\infty} \xi_n e_n$$

其中 ξ_n 为实数或复数，仅与 x 有关，且右端的级数依 X 中的范数收敛，则称 $\{e_n\}$ 为 X 的 *Schauder* 基或简称基。

定理 8.5. 具有 *Schauder* 基的 *Banach* 空间可分。

证明. 设 X 为具有 Schauder 基 $\{e_n\}$ 的 Banach 空间。取 X 的一个子集 E，E 是以下点构成的集合：

$$y = \sum_{i=1}^{n} r_i e_i,\ \forall\, n \in \mathbb{N}^+$$

任取 $x \in X$，则 x 可表示为 $\sum\limits_{n=1}^{\infty} \xi_i e_i$。在 E 中取点列 $\{x_n\}$，其中:

$$x_n = \sum_{i=1}^{n} \xi_i e_i$$

则显然 $\{x_n\} \to x$，且 $x_n \in E,\ \forall\, n \in \mathbb{N}^+$。因此 x 是 E 的一个聚点。由 x 的任意性，$X \subset \overline{E}$。而 E 是可数集合，因此 X 可分。 □

8.4 Hilbert 空间

Hilbert 空间的定义

定义 8.9. 设 X 是一个内积空间（可参考定义 *1.1*），在其上可定义如下范数：

$$||x|| = \sqrt{(x, x)}$$

那么 X 成为赋范线性空间。若 X 是完备的，则称其为*Hilbert 空间 (Hilbert space)*。若 X 不完备，则称其为*准 Hilbert 空间 (pre-Hilbert space)*。

下证这个定义满足范数的定义：

证明. (1) 非负性和 (2) 数乘可分别由内积的定义 (3) 和 (1) 立刻得出。

(3) 三角不等式：由内积形式的 Cauchy-Schwarz 不等式（即不等式 3），可得：

$$\begin{aligned}
||x+y||^2 &= |(x+y, x+y)| \\
&= |(x, x+y) + (y, x+y)| \\
&\leqslant |(x, x+y)| + |(y, x+y)| \\
&\leqslant \sqrt{(x,x)(x+y,x+y)} + \sqrt{(y,y)(x+y,x+y)} \\
&= \sqrt{||x||^2||x+y||^2} + \sqrt{||y||^2||x+y||^2} \\
&= ||x||\ ||x+y|| + ||y||\ ||x+y||
\end{aligned}$$

两边除 $||x+y||$，即有：

$$||x+y|| \leqslant ||x|| + ||y|| \qquad \square$$

内积是连续函数

设 $\{x_n\}, \{y_n\}$ 是内积空间 X 中的点列，且分别依范数收敛于 $x, y \in X$，注意到：

$$\begin{aligned}
|(x_n, y_n) - (x, y)| &= |(x_n, y_n) - (x_n, y) + (x_n, y) - (x, y)| \\
&= |(x_n, y_n - y) + (x_n - x, y)| \\
&\leqslant |(x_n, y_n - y)| + |(x_n - x, y)| \\
&\leqslant ||x_n||\ ||y_n - y|| + ||x_n - x||\ ||y||
\end{aligned}$$

由 $\{x_n\}$ 收敛，可得到 $||x_n||$ 有界。于是上式极限为 0，即内积是连续函数。

8.4.1 内积与范数的关系

极化恒等式

如下公式反映了内积和范数之间的关系，被称为极化恒等式 (polarization identity)。第一个公式针对于实内积空间，第二个针对于复内积空间。

$$(x, y) = \frac{1}{4}(||x+y||^2 - ||x-y||^2)$$
$$(x, y) = \frac{1}{4}(||x+y||^2 - ||x-y||^2 + i||x+iy||^2 - i||x-iy||^2)$$

中线公式

引理 8.4. 设 $f(x)$ 是定义在 $\mathbb{R}$ 上的连续实值函数，且对 $\forall\, a_1, a_2 \in \mathbb{R}$，有：

$$f(a_1 + a_2) = f(a_1) + f(a_2)$$

则对于 $\forall\, a \in \mathbb{R}$，有：

$$f(a) = af(1)$$

证明. 由条件，对 $\forall\, n \in \mathbb{N}^+$、有：

$$f(1) = f(n\frac{1}{n}) = nf(\frac{1}{n})$$

于是对 $\forall\, \frac{n}{m} \in \mathbb{Q}^+$，有：

$$f(\frac{n}{m}) = n\frac{1}{m} = \frac{n}{m}f(1)$$

又因：

$$f(0) = f(2*0) = 2f(0), f(0) = 0$$
$$f(0) = f(a-a) = f(a) + f(-a) = 0, f(a) = -f(a)$$

于是对 $\forall\, \frac{n}{m} \in \mathbb{Q}^+$，有：

$$f(-\frac{n}{m}) = -\frac{n}{m}f(1)$$

综上对 $\forall\, x \in \mathbb{Q}$ 成立。对于 $\forall\, x \in \mathbb{R}\backslash\mathbb{Q}$, $\exists\, \{x_n\} \in \mathbb{Q}$, $\{x_n\} \to x$，由 f 的连续性，即有：

$$f(x) = \lim_{n\to+\infty} f(x_n) = \lim_{n\to+\infty} x_n f(1) = xf(1)$$

所以对 $\forall\, x \in \mathbb{R}$ 成立。 □

定理 8.6. 设 X 是内积空间，则对 $\forall\, x, y \in X$，由 X 的内积导出的范数 $||\cdot||$ 满足：

$$||x+y||^2 + ||x-y||^2 = 2||x||^2 + 2||y||^2$$

反之，如果 X 是赋范线性空间，X 的范数满足上式，则可以在 X 中定义内积 $(\cdot,\cdot)$ 使 X 成为内积空间，且其范数就是由内积 $(\cdot,\cdot)$ 导出的。

证明. (1)

$$\begin{aligned}
||x+y||^2 + ||x-y||^2 &= (x+y, x+y) + (x-y, x-y) \\
&= (x,x) + (x,y) + (y,x) + (y,y) + (x,x) - (x,y) - (y,x) + (y,y) \\
&= 2(x,x) + 2(y,y) \\
&= 2||x||^2 + 2||y||^2
\end{aligned}$$

(2) 利用极化恒等式来定义内积。 □

Chapter 9

常见度量空间与赋范线性空间

这章讨论各种常见的度量空间与赋范线性空间，讨论它们上具体的一些距离、范数。

9.1 $\mathbb{R}^n$

记 $\mathbb{R}^n$ 为所有 n 维实向量 $(\xi_1, \xi_2, \ldots, \xi_n)$ 构成的线性空间。

9.1.1 $\mathbb{R}^n$ 上的距离

定义 9.1. 在 $\mathbb{R}^n$ 中定义向量 $x = (\xi_1, \xi_2, \ldots, \xi_n)$ 和向量 $y = (\eta_1, \eta_2, \ldots, \eta_n)$ 之间的距离为：

$$\rho(x, y) = \left(\sum_{i=1}^{n} (\xi_i - \eta_i)^2 \right)^{\frac{1}{2}}$$

则 $(\mathbb{R}^n, \rho)$ 是一个度量空间。

下证明上式定义的距离满足距离公理：

证明. (1) 显然 $\rho \in R$；(2) 非负性直接可得；(3) 对称性直接可得；

(4) 三角不等式：由不等式 1，可得：

$$\begin{aligned}
\sum_{i=1}^{n} (a_i + b_i)^2 &= \sum_{i=1}^{n} a_i^2 + 2 \sum_{i=1}^{n} a_i b_i + \sum_{i=1}^{n} b_i^2 \\
&\leqslant \sum_{i=1}^{n} a_i^2 + 2 \left(\sum_{i=1}^{n} a_i^2 \cdot \sum_{i=1}^{n} b_i^2 \right)^{\frac{1}{2}} + \sum_{i=1}^{n} b_i^2 \\
&= \left[\left(\sum_{i=1}^{k} a_i^2 \right)^{\frac{1}{2}} + \left(\sum_{i=1}^{k} b_i^2 \right)^{\frac{1}{2}} \right]^2
\end{aligned}$$

设 $x = (\xi_1, \xi_2, \ldots, \xi_n), y = (\eta_1, \eta_2, \ldots, \eta_n), z = (\zeta_1, \zeta_2, \ldots, \zeta_n)$ 是 $\mathbb{R}^n$ 中的任意三点，在上式中令 $a_i = (\xi_i - \zeta_i), b_i = (\zeta_i - \eta_i)$，则

$$\left[\sum_{i=1}^{n} (\xi_i - \eta_i)^2 \right]^{\frac{1}{2}} \leqslant \left[\sum_{i=1}^{n} (\xi_i - \zeta_i)^2 \right]^{\frac{1}{2}} + \left[\sum_{i=1}^{n} (\zeta_i - \eta_i)^2 \right]^{\frac{1}{2}}$$

即

$$\rho(x,y) \leqslant \rho(x,z) + \rho(z,y) \qquad \square$$

9.2 $\mathbb{C}^n$

记 $\mathbb{C}^n$ 为所有 n 维复向量 $(\xi_1, \xi_2, \ldots, \xi_n)$ 构成的线性空间。

9.2.1 $\mathbb{C}^n$ 上的距离

定义 9.2. 在 $\mathbb{C}^n$ 中定义向量 $x = (\xi_1, \xi_2, \ldots, \xi_n)$ 和向量 $y = (\eta_1, \eta_2, \ldots, \eta_n)$ 之间的距离为：

$$\rho(x,y) = \left(\sum_{i=1}^{n} |\xi_i - \eta_i|^2\right)^{\frac{1}{2}}$$

则 $(\mathbb{C}^n, \rho)$ 是一个度量空间。

下证明上式定义的距离满足距离公理：

证明. (1) 显然 $\rho \in R$；(2) 非负性直接可得；(3) 对称性直接可得；

(4) 三角不等式：由不等式 2，可得：

$$\begin{aligned}
\sum_{i=1}^{n} |a_i + b_i|^2 &= \sum_{i=1}^{n} |a_i|^2 + 2\sum_{i=1}^{n} |a_i b_i| + \sum_{i=1}^{n} |b_i|^2 \\
&\leqslant \sum_{i=1}^{n} |a_i|^2 + 2\left(\sum_{i=1}^{n} |a_i|^2 \cdot \sum_{i=1}^{n} |b_i|^2\right)^{\frac{1}{2}} + \sum_{i=1}^{n} |b_i|^2 \\
&= \left[\left(\sum_{i=1}^{k} |a_i|^2\right)^{\frac{1}{2}} + \left(\sum_{i=1}^{k} |b_i|^2\right)^{\frac{1}{2}}\right]^2
\end{aligned}$$

设 $x = (\xi_1, \xi_2, \ldots, \xi_n), y = (\eta_1, \eta_2, \ldots, \eta_n), z = (\zeta_1, \zeta_2, \ldots, \zeta_n)$ 是 $\mathbb{R}^n$ 中的任意三点，在上式中令 $a_i = (\xi_i - \zeta_i), b_i = (\zeta_i - \eta_i)$，则

$$\left[\sum_{i=1}^{n} |\xi_i - \eta_i|^2\right]^{\frac{1}{2}} \leqslant \left[\sum_{i=1}^{n} |\xi_i - \zeta_i|^2\right]^{\frac{1}{2}} + \left[\sum_{i=1}^{n} |\zeta_i - \eta_i|^2\right]^{\frac{1}{2}}$$

即

$$\rho(x,y) \leqslant \rho(x,z) + \rho(z,y) \qquad \square$$

9.3 l^p

记 $l^p (1 \leqslant p < \infty)$ 为全体满足下列不等式的实或复数列 $\{\xi_n\}$ 构成的集合：

$$\sum_{n=1}^{\infty} |\xi_n|^p < \infty$$

9.3.1 l^p 上的距离

定义 9.3. 在 l^p 中定义元素 $x=\{x_n\}$ 和元素 $y=\{y_n\}$ 之间的距离为：

$$\rho(x,y)=\left(\sum_{n=1}^{\infty}|x_n-y_n|^p\right)^{\frac{1}{p}}$$

则 (l^p,ρ) 是一个度量空间。

下证明上式定义的距离满足距离公理：

证明. (1)$\rho\in R$ 可由 l^p 空间定义中级数的有界性推出；(2) 非负性直接可得；(3) 对称性直接可得；(4) 三角不等式：设 $\{x_n\},\{y_n\},\{z_n\}$ 是任意的三个实或复有界数列。$p=1$ 时可由绝对值得三角不等式或模长的三角不等式立即得到，$p>1$ 时在 Minkowski 不等式（即不等式 8）

$$\left(\sum_{i=1}^{\infty}|\xi_i+\eta_i|^p\right)^{\frac{1}{p}}\leqslant\left(\sum_{i=1}^{\infty}|\xi_i|^p\right)^{\frac{1}{p}}+\left(\sum_{i=1}^{\infty}|\eta_i|^p\right)^{\frac{1}{p}}$$

中取 $\xi_i=x_i-z_i,\eta_i=z_i-y_i$ 即可立即得到。 □

9.4 l^∞

记 l^∞ 为全体实或复有界序列构成的集合。

9.4.1 l^∞ 上的距离

定义 9.4. 在 l^∞ 中定义元素 $x=\{x_n\}$ 和元素 $y=\{y_n\}$ 之间的距离为：

$$\rho(x,y)=\sup_{i\in\mathbb{N}}|x_n-y_n|$$

则 (l^∞,ρ) 是一个度量空间。

下证明上式定义的距离满足距离公理：

证明. (1)$\rho\in R$ 可由序列的有界性推出；(2) 非负性直接可得；(3) 对称性直接可得；

(4) 三角不等式：设 $\{x_n\},\{y_n\},\{z_n\}$ 是任意的三个实或复有界序列。由绝对值的三角不等式或模长的三角不等式：

$$\begin{aligned}|x_n-y_n|&\leqslant|x_n-z_n|+|z_n-y_n|\\&\leqslant\sup_{i\in\mathbb{N}}|x_n-z_n|+\sup_{i\in\mathbb{N}}|z_n-y_n|\\&=\rho(x,z)+\rho(z,y)\end{aligned}$$

因此：

$$\rho(x,y)=\sup_{i\in\mathbb{N}}|x_n-y_n|\leqslant\rho(x,z)+\rho(z,y)$$ □

9.5 s

记 s 为全体实或复数列 $\{\xi_n\}$ 构成的集合。

9.5.1 s 上的距离

定义 9.5. 在 s 中定义定义元素 $x=\{x_n\}$ 和元素 $y=\{y_n\}$ 之间的距离为：

$$\rho(x,y)=\sum_{i=1}^{\infty}\frac{1}{2^i}\frac{|x_i-y_i|}{1+|x_i-y_i|}$$

则 (s,ρ) 是一个度量空间。

下证明上式定义的距离满足距离公理：

证明. (1) 由比较判别法，$\rho<\sum\limits_{i=1}^{\infty}\frac{1}{2^i}$，于是 $\rho\in\mathbb{R}$；(2) 非负性直接可得；(3) 对称性直接可得；(4) 三角不等式：设 $x=\{x_n\},y=\{y_n\},z=\{z_n\}$ 是任意的三个实或复有界数列。考虑函数 $f(t)=\frac{t}{1+t}=1-\frac{1}{1+t},t\in(0,+\infty)$，该函数是单调增函数。由 $|x_i-y_i|<|x_i-z_i|+|z_i-y_i|,i\in\mathbb{N}^+$，有：

$$\begin{aligned}\frac{|x_i-y_i|}{1+|x_i-y_i|}&\leqslant\frac{|x_i-z_i|+|z_i-y_i|}{1+|x_i-z_i|+|z_i-y_i|}\\&=\frac{|x_i-z_i|}{1+|x_i-z_i|+|z_i-y_i|}+\frac{|z_i-y_i|}{1+|x_i-z_i|+|z_i-y_i|}\\&\leqslant\frac{|x_i-z_i|}{1+|x_i-z_i|}+\frac{|z_i-y_i|}{|z_i-y_i|}\end{aligned}$$

将上式对 i 求和即有：

$$\rho(x,y)\leqslant\rho(x,z)+\rho(z,y)$$ □

9.6 S

记 S 为定义在测度有限的可测集 F 上的一切 $a.e.$ 有限的可测函数构成的集合。

9.6.1 S 上的距离

定义 9.6. 在 S 中定义定义元素 $x=x(t)$ 和元素 $y=y(t)$ 之间的距离为：

$$\rho(x,y)=\int_F\frac{|x(t)-y(t)|}{1+|x(t)-y(t)|}\,\mathrm{d}x$$

则 (S,ρ) 是一个度量空间。

下证明上式定义的距离满足距离公理：

9.7 $C[a,b]$

记 $C[a,b]$ 为闭区间 $[a,b]$ 上全体实或复连续函数构成的集合。

9.7.1 $C[a,b]$ 上的距离

定义 9.7. 在 $C[a,b]$ 中定义元素 $x=x(t)$ 和元素 $y=y(t)$ 之间的距离为：

$$\rho(x,y)=\max_{t\in[a,b]}|x(t)-y(t)|$$

则 $(C[a,b],\rho)$ 是一个度量空间。

下证明上式定义的距离满足距离公理：

证明. (1)$\rho\in R$ 可由连续函数的有界性推出；(2) 非负性直接可得；(3) 对称性直接可得；

(4) 三角不等式：设 $x(t),y(t),z(t)$ 是 $[a,b]$ 上任意的三个连续函数。由绝对值的三角不等式或模长的三角不等式：

$$\begin{aligned}|x(t)-y(t)| &\leqslant |x(t)-z(t)|+|z(t)-y(t)|\\ &\leqslant \max_{t\in[a,b]}|x(t)-z(t)|+\max_{t\in[a,b]}|z(t)-y(t)|\\ &=\rho(x,z)+\rho(z,y)\end{aligned}$$

因此：

$$\rho(x,y)=\max_{t\in[a,b]}|x(t)-y(t)|\leqslant\rho(x,z)+\rho(z,y)$$ □

9.8 L^p

9.8.1 L^p 上的距离

9.9 L^∞

9.9.1 L^∞ 上的距离

Chapter 10

Banach 空间上的有界线性算子

10.1 线性算子

10.1.1 线性算子的定义

定义 10.1. 设 X 和 Y 都是实（复）线性空间，T 是由 X 的某个子空间 E 到线性空间 Y 的一个映射，如果对于 $\forall\, x, y \in E$，有：

$$T(x+y) = Tx + Ty$$

则称 T 是可加的。若对 $\forall\, \alpha \in \mathbb{R}$（或 $\forall\, \alpha \in \mathbb{R}$）即 $\forall\, x \in E$，有：

$$T(\alpha x) = \alpha Tx$$

则称 T 是齐次的。称可加齐次映射为线性算子 *(linear operator)*。

10.1.2 线性算子的连续性

定义 10.2. 设 X 和 Y 都是实（复）的赋范线性空间，T 是由 X 的某个子空间 E 到线性空间 Y 的线性算子。如果 T 是连续的，则称 T 为连续线性算子 *(continuous linear operator)*。

连续可加等价于连续线性

定理 10.1. 设 X 和 Y 都是实赋范线性空间，T 是由 X 的某个子空间 E 到线性空间 Y 的连续可加算子，则 T 是连续线性算子。

证明. □

定理 10.2. 设 X 和 Y 都是复赋范线性空间，T 是由 X 的某个子空间 E 到线性空间 Y 的连续可加算子，且 $T(ix) = iTx$，则 T 是连续线性算子。

证明. 设 $a = a_1 + ia_2 \in \mathbb{C}$，由定理 10.1：

$$\begin{aligned} T(ax) &= T[(a_1 + ia_2)x] = T(a_1x + ia_2x) = T(a_1x) + T(ia_2x) \\ &= a_1Tx + iT(a_2x) = a_1Tx + ia_2Tx = (a_1 + ia_2)Tx = aTx \end{aligned}$$

□

10.1.3 线性算子的有界性

定义 10.3. 如果 T 将 E 中的任一有界集映射为 Y 中的有界集，则称 T 是有界线性算子 *(bounded linear operator)*。如果存在 E 中的有界集 A，使得 TA 是 Y 中的无界集，则称 T 是无界线性算子 *(unbounded linear operator)*。

线性算子有界的等价定义

定理 10.3. 设 X 和 Y 都是实赋范线性空间，T 是由 X 的某个子空间 E 到线性空间 Y 的线性算子，则 T 有界的充分必要条件为：

$$\exists\, M > 0,\ \forall\, x \in E,\ ||Tx|| \leqslant M||x||$$

证明. (1) 充分性：任取 $A \subset E$ 是一个有界集，则：

$$\exists\, K > 0,\ \forall\, x \in A,\ ||x|| \leqslant K$$

因此：

$$\exists\, M > 0,\ \exists\, K > 0,\ \forall\, x \in A,\ ||Tx|| \leqslant M||x|| \leqslant MK$$

所以 TA 是 Y 中的有界集。由 A 的任意性，T 有界。

(2) 必要性：在 E 中取单位球面 $S = \{x \in E : ||x|| = 1\}$，显然 S 有界，因此 TS 有界。于是：

$$\exists\, M > 0,\ \forall\, x \in S,\ ||Tx|| \leqslant M$$

设 x 为 E 中任意非 $\mathbf{0}$ 的元素，则：

$$\frac{x}{||x||} \in S$$

所以有：

$$\left\| T\left(\frac{x}{||x||}\right) \right\| \leqslant M$$

由 T 的齐次性：

$$||Tx|| \leqslant M||x||$$

因为 X 中的零元必然被线性算子 T 映射为 Y 中的零元，当 $x = \mathbf{0}$ 时，Tx 必然是 Y 中的零元，上式显然也成立。 □

10.1.4 线性算子有界与连续的关系

定理 10.4. 设 X 和 Y 都是实赋范线性空间，T 是由 X 的某个子空间 E 到线性空间 Y 的线性算子，则以下陈述等价：

1. T 连续。
2. T 在 E 中某给定点 x_0 连续。
3. T 有界。

证明. (1) $\to$ (2) 是显然的。下证 (2) $\to$ (3)。

因为 T 在 x_0 连续，因此对 $\varepsilon = 1$, $\exists\, \delta > 0$, $\forall\, x \in E$，当 $||x - x_0|| \leqslant \delta$ 时，有：

$$||Tx - Tx_0|| \leqslant \varepsilon = 1$$

任取 $x_1 \neq x_0$，且 $x_1 \in E$，因为：

$$\left\| \frac{\delta(x_1 - x_0)}{||x_1 - x_0||} \right\| = \delta \leqslant \delta$$

所以：

$$\left\| T\left(\frac{\delta(x_1 - x_0)}{||x_1 - x_0||} \right) \right\| \leqslant 1$$

作变形即有：

$$||T(x_1 - x_0)|| \leqslant \frac{1}{\delta}||x_1 - x_0||$$

因为 X 中的零元必然被线性算子 T 映射为 Y 中的零元，所以

$$||T(x_0 - x_0)|| = 0 = \frac{1}{\delta}||x_0 - x_0||$$

所以对 $\forall\, x \in E$，有：

$$||T(x - x_0)|| \leqslant \frac{1}{\delta}||x - x_0||$$

因此 T 定义在 $E - x_0$ 上的时候是有界的，而 $E - x_0$ 实际上就是 E，所以 T 是有界的。

(3) $\to$ (1)：设 $\{x_n\} \in D$，且有 $\{x_n\} \to x \in D$，因为 T 有界，所以 $\exists\, M$ 使得：

$$||Tx_n - Tx|| = ||T(x_n - x)|| \leqslant M||x_n - x||$$

显然 T 连续。 □

10.2 有界线性算子空间

10.2.1 有界线性算子空间的范数

定理 10.5. 设 X 和 Y 都是赋范线性空间，用 $\mathscr{B}(X, Y)$ 表示 X 到 Y 上的所有有界线性算子构成的空间[1]。在 $\mathscr{B}(X, Y)$ 中定义线性运算如下：

$$(T_1 + T_2)x = T_1x + T_2x$$
$$(\alpha T)x = \alpha Tx$$

其中 $T, T_1, T_2 \in \mathscr{B}(X, Y)$，$\alpha$ 是一个数。$\mathscr{B}(X, Y)$ 在该线性运算下构成一个线性空间。定义 $\mathscr{B}(X, Y)$ 中的范数如下：

$$\forall\, T \in \mathscr{B}(X, Y),\ ||T|| = \sup_{x \in D, x \neq \mathbf{0}} \frac{||Tx||}{||x||}$$

则 $\mathscr{B}(X, Y)$ 构成一个赋范线性空间。

间证明线性空

证明. (1) 非负性和 (2) 数乘是显然的。

(3) 三角不等式：

$$\begin{aligned}||T_1+T_2|| &= \sup_{x\in D, x\neq \mathbf{0}} \frac{||(T_1+T_2)x||}{||x||} \\ &\leqslant \sup_{x\in D, x\neq \mathbf{0}} \frac{||T_1x||}{||x||} + \sup_{x\in D, x\neq \mathbf{0}} \frac{||T_2x||}{||x||} \\ &= ||T_1|| + ||T_2||\end{aligned}$$

□

如上定义的范数公式有如下性质：

定理 10.6. *(1)* $\forall\, x\in X,\ ||Tx|| \leqslant ||T||\,||x||$。*(2)* $||T|| = \sup\limits_{x\in D, ||x||\leqslant 1} ||Tx|| = \sup\limits_{x\in D, ||x||=1} ||Tx||$。

证明是显然的，(1) 中只需再验证 X 中的零元，(2) 可由范数定义中的数乘与线性算子的数乘直接推出。

10.2.2 有界线性算子空间中的依算子范数收敛

定义 10.4. 设 $\{T_n\}\in\mathscr{B}$。若 $\{T_n\}$ 依 $\mathscr{B}$ 中的范数收敛于 $T\in\mathscr{B}$，即：

$$\lim_{n\to+\infty} ||T_n - T|| = 0$$

则称 $\{T_n\}$ 依算子范数收敛到 T。

依算子范数收敛与一致收敛的等价性

定理 10.7. 设 $\{T_n\}\in\mathscr{B}(X,Y)$。$\{T_n\}$ 依一致算子拓扑收敛于 $T\in\mathscr{B}$ 的充分必要条件为 $\{T_n\}$ 在 E 中的任意有界集上一致收敛于 T。

证明. (1) 必要性：任取 $A\subset X$ 为有界集。由 A 的有界性：

$$\exists\, K>0,\ \forall\, x\in A,\ ||x||\leqslant K$$

因此：

$$||T_nx - Tx|| \leqslant ||T_n - T||\,||x|| \leqslant K||T_n - T||$$

由 $\lim\limits_{n\to+\infty} ||T_n - T|| = 0$ 可得：

$$\forall\, \varepsilon>0,\ \exists\, N\in\mathbb{N}^+,\ \forall\, n>N,\ ||T_n - T|| < \frac{\varepsilon}{K}$$

于是：

$$\forall\, \varepsilon>0,\ \exists\, N\in\mathbb{N}^+,\ \forall\, n>N,\ \forall\, x\in A,\ ||T_nx - Tx|| < \varepsilon$$

[1]若不作特殊说明，有界线性算子的定义域均假定为 X。

(2) 充分性：在 X 中取单位球面 $S=\{x\in X:||x||=1\}$。显然 S 是一个有界集，由一致收敛可得：

$$\forall\,\varepsilon>0,\ \exists\,N\in\mathbb{N}^+,\ \forall\,n>N,\ \ forall\ x\in X,\ ||T_nx-Tx||<\varepsilon$$

于是：

$$\forall\,n>N,\ ||T_n-T||=\sup_{x\in D,||x||=1}||T_nx-Tx||\leqslant\varepsilon$$

即 $\{T_n\}$ 依算子范数收敛到 T。 □

由以上定理，$\{T_n\}$ 依一致算子拓扑收敛于 T 又称为 $\{T_n\}$ 依一致算子拓扑收敛于 T。

10.2.3 有界线性算子空间中的强收敛

定义 10.5. 设 $\{T_n\}\in\mathscr{B}(X,Y)$。若：

$$\forall\,x\in X,\ \lim_{n\to+\infty}||T_nx-Tx||=0$$

则称 $\{T_n\}$强收敛 *(strong convergence)*到 T 或依强算子拓扑收敛于 T。

10.2.4 有界线性算子空间的完备性

定理 10.8. 若 Y 是 *Banach* 空间，则 $\mathscr{B}(X,Y)$ 也是 *Banach* 空间。

证明. 设 $\{T_n\}$ 是 $\mathscr{B}(X,Y)$ 中的一个基本点列，那么：

$$\forall\,\varepsilon>0,\ \exists\,N\in\mathbb{N}^+,\ \forall\,n,m>N,\ m>n,\ ||T_m-T_n||<\varepsilon$$

此时有：

$$\forall\,x\in X,\ ||T_mx-T_nx||\leqslant||T_m-T_n||\,||x||<\varepsilon||x||$$

因此 $\{T_nx\}$（x 为定值）是 Y 中的基本点列。因为 Y 完备，所以 $\{T_nx\}$ 在 Y 中收敛于一个元素，记为 y，即：

$$\lim_{n\to+\infty}T_nx=y$$

定义算子 $T:Tx=y$，即：

$$Tx=\lim_{n\to+\infty}T_nx=y$$

下证明 T 是定义在 X 上而值域包含在 Y 中的有界线性算子，且是 $\{T_n\}$ 依一致算子拓扑收敛的极限。其中 T 定义域与值域是显然的。

设 $x_1,x_2\in X$，可得（第一行到第二行利用了 T_n 的可加性，第二行到第三行利用了范数极限的可加运算）：

$$\begin{aligned}T(x_1+x_2)&=\lim_{n\to+\infty}T_n(x_1+x_2)\\&=\lim_{n\to+\infty}(T_nx_1+T_nx_2)\\&=\lim_{n\to+\infty}T_nx_1+\lim_{n\to+\infty}T_nx_2\\&=Tx_1+Tx_2\end{aligned}$$

可加性得证。设 $x_3 \in X$，α 是一个数，可得（第二步到第三步利用了 T_n 的齐次性，第三步到第四步利用了范数极限的数乘运算）：

$$T(\alpha x_3) = \lim_{n\to+\infty} T_n(\alpha x_3) = \lim_{n\to+\infty} \alpha T_n x_3 = \alpha \lim_{n\to+\infty} T_n x_3 = \alpha T x_3$$

齐次性得证。综上，T 是线性算子。

注意到：

$$|\,||T_n|| - ||T_m||\,| \leqslant ||T_n - T_m|| \to 0$$

所以 $\{||T_n||\}$ 是 Cauchy 序列。因此 $\{||T_n||\}$ 有界，即：

$$\exists\, M > 0,\ \forall\, n \in \mathbb{N}^+,\ ||T_n|| \leqslant M$$

由范数的连续性：

$$||Tx|| = ||\lim_{n\to+\infty} T_n x|| \leqslant \lim_{n\to+\infty} ||T_n||\,||x|| \leqslant M||x||$$

有界性得证。

因为：

$$\forall\, \varepsilon > 0,\ \exists\, N \in \mathbb{N}^+,\ \forall\, n, m > N,\ m > n,\ \forall\, x \in X,\ ||T_m x - T_n x|| < \varepsilon ||x||$$

在上式中取 $m \to +\infty$，可得（第一步到第二步利用范数的连续性，第三步到第四步利用 $\mathscr{B}(X,Y)$ 中线性运算的定义，注意到此时已经证得 $T \in \mathscr{B}(X,Y)$）：

$$\lim_{m\to+\infty} ||T_m x - T_n x|| = ||\lim_{m\to+\infty} T_m x - T_n x|| = ||Tx - T_n x|| = ||(T - T_n)x|| \leqslant \varepsilon\, ||x||$$

此时即有：

$$\forall\, x \in X,\ \frac{||(T - T_n)x||}{||x||} \leqslant \varepsilon$$

也即 $||T - T_n|| \to 0$。依一致算子拓扑收敛得证。

综上，$\mathscr{B}(X,Y)$ 是 Banach 空间。 □

10.2.5 有界线性算子的乘法

定义 10.6. 设 X, Y, Z 都是赋范线性空间。对 $T_1 \in \mathscr{B}(X,Y)$，$T_2 \in \mathscr{B}(Y,Z)$，定义 T_1 与 T_2 的算子乘积 *(product of operators)* T_2T_1 如下：

$$\forall\, x \in X,\ (T_2T_1)x = T_2(T_1x)$$

算子乘法的性质

性质. 设 X, Y, Z, K 都是赋范线性空间。

1. 结合律：

$$(T_3T_2)T_1 = T_3(T_2T_1),\ (\alpha T_2)T_1 = \alpha T_2T_1,\ T_2(\alpha T_1) = \alpha(T_2T_1)$$

这里 $T_1 \in \mathscr{B}(X,Y)$，$T_2 \in \mathscr{B}(Y,Z)$，$T_3 \in \mathscr{B}(Z,K)$。

2. 分配律：

$$T_3(T_1+T_2)=T_3T_1+T_3T_2,\ (T_2+T_3)T_1=T_2T_1+T_3T_1$$

第一个式子中 $T_1,T_2\in\mathscr{B}(X,Y),\ T_3\in\mathscr{B}(Y,Z)$。
第二个式子中 $T_3,T_2\in\mathscr{B}(Y,Z),\ T_1\in\mathscr{B}(X,Y)$。

3. 当 $T_1\in\mathscr{B}(X,Y),\ T_2\in\mathscr{B}(Y,Z)$ 时，$T_2T_1\in\mathscr{B}(X,Z)$，且有 $||T_2T_1||\leqslant||T_2||\,||T_1||$。

证明. 只证 (3)。(1)(2) 证了没多大意思。对于 $\forall\, x\in X$，有：

$$||T_2T_1x||=||T_2(T_1)x||\leqslant||T_2||\,||T_1x||\leqslant||T_2||\,||T_1||\,||x||$$

即：

$$\frac{||T_2T_1x||}{||x||}\leqslant||T_2||\,||T_1||$$

由上确界的不等式性可得：

$$||T_2T_1||\leqslant||T_2||\,||T_1||$$

□

10.3 Banach 空间上有界线性算子的四大定理

10.3.1 开映射定理

定义 10.7. 设 X 和 Y 都是赋范线性空间。如果映射 T 把 X 中的任何开集映成 Y 中的开集，则称 T 为开映射 *(open mapping)*。

定理 10.9 (开映射定理)**.** 设 X 和 Y 都是 *Banach* 空间。如果有界线性算子 T 把 X 映成 Y 中的某个第二型集 F，则：

1. $\exists\, K\in\mathbb{R}^+,\ \forall\, y\in Y,\ \exists\, x\in X,\ Tx=y,\ ||x||\leqslant K||Tx||$。

2. T 是一个开映射。

第三部分

概率论

Chapter 11

大数定律与中心极限定理

11.1 连续性校正

11.1.1 使用原因

由中心极限定理，独立同分布的随机变量序列 $X_i,\ i=1,2\ldots,n$ 的和 $\sum\limits_{i=1}^{n} X_i$ 将在随机变量个数 $n \to +\infty$ 时服从正态分布，因此，在某些情况下，我们可以利用正态分布 CDF(Cumulative Distribution Function) 值来近似一些难以计算的离散型随机变量 (Discrete Variable) 的 CDF 值。

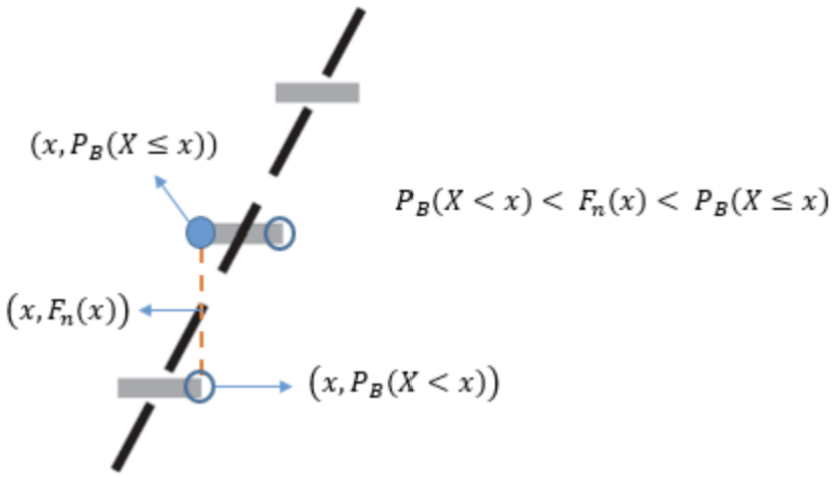

图 11.1: 连续型、离散型随机变量 CDF 图

对于离散型随机变量，常出现 $P(X < x) \neq P(X \leqslant x)$，而对于连续型随机变量 (Continuous Variable)，二者的值是相等的，因此，CDF 值的近似将出现以下问题：

1. 使用正态分布 CDF 值近似 $P(X \leqslant x)$ 时近似值偏小。
2. 使用正态分布 CDF 值近似 $P(X < x)$ 时近似值偏大。

而我们会想要得到一个一致的近似，即对于以上两个近似，结果总是一致地偏大或偏小，这样利于分析。

11.1.2 具体方法

- 根据近似的分布选择一个 $\alpha \in (-1, 1)$，一般选择 $\pm\frac{1}{2}$。
- 使用正态分布 CDF 值 $F(\frac{x+\alpha-\mu}{\sigma})$ 近似 $P(X < x)$ 与 $P(X \leqslant x)$。

第四部分

不等式

Chapter 12

不等式

这章讨论各种常见不等式。

12.1 Cauchy 不等式

12.1.1 实数域上的 Cauchy 不等式

若 $a_i, b_i \in \mathbb{R}, i = 1, 2, \ldots, n$，则有如下不等式：

$$\left(\sum_{i=1}^{n} a_i b_i\right)^2 \leqslant \sum_{i=1}^{n} a_i^2 \cdot \sum_{i=1}^{n} b_i^2$$

证明. 取 $\lambda \in \mathbb{R}$：

$$0 \leqslant \sum_{i=1}^{n} (a_i + \lambda b_i)^2 = \sum_{i=1}^{n} a_i^2 + 2\lambda \sum_{i=1}^{n} a_i b_i + \lambda^2 \sum_{i=1}^{n} b_i^2$$

将 λ 看作自变量，a_i, b_i 为常数。由判别式可得：

$$4\left(\sum_{i=1}^{n} a_i b_i\right)^2 \leqslant 4\sum_{i=1}^{n} a_i^2 \cdot \sum_{i=1}^{n} b_i^2$$ □

12.1.2 复数域上的 Cauchy 不等式

若 $a_i, b_i \in \mathbb{C}, i = 1, 2, \ldots, n$，则有如下不等式：

$$\left(\sum_{i=1}^{n} |a_i b_i|\right)^2 \leqslant \sum_{i=1}^{n} |a_i|^2 \cdot \sum_{i=1}^{n} |b_i|^2$$

证明. 由复数模的性质可得到

$$|a_i b_i| = |a_i||b_i|$$

然后使用实数域上的 Cauchy 不等式即可立即得到结果。 □

12.1.3 内积导出的 Cauchy-Schiwarz 不等式

设 X 是一个实或复内积空间，$x, y \in X$，则有如下不等式：

$$|(x,y)|^2 \leqslant (x,x)(y,y)$$

下给出复数域内的证明，实数域的证明显然类似。

证明. 设 $x, y \in X$。对 $\forall\, \lambda \in \mathbb{C}$，有：

$$(x+\lambda y, x+\lambda y) \geqslant 0$$

即：

$$(x,x) + \overline{\lambda}(x,y) + \lambda(y,x) + |\lambda|^2(y,y) \geqslant 0$$

令 $\lambda = -\frac{(x,y)}{(y,y)}$，得到：

$$(x,x) - 2\frac{|(x,y)|^2}{(y,y)} + \frac{|(x,y)|^2}{(y,y)^2}(y,y) \geqslant 0$$
$$|(x,y)|^2 \leqslant (x,x)(y,y)$$

□

12.2 Young's 不等式

12.2.1 一般形式

设 $a, b \in \mathbb{R}$ 且 $a, b > 0$，$p, q \in \mathbb{R}$ 且 $p, q > 1$，满足 $\frac{1}{p} + \frac{1}{q} = 1$，则有如下不等式：

$$ab \leqslant \frac{a^p}{p} + \frac{b^q}{q}$$

等号成立当且仅当 $a^p = b^q$。

证明. $f(x) = e^x$ 是一个凸函数，因此对 $\forall\, t \in (0,1)$：

$$e^{tx+(1-t)y} \leqslant te^x + (1-t)e^y$$

令 $\frac{1}{p} = t$，利用上式则有：

$$ab = e^{\ln(a)+\ln(b)} = e^{\frac{\ln(a^p)}{p}+\frac{\ln(b^q)}{q}} \leqslant \frac{1}{p}e^{\ln(a^p)} + \frac{1}{q}e^{\ln(b^q)} = \frac{a^p}{p} + \frac{b^q}{q}$$ □

12.3 Holder 不等式

12.3.1 离散形式的 Holder 不等式

有穷级数形式

设 $\xi_i, \eta_i, i = 1, 2, \ldots, n$ 同为实数或复数，$p, q \in \mathbb{R}$ 且 $p, q > 1$，满足 $\frac{1}{p} + \frac{1}{q} = 1$，则有如下不等式：

$$\sum_{i=1}^{n} |\xi_i \eta_i| \leqslant \left(\sum_{i=1}^{n} |\xi_i|^p\right)^{\frac{1}{p}} \cdot \left(\sum_{i=1}^{n} |\eta_i|^q\right)^{\frac{1}{q}}$$

证明. 在 Young's 不等式（即不等式 4）中取：

$$a = \frac{|\xi_i|}{\left(\sum\limits_{i=1}^{n} |\xi_i|^p\right)^{\frac{1}{p}}}, \quad b = \frac{|\eta_i|}{\left(\sum\limits_{i=1}^{n} |\eta_i|^q\right)^{\frac{1}{q}}}$$

即有：

$$\frac{|\xi_i||\eta_i|}{\left(\sum\limits_{i=1}^{n} |\xi_i|^p\right)^{\frac{1}{p}} \cdot \left(\sum\limits_{i=1}^{n} |\eta_i|^q\right)^{\frac{1}{q}}} \leqslant \frac{|\xi_i|^p}{p\left(\sum\limits_{i=1}^{n} |\xi_i|^p\right)} + \frac{|\eta_i|^q}{q\left(\sum\limits_{i=1}^{n} |\eta_i|^q\right)}$$

$$\frac{\sum\limits_{i=1}^{n} |\xi_i \eta_i|}{\left(\sum\limits_{i=1}^{n} |\xi_i|^p\right)^{\frac{1}{p}} \cdot \left(\sum\limits_{i=1}^{n} |\eta_i|^q\right)^{\frac{1}{q}}} \leqslant \frac{\sum\limits_{i=1}^{n} |\xi_i|^p}{p\left(\sum\limits_{i=1}^{n} |\xi_i|^p\right)} + \frac{\sum\limits_{i=1}^{n} |\eta_i|^q}{q\left(\sum\limits_{i=1}^{n} |\eta_i|^q\right)} \leqslant \frac{1}{p} + \frac{1}{q} = 1 \qquad \square$$

无穷级数形式

设 $\xi_i, \eta_i, i \in \mathbb{N}^+$ 同为实数或复数，$p, q \in \mathbb{R}$ 且 $p, q > 1$，满足 $\frac{1}{p} + \frac{1}{q} = 1$，则有如下不等式：

$$\sum_{i=1}^{\infty} |\xi_i \eta_i| \leqslant \left(\sum_{i=1}^{\infty} |\xi_i|^p\right)^{\frac{1}{p}} \cdot \left(\sum_{i=1}^{\infty} |\eta_i|^q\right)^{\frac{1}{q}}$$

证明. 证明过程与有穷级数几乎一样，只是把求和中的 n 改为 ∞ 的区别。 $\square$

12.4 Minkowski 不等式

12.4.1 离散形式的 Minkowski 不等式

有穷级数形式

设 $\xi_i, \eta_i, i = 1, 2, \ldots, n$ 同为实数或复数，$p \in \mathbb{R}$ 且 $p > 1$，则有如下不等式：

$$\left(\sum_{i=1}^{n} |\xi_i + \eta_i|^p\right)^{\frac{1}{p}} \leqslant \left(\sum_{i=1}^{n} |\xi_i|^p\right)^{\frac{1}{p}} + \left(\sum_{i=1}^{n} |\eta_i|^p\right)^{\frac{1}{p}}$$

证明. 取 $p,q\in\mathbb{R}$ 且 $p,q>1$，满足 $\frac{1}{p}+\frac{1}{q}=1$，由 Holder 不等式（即不等式 5）：

$$\sum_{i=1}^{n}|\xi_i||\xi_i+\eta_i|^{\frac{p}{q}}\leqslant\left(\sum_{i=1}^{n}|\xi_i|^p\right)^{\frac{1}{p}}\cdot\left(\sum_{i=1}^{n}|\xi_i+\eta_i|^p\right)^{\frac{1}{q}}$$
$$\sum_{i=1}^{n}|\eta_i||\xi_i+\eta_i|^{\frac{p}{q}}\leqslant\left(\sum_{i=1}^{n}|\eta_i|^p\right)^{\frac{1}{p}}\cdot\left(\sum_{i=1}^{n}|\xi_i+\eta_i|^p\right)^{\frac{1}{q}}$$

因此：

$$\begin{aligned}\sum_{i=1}^{n}|\xi_i+\eta_i|^p&=\sum_{i=1}^{n}\left[(|\xi_i+\eta_i|)\,|\xi_i+\eta_i|^{p-1}\right]\\&\leqslant\sum_{i=1}^{n}\left[(|\xi_i|+|\eta_i|)\,|\xi_i+\eta_i|^{\frac{p}{q}}\right]\\&=\sum_{i=1}^{n}|\xi_i||\xi_i+\eta_i|^{\frac{p}{q}}+\sum_{i=1}^{n}|\eta_i||\xi_i+\eta_i|^{\frac{p}{q}}\\&\leqslant\left[\left(\sum_{i=1}^{n}|\xi_i|^p\right)^{\frac{1}{p}}+\left(\sum_{i=1}^{n}|\eta_i|^p\right)^{\frac{1}{p}}\right]\cdot\left(\sum_{i=1}^{n}|\xi_i+\eta_i|^p\right)^{\frac{1}{q}}\end{aligned}$$

上式第一行到第二行需要注意到 $p-1=\frac{p}{q}$。两边同除 $\left(\sum\limits_{i=1}^{n}|\xi_i+\eta_i|^p\right)^{\frac{1}{q}}$ 即有：

$$\left(\sum_{i=1}^{n}|\xi_i+\eta_i|^p\right)^{\frac{1}{p}}\leqslant\left(\sum_{i=1}^{n}|\xi_i|^p\right)^{\frac{1}{p}}+\left(\sum_{i=1}^{n}|\eta_i|^p\right)^{\frac{1}{p}}$$ □

无穷级数形式

设 $\xi_i,\eta_i,i=1,2,\ldots,n$ 同为实数或复数，$p\in\mathbb{R}$ 且 $p>1$，则有如下不等式：

$$\left(\sum_{i=1}^{\infty}|\xi_i+\eta_i|^p\right)^{\frac{1}{p}}\leqslant\left(\sum_{i=1}^{\infty}|\xi_i|^p\right)^{\frac{1}{p}}+\left(\sum_{i=1}^{\infty}|\eta_i|^p\right)^{\frac{1}{p}}$$

证明. 证明过程与有穷级数几乎一样，只是把求和中的 n 改为 ∞ 的区别。 □

第五部分

统计学

Chapter 13

正态分布与三大抽样分布

13.1 多维正态分布

13.1.1 多维正态分布的定义

若一个随机向量满足以下概率密度函数：

$$f(\mathbf{X}) = \frac{1}{(2\pi)^{\frac{n}{2}}(\det\boldsymbol{\Sigma})^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{X}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{X}-\boldsymbol{\mu})}$$

则称其为一个正态随机向量，记作 $\mathbf{X} \sim N(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$。其中 $\mathbf{X} = (x_1, x_2, \ldots, x_n)' \in \mathbb{R}^n$，$\boldsymbol{\mu} = (\mu_1, \mu_2, \ldots, \mu_n)'$，$\boldsymbol{\Sigma}$ 是一个 n 维矩阵。我们仅讨论 $\boldsymbol{\Sigma}$ 是正定非退化矩阵的情况。下面我们证明概率密度函数中的两个参数 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 分别是正态随机向量的均值向量与协方差阵。

证明. 令：

$$\mathbf{Y} = \boldsymbol{\Sigma}^{-\frac{1}{2}}(\mathbf{X} - \boldsymbol{\mu})$$

则有 $\mathbf{X} = \boldsymbol{\Sigma}^{\frac{1}{2}}\mathbf{Y} + \boldsymbol{\mu}$，由求随机变量函数的分布中的变量变换法可知[1]：

$$g(\mathbf{Y}) = f(\boldsymbol{\Sigma}^{\frac{1}{2}}\mathbf{Y} + \boldsymbol{\mu})|\mathbf{J}|$$

其中 $\mathbf{J}$ 为变换的 Jacobi 行列式：

$$\mathbf{J} = \begin{vmatrix} \dfrac{\partial x_1}{\partial y_1} & \cdots & \dfrac{\partial x_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial x_n}{\partial y_1} & \cdots & \dfrac{\partial x_n}{\partial y_n} \end{vmatrix} = det(\boldsymbol{\Sigma}^{\frac{1}{2}}) = (det\boldsymbol{\Sigma})^{\frac{1}{2}}$$

[1]这是由于 $\mathbf{X}$ 到 $\mathbf{Y}$ 的变换是一个线性变换，线性变换让 $\mathbf{X}$ 关于 $\mathbf{Y}$ 有连续偏导数，同时这个线性变换可逆，满足变量变换法的两大条件。

那么 $\mathbf{Y}$ 为：

$$\begin{aligned} g(\mathbf{Y}) &= \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}\mathbf{Y}'\mathbf{Y}} \\ &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}} e^{-\frac{y_i^2}{2}} \\ &= \prod_{i=1}^{n} f(y_i) \end{aligned}$$

可见 $y_i \sim N(0,\ 1)$。同时，$\mathbf{Y}$ 的 n 个分量的联合密度等于每个分量密度函数的乘积，于是 $\mathbf{Y}$ 的各个分量相互独立，再结合 $\mathbf{Y}$ 与 $\mathbf{X}$ 的关系，有：

$$E(\mathbf{Y}) = \mathbf{0},\ Cov(\mathbf{Y}) = \mathbf{I}$$

$$E(\mathbf{X}) = \boldsymbol{\mu},\ Cov(\mathbf{X}) = \boldsymbol{\Sigma}$$

□

13.1.2 多维正态分布的性质

定理 13.1. 设 $\mathbf{X} \sim N(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$，且 $\mathbf{X}$、$\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 有如下分块形式：

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \\ \vdots \\ \mathbf{X}_a \end{pmatrix},\ \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \\ \vdots \\ \boldsymbol{\mu}_a \end{pmatrix},\ \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_1 & \mathbf{0} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_2 & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \ddots & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \boldsymbol{\Sigma}_a \end{pmatrix}$$

则有 $\mathbf{X}_i \sim N(\boldsymbol{\mu}_i,\ \boldsymbol{\Sigma}_i)$ 且相互独立。

证明. 显然此时有：

$$\det\boldsymbol{\Sigma} = \prod_{i=1}^{a} \det\boldsymbol{\Sigma}_i$$

$$(\mathbf{X}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{X}-\boldsymbol{\mu}) = \prod_{i=1}^{a} (\mathbf{X}_i-\boldsymbol{\mu}_i)'\boldsymbol{\Sigma}_i^{-1}(\mathbf{X}_i-\boldsymbol{\mu}_i)$$

□

定理 13.2. 设 $\mathbf{X} \sim N(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$，$\mathbf{A}$ 为 n 阶非随机可逆矩阵，$\mathbf{b}$ 为 n 维列向量，记 $\mathbf{Y} = \mathbf{AX}+\mathbf{b}$，则有：

$$\mathbf{Y} \sim N(\mathbf{AX}+\mathbf{b},\ \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$$

证明. 与证明 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 是多维正态随机变量 X 的均值与协方差矩阵一样，利用变量变换法求随机变量函数的分布。 □

定理 13.3. 设 $\mathbf{X} \sim N(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$，且 $\mathbf{X}$、$\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 有如下分块形式：

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \\ \vdots \\ \mathbf{X}_a \end{pmatrix},\ \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \\ \vdots \\ \boldsymbol{\mu}_a \end{pmatrix},\ \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} & \cdots & \boldsymbol{\Sigma}_{1a} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} & \cdots & \boldsymbol{\Sigma}_{2a} \\ \vdots & \vdots & \ddots & \vdots \\ \boldsymbol{\Sigma}_{a1} & \boldsymbol{\Sigma}_{a2} & \cdots & \boldsymbol{\Sigma}_{aa} \end{pmatrix}$$

则有 $\mathbf{X}_i \sim N(\boldsymbol{\mu}_i,\ \boldsymbol{\Sigma}_{ii})$。

eo 引用

证明. 存在一个线性变换让其变成Equation 13.1中的形式。取：

$$\mathbf{A} = \begin{pmatrix} \mathbf{\Sigma}_{11} & \mathbf{\Sigma}_{12} & \cdots & \mathbf{\Sigma}_{1i} & \cdots & \mathbf{\Sigma}_{1a} \\ \vdots & \vdots & & \vdots & & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{I_{ii}} & \cdots & \mathbf{0} \end{pmatrix} \tag{13.1}$$

□

Chapter 14

something

14.1 Delta method

Delta method 可以给出随机变量函数的近似方差。

定理 14.1. 设随机向量 $\mathbf{X}$ 的均值为 $E(\mathbf{X})$，方差为 $Var(\mathbf{X})$，现有另一随机变量 $g(\mathbf{X})$，则该随机变量有如下近似方差：

$$Var[g(\mathbf{X})] \approx \nabla g\left[E(\mathbf{X})\right]^{\top} Cov(\mathbf{X}) \nabla g\left[E(\mathbf{X})\right]$$

证明. 将 $g(\mathbf{X})$ 在 $g\left[E(\mathbf{X})\right]$ 处进行泰勒展开：

$$g(\mathbf{X}) \approx g\left[E(\mathbf{X})\right] + \nabla g\left[E(\mathbf{X})\right]^{\top}\left[\mathbf{X} - E(\mathbf{X})\right]$$

对此式求方差：

$$Var\left[g(\mathbf{X})\right] \approx Var\left[\nabla g\left[E(\mathbf{X})\right]^{\top} \mathbf{X}\right] = \nabla g\left[E(\mathbf{X})\right]^{\top} Cov(\mathbf{X}) \nabla g\left[E(\mathbf{X})\right] \qquad \square$$

推论 14.1. 设随机变量 X 的均值为 $E(X)$，方差为 $Var(X)$，现有另一随机变量 $g(X)$，则该随机变量有如下近似方差：

$$Var\left[g(X)\right] \approx g'\left[E(X)\right]^2 Var(X)$$

14.2 主成分分析

Chapter 15

方差分析

这章讨论方差分析问题。方差分析的目的是判断因子的水平不同是否会对试验结果造成显著差异。

按因子数对方差分析进行分类

可按试验的因子数对方差分析进行分类：

1. 单因子方差分析：讨论单个因子的水平变动对试验结果造成的影响。

2. 多因子方差分析：讨论多个因子的水平变动对试验结果的影响，也讨论多个因子水平的组合对试验结果造成的额外影响。

按因子水平的选取方式对方差分析进行分类

可按因子水平的选取方式对方差分析进行分类：

1. 固定效应模型：试验中选择的因子的水平是在试验前由试验人按主观意图指定好的，只希望得到适用于这些水平的结论。在多因子方差分析中可进一步分类：

   - 可加效应模型：仅讨论各因子对试验结果影响的大小。
   - 交互效应模型：不仅讨论各因子对试验结果影响的大小，也讨论因子的水平组合对试验结果造成的额外影响。

2. 随机效应模型：试验中选择的因子的水平是从全部可能的水平中随机选择的一个样本，希望得到适用于全部水平（无论是否参与试验）的结论。

3. 混合模型：仅存在于多因子方差分析，部分因子的水平在试验前由试验人按主观意图指定，另一部分因子的水平是随机选定的。

15.1 固定效应下的单因子方差分析

水平	观测值			
A_1	y_{11}	y_{12}	$\cdots$	y_{1n_1}
A_2	y_{21}	y_{22}	$\cdots$	y_{2n_2}
$\vdots$	$\vdots$	$\vdots$		$\vdots$
A_a	y_{a1}	y_{a2}	$\cdots$	y_{an_a}

表 15.1: 固定效应下的单因子试验数据

其中 y_{ij} 表示在第 i 个水平 A_i 下第 j 次重复试验的观察值。记 $n=\sum\limits_{i=1}^{a} n_i$。

15.1.1 统计模型

假设一个数据 y 由两部分组成：

1. 因子的影响部分 μ，随因子水平的变化而变化。
2. 试验的随机误差 ε，假设所有随机误差来自同一个正态总体 $N(0,\sigma^2)$。

则统计模型可写作：

$$\begin{cases} y_{ij}=\mu_i+\varepsilon_{ij} \\ 诸\varepsilon_{ij} \quad \text{i.i.d. } N(0,\sigma^2) \end{cases} \qquad i=1,2,\ldots,a,\ j=1,2,\ldots,n_i$$

还可将统计模型写成意义更清晰的形式，记：

$$\mu=\frac{1}{n}\sum_{i=1}^{a} n_i\mu_i, \quad \tau_i=\mu_i-\mu,\ i=1,2,\ldots,a$$

称 μ 为一般平均（这里表示因子 A 的这 a 个水平对数据的一般影响），τ_i 为因子 A 第 i 个水平 A_i 的效应。那么统计模型即可改写为：

$$\begin{cases} y_{ij}=\mu+\tau_i+\varepsilon_{ij} \\ 诸\varepsilon_{ij} \quad \text{i.i.d. } N(0,\sigma^2) \\ s.t. \quad \sum\limits_{i=1}^{a} n_i\tau_i=0 \end{cases} \qquad i=1,2,\ldots,a,\ j=1,2,\ldots,n_i$$

15.1.2 统计假设

由上述统计模型，方差分析即需要判断 $\tau_1,\tau_2,\ldots,\tau_a$ 是否相同。如果我们对这 a 个参数两两进行比较，一共需要检验 $\binom{a}{2}$ 个不同的假设。对于其中一个假设，如果控制犯第一类错误的概率是 $\alpha=0.05$ 并且这些检验是相互独立的，则错误地拒绝这 $\binom{a}{2}$ 个假设中至少

一个假设的概率为 $1-(0.95)^{\binom{a}{2}}$。当 $a=5$ 时，这个概率就已经达到了 40%。这种方式会大大提高犯第一类错误的概率。

为了控制犯第一类错误的概率，我们应该直接检验如下假设：

$$\begin{cases} H_0: \tau_1=\tau_2=\cdots=\tau_a=0, \\ H_1: \tau_i \neq 0 \quad \text{至少对一个 } i \text{ 不成立} \end{cases}$$

15.1.3 偏差平方和的分解

记：

$$y_{..}=\sum_{i=1}^{a}\sum_{j=1}^{n_i} y_{ij}, \quad \bar{y}_{..}=\frac{y_{..}}{n}, \quad y_{i.}=\sum_{j=1}^{n_i} y_{ij}, \quad \bar{y}_{i.}=\frac{y_{i.}}{n_i},\ i=1,2,\ldots,a$$

全部数据之间的差异可用下述总偏差平方和表示：

$$SST=\sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_{..})^2$$

引起数据 y_{ij} 之间差异的原因有两点：

1. 因子 A 的 a 个水平对试验结果的影响不同。
2. 试验具有误差。

为了区分并比较这两个原因对数据的影响，需要对 SST 进行分解：

$$\begin{aligned} SST &= \sum_{i=1}^{a}\sum_{j=1}^{n_i}[(y_{ij}-\bar{y}_{i.})+(\bar{y}_{i.}-\bar{y}_{..})]^2 \\ &= \sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_{i.})^2+\sum_{i=1}^{a}\sum_{j=1}^{n_i}(\bar{y}_{i.}-\bar{y}_{..})^2+\sum_{i=1}^{a}\sum_{j=1}^{n_i}2(y_{ij}-\bar{y}_{i.})(\bar{y}_{i.}-\bar{y}_{..}) \\ &= \sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_{i.})^2+\sum_{i=1}^{a}n_i(\bar{y}_{i.}-\bar{y}_{..})^2+2\sum_{i=1}^{a}(\bar{y}_{i.}-\bar{y}_{..})\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_{i.}) \\ &= \sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_{i.})^2+\sum_{i=1}^{a}n_i(\bar{y}_{i.}-\bar{y}_{..})^2 \end{aligned}$$

SSe

记：

$$\varepsilon_{..}=\sum_{i=1}^{a}\sum_{j=1}^{n_i}\varepsilon_{ij}, \quad \bar{\varepsilon}_{..}=\frac{\varepsilon_{..}}{n}, \quad \varepsilon_{i.}=\sum_{j=1}^{n_i}\varepsilon_{ij}, \quad \bar{\varepsilon}_{i.}=\frac{1}{n_i}\sum_{j=1}^{n_i}\varepsilon_{ij}$$

因此在上偏差平方和的分解中，第一项可写作：

$$\sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_{i.})^2=\sum_{i=1}^{a}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_{i.})^2$$

因为该项完全是由误差引起的，所以称之为误差平方和或组内差异，记作 SSe。

SSA

因为：

$$
\begin{aligned}
\bar{y}_{i.}-\bar{y}_{..} &= \mu+\tau_i+\bar{\varepsilon}_{i.}-\frac{1}{n}\sum_{k=1}^{a}\sum_{j=1}^{n_k}(\mu+\tau_k+\varepsilon_{kj}) \\
&= \mu+\tau_i+\bar{\varepsilon}_{i.}-\frac{1}{n}\left(n\mu+\sum_{k=1}^{a}n_k\tau_k+\varepsilon_{..}\right) \\
&= \mu+\tau_i+\bar{\varepsilon}_{i.}-\frac{1}{n}\left(n\mu+\varepsilon_{..}\right) \\
&= \tau_i+\bar{\varepsilon}_{i.}-\bar{\varepsilon}_{..}
\end{aligned}
$$

所以：

$$
\sum_{i=1}^{a}n_i(\bar{y}_{i.}-\bar{y}_{..})^2=\sum_{i=1}^{a}n_i(\tau_i+\bar{\varepsilon}_{i.}-\bar{\varepsilon}_{..})^2
$$

其中的随机误差都是平均过的，期望值不变而且方差缩小了。所以这个平方和虽然受到水平变动和随机误差两方面的影响，但是当因子 A 的不同水平对试验结果有显著差异的时候，它主要受到因子 A 水平变动的影响。所以称该平方和为因子的平方和或组间差异，记作 SSA。

总偏差平方和分解公式

综上，总偏差平方和有如下分解公式：

$$
SST=SSA+SSe
$$

15.1.4 检验统计量

关于 ε 的一些结论

下给出关于 ε 的一些结论：

$$
\bar{\varepsilon}_{i.}\sim N(0,\frac{\sigma^2}{n_i}),\quad \bar{\varepsilon}_{..}\sim N(0,\frac{\sigma^2}{n})
$$

$$
E(\varepsilon_{ij}^2)=\sigma^2,\quad E(\bar{\varepsilon}_{i.}^2)=\frac{\sigma^2}{n_i},\quad E(\bar{\varepsilon}_{..}^2)=\frac{\sigma^2}{n},\quad E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..})=\frac{\sigma^2}{n},\quad E(\varepsilon_{ij}\bar{\varepsilon}_{i.})=\frac{\sigma^2}{n_i}
$$

证明. 正态分布的两个结论可直接由独立正态随机变量的线性运算求得。

$$
\begin{aligned}
E(\bar{\varepsilon}_{ij}^2) &= Var(\bar{\varepsilon}_{ij})+[E(\bar{\varepsilon}_{ij})]^2=\sigma^2 \\
E(\bar{\varepsilon}_{i.}^2) &= Var(\bar{\varepsilon}_{i.})+[E(\bar{\varepsilon}_{i.})]^2=\frac{\sigma^2}{n_i} \\
E(\bar{\varepsilon}_{..}^2) &= Var(\bar{\varepsilon}_{..})+[E(\bar{\varepsilon}_{..})]^2=\frac{\sigma^2}{n}
\end{aligned}
$$

下求 $E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..})$：

$$
\begin{aligned}
E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..}) &= E\left[\left(\frac{1}{n_i}\sum_{j=1}^{n_i}\varepsilon_{ij}\right)\left(\frac{1}{n}\sum_{k=1}^{a}\sum_{j=1}^{n_i}\varepsilon_{kj}\right)\right] \\
&= \frac{1}{n_i n}E\left[\left(\sum_{j=1}^{n_i}\varepsilon_{ij}\right)^2 + \left(\sum_{j=1}^{n_i}\varepsilon_{ij}\right)\left(\sum_{k\neq i}\sum_{j=1}^{n_k}\varepsilon_{kj}\right)\right] \\
&= \frac{1}{n_i n}E\left[\left(\sum_{j=1}^{n_i}\varepsilon_{ij}\right)^2\right] + \frac{1}{n_i n}E\left[\left(\sum_{j=1}^{n_i}\varepsilon_{ij}\right)\left(\sum_{k\neq i}\sum_{j=1}^{n_k}\varepsilon_{kj}\right)\right]
\end{aligned}
$$

因为 ε_{ij} 彼此独立，所以上式中第二项为 0：

$$
E\left[\left(\sum_{j=1}^{n_i}\varepsilon_{ij}\right)\left(\sum_{k\neq i}\sum_{j=1}^{n_k}\varepsilon_{kj}\right)\right] = E\left(\sum_{j=1}^{n_i}\varepsilon_{ij}\right)E\left(\sum_{k\neq i}\sum_{j=1}^{n_k}\varepsilon_{kj}\right) = 0
$$

所以：

$$
\begin{aligned}
E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..}) &= \frac{1}{n_i n}E\left[\left(\sum_{j=1}^{n_i}\varepsilon_{ij}\right)^2\right] \\
&= \frac{1}{n_i n}E\left(\sum_{j=1}^{n_i}\varepsilon_{ij}^2 + \sum_{k\neq j}\varepsilon_{ij}\varepsilon_{ik}\right) \\
&= \frac{1}{n_i n}\left[\sum_{j=1}^{n_i}E(\varepsilon_{ij}^2) + \sum_{k\neq j}E(\varepsilon_{ij}\varepsilon_{ik})\right] \\
&= \frac{1}{n_i n}\left[n_i\sigma^2 + \sum_{k\neq j}E(\varepsilon_{ij})E(\varepsilon_{ik})\right] \\
&= \frac{1}{n}\sigma^2
\end{aligned}
$$

下求 $E(\varepsilon_{ij}\bar{\varepsilon}_{i.})$：

$$
\begin{aligned}
E(\varepsilon_{ij}\bar{\varepsilon}_{i.}) &= E\left(\varepsilon_{ij}\frac{1}{n_i}\sum_{k=1}^{n_i}\varepsilon_{ik}\right) \\
&= E\left(\frac{1}{n_i}\varepsilon_{ij}^2 + \frac{1}{n_i}\sum_{k\neq j}\varepsilon_{ij}\varepsilon_{ik}\right) \\
&= \frac{1}{n_i}\left[E(\varepsilon_{ij}^2) + \sum_{k\neq j}E(\varepsilon_{ij}\varepsilon_{ik})\right] \\
&= \frac{1}{n_i}\left[\sigma^2 + \sum_{k\neq j}E(\varepsilon_{ij})E(\varepsilon_{ik})\right] \\
&= \frac{\sigma^2}{n_i}
\end{aligned}
$$

□

SSA 的期望

下求 SSA 的期望：

$$
\begin{aligned}
E(SSA) &= E\left[\sum_{i=1}^{a} n_i(\tau_i + \bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..})^2\right] \\
&= E\left[\sum_{i=1}^{a} n_i(\tau_i^2 + \bar{\varepsilon}_{i.}^2 + \bar{\varepsilon}_{..}^2 + 2\tau_i\bar{\varepsilon}_{i.} - 2\tau_i\bar{\varepsilon}_{..} - 2\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..})\right] \\
&= \sum_{i=1}^{a} n_i\tau_i^2 + \sum_{i=1}^{a} n_i E(\bar{\varepsilon}_{i.}^2) + \sum_{i=1}^{a} n_i E(\bar{\varepsilon}_{..}^2) - 2\sum_{i=1}^{a} n_i E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..}) \\
&= \sum_{i=1}^{a} n_i\tau_i^2 + \sum_{i=1}^{a} n_i\frac{\sigma^2}{n_i} + \sum_{i=1}^{a} n_i\frac{\sigma^2}{n} - 2\sum_{i=1}^{a} n_i\frac{\sigma^2}{n} \\
&= \sum_{i=1}^{a} n_i\tau_i^2 + (a-1)\sigma^2
\end{aligned}
$$

SSe 的期望

下求 SSe 的期望：

$$
\begin{aligned}
E(SSe) &= E\left[\sum_{i=1}^{a}\sum_{j=1}^{n_i}(\varepsilon_{ij} - \bar{\varepsilon}_{i.})^2\right] \\
&= \sum_{i=1}^{a}\sum_{j=1}^{n_i} E[(\varepsilon_{ij} - \bar{\varepsilon}_{i.})^2] \\
&= \sum_{i=1}^{a}\sum_{j=1}^{n_i} E(\varepsilon_{ij}^2 + \bar{\varepsilon}_{i.}^2 - 2\varepsilon_{ij}\bar{\varepsilon}_{i.}) \\
&= \sum_{i=1}^{a}\sum_{j=1}^{n_i}\left(\sigma^2 + \frac{\sigma^2}{n_i} - \frac{2\sigma^2}{n_i}\right) \\
&= (n-a)\sigma^2
\end{aligned}
$$

构建统计量

称 $\frac{SSA}{a-1}$ 为因子 A 的均方和，记为 MSA；称 $\frac{SSe}{n-a}$ 为误差均方和，记为 MSe。

由前述，MSe 是 σ^2 的无偏估计，而当零假设成立时，MSA 也是 σ^2 的一个无偏估计。如果二者比值很大，即 MSA 比 MSe 大很多（$\sum\limits_{i=1}^{a}\tau_i^2$ 很大），我们就有理由怀疑零假设。由此构建统计量：

$$
F = \frac{MSA}{MSe} = \frac{\frac{SSA}{a-1}}{\frac{SSe}{n-a}}
$$

在该统计量的情况下，H_0 的拒绝域是右向单尾的。下求该统计量的分布。

15.1.5 统计量的分布

上述统计量服从如下分布：

$$F \sim F(a-1,\ n-a)$$

所以 H_0 在显著性水平为 α 时的拒绝域为：

$$F > F_{1-\alpha}(a-1,\ n-a)$$

15.1.6 方差分析表

来源	平方和	自由度	均方和	F 值
因子 A	SSA	$f_A = a-1$	$\frac{SSA}{a-1}$	$F = \frac{MSA}{MSe}$
误差	SSe	$f_e = n-a$	$\frac{SSe}{n-a}$	
总	SST	$f_T = n-1$		

表 15.2: 固定效应下单因子试验方差分析表

平方和公式可按下列公式计算：

$$\begin{cases} SST = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{n_i} y_{ij}^2 - \frac{y_{..}^2}{n} \\ SSA = \sum\limits_{i=1}^{a} \frac{y_{i.}^2}{n_i} - \frac{y_{..}^2}{n} \\ SSe = SST - SSA \end{cases}$$

15.1.7 参数估计

固定效应下的单因素方差分析有三类参数：μ，诸 τ_i 和 σ^2。下讨论这三类参数的点估计与区间估计问题。

点估计

参数的点估计如下：

$$\hat{\sigma^2} = MSe$$

$$\hat{\mu} = \bar{y}_{..}$$

$$\hat{\tau}_i = \bar{y}_{i.} - \bar{y}_{..},\ i = 1, 2, \ldots, a$$

其中 $\hat{\mu}$, $\hat{\tau}_i$ 是使用最小二乘估计得到的。

证明. 分别用 $\hat{\mu}$, $\hat{\tau}_i$ 表示 μ 与诸 τ_i 的估计，用 $\hat{y}_{ij} = \hat{\mu}+\hat{\tau}_i$ 表示 y_{ij} 的估计，$i = 1, 2, \ldots, a$, $j = 1, 2, \ldots, n_i$。损失函数为：

$$L = \sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij} - \hat{y}_{ij})^2 = \sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij} - \hat{\mu} - \hat{\tau}_i)^2$$

最小二乘解需要满足：

$$\begin{cases} \dfrac{\partial L}{\partial \hat{\mu}} = 0, \\ \dfrac{\partial L}{\partial \hat{\tau}_i} = 0, \quad i = 1, 2, \ldots, a \\ \sum\limits_{i=1}^{a} n_i\hat{\tau}_i = 0 \end{cases}$$

解得：

$$\begin{cases} \hat{\mu} = \bar{y}_{..} \\ \hat{\tau}_i = \bar{y}_{i.} - \bar{y}_{..},\ i = 1, 2, \ldots, a \end{cases}$$

□

区间估计

$\mu_i = \mu + \tau_i$:

$$\bar{y}_{i.} \pm t_{1-\alpha}(n-a)\sqrt{\frac{MSe}{n_i}}$$

τ_i:

$$\bar{y}_{i.} - \bar{y}_{..} \pm t_{1-\alpha}(n-a)\sqrt{MSe\left(\frac{1}{n_i} - \frac{1}{n}\right)}$$

$\mu_i - \mu_j = \tau_i - \tau_j$:

$$\bar{y}_{i.} - \bar{y}_{j.} \pm t_{1-\alpha}(n-a)\sqrt{MSe\left(\frac{1}{n_i} - \frac{1}{n_j}\right)}$$

15.2 多重假设检验

当方差分析拒绝零假设，认为因子的不同水平对实验结果的影响有显著差异时，随之而来的问题就是到底哪几个因子之间是有显著差异的，此时就需要进行比较。但是如果对于每一对水平都使用通常的 t 检验的话，将大大提高整个检验问题犯第一类错误的概率（见 section 15.1.2）。本节先介绍一般的对比，再介绍等重复情况下的 Duncan 多重比较法与一般情形下的 Scheffe 多重比较法。

15.2.1 对比

对比的定义

定义 15.1. 对比是指因子诸效应的一个线性组合：

$$\begin{cases} c = \sum_{i=1}^{a} c_i \tau_i, \\ s.t. \quad \sum_{i=1}^{a} c_i = 0 \end{cases}$$

因为 $\mu_i = \mu + \tau_i$，所以对比也可表示为：

$$\begin{cases} c = \sum_{i=1}^{a} c_i \mu_i, \\ s.t. \quad \sum_{i=1}^{a} c_i = 0 \end{cases}$$

全体对比构成一个 $a-1$ 维线性空间：

$$\{\mathbf{c} = (c_1, c_2, \ldots, c_a)' : \sum_{i=1}^{a} c_i = 0\}$$

目的

我们此时希望检验假设：

$$H_0 : \sum_{i=1}^{a} c_i \mu_i = 0, \quad s.t. \sum_{i=1}^{a} c_i = 0$$

假设的检验方法

由固定效应下的单因子方差分析的统计模型 section 15.1.1，可知：

$$\sum_{i=1}^{a} c_i \bar{y}_{i.} \sim N(\sum_{i=1}^{a} c_i \mu_i, \ \sum_{i=1}^{a} \frac{c_i^2 \sigma^2}{n_i})$$

定义对比的平方和为：

$$SSc = \frac{\left(\sum_{i=1}^{a} c_i \bar{y}_{i.}\right)^2}{\sum_{i=1}^{a} \frac{c_i^2}{n_i}}$$

证明独立

当 H_0 成立时，$\frac{SSc}{\sigma^2}$ 是一个标准正态变量的平方，也就是说它服从 $\chi^2(1)$。所以，当 H_0 成立的时候，统计量

$$F = \frac{SSc}{MSe} \sim \mathrm{F}(1, \ n-a)$$

MSe 是 σ^2 的无偏估计，而当 H_0 成立时，SSc 也是 σ^2 的无偏估计。如果 F 值很大，则有理由怀疑零假设（从 $\left(\sum_{i=1}^{a} c_i \bar{y}_{i.}\right)^2$ 较大这一点怀疑它的期望不为 0）。所以 H_0 的拒绝域是右向单尾的，显著性水平为 α 时的拒绝域为：

$$F = \frac{SSc}{MSe} > F_{1-\alpha}(1, \ n-a)$$

15.2.2 正交对比

仅讨论等重复情况下对比系数向量标准化（即模长为 1）的正交对比。

正交对比的定义

对比有一种特殊情况，即正交对比：

定义 15.2. $c=\sum\limits_{i=1}^{a} c_i\mu_i$ 和 $d=\sum\limits_{i=1}^{a} d_i\mu_i$ 是两个对比。若：

$$\sum_{i=1}^{a} c_i d_i = 0$$

则称这两个对比为正交对比。

目的

由对比空间的维数可知，线性无关的正交对比组最多有 $a-1$ 个对比。而正交对比即是为了检验任意 $a-1$ 个对比的值是否为 0：

$$\begin{aligned} c^1 &= \sum_{i=1}^{a} c_{1,i}\mu_i \\ c^2 &= \sum_{i=1}^{a} c_{2,i}\mu_i \\ &\cdots\cdots \\ c^{(a-1)} &= \sum_{i=1}^{a} c_{a-1,i}\mu_i \end{aligned}$$

假设的检验方法

只需注意到此时：

$$SScj = \frac{\left(\sum\limits_{i=1}^{a} c_{j,i}\bar{y}_{i.}\right)^2}{\sum\limits_{i=1}^{a} \frac{c_{j,i}^2}{m}} = m\left(\sum_{i=1}^{a} c_{j,i}\bar{y}_{i.}\right)^2$$

剩余步骤与对比一样。

正交对比与 SSA 的关系

上述对比的一个无偏估计为：

$$\hat{c}^1 = \sum_{i=1}^{a} c_{1,i}\bar{y}_{i.}$$
$$\hat{c}^2 = \sum_{i=1}^{a} c_{2,i}\bar{y}_{i.}$$
$$\cdots\cdots$$
$$\hat{c}^{(a-1)} = \sum_{i=1}^{a} c_{a-1,i}\bar{y}_{i.}$$

令：

$$\hat{c}^a = \sum_{i=1}^{a} \frac{1}{\sqrt{a}}\bar{y}_{i.}$$

需要注意这并不是一个对比。

注意到：

$$(\hat{c}^1, \hat{c}^2, \ldots, \hat{c}^a)' = A(\bar{y}_{1.}, \bar{y}_{2.}, \ldots, \bar{y}_{a.})'$$

这之中的矩阵 A 是一个正交矩阵。所以：

$$(\hat{c}^1)^2 + (\hat{c}^2)^2 + \cdots + (\hat{c}^a)^2 = \sum_{i=1}^{a} \bar{y}_{i.}^2$$

于是：

$$\begin{aligned}
(\hat{c}^1)^2 + (\hat{c}^2)^2 + \cdots + (\hat{c}^{a-1})^2 &= \sum_{i=1}^{a} \bar{y}_{i.}^2 - \frac{1}{a}\left(\sum_{i=1}^{a} \bar{y}_{i.}\right)^2 \\
&= \sum_{i=1}^{a} \left(\frac{y_{i.}}{m}\right)^2 - \frac{1}{a}\left(\frac{\sum_{i=1}^{a} m\bar{y}_{i.}}{m}\right)^2 \\
&= \sum_{i=1}^{a} \frac{y_{i.}^2}{m^2} - \frac{y_{..}^2}{am^2} \\
&= \frac{1}{m} SSA
\end{aligned}$$

再由：

$$SScj = \frac{\left(\sum\limits_{i=1}^{a} c_{j,i}\bar{y}_{i.}\right)^2}{\sum\limits_{i=1}^{a} \frac{c_{j,i}^2}{m}} = \frac{(\hat{c}^j)^2}{\frac{1}{m}} = m(\hat{c}^j)^2$$

所以：

$$SSc1 + SSc2 + \cdots + SSc(a-1) = SSA$$

15.2.3 Duncan 多重比较法

在很多问题中，我们往往不知道要如何构造适当的对比，也有可能检验 $a-1$ 个以上的比较，此时对比的相关方法就无法使用了。接下来介绍这种情况下的一种解决方案，即 Duncan 多重比较法，它只适用于等重复情况。

目的

检验 $H_0: \mu_i = \mu_j,\ \forall\, i \neq j$。

p 级极差的定义

定义 15.3. 将 a 个水平下观察值的平均值 $\bar{y}_{1.}, \bar{y}_{2.}, \ldots, \bar{y}_{a.}$ 从小到大排序。如果其中任意两个数在排序后中间还有 $p-2$, $p \geqslant 2$ 个数，那么这两个数的差称为 p 级极差，记为 R_p。

统计量及其分布

设 f 为 SSe 的自由度，m 为重复次数，则 Duncan 多重比较法的统计量为：

$$r(p,f) = \frac{R_p}{\sqrt{\dfrac{MSe}{m}}}$$

在 $\mu_1 = \mu_2 = \cdots = \mu_a$ 即 $\tau_1 = \tau_2 = \cdots = \tau_a$ 的情况下，$r(p,f)$ 与 μ, σ^2 无关。

证明. 将 $r(p,f)$ 分子分母同除 σ 可得：

$$r(p.f) = \frac{\dfrac{R_p}{\sigma/\sqrt{m}}}{\sqrt{\dfrac{MSe}{\sigma^2}}}$$

注意到分母：

$$\frac{MSe}{\sigma^2} = \frac{1}{f}\frac{SSe}{\sigma^2}$$

是一个服从 $\chi^2(f)$ 分布变量的 $\dfrac{1}{f}$ 倍，其分布与 μ, σ^2 无关。

在零假设成立的情况下：

$$\frac{\bar{y}_{i.} - \mu}{\sigma/\sqrt{m}} \sim N(0,\ 1)$$

这个分布与 μ, σ^2 无关，所以分子：

$$\frac{R_p}{\sigma/\sqrt{m}} = \max\left(\frac{\bar{y}_{1.} - \mu}{\sigma/\sqrt{m}}, \ldots, \frac{\bar{y}_{a.} - \mu}{\sigma/\sqrt{m}}\right) - \min\left(\frac{\bar{y}_{1.} - \mu}{\sigma/\sqrt{m}}, \ldots, \frac{\bar{y}_{a.} - \mu}{\sigma/\sqrt{m}}\right)$$

也与 μ, σ^2 无关。

综上，此时 $r(p,f)$ 与 μ, σ^2 无关。 □

检验原理

当 $\mu_i = \mu_j$ 不成立时，对应的 R_p 会较大。因此当 $r(p,f)$ 较大时，有理由怀疑零假设。所以 H_0 的拒绝域是右向单尾的，显著性水平为 α 时的拒绝域为：

$$r(p,f) > r_{1-\alpha}(p,f)$$

即：

$$R_p > r_{1-\alpha}(p,f)\sqrt{\frac{MSe}{m}}$$

$r(p,f)$ 分布的 Monte Carlo 模拟

Algorithm 1 Duncan 多重比较法统计量分布的蒙特卡洛模拟

Input: m, a, p, f, N ▷ 组内重复次数、组数、极差的级数、SSe 的自由度、模拟次数

Output: $r(p,f)$ 的模拟分布

初始化模拟值存储向量：$List \leftarrow \emptyset$

for $i \leftarrow 1$ to N **do**

  生成 a 个随机数 $x_i \sim N(0,1),\ i = 1,2,\ldots,a$

  计算 $\frac{R_p}{\sigma/\sqrt{m}}$：

$$\frac{R_p}{\sigma/\sqrt{m}} = \max_{i=1,2,\ldots,a}\{x_i\} - \min_{i=1,2,\ldots,a}\{x_i\}$$

  从 $\chi^2(f)$ 中产生一个样本记为 χ^2

  计算 $r(p,f)$：

$$r(p,f) = \frac{\frac{R_p}{\sigma/\sqrt{m}}}{\sqrt{\chi^2/f}}$$

  将 $r(p,f)$ 加入 $List$

end for

返回 $List$

检验步骤

将 $\bar{y}_{1.}, \bar{y}_{2.}, \ldots, \bar{y}_{a.}$ 从小到大排序为 $\bar{y}^1, \bar{y}^2, \ldots, \bar{y}^a$。令：

$$r_{1-\alpha}(p,f)\sqrt{\frac{MSe}{m}} = R_p^*$$

按以下顺序进行比较：

$$\bar{y}^a - \bar{y}^1 \text{与 } R_a^* \text{ 进行比较}$$
$$\bar{y}^a - \bar{y}^2 \text{与 } R_{a-1}^* \text{ 进行比较}$$
$$\cdots\cdots$$
$$\bar{y}^a - \bar{y}^{a-1} \text{与 } R_2^* \text{ 进行比较}$$
$$\bar{y}^{a-1} - \bar{y}^1 \text{与 } R_{a-1}^* \text{ 进行比较}$$
$$\bar{y}^{a-1} - \bar{y}^2 \text{与 } R_{a-2}^* \text{ 进行比较}$$
$$\cdots\cdots$$

直到全部 $\binom{a}{2}$ 对水平均值比较完为止。

15.2.4 Scheffe 多重比较法

Scheffe 证明了，在固定效应下的单因子方差分析统计模型下（即 section 15.1.1），对显著性水平 α，一切对比 c 的值同时满足不等式：

$$|\hat{c} - c| = \left|\sum_{i=1}^{a} c_i \bar{y}_{i.} - c\right| \leqslant \sqrt{(a-1)F_{1-\alpha}(a-1,\ n-a)MSe\sum_{i=1}^{a}\frac{c_i^2}{n_i}}$$

的概率等于 $1-\alpha$。也就是说，$H_0 : \sum\limits_{i=1}^{a} c_i\mu_i = 0$ 的拒绝域都是：

$$|\hat{c}| > \sqrt{(a-1)F_{1-\alpha}(a-1,\ n-a)MSe\sum_{i=1}^{a}\frac{c_i^2}{n_i}}$$

15.3 随机效应下的单因子方差分析

水平	观测值			
A_1	y_{11}	y_{12}	$\cdots$	y_{1n_1}
A_2	y_{21}	y_{22}	$\cdots$	y_{2n_2}
$\vdots$	$\vdots$	$\vdots$		$\vdots$
A_a	y_{a1}	y_{a2}	$\cdots$	y_{an_a}

表 15.3: 随机效应下的单因子试验数据

其中 y_{ij} 表示在第 i 个水平 A_i 下第 j 次重复试验的观察值。记 $n = \sum\limits_{i=1}^{a} n_i$。

15.3.1 统计模型

随机效应下的单因子方差分析统计模型为：

$$\begin{cases} y_{ij} = \mu + \tau_i + \varepsilon_{ij} \\ \text{诸}\tau_i \quad \text{i.i.d. } N(0, \sigma_\tau^2) \\ \text{诸}\varepsilon_{ij} \quad \text{i.i.d. } N(0, \sigma^2) \\ \text{诸}\varepsilon_{ij}\text{、诸}\tau_i\text{相互独立} \end{cases} \qquad i = 1, 2, \cdots, a,\ j = 1, 2, \cdots, n_i$$

称 μ 为一般平均（这里表示因子对数据的一般影响），τ_i 为因子 A 的第 i 个水品的随机效应。

15.3.2 统计假设

随机效应下单因素方差分析检验的统计假设为：

$$\begin{cases} H_0 : \sigma_\tau^2 = 0 \\ H_1 : \sigma_\tau^2 > 0 \end{cases}$$

需要注意的是，此时拒绝零假设意味着因子的全部水平（不论是否参与过试验）之间有显著差异。

15.3.3 方差分析

偏差平方和的分解

由于与固定效应情况下三个平方和的定义完全相同，所以随机效应下偏差平方和分解公式与之前一模一样。

$$SST = SSA + SSe$$

$$SSA = \sum_{i=1}^{a} n_i (\bar{y}_{i.} - \bar{y}_{..})^2$$

$$SSe = \sum_{i=1}^{a} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 = \sum_{i=1}^{a} \sum_{j=1}^{n_i} (\varepsilon_{ij} - \bar{\varepsilon}_{i.})^2$$

各平方和的期望

先计算 SSA 与 SSe 的期望。

$$E(SSe) = (n-a)\sigma^2,\ E(SSA) = \left(n - \frac{\sum_{i=1}^{a} n_i^2}{n} \right) \sigma_\tau^2 + (a-1)\sigma^2$$

证明. (1) 因为数据结构的形式完全一样，所以 SSe 的期望与固定效应情形下的一模一样。

(2) 注意到 τ_i 的形式发生变化，$E(SSA)$ 需要重新求解。

$$\begin{aligned}\bar{y}_{i.}-\bar{y}_{..}&=\mu+\tau_i+\bar{\varepsilon}_{i.}-\frac{1}{n}\sum_{k=1}^{a}\sum_{j=1}^{n_k}(\mu+\tau_k+\varepsilon_{kj})\\&=\mu+\tau_i+\bar{\varepsilon}_{i.}-\frac{1}{n}\left(n\mu+\sum_{k=1}^{a}n_k\tau_k+\varepsilon_{..}\right)\\&=\tau_i-\frac{\sum\limits_{k=1}^{a}n_k\tau_k}{n}+\bar{\varepsilon}_{i.}-\bar{\varepsilon}_{..}\end{aligned}$$

$$\begin{aligned}E(SSA)&=E\left[\sum_{i=1}^{a}n_i\left(\tau_i-\frac{\sum\limits_{k=1}^{a}n_k\tau_k}{n}+\bar{\varepsilon}_{i.}-\bar{\varepsilon}_{..}\right)^2\right]\\&=E\left\{\sum_{i=1}^{a}n_i\left[\tau_i^2+\left(\frac{\sum\limits_{k=1}^{a}n_k\tau_k}{n}\right)^2+\bar{\varepsilon}_{i.}^2+\bar{\varepsilon}_{..}^2-2\tau_i\frac{\sum\limits_{k=1}^{a}n_k\tau_k}{n}+2\tau_i\bar{\varepsilon}_{i.}-2\tau_i\bar{\varepsilon}_{..}-2\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..}\right]\right\}\\&=\sum_{i=1}^{a}n_iE(\tau_i^2)+\sum_{i=1}^{a}n_iE(\bar{\varepsilon}_{i.}^2)+\sum_{i=1}^{a}n_iE(\bar{\varepsilon}_{..}^2)-2\sum_{i=1}^{a}n_iE(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..})-\frac{\sum\limits_{i=1}^{a}n_i^2E(\tau_i^2)}{n}\\&=\sum_{i=1}^{a}n_i\sigma_\tau^2+\sum_{i=1}^{a}n_i\frac{\sigma^2}{n_i}+\sum_{i=1}^{a}n_i\frac{\sigma^2}{n}-2\sum_{i=1}^{a}n_i\frac{\sigma^2}{n}-\frac{\sum\limits_{i=1}^{a}n_i^2\sigma_\tau^2}{n}\\&=\left(n-\frac{\sum_{i=1}^{a}n_i^2}{n}\right)\sigma_\tau^2+(a-1)\sigma^2\end{aligned}$$

□

统计量及其分布

称 $\frac{SSA}{a-1}$ 为因子 A 的均方和，记为 MSA；称 $\frac{SSe}{n-a}$ 为误差均方和，记为 MSe。

由前述，MSe 是 σ^2 的无偏估计，而当零假设成立时，MSA 也是 σ^2 的一个无偏估计。如果二者比值很大，即 MSA 比 MSe 大很多（$\left(\frac{n^2-\sum_{i=1}^{a}n_i^2}{n(a-1)}\right)\sigma_\tau^2$ 很大），我们就有理由怀疑零假设。由此构建统计量：

$$F=\frac{MSA}{MSe}=\frac{\frac{SSA}{a-1}}{\frac{SSe}{n-a}}$$

在该统计量的情况下，H_0 的拒绝域是右向单尾的。

由于在假设 H_0 成立时，随机效应模型与固定效应模型的观察值 y_{ij} 的数据结构的形式完全一样，所以在随机效应模型中仍然有：

$$F\sim F(a-1,\ n-a)$$

拒绝域

综上所述，显著性水平为 α 时的拒绝域为：

$$F > F_{1-\alpha}(a-1,\ n-a)$$

15.3.4 方差分析表

来源	平方和	自由度	均方和	F 值
因子 A	SSA	$f_A = a-1$	$\frac{SSA}{a-1}$	$F = \frac{MSA}{MSe}$
误差	SSe	$f_e = n-a$	$\frac{SSe}{n-a}$	
总	SST	$f_T = n-1$		

表 15.4: 随机效应下单因子试验方差分析表

平方和公式可按下列公式计算：

$$\begin{cases} SST = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{n_i} y_{ij}^2 - \frac{y_{..}^2}{n} \\ SSA = \sum\limits_{i=1}^{a} \frac{y_{i.}^2}{n_i} - \frac{y_{..}^2}{n} \\ SSe = SST - SSA \end{cases}$$

15.3.5 参数估计

我们此时关心方差分量的估计。

点估计

由 SSA、SSe 期望的计算，可给出各方差分量的无偏点估计如下：

$$\hat{\sigma^2} = MSe$$

$$\hat{\sigma^2}_\tau = \frac{n(a-1)(MSA - MSe)}{n^2 - \sum\limits_{i=1}^{a} n_i^2}$$

这里需要注意的是，$\hat{\sigma^2}_\tau$ 有可能小于 0，这是由估计方法决定的。

区间估计

考虑 σ^2 的区间估计。因为：

$$\frac{SSe}{\sigma^2} \sim \chi^2(n-a)$$

所以显著性水平为 α 时，σ^2 的置信区间为：

$$\left(\frac{SSe}{\chi^2_{\alpha/2}(n-a)}, \frac{SSe}{\chi^2_{1-\alpha/2}(n-a)}\right)$$

15.4 可加效应下的两因子方差分析

可加效应模型一般不必进行重复实验，每个水平组合下只做一次实验就够了。

因子 A \ 因子 B	B_1	B_2	$\cdots$	B_b
A_1	y_{11}	y_{12}	$\cdots$	y_{1b}
A_2	y_{21}	y_{22}	$\cdots$	y_{2b}
$\vdots$	$\vdots$	$\vdots$		$\vdots$
A_a	y_{a1}	y_{a2}	$\cdots$	y_{ab}

表 15.5: 无重复两因子试验数据表

其中 y_{ij} 表示在因子 A 的第 i 个水平 A_i 和因子 B 的第 j 个水平 B_j 下试验的观察值。记 $n = ab$。

15.4.1 统计模型

假设一个数据 y 由两部分组成：

1. 因子组合 (A_i, B_j) 的影响部分 μ_{ij}，随因子水平组合的变化而变化。

2. 试验的随机误差 ε，假设所有随机误差来自同一个正态总体 $N(0, \sigma^2)$。

则统计模型可写作：

$$\begin{cases} y_{ij} = \mu_{ij} + \varepsilon_{ij} \\ \text{诸}\varepsilon_{ij} \quad \text{i.i.d. } N(0, \sigma^2) \\ i = 1, 2, \ldots, a,\ j = 1, 2, \ldots, b \end{cases}$$

还可将统计模型写成意义更清晰的形式，记：

$$\mu = \frac{1}{ab} \sum_{i=1}^{a} \sum_{j=1}^{b} \mu_{ij}$$

$$\bar{\mu}_{i.} = \sum_{j=1}^{b} \mu_{ij}, \quad \tau_i = \bar{\mu}_{i.} - \mu, \quad i = 1, 2, \ldots, a$$

$$\bar{\mu}_{.j} = \sum_{i=1}^{a} \mu_{ij}, \quad \beta_j = \bar{\mu}_{.j} - \mu, \quad j = 1, 2, \ldots, b$$

称 μ 为一般平均，表示 ab 个总体的均值的平均值。称 τ_i 为因子 A 第 i 个水平 A_i 的主效应。称 β_j 为因子 B 第 j 个水平 B_j 的主效应。那么统计模型即可改写为：

$$\begin{cases} y_{ij} = \mu + \tau_i + \beta_j + \varepsilon_{ij} \\ \text{诸}\varepsilon_{ij} \quad \text{i.i.d. } N(0, \sigma^2) \\ s.t. \quad \sum\limits_{i=1}^{a} \tau_i = 0, \quad \sum\limits_{j=1}^{b} \beta_j = 0 \\ i = 1, 2, \ldots, a, \ j = 1, 2, \ldots, b \end{cases}$$

15.4.2 统计假设

可加效应下的两因子方差分析需要检验如下两个零假设：

$$\begin{cases} H_{01} : \tau_1 = \tau_2 = \cdots = \tau_a = 0, \\ H_{02} : \beta_1 = \beta_2 = \cdots = \beta_b = 0 \end{cases}$$

15.4.3 偏差平方和的分解

记：

$$y_{..} = \sum_{i=1}^{a} \sum_{j=1}^{b} y_{ij}, \quad \bar{y}_{..} = \frac{y_{..}}{ab}$$

$$y_{i.} = \sum_{j=1}^{b} y_{ij}, \quad \bar{y}_{i.} = \frac{y_{i.}}{b}, \quad i = 1, 2, \ldots, a$$

$$y_{.j} = \sum_{i=1}^{a} y_{ij}, \quad \bar{y}_{.j} = \frac{y_{.j}}{a}, \quad j = 1, 2, \ldots, b$$

全部数据之间的差异可用下述总偏差平方和表示：

$$SST = \sum_{i=1}^{a} \sum_{j=1}^{b} (y_{ij} - \bar{y}_{..})^2$$

引起数据 y_{ij} 之间差异的原因有三点：

1. 因子 A 的 a 个水平对试验结果的影响不同。

2. 因子 B 的 b 个水平对试验结果的影响不同。

3. 试验具有误差。

为了区分并比较这三个原因对数据的影响，需要对 SST 进行分解：

$$
\begin{aligned}
SST &= \sum_{i=1}^{a}\sum_{j=1}^{b}(y_{ij}-\bar{y}_{..})^2 \\
&= \sum_{i=1}^{a}\sum_{j=1}^{b}[(\bar{y}_{i.}-\bar{y}_{..})+(\bar{y}_{.j}-\bar{y}_{..})+(y_{ij}-\bar{y}_{i.}-\bar{y}_{.j}+\bar{y}_{..})]^2 \\
&= \sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{i.}-\bar{y}_{..})^2+\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{.j}-\bar{y}_{..})^2+\sum_{i=1}^{a}\sum_{j=1}^{b}(y_{ij}-\bar{y}_{i.}-\bar{y}_{.j}+\bar{y}_{..})^2 \\
&\quad +2\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{i.}-\bar{y}_{..})(\bar{y}_{.j}-\bar{y}_{..}) \\
&\quad +2\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{i.}-\bar{y}_{..})(y_{ij}-\bar{y}_{i.}-\bar{y}_{.j}+\bar{y}_{..}) \\
&\quad +2\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{.j}-\bar{y}_{..})(y_{ij}-\bar{y}_{i.}-\bar{y}_{.j}+\bar{y}_{..})
\end{aligned}
$$

由定义可发现上式后三项为 0（第三项需要注意交换求和顺序）。

SSe

记：

$$
SSe=\sum_{i=1}^{a}\sum_{j=1}^{b}(y_{ij}-\bar{y}_{i.}-\bar{y}_{.j}+\bar{y}_{..})^2
$$

$$
\varepsilon_{..}=\sum_{i=1}^{a}\sum_{j=1}^{b}\varepsilon_{ij},\quad \bar{\varepsilon}_{..}=\frac{\varepsilon_{..}}{ab}
$$

$$
\varepsilon_{i.}=\sum_{j=1}^{b}\varepsilon_{ij},\quad \bar{\varepsilon}_{i.}=\frac{1}{b}\sum_{j=1}^{b}\varepsilon_{ij},\quad i=1,2,\ldots,a
$$

$$
\varepsilon_{.j}=\sum_{i=1}^{a}\varepsilon_{ij},\quad \bar{\varepsilon}_{.j}=\frac{1}{a}\sum_{i=1}^{a}\varepsilon_{ij},\quad j=1,2,\ldots,b
$$

$$
\bar{\tau}=\frac{1}{a}\sum_{i=1}^{a}\tau_i=0,\quad \bar{\beta}=\frac{1}{b}\sum_{j=1}^{b}\beta_j=0
$$

则有：

$$
\begin{aligned}
SSe &= \sum_{i=1}^{a}\sum_{j=1}^{b}(y_{ij}-\bar{y}_{i.}-\bar{y}_{.j}+\bar{y}_{..})^2 \\
&= \sum_{i=1}^{a}\sum_{j=1}^{b}(\mu+\tau_i+\beta_j+\varepsilon_{ij}-\mu-\tau_i-\bar{\beta}-\bar{\varepsilon}_{i.}-\mu-\bar{\tau}-\beta_j-\bar{\varepsilon}_{.j}+\mu+\bar{\tau}+\bar{\beta}+\bar{\varepsilon}_{..})^2 \\
&= \sum_{i=1}^{a}\sum_{j=1}^{b}(\varepsilon_{ij}-\bar{\varepsilon}_{i.}-\bar{\varepsilon}_{.j}+\bar{\varepsilon}_{..})^2
\end{aligned}
$$

因为该项完全是由误差引起的，所以称之为误差平方和。

SSA

记：

$$SSA = \sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{i.} - \bar{y}_{..})^2 = b\sum_{i=1}^{a}(\bar{y}_{i.} - \bar{y}_{..})^2$$

可以发现：

$$\begin{aligned} SSA &= b\sum_{i=1}^{a}(\bar{y}_{i.} - \bar{y}_{..})^2 \\ &= b\sum_{i=1}^{a}(\mu + \tau_i + \bar{\beta} + \bar{\varepsilon}_{i.} - \mu - \bar{\tau} - \bar{\beta} - \bar{\varepsilon}_{..})^2 \\ &= b\sum_{i=1}^{a}(\tau_i + \bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..})^2 \end{aligned}$$

其中的随机误差都是平均过的，期望值不变而且方差缩小了。所以这个平方和虽然受到水平变动和随机误差两方面的影响，但是当因子 A 的不同水平对试验结果有显著差异的时候，它主要受到因子 A 水平变动的影响。所以称该平方和为因子 A 的平方和。

SSB

记：

$$SSB = \sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{.j} - \bar{y}_{..})^2 = a\sum_{j=1}^{b}(\bar{y}_{.j} - \bar{y}_{..})^2$$

可以发现：

$$\begin{aligned} SSB &= a\sum_{j=1}^{b}(\bar{y}_{.j} - \bar{y}_{..})^2 \\ &= a\sum_{j=1}^{b}(\mu + \bar{\tau} + \beta_j + \bar{\varepsilon}_{.j} - \mu - \bar{\tau} - \bar{\beta} - \bar{\varepsilon}_{..})^2 \\ &= a\sum_{j=1}^{b}(\beta_j + \bar{\varepsilon}_{.j} - \bar{\varepsilon}_{..})^2 \end{aligned}$$

其中的随机误差都是平均过的，期望值不变而且方差缩小了。所以这个平方和虽然受到水平变动和随机误差两方面的影响，但是当因子 B 的不同水平对试验结果有显著差异的时候，它主要受到因子 B 水平变动的影响。所以称该平方和为因子 B 的平方和。

总偏差平方和分解公式

综上，总偏差平方和有如下分解公式：

$$SST = SSA + SSB + SSe$$

15.4.4 检验统计量

关于 ε 的一些结论

下给出关于 ε 的一些结论：

$$\bar{\varepsilon}_{i.} \sim N(0, \frac{\sigma^2}{b}), \quad \bar{\varepsilon}_{.j} \sim N(0, \frac{\sigma^2}{a}), \quad \bar{\varepsilon}_{..} \sim N(0, \frac{\sigma^2}{ab})$$
$$E(\varepsilon_{ij}^2) = \sigma^2, \quad E(\bar{\varepsilon}_{i.}^2) = \frac{\sigma^2}{b}, \quad E(\bar{\varepsilon}_{.j}^2) = \frac{\sigma^2}{a}, \quad E(\bar{\varepsilon}_{..}^2) = \frac{\sigma^2}{ab}$$
$$E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..}) = \frac{\sigma^2}{ab}, \quad E(\varepsilon_{.j}\bar{\varepsilon}_{..}) = \frac{\sigma^2}{ab}$$

证明. 正态分布的三个结论可直接由独立正态随机变量的线性运算求得。

$$E(\bar{\varepsilon}_{ij}^2) = Var(\bar{\varepsilon}_{ij}) + [E(\bar{\varepsilon}_{ij})]^2 = \sigma^2$$
$$E(\bar{\varepsilon}_{i.}^2) = Var(\bar{\varepsilon}_{i.}) + [E(\bar{\varepsilon}_{i.})]^2 = \frac{\sigma^2}{b}$$
$$E(\bar{\varepsilon}_{.j}^2) = Var(\bar{\varepsilon}_{.j}) + [E(\bar{\varepsilon}_{.j})]^2 = \frac{\sigma^2}{a}$$
$$E(\bar{\varepsilon}_{..}^2) = Var(\bar{\varepsilon}_{..}) + [E(\bar{\varepsilon}_{..})]^2 = \frac{\sigma^2}{ab}$$

下求 $E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..})$：

$$\begin{aligned}
E(\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..}) &= E\left[\left(\frac{1}{b}\sum_{j=1}^{b}\varepsilon_{ij}\right)\left(\frac{1}{ab}\sum_{i=1}^{a}\sum_{j=1}^{b}\varepsilon_{ij}\right)\right] \\
&= \frac{1}{ab^2}E\left(\sum_{j=1}^{b}\varepsilon_{ij}^2\right) \\
&= \frac{1}{ab^2}\sum_{j=1}^{b}E(\varepsilon_{ij}^2) \\
&= \frac{\sigma^2}{ab}
\end{aligned}$$

下求 $E(\varepsilon_{.j}\bar{\varepsilon}_{..})$：

$$\begin{aligned}
E(\varepsilon_{.j}\bar{\varepsilon}_{..}) &= E\left[\left(\frac{1}{a}\sum_{i=1}^{a}\varepsilon_{ij}\right)\left(\frac{1}{ab}\sum_{i=1}^{a}\sum_{j=1}^{b}\varepsilon_{ij}\right)\right] \\
&= \frac{1}{a^2b}E\left(\sum_{i=1}^{a}\varepsilon_{ij}^2\right) \\
&= \frac{1}{ab^2}\sum_{i=1}^{a}E(\varepsilon_{ij}^2) \\
&= \frac{\sigma^2}{ab}
\end{aligned}$$

□

SSA 的期望

下求 SSA 的期望：

$$
\begin{aligned}
E(SSA) &= E\left[b\sum_{i=1}^{a}(\tau_i+\bar{\varepsilon}_{i.}-\bar{\varepsilon}_{..})^2\right] \\
&= E\left[b\sum_{i=1}^{a}(\tau_i^2+\bar{\varepsilon}_{i.}^2+\bar{\varepsilon}_{..}^2+2\tau_i\bar{\varepsilon}_{i.}-2\tau_i\bar{\varepsilon}_{..}-2\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..})\right] \\
&= b\sum_{i=1}^{a}\tau_i^2+b\sum_{i=1}^{a}E(\bar{\varepsilon}_{i.}^2)+b\sum_{i=1}^{a}E(\bar{\varepsilon}_{..}^2)-\frac{2b}{ab^2}\sum_{i=1}^{a}\sum_{j=1}^{b}E(\varepsilon_{ij}^2) \\
&= b\sum_{i=1}^{a}\tau_i^2+ba\frac{\sigma^2}{b}+ab\frac{\sigma^2}{ab}-\frac{2b}{ab^2}ab\sigma^2 \\
&= b\sum_{i=1}^{a}\tau_i^2+(a-1)\sigma^2
\end{aligned}
$$

SSB 的期望

下求 SSB 的期望：

$$
\begin{aligned}
E(SSB) &= E\left[a\sum_{j=1}^{b}(\beta_j+\bar{\varepsilon}_{.j}-\bar{\varepsilon}_{..})^2\right] \\
&= E\left[a\sum_{j=1}^{b}(\beta_j^2+\bar{\varepsilon}_{.j}^2+\bar{\varepsilon}_{..}^2+2\beta_j\bar{\varepsilon}_{.j}-2\beta_j\bar{\varepsilon}_{..}-2\bar{\varepsilon}_{.j}\bar{\varepsilon}_{..})\right] \\
&= a\sum_{j=1}^{b}\beta_j^2+a\sum_{j=1}^{b}E(\bar{\varepsilon}_{.j}^2)+a\sum_{j=1}^{b}E(\bar{\varepsilon}_{..}^2)-\frac{2a}{a^2b}\sum_{i=1}^{a}\sum_{j=1}^{b}E(\varepsilon_{ij}^2) \\
&= a\sum_{j=1}^{b}\beta_j^2+ab\frac{\sigma^2}{a}+ab\frac{\sigma^2}{ab}-\frac{2a}{a^2b}ab\sigma^2 \\
&= a\sum_{j=1}^{b}\beta_j^2+(b-1)\sigma^2
\end{aligned}
$$

SSe 的期望

下求 SSe 的期望（把均值展开，利用独立性就可以得到结果）：

$$
\begin{aligned}
E(SSe) &= E\left[\sum_{i=1}^{a}\sum_{j=1}^{b}(\varepsilon_{ij}-\bar{\varepsilon}_{i.}-\bar{\varepsilon}_{.j}+\bar{\varepsilon}_{..})^2\right] \\
&= E\left[\sum_{i=1}^{a}\sum_{j=1}^{b}(\varepsilon_{ij}^2+\bar{\varepsilon}_{i.}^2+\bar{\varepsilon}_{.j}^2+\bar{\varepsilon}_{..}^2-2\varepsilon_{ij}\bar{\varepsilon}_{i.}-2\varepsilon_{ij}\bar{\varepsilon}_{.j}+2\varepsilon_{ij}\bar{\varepsilon}_{..}+2\bar{\varepsilon}_{i.}\bar{\varepsilon}_{.j}-2\bar{\varepsilon}_{i.}\bar{\varepsilon}_{..}-2\bar{\varepsilon}_{.j}\bar{\varepsilon}_{..})\right] \\
&= (a-1)(b-1)\sigma^2
\end{aligned}
$$

构建统计量

称 $\frac{SSA}{a-1}$ 为因子 A 的均方和，记为 MSA；称 $\frac{SSB}{b-1}$ 为因子 B 的均方和，记为 MSB；称 $\frac{SSe}{(a-1)(b-1)}$ 为误差均方和，记为 MSe。

由前述，MSe 是 σ^2 的无偏估计，而当零假设成立时，MSA 和 MSB 也是 σ^2 的一个无偏估计。如果 MSA、MSB 与 MSe 比值很大，即 MSA、MSB 比 MSe 大很多（$b\sum\limits_{i=1}^{a}\tau_i^2$，$a\sum\limits_{j=1}^{b}\beta_j^2$ 很大），我们就有理由怀疑零假设。。由此构建统计量：

$$F_A = \frac{MSA}{MSe} = \frac{\frac{SSA}{a-1}}{\frac{SSe}{(a-1)(b-1)}}$$
$$F_B = \frac{MSB}{MSe} = \frac{\frac{SSB}{b-1}}{\frac{SSe}{(a-1)(b-1)}}$$

在这些统计量的情况下，H_{01}，H_{02} 的拒绝域是右向单尾的。下求统计量的分布。

15.4.5 统计量的分布

上述统计量服从如下分布：

$$F_A \sim F(a-1,\ (a-1)(b-1))$$
$$F_B \sim F(b-1,\ (a-1)(b-1))$$

所以 H_{01}，H_{02} 在显著性水平为 α 时的拒绝域为：

$$F_A > F_{1-\alpha}(a-1,\ (a-1)(b-1))$$
$$F_B > F_{1-\alpha}(b-1,\ (a-1)(b-1))$$

15.4.6 方差分析表

来源	平方和	自由度	均方和	F 值
因子 A	SSA	$f_A = a-1$	$\frac{SSA}{a-1}$	$F = \frac{MSA}{MSe}$
因子 B	SSB	$f_B = b-1$	$\frac{SSB}{b-1}$	$F = \frac{MSB}{MSe}$
误差	SSe	$f_e = (a-1)(b-1)$	$\frac{SSe}{(a-1)(b-1)}$	
总	SST	$f_T = ab-1$		

表 15.6: 无重复可加效应下两因子试验方差分析表

平方和公式可按下列公式计算：

$$\begin{cases} SST = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b} y_{ij}^2 - \frac{y_{..}^2}{ab} \\ SSA = \sum\limits_{i=1}^{a} \frac{y_{i.}^2}{b} - \frac{y_{..}^2}{ab} \\ SSB = \sum\limits_{j=1}^{b} \frac{y_{.j}^2}{a} - \frac{y_{..}^2}{ab} \\ SSe = SST - SSA - SSB \end{cases}$$

15.4.7 参数估计

可加效应下的两因子方差分析有四类参数：μ，诸 τ_i，诸 β_j 和 σ^2。下讨论这四类参数的点估计问题。

点估计

参数的点估计如下：

$$\hat{\sigma^2} = MSe$$

$$\hat{\mu} = \bar{y}_{..}$$

$$\hat{\tau}_i = \bar{y}_{i.} - \bar{y}_{..},\ i = 1, 2, \ldots, a$$

$$\hat{\beta}_j = \bar{y}_{.j} - \bar{y}_{..},\ j = 1, 2, \ldots, b$$

其中 $\hat{\mu}$, $\hat{\tau}_i$, $\hat{\beta}_j$ 是使用最小二乘估计得到的。

证明. 分别用 $\hat{\mu}$, $\hat{\tau}_i$, $\hat{\beta}_j$ 表示 μ，诸 τ_i 和诸 β_j 的估计，用 $\hat{y}_{ij} = \hat{\mu} + \hat{\tau}_i + \hat{\beta}_j$ 表示 y_{ij} 的估计，$i = 1, 2, \ldots, a$, $j = 1, 2, \ldots, b$。损失函数为：

$$L = \sum_{i=1}^{a}\sum_{j=1}^{b}(y_{ij} - \hat{y}_{ij})^2 = \sum_{i=1}^{a}\sum_{j=1}^{b}(y_{ij} - \hat{\mu} - \hat{\tau}_i - \hat{\beta}_j)^2$$

最小二乘解需要满足：

$$\begin{cases} \dfrac{\partial L}{\partial \hat{\mu}} = 0, \\ \dfrac{\partial L}{\partial \hat{\tau}_i} = 0, \quad i = 1, 2, \ldots, a \\ \dfrac{\partial L}{\partial \hat{\beta}_j} = 0, \quad j = 1, 2, \ldots, b \\ \sum\limits_{i=1}^{a} \hat{\tau}_i = 0 \\ \sum\limits_{j=1}^{b} \hat{\beta}_j = 0 \end{cases}$$

上式即可解出结果。 □

15.4.8 多重比较问题

如果此时某因子显著，则需要对它的各水平均值采用 Duncan 多重比较法去判断哪些水平之间存在显著差异。此时的水平均值即为在另一因子各水平下的均值。

15.4.9 等重复试验情形

等重复试验下的方差分析表

来源	平方和	自由度	均方和	F 值
因子 A	SSA	$f_A = a - 1$	$\frac{SSA}{a-1}$	$F = \frac{MSA}{MSe}$
因子 B	SSB	$f_B = b - 1$	$\frac{SSB}{b-1}$	$F = \frac{MSB}{MSe}$
误差	SSe	$f_e = abm - a - b + 1$	$\frac{SSe}{f_e}$	
总	SST	$f_T = abm - 1$		

表 15.7: 可加效应下两因子等重复试验方差分析表

其中 m 为重复实验次数。平方和公式可按下列公式计算：

$$\begin{cases} SST = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b}\sum\limits_{k=1}^{m} y_{ijk}^2 - \frac{y_{...}^2}{abm} \\ SSA = \sum\limits_{i=1}^{a} \frac{y_{i..}^2}{bm} - \frac{y_{...}^2}{abm} \\ SSB = \sum\limits_{j=1}^{b} \frac{y_{.j.}^2}{am} - \frac{y_{..}^2}{abm} \\ SSe = SST - SSA - SSB \end{cases}$$

其中：

$$y_{...} = \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m} y_{ijk}$$

$$y_{i..} = \sum_{j=1}^{b}\sum_{k=1}^{m} y_{ijk}, \quad i = 1, 2, \ldots, a$$

$$y_{.j.} = \sum_{i=1}^{a}\sum_{k=1}^{m} y_{ijk}, \quad j = 1, 2, \ldots, b$$

参数估计

参数的点估计如下：

$$\hat{\mu} = \bar{y}_{...}$$
$$\hat{\tau}_i = \bar{y}_{i..} - \bar{y}_{...},\ i = 1, 2, \ldots, a$$
$$\hat{\beta}_j = \bar{y}_{.j.} - \bar{y}_{...},\ j = 1, 2, \ldots, b$$

多重比较问题

此时的 Duncan 多重比较过程与无重复试验的情况完全一样，只是需要注意：

$$A : R_p > r_{1-\alpha}(p, f)\sqrt{\frac{MSe}{bm}}$$
$$B : R_p > r_{1-\alpha}(p, f)\sqrt{\frac{MSe}{am}}$$

15.5 交互效应下的两因子方差分析

仅讨论等重复情形。

因子 A \ 因子 B	B_1	B_2	$\cdots$	B_b
A_1	$y_{111}, y_{112}, \ldots, y_{11m}$	$y_{121}, y_{122}, \ldots, y_{12m}$	$\cdots$	$y_{1b1}, y_{1b2}, \ldots, y_{1bm}$
A_2	$y_{211}, y_{212}, \ldots, y_{21m}$	$y_{221}, y_{222}, \ldots, y_{22m}$	$\cdots$	$y_{2b1}, y_{2b2}, \ldots, y_{2bm}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$
A_a	$y_{a11}, y_{a12}, \ldots, y_{a1m}$	$y_{a21}, y_{a22}, \ldots, y_{a2m}$	$\cdots$	$y_{ab1}, y_{ab2}, \ldots, y_{abm}$

表 15.8: 等重复两因子试验数据表

其中 y_{ijk} 表示在因子 A 的第 i 个水平 A_i 和因子 B 的第 j 个水平 B_j 下第 k 次重复试验的观察值。

15.5.1 统计模型

由可加效应下的两因子方差分析模型（见 section 15.4.1），如果：

$$\mu_{ij} \neq \mu + \tau_i + \beta_j$$

则记：

$$(\tau\beta)_{ij} = \mu_{ij} - (\mu + \tau_i + \beta_j), \quad i = 1, 2, \ldots, a,\ j = 1, 2, \ldots, b$$

称 $(\tau\beta)_{ij}$ 为因子 A 的水平 A_i 和因子 B 的水平 B_j 的交互效应。它表示两个因子的主效应之外，由于水平搭配而引起的新的效应。所有交互效应的全体称为交互作用，记为 AB 或

A×B。交互效应应满足如下条件：

$$\sum_{j=1}^{b}(\tau\beta)_{ij}=0,\quad i=1,2,\ldots,a$$
$$\sum_{i=1}^{a}(\tau\beta)_{ij}=0,\quad j=1,2,\ldots,b$$

此时的统计模型即为：

$$\begin{cases} y_{ijk}=\mu+\tau_i+\beta_j+(\tau\beta)_{ij}+\varepsilon_{ijk} \\ \text{诸}\varepsilon_{ijk}\quad \text{i.i.d. } N(0,\sigma^2) \\ s.t.\quad \sum\limits_{i=1}^{a}\tau_i=0,\quad \sum\limits_{j=1}^{b}\beta_j=0 \\ \qquad \sum\limits_{j=1}^{b}(\tau\beta)_{ij}=0,\quad \sum\limits_{i=1}^{a}(\tau\beta)_{ij}=0 \\ i=1,2,\ldots,a,\ j=1,2,\ldots,b,\ k=1,2,\ldots,m \end{cases}$$

15.5.2 统计假设

交互效应下的两因子方差分析需要检验如下三个零假设：

$$\begin{cases} H_{01}:\tau_1=\tau_2=\cdots=\tau_a=0, \\ H_{02}:\beta_1=\beta_2=\cdots=\beta_b=0 \\ H_{03}:(\tau\beta)_{ij}=0,\ \forall\, i,j \end{cases}$$

15.5.3 偏差平方和的分解

记：

$$y_{\cdots}=\sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}y_{ijk},\quad \bar{y}_{\cdots}=\frac{y_{\cdots}}{abm}$$
$$y_{i\cdot\cdot}=\sum_{j=1}^{b}\sum_{k=1}^{m}y_{ijk},\quad \bar{y}_{i\cdot\cdot}=\frac{y_{i\cdot\cdot}}{bm},\quad i=1,2,\ldots,a$$
$$y_{\cdot j\cdot}=\sum_{i=1}^{a}\sum_{k=1}^{m}y_{ijk},\quad \bar{y}_{\cdot j\cdot}=\frac{y_{\cdot j\cdot}}{am},\quad j=1,2,\ldots,b$$
$$y_{ij\cdot}=\sum_{k=1}^{m}y_{ijk},\quad \bar{y}_{ij\cdot}=\frac{y_{ij\cdot}}{m}$$

全部数据之间的差异可用下述总偏差平方和表示：

$$SST=\sum_{i=1}^{a}\sum_{j=1}^{b}(y_{ij}-\bar{y}_{\cdot\cdot})^2$$

引起数据 y_{ij} 之间差异的原因有四点：

1. 因子 A 的 a 个水平对试验结果的影响不同。

2. 因子 B 的 b 个水平对试验结果的影响不同。

3. 因子 A 和因子 B 的交互作用。

4. 试验具有误差。

为了区分并比较这四个原因对数据的影响，需要对 SST 进行分解：

$$
\begin{aligned}
SST &= \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}(y_{ijk}-\bar{y}_{...})^2 \\
&= \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}\left[(\bar{y}_{i..}-\bar{y}_{...})+(\bar{y}_{.j.}-\bar{y}_{...})+(\bar{y}_{ij.}-\bar{y}_{i..}-\bar{y}_{.j.}+\bar{y}_{...})+(y_{ijk}-\bar{y}_{ij.})\right]^2 \\
&= bm\sum_{i=1}^{a}(\bar{y}_{i..}-\bar{y}_{...})^2+am\sum_{j=1}^{b}(\bar{y}_{.j.}-\bar{y}_{...})^2+m\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{ij.}-\bar{y}_{i..}-\bar{y}_{.j.}+\bar{y}_{...})^2+\sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}(y_{ijk}-\bar{y}_{ij.})^2
\end{aligned}
$$

仿照单因子方差分析、可加效应下的两因子方差分析的做法，仍可以分别定义：

$$
\begin{aligned}
SSA &= bm\sum_{i=1}^{a}(\bar{y}_{i..}-\bar{y}_{...})^2 = bm\sum_{i=1}^{a}(\tau_i+\bar{\varepsilon}_{i..}-\bar{\varepsilon}_{...})^2 \\
SSB &= am\sum_{j=1}^{b}(\bar{y}_{.j.}-\bar{y}_{...})^2 = am\sum_{j=1}^{b}(\beta_j+\bar{\varepsilon}_{.j.}-\bar{\varepsilon}_{...})^2 \\
SSAB &= m\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{ij.}-\bar{y}_{i..}-\bar{y}_{.j.}+\bar{y}_{...})^2 = m\sum_{i=1}^{a}\sum_{j=1}^{b}\left[(\tau\beta)_{ij}+\bar{\varepsilon}_{ij.}-\bar{\varepsilon}_{i..}-\bar{\varepsilon}_{.j.}+3\bar{\varepsilon}_{...}\right]^2 \\
SSe &= \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}(y_{ijk}-\bar{y}_{ij.})^2 = \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}(\varepsilon_{ijk}-\bar{\varepsilon}_{ij.})^2
\end{aligned}
$$

分别称如上公式为：因子 A 的偏差平方和、因子 B 的偏差平方和、因子 A 与因子 B 的交互作用的偏差平方和、误差平方和。

总偏差平方和分解公式

综上，总偏差平方和有如下分解公式：

$$SST = SSA + SSB + +SSAB + SSe$$

15.5.4 检验统计量

仿照单因子方差分析、可加效应下的两因子方差分析的做法，仍可以求得有关 ε 的一系列结论，以及各偏差平方和的期望。这里直接列出结论：

$$E(SSA) = (a-1)\sigma^2 + bm\sum_{i=1}^{a}\tau_i^2$$

$$E(SSB) = (b-1)\sigma^2 + am\sum_{j=1}^{b}\beta_j^2$$

$$E(SSAB) = (a-1)(b-1)\sigma^2 + m\sum_{i=1}^{a}\sum_{j=1}^{b}(\tau\beta)_{ij}^2$$

$$E(SSe) = ab(m-1)\sigma^2$$

称 $\frac{SSA}{a-1}$ 为因子 A 的均方和，记为 MSA；称 $\frac{SSB}{b-1}$ 为因子 B 的均方和，记为 MSB；称 $\frac{SSAB}{(a-1)(b-1)}$ 为因子 A 与因子 B 的交互作用的均方和，记为 MSAB；称 $\frac{SSe}{ab(m-1)}$ 为误差均方和，记为 MSe。

由前述，MSe 是 σ^2 的无偏估计，而当零假设成立时，MSA、MSB、MSAB 也是 σ^2 的一个无偏估计。如果 MSA、MSB、MSAB 与 MSe 比值很大，即 MSA、MSB、MSAB 比 MSe 大很多（$b\sum\limits_{i=1}^{a}\tau_i^2$, $a\sum\limits_{j=1}^{b}\beta_j^2$, $m\sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b}(\tau\beta)_{ij}^2$ 很大），我们就有理由怀疑零假设。由此构建统计量：

$$F_A = \frac{MSA}{MSe} = \frac{\frac{SSA}{a-1}}{\frac{SSe}{ab(m-1)}}$$

$$F_B = \frac{MSB}{MSe} = \frac{\frac{SSB}{b-1}}{\frac{SSe}{ab(m-1)}}$$

$$F_{AB} = \frac{MSAB}{MSe} = \frac{\frac{SSAB}{(a-1)(b-1)}}{\frac{SSe}{ab(m-1)}}$$

在这些统计量的情况下，H_{01}, H_{02}, H_{03} 的拒绝域是右向单尾的。下求统计量的分布。

15.5.5 统计量的分布

上述统计量服从如下分布：

$$F_A \sim F(a-1,\ ab(m-1))$$

$$F_B \sim F(b-1,\ ab(m-1))$$

$$F_{AB} \sim F((a-1)(b-1),\ ab(m-1))$$

所以 H_{01}, H_{02} 在显著性水平为 α 时的拒绝域为：

$$F_A > F_{1-\alpha}(a-1,\ ab(m-1))$$

$$F_B > F_{1-\alpha}(b-1,\ ab(m-1))$$

$$F_{AB} > F_{1-\alpha}((a-1)(b-1),\ ab(m-1))$$

15.5.6 方差分析表

来源	平方和	自由度	均方和	F 值
因子 A	SSA	$f_A = a-1$	$\frac{SSA}{a-1}$	$F = \frac{MSA}{MSe}$
因子 B	SSB	$f_B = b-1$	$\frac{SSB}{b-1}$	$F = \frac{MSB}{MSe}$
交互作用 AB	SSAB	$f_{AB} = (a-1)(b-1)$	$\frac{SSAB}{(a-1)(b-1)}$	$F = \frac{MSAB}{MSe}$
误差	SSe	$f_e = ab(m-1)$	$\frac{SSe}{ab(m-1)}$	
总	SST	$f_T = abm-1$		

表 15.9: 等重复交互效应下两因子试验方差分析表

平方和公式可按下列公式计算：

$$\begin{cases} SST = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b}\sum\limits_{k=1}^{m} y_{ijk}^2 - \frac{y_{...}^2}{abm} \\ SSA = \sum\limits_{i=1}^{a} \frac{y_{i..}^2}{bm} - \frac{y_{...}^2}{abm} \\ SSB = \sum\limits_{j=1}^{b} \frac{y_{.j.}^2}{am} - \frac{y_{...}^2}{abm} \\ SSAB = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b} \frac{y_{ij.}^2}{m} - \frac{y_{...}^2}{abm} - SSA - SSB \\ SSe = SST - SSA - SSB - SSAB \end{cases}$$

15.5.7 参数估计

交互效应下的两因子方差分析有五类参数：μ，诸 τ_i，诸 β_j，诸 $(\tau\beta)_{ij}$ 和 σ^2。下讨论这五类参数的点估计问题。

点估计

参数的点估计如下：

$$\hat{\sigma^2} = MSe$$

$$\hat{\mu} = \bar{y}_{...}$$

$$\hat{\tau}_i = \bar{y}_{i..} - \bar{y}_{...}, \quad \hat{\beta}_j = \bar{y}_{.j.} - \bar{y}_{...}$$

$$\widehat{(\tau\beta)}_{ij} = \bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}_{...}$$

$$i = 1, 2, \ldots, a, \ j = 1, 2, \ldots, b$$

证明过程与之前类似。

15.6 随机效应下的两因子方差分析

仅讨论等重复、有交互作用情形。

因子 A \ 因子 B	B_1	B_2	$\cdots$	B_b
A_1	$y_{111}, y_{112}, \ldots, y_{11m}$	$y_{121}, y_{122}, \ldots, y_{12m}$	$\cdots$	$y_{1b1}, y_{1b2}, \ldots, y_{1bm}$
A_2	$y_{211}, y_{212}, \ldots, y_{21m}$	$y_{221}, y_{222}, \ldots, y_{22m}$	$\cdots$	$y_{2b1}, y_{2b2}, \ldots, y_{2bm}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$
A_a	$y_{a11}, y_{a12}, \ldots, y_{a1m}$	$y_{a21}, y_{a22}, \ldots, y_{a2m}$	$\cdots$	$y_{ab1}, y_{ab2}, \ldots, y_{abm}$

表 15.10: 等重复两因子试验数据表

其中 y_{ijk} 表示在因子 A 的第 i 个水平 A_i 和因子 B 的第 j 个水平 B_j 下第 k 次重复试验的观察值。

15.6.1 统计模型

此时的统计模型为：

$$\begin{cases} y_{ijk} = \mu + \tau_i + \beta_j + (\tau\beta)_{ij} + \varepsilon_{ijk} \\ \text{诸}\varepsilon_{ijk} \quad \text{i.i.d. } N(0, \sigma^2) \\ \text{诸}\tau_i \quad \text{i.i.d. } N(0, \sigma_\tau^2) \\ \text{诸}\beta_j \quad \text{i.i.d. } N(0, \sigma_\beta^2) \\ \text{诸}(\tau\beta)_{ij} \quad \text{i.i.d. } N(0, \sigma_{\tau\beta}^2) \\ \text{诸}\varepsilon_{ijk}\text{、诸}\tau_i\text{、诸}\beta_j\text{、诸}(\tau\beta)_{ij}\text{相互独立} \\ i = 1, 2, \ldots, a,\ j = 1, 2, \ldots, b,\ k = 1, 2, \ldots, m \end{cases}$$

15.6.2 统计假设

此时需要检验如下三个零假设：

$$\begin{cases} H_{01} : \sigma_\tau^2 = 0, \\ H_{02} : \sigma_\beta^2 = 0 \\ H_{03} : \sigma_{\tau\beta}^2 = 0 \end{cases}$$

15.6.3 方差分析

偏差平方和的分解

由于与交互效应情况下五个平方和的定义完全相同，所以随机效应下偏差平方和分解公式与之前一模一样。

$$SST = SSA + SSB + SSAB + SSe$$

$$SSA = bm\sum_{i=1}^{a}(\bar{y}_{i..} - \bar{y}_{...})^2 = bm\sum_{i=1}^{a}(\tau_i + \bar{\varepsilon}_{i..} - \bar{\varepsilon}_{...})^2$$

$$SSB = am\sum_{j=1}^{b}(\bar{y}_{.j.} - \bar{y}_{...})^2 = am\sum_{j=1}^{b}(\beta_j + \bar{\varepsilon}_{.j.} - \bar{\varepsilon}_{...})^2$$

$$SSAB = m\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}_{...})^2 = m\sum_{i=1}^{a}\sum_{j=1}^{b}[(\tau\beta)_{ij} + \bar{\varepsilon}_{ij.} - \bar{\varepsilon}_{i..} - \bar{\varepsilon}_{.j.} + 3\bar{\varepsilon}_{...}]^2$$

$$SSe = \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}(y_{ijk} - \bar{y}_{ij.})^2 = \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{m}(\varepsilon_{ijk} - \bar{\varepsilon}_{ij.})^2$$

各平方和的期望

这里直接列出各平方和的期望，证明是容易的。

$$E(SSA) = (a-1)\sigma^2 + m(a-1)\sigma_{\tau\beta}^2 + (a-1)bm\sigma_{\tau}^2$$

$$E(SSB) = (b-1)\sigma^2 + m(b-1)\sigma_{\tau\beta}^2 + (b-1)am\sigma_{\beta}^2$$

$$E(SSAB) = (a-1)(b-1)\sigma^2 + m(a-1)(b-1)\sigma_{\tau\beta}^2$$

$$E(SSe) = ab(m-1)\sigma^2$$

统计量及其分布

称 $\frac{SSA}{a-1}$ 为因子 A 的均方和，记为 MSA；称 $\frac{SSB}{b-1}$ 为因子 B 的均方和，记为 MSB；称 $\frac{SSAB}{(a-1)(b-1)}$ 为因子 A 与因子 B 的交互作用的均方和，记为 MSAB；称 $\frac{SSe}{ab(m-1)}$ 为误差均方和，记为 MSe。

由前述，MSe 是 σ^2 的无偏估计。在 H_{01} 成立时，MSA 是 $\sigma^2 + m\sigma_{\tau\beta}^2$ 的无偏估计；在 H_{02} 成立时，MSA 是 $\sigma^2 + m\sigma_{\tau\beta}^2$ 的无偏估计；在 H_{03} 成立时，MSAB 是 σ^2 的无偏估计。如果 MSA 与 MSAB 比值很大，则有理由怀疑 H_01；如果 MSB 与 MSAB 比值很大，则有理由怀疑 H_02；如果 MSAB 与 MSe 比值很大，则有理由怀疑 H_03。由此构建统计量：

$$F_A = \frac{MSA}{MSAB} = \frac{\frac{SSA}{a-1}}{\frac{SSAB}{(a-1)(b-1)}}$$

$$F_B = \frac{MSB}{MSAB} = \frac{\frac{SSB}{b-1}}{\frac{SSAB}{(a-1)(b-1)}}$$

$$F_{AB} = \frac{MSAB}{MSe} = \frac{\frac{SSAB}{(a-1)(b-1)}}{\frac{SSe}{ab(m-1)}}$$

在这些统计量的情况下，H_{01}，H_{02}，H_{03} 的拒绝域是右向单尾的。

由于在假设 H_{01}，H_{02}，H_{03} 成立时，随机效应模型与可加效应模型的观察值 y_{ijk} 的数据结构的形式完全一样，所以在随机效应模型中仍然有：

$$F_A \sim F(a-1,\ (a-1)(b-1))$$
$$F_B \sim F(b-1,\ (a-1)(b-1))$$
$$F_{AB} \sim F((a-1)(b-1),\ ab(m-1))$$

拒绝域

综上所述，显著性水平为 α 时的拒绝域为：

$$F_A > F_{1-\alpha}(a-1,\ (a-1)(b-1))$$
$$F_B > F_{1-\alpha}(b-1,\ (a-1)(b-1))$$
$$F_{AB} > F_{1-\alpha}((a-1)(b-1),\ ab(m-1))$$

15.6.4 方差分析表

来源	平方和	自由度	均方和	F 值
因子 A	SSA	$f_A = a-1$	$\frac{SSA}{a-1}$	$F = \frac{MSA}{MSAB}$
因子 B	SSB	$f_B = b-1$	$\frac{SSB}{b-1}$	$F = \frac{MSB}{MSAB}$
交互作用 AB	SSAB	$f_{AB} = (a-1)(b-1)$	$\frac{SSAB}{(a-1)(b-1)}$	$F = \frac{MSAB}{MSe}$
误差	SSe	$f_e = ab(m-1)$	$\frac{SSe}{ab(m-1)}$	
总	SST	$f_T = abm-1$		

表 15.11: 等重复、有交互作用的随机效应下两因子试验方差分析表

平方和公式可按下列公式计算：

$$\begin{cases} SST = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b}\sum\limits_{k=1}^{m} y_{ijk}^2 - \frac{y_{...}^2}{abm} \\ SSA = \sum\limits_{i=1}^{a} \frac{y_{i..}^2}{bm} - \frac{y_{...}^2}{abm} \\ SSB = \sum\limits_{j=1}^{b} \frac{y_{.j.}^2}{am} - \frac{y_{...}^2}{abm} \\ SSAB = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b} \frac{y_{ij.}^2}{m} - \frac{y_{...}^2}{abm} - SSA - SSB \\ SSe = SST - SSA - SSB - SSAB \end{cases}$$

15.6.5 参数估计

我们此时关心方差分量的估计。

点估计

由 SSA、SSB、SSAB、SSe 期望的计算，可给出各方差分量的无偏点估计如下：

$$\hat{\sigma^2} = MSe$$
$$\hat{\sigma^2}_\tau = \frac{MSA - MSAB}{bm}$$
$$\hat{\sigma^2}_\beta = \frac{MSB - MSAB}{am}$$
$$\hat{\sigma^2}_{\tau\beta} = \frac{MSAB - MSe}{m}$$

15.7 混合模型下的两因子方差分析

仅讨论等重复情形。

因子 A \ 因子 B	B_1	B_2	$\cdots$	B_b
A_1	$y_{111}, y_{112}, \ldots, y_{11m}$	$y_{121}, y_{122}, \ldots, y_{12m}$	$\cdots$	$y_{1b1}, y_{1b2}, \ldots, y_{1bm}$
A_2	$y_{211}, y_{212}, \ldots, y_{21m}$	$y_{221}, y_{222}, \ldots, y_{22m}$	$\cdots$	$y_{2b1}, y_{2b2}, \ldots, y_{2bm}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$
A_a	$y_{a11}, y_{a12}, \ldots, y_{a1m}$	$y_{a21}, y_{a22}, \ldots, y_{a2m}$	$\cdots$	$y_{ab1}, y_{ab2}, \ldots, y_{abm}$

表 15.12: 等重复两因子试验数据表

其中 y_{ijk} 表示在因子 A 的第 i 个水平 A_i 和因子 B 的第 j 个水平 B_j 下第 k 次重复试验的观察值。设因子 A 是固定地，因子 B 是随机的。

15.7.1 统计模型

此时的统计模型为：

$$\begin{cases} y_{ijk} = \mu + \tau_i + \beta_j + (\tau\beta)_{ij} + \varepsilon_{ijk} \\ \text{诸}\varepsilon_{ijk} \quad \text{i.i.d. } N(0, \sigma^2) \\ \text{诸}\beta_j \quad \text{i.i.d. } N(0, \sigma_\beta^2) \\ \text{诸}(\tau\beta)_{ij} \quad \text{i.i.d. } N(0, \frac{a-1}{a}\sigma_{\tau\beta}^2) \\ \sum\limits_{i=1}^{a} \tau_i = 0, \quad \sum\limits_{i=1}^{a} (\tau\beta)_{ij} = 0 \\ \text{诸}(\tau\beta)_{ij}\text{彼此之间是不相关的} \\ i = 1, 2, \ldots, a,\ j = 1, 2, \ldots, b,\ k = 1, 2, \ldots, m \end{cases}$$

这里 $(\tau\beta)_{ij}$ 的方差写成这样是为了让底下的计算更加简洁。

15.7.2 统计假设

此时需要检验如下三个零假设：

$$\begin{cases} H_{01}: \tau_1 = \tau_2 = \cdots = \tau_a = 0, \\ H_{02}: \sigma_\beta^2 = 0 \\ H_{03}: \sigma_{\tau\beta}^2 = 0 \end{cases}$$

15.7.3 方差分析

偏差平方和的分解

公式仍然成立：

$$SST = SSA + SSB + SSAB + SSe$$

各平方和的期望

这里直接列出各平方和的期望。

$$E(MSA) = \sigma^2 + m\sigma_{\tau\beta}^2 + \frac{bm\sum\limits_{i=1}^{a}\tau_i^2}{a-1}$$
$$E(MSB) = \sigma^2 + am\sigma_\beta^2$$
$$E(MSAB) = \sigma^2 + m\sigma_{\tau\beta}^2$$
$$E(MSe) = \sigma^2$$

统计量及其分布

统计量及其分布如下：

$$F_A = \frac{MSA}{MSAB} \sim F(a-1,\ (a-1)(b-1))$$
$$F_B = \frac{MSB}{MSe} \sim F(b-1,\ ab(m-1))$$
$$F_{AB} = \frac{MSAB}{MSe} \sim F((a-1)(b-1),\ ab(m-1))$$

拒绝域

显著性水平为 α 时的拒绝域为：

$$F_A > F_{1-\alpha}(a-1,\ (a-1)(b-1))$$
$$F_B > F_{1-\alpha}(b-1,\ ab(m-1))$$
$$F_{AB} > F_{1-\alpha}((a-1)(b-1),\ ab(m-1))$$

15.7.4 方差分析表

来源	平方和	自由度	均方和	F 值
因子 A（固定）	SSA	$f_A = a-1$	$\frac{SSA}{a-1}$	$F = \frac{MSA}{MSAB}$
因子 B（随机）	SSB	$f_B = b-1$	$\frac{SSB}{b-1}$	$F = \frac{MSB}{MSe}$
交互作用 AB	SSAB	$f_{AB} = (a-1)(b-1)$	$\frac{SSAB}{(a-1)(b-1)}$	$F = \frac{MSAB}{MSe}$
误差	SSe	$f_e = ab(m-1)$	$\frac{SSe}{ab(m-1)}$	
总	SST	$f_T = abm-1$		

表 15.13: 等重复、有交互作用的混合模型下两因子试验方差分析表

平方和公式可按下列公式计算：

$$\begin{cases} SST = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b}\sum\limits_{k=1}^{m} y_{ijk}^2 - \frac{y_{...}^2}{abm} \\ SSA = \sum\limits_{i=1}^{a} \frac{y_{i..}^2}{bm} - \frac{y_{...}^2}{abm} \\ SSB = \sum\limits_{j=1}^{b} \frac{y_{.j.}^2}{am} - \frac{y_{...}^2}{abm} \\ SSAB = \sum\limits_{i=1}^{a}\sum\limits_{j=1}^{b} \frac{y_{ij.}^2}{m} - \frac{y_{...}^2}{abm} - SSA - SSB \\ SSe = SST - SSA - SSB - SSAB \end{cases}$$

15.7.5 多重比较比较问题

如果固定因子 A 显著，则可使用 Duncan 多重比较法，但此时需要注意拒绝域应修改为如下形式：

$$A : R_p > r_{1-\alpha}(p, f)\sqrt{\frac{MSAB}{bm}}$$

15.7.6 参数估计

点估计

下给出混合模型参数的点估计：

$$\hat{\mu} = \bar{y}_{...}, \quad \hat{\tau}_i = \bar{y}_{i..} - \bar{y}_{...}, \quad i = 1, 2, \ldots, a$$
$$\hat{\sigma^2} = MSe, \quad \hat{\sigma^2}_\beta = \frac{MSB - MSe}{am}, \quad \hat{\sigma^2}_{\tau\beta} = \frac{MSAB - MSe}{m}$$

15.8 部分实施问题

前几节介绍的方法都要求每个水平组合至少做一次试验，如果考虑因子间的交互作用，对每个水平组合还要做重复试验。这就导致当因子数较多或者因子水平书较多时，试验总次数会非常多。这就提出了一个问题：如何做到只对全部水平组合的一部分做试验，也能比较因子的各水平对试验结果是否有显著差异、不同因子间是否有交互作用？这就是全因子试验的部分实施问题。

15.8.1 正交拉丁方设计

本节介绍一种在无交互效应、各因子水平数相等情况下的部分实施问题的解决方案。设每个因子有 n 个水平，一共有 k 个因子。

原理

要使得在对任一因子的效应作比较时能够消除其它因子水平变动对数据的影响，就需要保证：在任一因子的任一水平下，其它因子的每个水平都重复相同次数。此时称这些因子彼此之间正交。

定义 15.4. 由 p 个不同符号排成的 p 阶方阵中，如果每行的 p 个元素不同，每列的 p 个元素也不同，则称这个方阵为一个 p 阶拉丁方。如果两个 p 阶拉丁方重叠时，第一个拉丁方中的任一元素与第二个拉丁方中的每个元素都相遇且只相遇一次，则称这一对拉丁方相互正交。

下面的第一个方阵就是一个 3 阶拉丁方，第二个矩阵表示一对正交拉丁方重叠。

$$\begin{pmatrix} A & B & C \\ B & C & A \\ C & A & B \end{pmatrix} \qquad \begin{pmatrix} A\alpha & B\beta & C\gamma \\ B\gamma & C\alpha & A\beta \\ C\beta & A\gamma & B\alpha \end{pmatrix}$$

我们可以发现，拉丁方中的元素作为某一个因子的不同水平时，互相正交的拉丁方满足因子间正交。由此产生了正交拉丁方设计。

列因子 / 行因子	C_1	C_2	$\cdots$	C_n
R_1	$\cdots$	$\cdots$	$\cdots$	$\cdots$
R_2	$\cdots$	$\cdots$	$\cdots$	$\cdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
R_n	$\cdots$	$\cdots$	$\cdots$	$\cdots$

表 15.14: k 因子各 n 水平正交拉丁方设计表

上表中 $\cdots$ 部分表示 $k-2$ 个互相正交的拉丁方重叠后矩阵位置上的对应元素。因为拉丁方之间是正交的，所以不同的拉丁因子之间是正交的，而每个拉丁因子与行因子、列

因子也是正交的，列因子与行因子显然正交，所以该试验方案可以被用作 k 因子各 n 水平的研究，其中需要做 n^2 次试验，每一次试验使用到的因子水平即为上表每一个单元中的 $k-2$ 个拉丁方因子水平与其行列因子水平的组合。

三因子正交拉丁方设计又称拉丁方设计，四因子正交拉丁方设计又称希腊-拉丁方设计，涉及到四个以上因子的正交拉丁方设计称为超方设计。下对拉丁方设计与希腊-拉丁方设计做详细介绍。

拉丁方设计

拉丁方设计命名的由来是因为其中拉丁方的元素用拉丁字母来表示。

列因子 / 行因子	C_1	C_2	C_3
R_1	A	B	C
R_2	B	C	A
R_3	C	A	B

表 15.15: 拉丁方设计表

统计模型

$$\begin{cases} y_{ijk} = \mu + \alpha_i + \tau_j + \beta_k + \varepsilon_{ijk} \\ \text{诸}\varepsilon_{ijk} \quad \text{i.i.d. } N(0, \sigma^2) \\ s.t. \quad \sum\limits_{i=1}^{p} \alpha_i = 0, \quad \sum\limits_{j=1}^{p} \tau_j = 0, \quad \sum\limits_{k=1}^{p} \beta_k = 0 \\ i = 1, 2, \ldots, p,\ j = 1, 2, \ldots, p,\ k = 1, 2, \ldots, p \end{cases}$$

其中 y_{ijk} 是在行因子第 i 个水平、列因子第 k 个水平和拉丁因子第 j 个水平下试验的观察值。μ 为一般平均，α_i 是行因子第 i 个水平的效应，τ_j 是拉丁因子第 j 个水平的效应，β_k 是列因子第 k 个水平的效应。需要注意的是，因为拉丁方设计的缘故，三个下标之间不是独立的。

方差分析

$$SST = SS_{\text{拉丁}} + SS_{\text{行}} + SS_{\text{列}} + SSe$$

来源	平方和	自由度	均方和	F 值
拉丁因子	$SS_{拉丁}$	$p-1$	$MS_{拉丁}=\frac{SS_{拉丁}}{p-1}$	$F=\frac{MS_{拉丁}}{MS_e}$
行因子	$SS_{行}$	$p-1$	$MS_{行}=\frac{SS_{行}}{p-1}$	$F=\frac{MS_{行}}{MS_e}$
列因子	$SS_{列}$	$p-1$	$MS_{列}=\frac{SS_{列}}{p-1}$	$F=\frac{MS_{列}}{MS_e}$
误差	SS_e	$(p-2)(p-1)$	$MS_e=\frac{SS_e}{(p-2)(p-1)}$	
总和	SS_T	p^2-1		

表 15.16: 拉丁方设计方差分析表

其中：

$$\begin{cases} SST=\sum\limits_{i=1}^{p}\sum\limits_{j=1}^{p}\sum\limits_{k=1}^{p}y_{ijk}^2-\frac{y_{...}^2}{p^2} \\ SS_{行}=\sum\limits_{i=1}^{p}\frac{y_{i..}^2}{p}-\frac{y_{...}^2}{p^2} \\ SS_{列}=\sum\limits_{k=1}^{p}\frac{y_{..k}^2}{p}-\frac{y_{...}^2}{p^2} \\ SS_{拉丁}=\sum\limits_{j=1}^{p}\frac{y_{.j.}^2}{p}-\frac{y_{...}^2}{p^2} \\ SSe=SST-SS_{行}-SS_{列}-SS_{拉丁} \end{cases}$$

多重比较问题

此时的 Duncan 多重比较过程需要注意：

$$R_p>r_{1-\alpha}(p,f)\sqrt{\frac{MSe}{p}}$$

希腊拉丁方设计

希腊-拉丁方设计命名的由来是因为其中拉丁方的元素分别用拉丁字母和希腊字母来表示。

列因子 / 行因子	C_1	C_2	C_3
R_1	$A\alpha$	$B\beta$	$C\gamma$
R_2	$B\gamma$	$C\alpha$	$A\beta$
R_3	$C\beta$	$A\gamma$	$B\alpha$

表 15.17: 希腊-拉丁方设计表

统计模型

$$\begin{cases} y_{ijkl} = \mu + \alpha_i + \tau_j + \phi_k + \beta_l + \varepsilon_{ijk} \\ \text{诸}\varepsilon_{ijkl} \quad \text{i.i.d. } N(0, \sigma^2) \\ s.t. \quad \sum\limits_{i=1}^{p} \alpha_i = 0, \quad \sum\limits_{j=1}^{p} \tau_j = 0, \quad \sum\limits_{k=1}^{p} \pi_k = 0, \quad \sum\limits_{l=1}^{p} \beta_l = 0 \\ i = 1, 2, \ldots, p,\ j = 1, 2, \ldots, p,\ k = 1, 2, \ldots, p,\ l = 1, 2, \ldots, p \end{cases}$$

其中 y_{ijkl} 是在行因子第 i 个水平、列因子第 l 个水平、拉丁因子第 j 个水平和希腊因子第 k 个水平下试验的观察值。μ 为一般平均，α_i 是行因子第 i 个水平的效应，τ_j 是拉丁因子第 j 个水平的效应，ϕ_k 是希腊因子第 k 个水平的效应，β_l 是列因子第 l 个水平的效应。需要注意的是，因为希腊-拉丁方设计的缘故，四个下标之间不是独立的。

方差分析

$$SST = SS_{\text{拉丁}} + SS_{\text{希腊}} + SS_{\text{行}} + SS_{\text{列}} + SSe$$

来源	平方和	自由度	均方和	F 值
拉丁因子	$SS_{\text{拉丁}}$	$p-1$	$MS_{\text{拉丁}} = \frac{SS_{\text{拉丁}}}{p-1}$	$F = \frac{MS_{\text{拉丁}}}{MS_e}$
希腊因子	$SS_{\text{希腊}}$	$p-1$	$MS_{\text{希腊}} = \frac{SS_{\text{希腊}}}{p-1}$	$F = \frac{MS_{\text{希腊}}}{MS_e}$
行因子	$SS_{\text{行}}$	$p-1$	$MS_{\text{行}} = \frac{SS_{\text{行}}}{p-1}$	$F = \frac{MS_{\text{行}}}{MS_e}$
列因子	$SS_{\text{列}}$	$p-1$	$MS_{\text{列}} = \frac{SS_{\text{列}}}{p-1}$	$F = \frac{MS_{\text{列}}}{MS_e}$
误差	SS_e	$(p-3)(p-1)$	$MS_e = \frac{SS_e}{(p-3)(p-1)}$	
总和	SS_T	p^2-1		

表 15.18: 拉丁方设计方差分析表

其中：

$$\begin{cases} SST = \sum\limits_{i=1}^{p}\sum\limits_{j=1}^{p}\sum\limits_{k=1}^{p}\sum\limits_{l=1}^{p} y_{ijkl}^2 - \frac{y_{\cdots\cdot}^2}{p^2} \\ SS_{\text{行}} = \sum\limits_{i=1}^{p} \frac{y_{i\cdots}^2}{p} - \frac{y_{\cdots\cdot}^2}{p^2} \\ SS_{\text{列}} = \sum\limits_{k=1}^{p} \frac{y_{\cdots l}^2}{p} - \frac{y_{\cdots\cdot}^2}{p^2} \\ SS_{\text{拉丁}} = \sum\limits_{j=1}^{p} \frac{y_{\cdot j\cdot\cdot}^2}{p} - \frac{y_{\cdots\cdot}^2}{p^2} \\ SS_{\text{希腊}} = \sum\limits_{k=1}^{p} \frac{y_{\cdot\cdot k\cdot}^2}{p} - \frac{y_{\cdots\cdot}^2}{p^2} \\ SSe = SST - SS_{\text{行}} - SS_{\text{列}} - SS_{\text{拉丁}} - SS_{\text{希腊}} \end{cases}$$

多重比较问题

此时的 Duncan 多重比较过程需要注意：

$$R_p > r_{1-\alpha}(p, f)\sqrt{\frac{MSe}{p}}$$

123456789

第六部分

试验设计

Chapter 16

试验设计基本概念

1. 响应变量 (response)：衡量实验结果好坏的指标。
   - 定量响应变量。
   - 定性响应变量。
2. 因子 (factor)：影响响应变量的因素。
3. 水平：试验中因子所处的各个状态称之为因子的水平。
4. 完全随机化设计：为了控制未作为因子考虑的其它因素，所有试验应按随机顺序进行，使得试验设计成为一个完全随机化设计。

第七部分

抽样调查

符号说明

符号		说明
N		总体单元个数
n		样本单元个数
Y_k	$k=1,2,\ldots,N$	总体中单元的值
y_k	$k=1,2,\ldots,n$	样本中单元的值
$p(s)$		样本概率
π_k	$k=1,2,\ldots,N$	单元的入样概率
w_k	$k=1,2,\ldots,N$	单元的抽样权重
τ		总量
μ		均值
σ^2		方差
s^2		样本方差
Z_i	$i=1,2,\ldots,N$	表示单元是否入样的示性变量
Q_i	$i=1,2,\ldots,N$	表示单元在样本中出现的次数
p		阳性率
d		误差幅度
X_k	$k=1,2,\ldots,N$	总体中辅助变量的值
x_k	$k=1,2,\ldots,n$	样本中辅助变量的值
B		比例估计系数
H		分层抽样总层数
h	$h=1,2,\ldots,H$	层下标
S_h	$h=1,2,\ldots,H$	某一层中所有单元构成的集合
N_h	$h=1,2,\ldots,H$	层中单元的总数
n_h	$h=1,2,\ldots,H$	层中的样本数
Y_{hj}	$h=1,2,\ldots,H,\ j=1,2,\ldots,N_h$	层中单元的值
y_{hj}	$h=1,2,\ldots,H,\ j=1,2,\ldots,n_h$	层中样本单元的值
c_h	$h=1,2,\ldots,H$	层中抽样的平均成本

表 16.1: 符号说明表

Chapter 17

抽样调查基本概念

17.1 抽样调查的目的

抽样调查最直接的主要任务，就是根据测得的样本数量指标 $\{y_1, y_2, \ldots, y_n\}$，对总体 $\{Y_1, Y_2, \ldots, Y_N\}$ 的一些数字特征进行估计。如估计：

1. 总体均值$\mu = \frac{1}{N}\sum_{i=1}^{N} Y_i$，总体总量$\tau = \sum_{i=1}^{N} Y_i$。

2. [1]总体方差$\sigma^2 = \frac{1}{N-1}\sum_{i=1}^{N}(Y_i - \overline{Y})^2$。

3. 总体中满足某一特征的单元所占比例 p。

4. 总体分布的分位数。

17.2 目标群体、源群体、研究群体

- 目标群体：研究者希望对其进行描述或推断的群体。

- 源群体：研究者实际用于选择样本的群体，通常是目标群体的一个子集或一个接近目标群体的群体。

- 研究群体：抽样后的样本

[1]这里指的是有限总体的方差，我们在抽样调查中认为有限总体也相当于一个样本，以样本方差公式计算其方差。在无限总体的情况下，分母取 N。

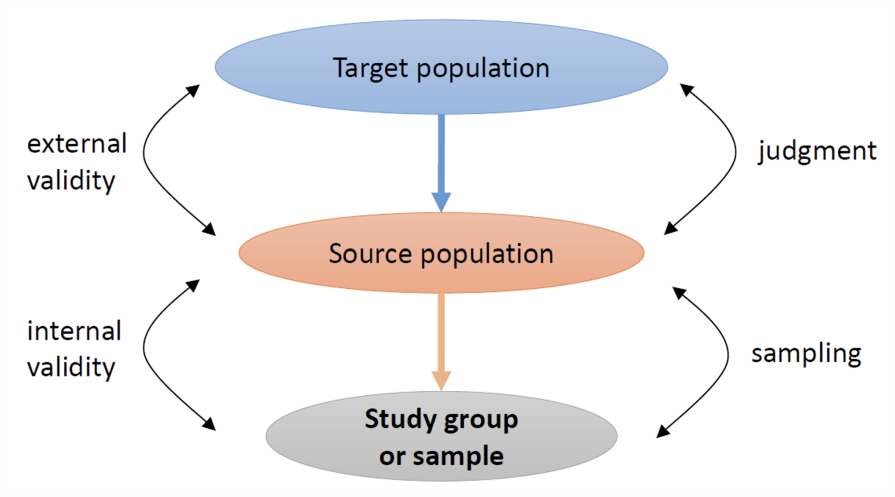

图 17.1: 群体

17.3 抽样设计

$$
\text{抽样设计}\begin{cases}\text{概率抽样}\begin{cases}\text{简单随机抽样}\\ \text{分层抽样}\\ \text{整群抽样}\end{cases}\\ \text{非概率抽样}\begin{cases}\text{方便抽样}\\ \text{雪球抽样}\\ \text{判断抽样}\end{cases}\end{cases}
$$

- 概率抽样样本是随机产生的，非概率抽样样本不是随机产生的。
- 非概率抽样无法判断样本是否具备代表性，也就无法确定抽样误差。但在一定程度上可以说明总体的特征。
- 方便抽样是选择最容易获得的样本作为研究对象。
- 雪球抽样是先选择一个较小的样本，再让这个样本中的单元去提供一些样本。
- 判断抽样是研究人员从总体中选择自己认为最能代表总体的个体。

17.4 抽样框架

对可以选择作为样本的群体单位列出的名册或排序编号，用以确定总体的抽样范围和结构。

17.5 抽样调查随机性的来源

17.5.1 基于模型的方法

绝大多数统计学课程是基于模型的 (model-based approch)，它将总体看作是背后随机变量的实现，随机性来源于随机变量的取值。

17.5.2 基于设计的方法

抽样调查是基于设计的 (design-based approch)，它将总体中单元的数值看作为定值，而随机性来源于是否抽到总体中的单元。

17.6 概率抽样概述

17.6.1 样本概率

记一个可能的样本为 s，记在抽样设计下出现这个样本的概率[2]为 $p(s)$，应有 $\sum_s p(s) = 1$。

17.6.2 入样概率与抽样权重

对于任意单元 Y_k，该单元的入样概率 π_k 记为 $\sum_{Y_k \in s} p(s)$，该单元的抽样权重 w_k 定义为 $\frac{1}{\pi_k}$，表示该单元可以代表总体里的多少个单元。

[2]样本出现的概率未必是等可能的。

Chapter 18

简单随机抽样

简单随机抽样分为不放回型简单随机抽样 (simple random sampling, SRS)与放回型简单随机抽样 (simple random sampling with replacement, SRSWR)两种。我们通常更喜欢不放回抽样，因为同一个单元出现多次并不能提供额外的信息，同时有放回抽样会导致估计量的方差更大。

再考虑一
不是 SRS 和
WR 都是这样的

简单随机抽样意味着每个样本出现的概率是一样的，即 $p(s)$ 一致，那么每个单元的入样概率也是一致的（样本出现概率一致时每个单元的入样概率服从古典概型）。

18.1 SRS 的参数估计

SRS 中 Z 的相关性质

$$
\begin{aligned}
E(Z_i) &= \frac{n}{N} \\
Var(Z_i) &= \frac{n}{N}\left(1-\frac{n}{N}\right) \\
Cov(Z_i, Z_j) &= \frac{-n}{N(N-1)}\left(1-\frac{n}{N}\right)
\end{aligned}
$$

证明. 每个单元被抽到的概率为：

$$\pi_k = \frac{\binom{N-1}{n-1}}{\binom{N}{n}} = \frac{n}{N}$$

由此可知单元示性变量的期望：

$$E(Z_i) = 1 \times P(Z_i = 1) = 1 \times \pi_i = \frac{n}{N}$$

注意到 $E(Z_i^2) = 0 \times P(Z_i^2 = 0) + 1 \times P(Z_i^2 = 1) = P(Z_i = 1) = E(Z_i)$，

$$
\begin{aligned}
Var(Z_i) &= E(Z_i^2) - E^2(Z_i) \\
&= E(Z_i)\left(1 - E(Z_i)\right) \\
&= \frac{n}{N}\left(1-\frac{n}{N}\right)
\end{aligned}
$$

注意到 $E(Z_iZ_j) = P(Z_i = 1,\ Z_j = 1)$，

$$\begin{aligned} Cov(Z_i, Z_j) &= E(Z_iZ_j) - E(Z_i)E(Z_j) \\ &= \frac{\binom{N-2}{n-2}}{\binom{N}{n}} - E^2(Z_i) \\ &= \frac{-n}{N(N-1)}\left(1 - \frac{n}{N}\right) \end{aligned} \qquad \square$$

18.1.1 SRS 总体均值 μ 的估计

点估计及点估计的性质

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} y_i = \frac{1}{n}\sum_{i=1}^{N} Y_iZ_i$$

$$E(\hat{\mu}) = \mu,\ Var(\hat{\mu}) = \frac{1}{n}\left(1 - \frac{n}{N}\right)\sigma^2$$

$$\widehat{Var}(\hat{\mu}) = \frac{1}{n}\left(1 - \frac{n}{N}\right)s^2\text{是关于}Var(\hat{\mu})\text{的无偏估计。}$$

其中方差的计算见下文总体总数方差的推导，由方差的性质即可推导出总体均值的方差。[1]

区间估计

$$\frac{\hat{\mu} - \mu}{\sqrt{Var(\hat{\mu})}} \sim N(0,\ 1)$$

由于 $Var(\hat{\mu})$ 的计算中涉及未知参数 σ^2，以 $\widehat{Var}(\hat{\mu})$ 代替，因此置信度为 $(1-\alpha)$ 的估计的双侧置信区间为：

$$\hat{\mu} \pm u_{1-\frac{\alpha}{2}} \times \sqrt{\widehat{Var}(\hat{\mu})}$$

18.1.2 SRS 总体总数 τ 的估计

利用样本平均值进行估计

$$\hat{\tau} = N\hat{\mu} = \frac{N}{n}\sum_{i=1}^{n} y_i = \frac{N}{n}\sum_{i=1}^{N} Y_iZ_i$$

$$E(\hat{\tau}) = \tau$$

[1] $\left(1 - \frac{n}{N}\right)$ 被称之为有限群体校正分数 (finite population correction fraction, FPC)，有放回抽样或 N 远大于 n 时不需要 FPC。

Horvitz-Thompson 估计量（HT 估计量）

点估计及其性质

$$\hat{\tau} = \sum_{i=1}^{n} w_i y_i = \sum_{i=1}^{N} w_i Y_i Z_i$$
$$E(\hat{\tau}) = \tau,\ Var(\hat{\tau}) = \frac{N^2}{n}\left(1 - \frac{n}{N}\right)\sigma^2$$
$$\widehat{Var}(\hat{\tau}) = \frac{N^2}{n}\left(1 - \frac{n}{N}\right)s^2$$

区间估计

$$\frac{\hat{\tau} - \tau}{\sqrt{Var(\hat{\tau})}} \sim N(0,\ 1)$$

由于 $Var(\hat{\tau})$ 的计算中涉及未知参数 σ^2，以 $\widehat{Var}(\hat{\tau})$ 代替，因此置信度为 $(1-\alpha)$ 的估计的双侧置信区间为：

$$\hat{\tau} \pm u_{1-\frac{\alpha}{2}} \times \sqrt{\widehat{Var}(\hat{\tau})}$$

下给出点估计估计量方差公式的证明。

证明.

$$\begin{aligned}
Var(\hat{\tau}) &= Var\left(\sum_{i=1}^{N} w_i Y_i Z_i\right) \\
&= \sum_{i=1}^{N} Var(w_i Y_i Z_i) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} Cov(w_i Y_i Z_i, w_j Y_j Z_j) \\
&= \sum_{i=1}^{N} w_i^2 Y_i^2 Var(Z_i) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} w_i Y_i w_j Y_j Cov(Z_i, Z_j)
\end{aligned}$$

注意到 $w_i = \frac{N}{n}$：

$$
\begin{aligned}
Var(\hat{\tau}) &= \sum_{i=1}^{N} w_i^2 Y_i^2 Var(Z_i) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} w_i Y_i w_j Y_j Cov(Z_i, Z_j) \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\sum_{i=1}^{N}\left[(N-1)Y_i^2 - \sum_{j=i+1}^{N} 2Y_iY_j\right] \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left[\sum_{i=1}^{N}(N-1)Y_i^2 - \sum_{i=1}^{N}\sum_{j=i+1}^{N} 2Y_iY_j\right] \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left[\sum_{i=1}^{N}(N-1)Y_i^2 - (\sum_{i=1}^{N} Y_i)^2 + \sum_{i=1}^{N} Y_i^2\right] \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left[N\sum_{i=1}^{N} Y_i^2 - (\sum_{i=1}^{N} Y_i)^2\right] \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left(\sum_{i=1}^{N} Y_i^2 - N\mu^2\right) \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left(\sum_{i=1}^{N} Y_i^2 - 2N\mu^2 + N\mu^2\right) \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left(\sum_{i=1}^{N} Y_i^2 - 2\mu\sum_{i=1}^{N} Y_i + N\mu^2\right) \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\sum_{i=1}^{N}(Y_i-\mu)^2 \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\sigma^2
\end{aligned}
$$

□

18.1.3 SRS 总体方差 σ^2 的估计

利用样本方差进行估计

$$
\hat{\sigma^2} = s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(y_i-\overline{y})^2 = \frac{1}{n-1}\sum_{i=1}^{N}(Y_i-\hat{\mu})^2 Z_i
$$

18.2 SRS 阳性率问题

阳性率问题是前述问题的一种特殊形式，Y_i 只能在 0 和 1 中取值。因此阳性率 p 即为总体均值 μ。

18.2.1 总体均值 p 的估计

点估计

$$\hat{p}=\frac{1}{n}\sum_{i=1}^{n}y_i=\frac{1}{n}\sum_{i=1}^{N}Y_iZ_i$$
$$E(\hat{p})=p,\ Var(\hat{p})=\frac{1}{n}\left(1-\frac{n}{N}\right)\sigma^2$$
$$\widehat{Var}(\hat{p})=\frac{1}{n}\left(1-\frac{n}{N}\right)s^2$$

区间估计

由于 $Var(\hat{p})$ 的计算中涉及未知参数 σ^2，以 $\widehat{Var}(\hat{p})$ 代替，因此置信度为 $(1-\alpha)$ 的估计的双侧置信区间为：

$$\hat{p}\pm u_{1-\frac{\alpha}{2}}\sqrt{\left(1-\frac{n}{N}\right)\frac{\hat{p}(1-\hat{p})}{n-1}}$$

需要注意上述计算公式需要满足 $n\hat{p}\geqslant 5$ 和 $n(1-\hat{p})\geqslant 5$，即大样本条件。

18.2.2 总体方差 σ^2 的估计

$$\hat{\sigma^2}=s^2=\frac{1}{n-1}\sum_{i=1}^{n}(y_i-\overline{y})^2=\frac{1}{n-1}\sum_{i=1}^{n}(y_i-\hat{p})^2=\frac{n}{n-1}\hat{p}(1-\hat{p})$$

18.2.3 总体方差 σ^2 与总体均值 p 的关系

由于 $Y_i^2=Y_i$，可得：

$$\sigma^2=\frac{1}{N-1}\sum_{i=1}^{N}(Y_i-p)^2=\frac{N}{N-1}p(1-p)$$

18.3 SRSWR 的参数估计

SRSWR 中 Q 的相关性质

$$\vec{Q}\sim\text{Multi}\left(n,\ \overbrace{\left(\frac{1}{N},\ \frac{1}{N},\ldots,\frac{1}{N}\right)}^{\text{N 个 }\frac{1}{N}}\right)$$
$$Q_i\sim\text{Binom}(n,\ \frac{1}{N})$$
$$E(Q_i)=\frac{n}{N},\ Var(Q_i)=\frac{n}{N}(1-\frac{n}{N})$$
$$Cov(Q_i,\ Q_j)=-\frac{n}{N^2}$$

证明. 由多项分布性质：多项分布随机变量的一维边际分布是二项分布，因此上第二、三式成立。下证第四式，将 Q_i 分解为独立二项分布随机变量的和，有：

$$\begin{aligned}
Cov(Q_i,\ Q_j) &= Cov\left(\sum_{k=1}^{n} I_i(k),\ \sum_{l=1}^{n} I_j(l)\right) \\
&= \sum_{k=1}^{n}\sum_{l=1}^{n} Cov(I_i(k),\ I_j(l)) \\
&= \sum_{k=l} Cov(I_i(k),\ I_j(l)) + \sum_{k\neq l} Cov(I_i(k),\ I_j(l))
\end{aligned}$$

由二项分布随机变量的独立性，后一项为 0：

$$\begin{aligned}
Cov(Q_i,\ Q_j) &= \sum_{k=1}^{n} Cov(I_i(k),\ I_j(k)) \\
&= \sum_{k=1}^{n} [E(I_i(k)I_j(k)) - E(I_i(k))E(I_j(k))]
\end{aligned}$$

同一次伯努利实验中不可能出现两个结果，前一项为 0：

$$\begin{aligned}
Cov(Q_i,\ Q_j) &= -\sum_{k=1}^{n} E(I_i(k))E(I_j(k)) \\
&= -np_ip_j \\
&= -\frac{n}{N^2}
\end{aligned}$$

□

18.3.1 SRSWR 总体总数 τ 的估计

$$\hat{\tau} = \frac{N}{n}\sum_{i=1}^{N} Y_iQ_i$$

$$E(\hat{\tau}) = \tau,\ ,Var(\hat{\tau}) = \frac{N(N-1)}{n}\sigma^2$$

证明.

$$\begin{aligned}
Var(\hat{\tau}) &= Var\left(\frac{N}{n}\sum_{i=1}^{N} Q_iY_i\right) \\
&= \frac{N^2}{n^2}\left[\sum_{i=1}^{N} Y_i^2 Var(Q_i) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} Y_iY_jCov(Q_i,Q_j)\right] \\
&= \frac{N^2}{n^2}\left[\sum_{i=1}^{N} Y_i^2\frac{n}{N}\left(1-\frac{1}{N}\right) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} Y_iY_j\frac{-n}{N^2}\right] \\
&= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2\left(1-\frac{1}{N}\right) - \frac{1}{N}\sum_{i=1}^{N}\sum_{j=i+1}^{N} 2Y_iY_j\right]
\end{aligned}$$

此处使用平方和公式（该技巧常用）：

$$
\begin{aligned}
Var(\hat{\tau}) &= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2\left(1-\frac{1}{N}\right)-\frac{1}{N}\left((\sum_{i=1}^{N} Y_i)^2-\sum_{i=1}^{N} Y_i^2\right)\right] \\
&= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2-\frac{1}{N}(\sum_{i=1}^{N} Y_i)^2\right]
\end{aligned}
$$

此处使用 $N\mu^2$ 并进行加减凑项（该技巧常用）：

$$
\begin{aligned}
Var(\hat{\tau}) &= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2-N\mu^2\right] \\
&= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2-2N\mu^2+N\mu^2\right]
\end{aligned}
$$

此处使用 $N\mu=\sum\limits_{i=1}^{N} Y_i$（该技巧常用）：

$$
\begin{aligned}
Var(\hat{\tau}) &= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2-2\mu\sum_{i=1}^{N} Y_i+N\mu^2\right] \\
&= \frac{N}{n}\sum_{i=1}^{N}(Y_i-\mu)^2 \\
&= \frac{N(N-1)}{n}\sigma^2
\end{aligned}
$$

□

18.4 样本容量的选择

抽样分布的方差决定置信区间的长度，样本容量增大的时候抽样分布的方差减小，置信区间变窄。

注意事项

通过控制总体均值的置信区间长度去选择样本容量而不从总体总数来考虑，因为总体总数的方差计算中还会涉及到 N^2，这对于无穷总体是无法进行计算的。

误差幅度 MOE

置信区间的半径称之为误差幅度 (margin of error, MOE)。

18.4.1 总体均值样本容量公式

$$
n_{\text{SRS}}=\frac{1}{\frac{d^2}{u^2\sigma^2}+\frac{1}{N}},\quad n_{\text{SRSWR}}=\frac{u^2\sigma^2}{d^2}
$$

二者有关系（又称为两步法）：

$$\frac{1}{n_{\text{SRS}}} = \frac{1}{n_{\text{SRSWR}}} + \frac{1}{N}$$

公式涉及到总体方差真实值 σ^2，解决方案：

1. 使用历史数据的样本方差代替 σ^2。
2. 由正态分布的性质，在 $\mu \pm 2\sigma$ 范围内应包含了 97.7% 的样本，因此，我们使用样本的极差来近似 4σ：用样本极差除 4 替代 σ。但是这个时候又涉及到极差从何而来的问题，因为是先确定样本容量再去做抽样，没有样本怎么来的极差呢？查阅资料得到样本的大致分布范围。

18.4.2 总体阳性率样本容量公式

$$n_{SRS} = \frac{Np(1-p)}{\frac{d^2}{u^2}(N-1) + p(1-p)}, \quad n_{\text{SRSWR}} = \frac{u^2 p(1-p)}{d^2}$$

但这里需要注意，阳性率问题两步法不能用，与理论公式不等。

公式涉及到阳性率的真实值 p，解决方法：

1. 有根据的推测，使用历史数据来替代真实阳性率。
2. 取 $p = 0.5$，最大化样本容量，进行保守估计。
3. 如果获取额外样本的代价大于开始一次抽样的代价（也就意味着最大化样本容量带来的代价大于去做一次抽样来估计一下真实值的代价），那在没有历史数据的情况下可以自己去抽样。

阳性率问题下理论公式难以推导的情况

蒙特卡罗，代码如下：

```
sample_size_p <- function(p, N, n, conf, repeat.times=10000) {
  moe_mc_help <- function(p, N, n, conf, repeat.times) {
    alpha <- 1 - conf
    u <- qnorm(1 - alpha / 2)
    X <- rep(c(0, 1), times = c(round(N * (1 - p)), round(N * p)))
    phat <- NULL
    for (i in 1:repeat.times) {
      x <- sample(X, n)
      phat <- append(phat, mean(x))
    }
    v <- var(phat)
```

```
    moe <- sqrt(v) * u
    moe
  }
  data.frame(n, sapply(n, moe_mc_help, p=p, N=N, conf=conf,
                       repeat.times=repeat.times))
}
set.seed(1234)
sample_size_p(0.15, 3000, 860:880, 0.95)
```

18.5 简单随机抽样适用条件

1. 可使用的额外信息较少。

2. 研究多元关系，没有特别特殊的理由使用别的抽样方法。

Chapter 19

回归估计与比例估计

本章介绍比例估计 (regression estimate)与比例估计 (ratio estimate)，回归估计认为待估参数 y 与某个变量 x（即辅助变量 (auxiliary variable)）之间存在如下关系：

$$y = B_1 x + B_0$$

比例估计中取 $B_0 = 0$，因此它可以看作为回归估计的一个特例。先来介绍辅助变量。

19.1 辅助变量

在回归估计中我们通过辅助变量去得到我们想要的估计值。

19.1.1 辅助变量选择要求

辅助变量需要满足以下条件：

1. 辅助变量的获得需要简单快捷。如果它的值都很难得到或者得不到那根本没办法作回归估计。
2. 辅助变量需要和样本之间存在高度的线性相关性，在比例估计中我们还要求二者线性方程中的截距为 0（如果存在截距那截距就会是一个偏倚）。

选择好辅助变量并获取数据后，可以去做辅助变量与样本的线性回归，来检验是否满足高度线性相关性（这里其实假设了数据满足正态分布）。在比例估计中我们还要去检验截距是否为 0。如果线性回归后的截距很小但不显著，我们可以认为满足要求；如果截距较大但不显著，我们认为是样本随机性带来的问题，可以认为截距满足为 0 的条件。

19.1.2 辅助变量与待估参数的相关性

对于辅助变量与待估参数的相关性，有如下结论：

$$Corr(\bar{x}, \bar{y}) = Corr(X, Y)$$

证明.

$$
\begin{aligned}
Cov(\bar{x},\bar{y}) &= Cov(\frac{1}{n}\sum_{i=1}^{N}X_iZ_i,\frac{1}{n}\sum_{j=1}^{N}Y_jZ_j)\\
&= \frac{1}{n^2}\left[\sum_{i=1}^{N}X_iY_iVar(Z_i)+2\sum_{i=1}^{N}\sum_{j\neq i}^{N}X_iY_jCov(Z_i,Z_j)\right]\\
&= (1-\frac{n}{N})\frac{1}{nN}\frac{1}{N-1}\left((N-1)\sum_{i=1}^{N}X_iY_i-\sum_{i=1}^{N}\sum_{j\neq i}^{N}X_iY_j\right)\\
&= (1-\frac{n}{N})\frac{1}{nN}\frac{1}{N-1}\left[(N-1)\sum_{i=1}^{N}X_iY_i-\left(\sum_{i=1}^{N}\sum_{j=1}^{N}X_iY_j-\sum_{i=1}^{N}X_iY_i\right)\right]\\
&= (1-\frac{n}{N})\frac{1}{nN}\frac{1}{N-1}\left(N\sum_{i=1}^{N}X_iY_i-\sum_{i=1}^{N}\sum_{j=1}^{N}X_iY_j\right)\\
&= (1-\frac{n}{N})\frac{1}{nN}\frac{1}{N-1}\left(N\sum_{i=1}^{N}X_iY_i-\sum_{i=1}^{N}X_i\sum_{j=1}^{N}Y_j\right)\\
&= (1-\frac{n}{N})\frac{1}{n}\frac{1}{N-1}\left(\sum_{i=1}^{N}X_iY_i-N\mu_X\mu_Y\right)\\
&= (1-\frac{n}{N})\frac{1}{n}\frac{1}{N-1}\left(\sum_{i=1}^{N}X_iY_i-2N\mu_X\mu_Y+N\mu_X\mu_Y\right)\\
&= (1-\frac{n}{N})\frac{1}{n}\frac{1}{N-1}\left(\sum_{i=1}^{N}X_iY_i-\sum_{i=1}^{N}X_i\mu_Y-\sum_{i=1}^{N}Y_i\mu_X+N\mu_X\mu_Y\right)\\
&= (1-\frac{n}{N})\frac{1}{n}\frac{1}{N-1}\sum_{i=1}^{N}(X_iY_i-X_i\mu_Y-Y_i\mu_X+\mu_X\mu_Y)\\
&= (1-\frac{n}{N})\frac{1}{n}\frac{\sum_{i=1}^{N}(X_iY_i-X_i\mu_Y-Y_i\mu_X+\mu_X\mu_Y)}{N-1}\\
&= (1-\frac{n}{N})\frac{1}{n}\frac{\sum_{i=1}^{N}(X_i-\mu_X)(Y_i-\mu_Y)}{N-1}\\
&= (1-\frac{n}{N})\frac{1}{n}Cov(X,Y)
\end{aligned}
$$

$$
\begin{aligned}
Corr(\bar{x},\bar{y}) &= \frac{Cov(\bar{x},\bar{y})}{\sqrt{Var(\bar{x})Var(\bar{y})}}\\
&= \frac{(1-\frac{n}{N})\frac{1}{n}Cov(X,Y)}{\sqrt{(1-\frac{n}{N})^2\frac{1}{n^2}Var(X)Var(Y)}}\\
&= \frac{Cov(X,Y)}{\sqrt{Var(X)Var(Y)}}\\
&= Corr(X,Y)
\end{aligned}
$$

□

19.2 估计量

19.2.1 回归估计量

比例估计量有如下计算公式（其中 μ_X 和 τ_X 是已知的）：

$$\hat{B}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{s_y \hat{R}}{s_x}$$

$$\hat{B}_0 = \bar{y} - \hat{B}_1 \bar{x}$$

$$\hat{\mu}_{Y_{reg}} = \hat{B}_1 \mu_X + \hat{B}_0 = \hat{B}_1(\mu_X - \bar{x}) + \bar{y}$$

$$\hat{\tau}_{Y_{reg}} = \hat{B}_1 \tau_X + \hat{B}_0$$

19.2.2 比例估计量

比例估计量有如下计算公式（其中 μ_X 和 τ_X 是已知的）：

$$\hat{B} = \frac{\bar{y}}{\bar{x}} = \frac{\tau_y}{\tau_x}$$

$$\hat{\mu}_{Yr} = \hat{B}\mu_X$$

$$\hat{\tau}_{Yr} = \hat{B}\tau_X$$

其中 $\hat{B}$ 是比例系数 B 的估计[1]，对于 B 的真实值，应有 $B = \frac{\mu_Y}{\mu_X} = \frac{\tau_Y}{\tau_X}$。[2]

19.3 偏差

19.3.1 回归估计的偏差

由回归估计量计算公式显然可知回归估计是有偏的。

19.3.2 比例估计的偏差

下给出比例估计量的偏差公式：

$$bias(\hat{\mu}_{Yr}) = E(\hat{\mu}_{Yr}) - \mu_Y = Cov(-\hat{B}, \bar{x})$$

$$bias(\hat{\tau}_{Yr}) = E(\hat{\tau}_{Yr}) - \tau_Y = Cov(-\hat{B}, \bar{x})N$$

[1]这是一个有偏估计!!!

[2]依据辅助变量的选择原则，X 与 Y 之间需要满足线性关系且截距为 0，B 其实就是线性关系中的斜率，同时证明了 $Corr(\bar{x}, \bar{y}) = Corr(X, Y)$，因此 $\hat{B}$ 和 B 既可以由均值来表示也可以由总体总数来表示。

证明.

$$
\begin{aligned}
Cov(-\hat{B},\bar{x}) &= -Cov(\hat{B},\bar{x}) \\
&= -\Big(E(\hat{B}\bar{x}) - E(\hat{B})E(\bar{x})\Big) \\
&= -\Big(E(\frac{\bar{y}}{\bar{x}}\bar{x}) - E(\hat{B})\mu_X\Big) \\
&= E(\hat{\mu}_{Yr}) - E(\bar{y}) \\
&= E(\hat{\mu}_{Yr}) - \mu_Y
\end{aligned}
$$

□

上式不便于计算，可以用下式进行估计：

$$
\begin{aligned}
bias(\hat{\mu}_{Yr}) &\approx \frac{1}{\mu_X}\left[BVar(\bar{x}) - Cov(\bar{x},\bar{y})\right] = \left(1-\frac{n}{N}\right)\frac{1}{n\mu_X}(B\sigma_X^2 - Corr(X,Y)\sigma_X\sigma_Y) \\
bias(\hat{\tau}_{Yr}) &\approx \frac{\tau_X}{\mu_X^2}\left[BVar(\bar{x}) - Cov(\bar{x},\bar{y})\right] = \left(1-\frac{n}{N}\right)\frac{\tau_X}{n\mu_X^2}(B\sigma_X^2 - Corr(X,Y)\sigma_X\sigma_Y)
\end{aligned}
$$

证明.

$$
\begin{aligned}
bias(\hat{\mu}_{Yr}) &= E(\hat{B}\mu_X) - \mu_Y \\
&= \mu_X E\left(\frac{\bar{y}}{\bar{x}} - \frac{\mu_Y}{\mu_X}\right) \\
&= \mu_X E\left(\frac{\bar{y}}{\mu_X}\frac{\mu_X}{\bar{x}} - \frac{\mu_Y}{\mu_X}\right) \\
&= \mu_X E\left(\frac{\bar{y}}{\mu_X} - \frac{\bar{y}}{\mu_X}\frac{\bar{x}-\mu_X}{\bar{x}} - \frac{\mu_Y}{\mu_X}\right) \\
&= \mu_X E\left(\frac{\bar{y}}{\mu_X}\frac{\mu_X-\bar{x}}{\bar{x}}\right) \\
&= \mu_X E\left(\frac{\bar{y}}{\mu_X}\frac{\mu_X-\bar{x}}{\bar{x}}\frac{\mu_X}{\bar{x}}\frac{\bar{x}}{\mu_X}\right) \\
&= \mu_X E\left[\frac{\bar{y}}{\mu_X^2}(\mu_X-\bar{x})\frac{\mu_X}{\bar{x}}\right] \\
&= \mu_X E\left[\frac{\bar{y}}{\mu_X^2}(\mu_X-\bar{x})(1-\frac{\bar{x}-\mu_X}{\bar{x}})\right] \\
&= \mu_X E\left[\frac{\bar{y}}{\mu_X^2}\left((\mu_X-\bar{x}) + \frac{(\bar{x}-\mu_X)^2}{\bar{x}}\right)\right] \\
&= \mu_X E\left[\frac{-\bar{y}(\bar{x}-\mu_X)}{\mu_X^2} + \frac{\bar{y}(\bar{x}-\mu_X)^2}{\mu_X^2\bar{x}}\right] \\
&= \frac{1}{\mu_X}E\left[\frac{\bar{x}}{\bar{y}}(\bar{x}-\mu_X)^2 - (\bar{x}-\mu_X)\bar{y}\right] \\
&= \frac{1}{\mu_X}\Big[E[\hat{B}(\bar{x}-\mu_X)^2] - E[\bar{y}(\bar{x}-\mu_X)]\Big] \\
&= \frac{1}{\mu_X}\Big[E[(\hat{B}-B+B)(\bar{x}-\mu_X)^2] - Cov(\bar{x},\bar{y})\Big] \\
&= \frac{1}{\mu_X}\Big[E[(\hat{B}-B)(\bar{x}-\mu_X)^2 + B(\bar{x}-\mu_X)^2] - Cov(\bar{x},\bar{y})\Big]
\end{aligned}
$$

由于 $E\left[(\hat{B}-B)(\bar{x}-\mu_X)^2\right]$ 极小（严谨证明不提供），因此:

$$\begin{aligned} bias(\hat{\mu}_{Yr}) &\approx \frac{1}{\mu_X}\left[E[B(\bar{x}-\mu_X)^2]-Cov(\bar{x},\bar{y})\right] \\ &= \frac{1}{\mu_X}\left[BVar(\bar{x})-Cov(\bar{x},\bar{y})\right] \end{aligned}$$ □

由此，在以下情况比例估计的偏倚会较小：

1. n 较大。
2. $\frac{n}{N}$ 较大。
3. μ_X 较大。
4. σ_x 较小。
5. R 接近 ± 1。

19.4 均方误差

19.4.1 回归估计量的均方误差

$$\begin{aligned} MSE(\hat{\mu}_{Y_{reg}}) &= E\left\{\left[\bar{y}+\hat{B}_1(\mu_X-\bar{x})-\mu_Y\right]^2\right\} \\ &\approx Var(\bar{d}) \\ &= \left(1-\frac{n}{N}\right)\frac{\sigma_d^2}{n} \end{aligned}$$

其中：

$$d_i = y_i - \left[\mu_Y + B_1(x_i-\mu_X)\right]$$

可进一步证明得到：

$$\sigma_d^2 = \frac{1}{N-1}\sum_{i=1}^{N}[y_i-\mu_Y-B_1(x_i-\mu_X)]^2 = (1-R^2)\sigma_Y^2$$

证明. 下求 $E(d)$：

$$E(d) = \frac{1}{N}\left[\sum_{i=1}^{N} y_i - N\mu_Y - B_1\sum_{i=1}^{N} x_i + B_1 N\mu_X\right] = 0$$

因此：

$$\begin{aligned} \sigma_d^2 &= \frac{1}{N-1}\sum_{i=1}^{N}\left[y_i-\mu_Y-B_1(x_i-\mu_X)\right]^2 \\ &= \frac{1}{N-1}\left[\sum_{i=1}^{N}(y_i-\mu_Y)^2+\sum_{i=1}^{N}B_1^2(x_i-\mu_X)^2-\sum_{i=1}^{N}2B_i(y_i-\mu_Y)(x_i-\mu_X)\right] \\ &= \sigma_Y^2 + B_1^2\sigma_X^2 - 2B_1R\sigma_X\sigma_Y \end{aligned}$$

而：

$$B_1 = \frac{\sigma_Y R}{\sigma_X}$$

所以：

$$\begin{aligned}
\sigma_d^2 &= \sigma_Y^2 + B_1^2\sigma_X^2 - 2B_1 R\sigma_X\sigma_Y \\
&= \sigma_Y^2 + \frac{\sigma_Y^2 R^2}{\sigma_X^2}\sigma_X^2 - 2\frac{\sigma_Y R}{\sigma_X}R\sigma_X\sigma_Y \\
&= \sigma_Y^2 - R^2\sigma_Y^2 \\
&= (1-R^2)\sigma_Y^2
\end{aligned}$$

□

由此，在以下情况 $MSE(\hat{\mu}_{Y_{reg}})$ 较小：

1. n 较大。
2. $\frac{n}{N}$ 较大。
3. σ_Y 较小。
4. R 接近 ± 1。

19.4.2 比例估计量的均方误差

由 David and Sukhatme, 1974：

$$\begin{aligned}
MSE(\hat{\mu}_{Yr}) &\approx E\left[(\bar{y} - B\bar{x})^2\right] \\
&= \left(1 - \frac{n}{N}\right)\frac{\sigma_Y^2 - 2BR\sigma_X\sigma_Y + B^2\sigma_X^2}{n} \\
&\approx Var(\hat{\mu}_{Yr})
\end{aligned}$$

19.5 方差

19.5.1 回归估计的方差

可证得：

$$Var(\hat{\mu}_{Y_{reg}}) = Var(\bar{d}) = \left(1 - \frac{n}{N}\right)\frac{\sigma_d^2}{n} = \left(1 - \frac{n}{N}\right)\frac{1}{n}(1-R^2)\sigma_Y^2$$

定义 $e_i = y_i - (\hat{B}_1 x_i + \hat{B}_0)$ 可得：

$$\widehat{Var}(\hat{\mu}_{Y_{reg}}) = \left(1 - \frac{n}{N}\right)\frac{s_e^2}{n}$$

这里 s_e^2 可取两种计算公式：

$$s_e^2 = \frac{1}{n-1}\sum_{i=1}^{n} e_i^2 = \left(1 - \frac{n}{N}\right)\frac{1}{n}(1-\hat{R}^2)s_y^2$$

$$s_e^2 = \frac{1}{n-2}\sum_{i=1}^{n} e_i^2$$

第二种是考虑回归估计有两个待估参数，自由度为 $n-2$，这样子做修正了回归中自由度的问题。

由上述总结：

$$\widehat{Var}(\hat{\mu}_{Y_{reg}}) = \left(1-\frac{n}{N}\right)\frac{1}{n}\frac{1}{n-1}\sum_{i=1}^{n}\left[y_i-(\hat{B}_1x_i+\hat{B}_0)\right]^2$$
$$\widehat{Var}(\hat{\mu}_{Y_{reg}}) = \left(1-\frac{n}{N}\right)\frac{1}{n}\frac{1}{n-2}\sum_{i=1}^{n}\left[y_i-(\hat{B}_1x_i+\hat{B}_0)\right]^2$$

19.5.2 比例估计的方差

由 Delta method（见定理 14.1），注意到关系：

$$\hat{B} = \frac{\bar{y}}{\bar{x}} = g(\bar{x},\bar{y})$$
$$\hat{\mu}_{Yr} = \hat{B}\mu_X = g(\hat{B})$$
$$\hat{\tau}_{Yr} = \hat{\mu}_{Yr}\frac{\tau_X}{\mu_X} = \hat{\mu}_{Yr}N$$

可得以下比例估计量的近似方差 ($R = Corr(X,Y)$)：

$$Var(\hat{B}) \approx \left(1-\frac{n}{N}\right)\frac{\sigma_Y^2-2BR\sigma_X\sigma_Y+B^2\sigma_X^2}{n\mu_X^2} = \left(1-\frac{n}{N}\right)\frac{\sigma_\varepsilon^2}{n\mu_X^2}$$
$$\widehat{Var}(\hat{B}) \approx \left(1-\frac{n}{N}\right)\frac{s_y^2-2\hat{B}\hat{R}s_xs_y+\hat{B}^2s_x^2}{n\bar{x}^2} = \left(1-\frac{n}{N}\right)\frac{s_e^2}{n\bar{x}^2}$$
$$Var(\hat{\mu}_{Yr}) \approx \left(1-\frac{n}{N}\right)\frac{\sigma_Y^2-2BR\sigma_X\sigma_Y+B^2\sigma_X^2}{n} = \left(1-\frac{n}{N}\right)\frac{\sigma_\varepsilon^2}{n}$$
$$\widehat{Var_1}(\hat{\mu}_{Yr}) \approx \left(1-\frac{n}{N}\right)\frac{s_y^2-2\hat{B}\hat{R}s_xs_y+\hat{B}^2s_x^2}{n} = \left(1-\frac{n}{N}\right)\frac{s_e^2}{n}$$
$$Var(\hat{\tau}_{Yr}) \approx N\left(N-n\right)\frac{\sigma_Y^2-2BR\sigma_X\sigma_Y+B^2\sigma_X^2}{n} = N(N-n)\frac{\sigma_\varepsilon^2}{n}$$
$$\widehat{Var_1}(\hat{\tau}_{Yr}) \approx N(N-n)\frac{s_y^2-2\hat{B}\hat{R}s_xs_y+\hat{B}^2s_x^2}{n} = N(N-n)\frac{s_e^2}{n}$$

再给出第二种总体均值、总体总数比例估计量抽样分布方差的估计：

$$\widehat{Var_2}(\hat{\mu}_{Yr}) = \widehat{Var}(\hat{B}\mu_X) = \widehat{Var}(\hat{B})\mu_X^2 \approx \left(1-\frac{n}{N}\right)\left(\frac{\mu_X}{\bar{x}}\right)^2\frac{s_e^2}{n}$$
$$\widehat{Var_2}(\hat{\tau}_{Yr}) \approx N(N-n)\left(\frac{\mu_X}{\bar{x}}\right)^2\frac{s_e^2}{n}$$

下给出上述公式中所有等式的推导。

证明. 从模型的角度，根据 MSE 的估计来看（最后一行是使用了 SRS 均值的方差公式）：

$$
\begin{aligned}
Var(\hat{\mu}_{Yr}) \approx MSE(\hat{\mu}_{Yr}) &\approx E\left[(\bar{y} - B\bar{x})^2\right] \\
&= E\left[(\frac{1}{n}\sum_{i=1}^{n} y_i - B\frac{1}{n}\sum_{i=1}^{n} x_i)^2\right] \\
&= E\left[(\frac{1}{n}\sum_{i=1}^{n}(y_i - Bx_i))^2\right] \\
\varepsilon_i = y_i - Bx_i,\ \mu_\varepsilon &= E(\varepsilon_i) = 0 \\
Var(\hat{\mu}_{Yr}) &\approx E\left[(\frac{1}{n}\sum_{i=1}^{n}(y_i - Bx_i))^2\right] \\
&= E\left[(\bar{\varepsilon})^2\right] \\
&= E\left[(\bar{\varepsilon} - 0)^2\right] \\
&= E\left[(\bar{\varepsilon} - \mu_\varepsilon)^2\right] \\
&= Var(\bar{\varepsilon}) \\
Var(\hat{\mu}_{Yr}) \approx Var(\bar{\varepsilon}) &= \left(1 - \frac{n}{N}\right)\frac{\sigma_\varepsilon^2}{n}
\end{aligned}
$$

对于 σ_ε^2：

$$
\begin{aligned}
\sigma_\varepsilon^2 &= \frac{1}{N-1}\left[\sum_{i=1}^{N} y_i^2 + B^2\sum_{i=1}^{N} x_i^2 - 2B\sum_{i=1}^{N} x_i yi\right] \\
&= \frac{1}{N-1}\left[\sum_{i=1}^{N}(y_i - \mu_Y + \mu_Y)^2 + B^2\sum_{i=1}^{N}(x_i - \mu_X + \mu_X)^2 - 2B\sum_{i=1}^{N} x_i yi\right] \\
&= \frac{1}{N-1}\left[\sum_{i=1}^{N}(y_i - \mu_Y)^2 + 2\sum_{i=1}^{N}(y_i - \mu_Y)\mu_Y + N\mu_Y^2\right. \\
&\qquad \left. + B^2\sum_{i=1}^{N}(x_i - \mu_X)^2 + 2B^2\sum_{i=1}^{N}(x_i - \mu_X)\mu_X + B^2 N\mu_X^2 - 2B\sum_{i=1}^{N} x_i y_i\right] \\
&= \sigma_Y^2 + B^2\sigma_X^2 + \frac{1}{N-1}\left[N\mu_Y^2 + B^2 N\mu_X^2 - 2B\sum_{i=1}^{N} x_i y_i\right] \\
&= \sigma_Y^2 + B^2\sigma_X^2 + \frac{1}{N-1}\left[N\mu_Y^2 + B^2 N\mu_X^2 - 2B\sum_{i=1}^{N}(x_i - \mu_X + \mu_X)(y_i - \mu_Y + \mu_Y)\right] \\
&= \sigma_Y^2 + B^2\sigma_X^2 + \frac{1}{N-1}\left[N\mu_Y^2 + B^2 N\mu_X^2 - 2B\sum_{i=1}^{N}(x_i - \mu_X)(y_i - \mu_Y) - 2BN\mu_X\mu_Y\right] \\
&= \sigma_Y^2 + B^2\sigma_X^2 - 2BCov(X,Y) + \frac{1}{N-1}\left[N\mu_Y^2 + B^2 N\mu_X^2 - 2BN\mu_X\mu_Y\right]
\end{aligned}
$$

因为：

$$
B = \frac{\mu_Y}{\mu_X}
$$

所以：

$$
\begin{aligned}
N\mu_Y^2 + B^2 N\mu_X^2 - 2BN\mu_X\mu_Y &= N\mu_Y^2 + \frac{\mu_Y^2}{\mu_X^2}N\mu_X^2 - 2\frac{\mu_Y}{\mu_X}N\mu_X\mu_Y \\
&= 2N\mu_Y^2 - 2N\mu_Y^2 \\
&= 0
\end{aligned}
$$

也就有：

$$\sigma_\varepsilon^2 = \sigma_Y^2 - 2BR\sigma_X\sigma_Y + B^2\sigma_X^2$$

令 $e_i = y_i - \hat{B}x_i$，将它看作为 ε_i 的估计，则有：

$$s_e^2 = s_y^2 - 2\hat{B}\hat{R}s_x s_y + \hat{B}^2 s_x^2 \qquad \square$$

19.6 置信区间

19.6.1 回归估计的置信区间

由于比例估计量抽样分布的方差公式中存在未知量，大样本情况下可得如下估计的置信区间：

$$\hat{\mu}_{Y_{reg}} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var}(\hat{\mu}_{Y_{reg}})}$$

19.6.2 比例估计的置信区间

由于比例估计量抽样分布的方差公式中存在未知量，大样本情况下可得如下估计的置信区间：

$$
\begin{gathered}
\hat{B} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var}(\hat{B})} \\
\hat{\mu}_{Yr} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var}(\hat{\mu}_{Yr})} \\
\hat{\tau}_{Yr} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var}(\hat{\tau}_{Yr})}
\end{gathered}
$$

19.7 比例估计样本容量的选择

$$n_r = \frac{Nu^2\sigma_\varepsilon^2}{u^2\sigma_\varepsilon^2 + Nd^2}$$

19.8 回归估计、比例估计与 HT 估计的比较

回归估计与比例估计是有偏的，但它们的方差比 HT 估计小很多，MSE 更小。

Chapter 20

标记重捕法

不对标记重捕法的具体操作进行介绍，高中都学过。

下给出标记重捕法 (tag recapture)的符号说明。

1. X：初始样本容量，即被标记数据。

2. y：被重捕的样本数。

3. x：重捕样本中被标记的数量。

4. t：总体总数。

20.1 假设

1. 种群是封闭的，种群数量在标记与重捕期间没有增减。

2. 每个样本都是来自种群的简单随机样本。

3. 两次样本独立。

4. 标记不能丢失。

即：重捕个体中已标记个体的比例与种群中已标记个体的比例相等。

20.2 总体总数 t 的估计

20.2.1 点估计

$$
\begin{aligned}
\hat{t} &= \frac{y}{x}X \\
Var(\hat{t}) &= \frac{(yX)^2}{E^3(x)}\frac{(t-y)(t-X)}{t(t-1)} \\
\widehat{Var}(\hat{t}) &= \frac{Xy(X-x)(y-x)}{x^3}
\end{aligned}
$$

下给出估计方差公式的证明。

证明. 在标记重捕法中，$x \sim H(y, X, t)$。因此可得：

$$
E(x) = \frac{yX}{t},\ Var(x) = \frac{yX(t-y)(t-X)}{t^2(t-1)}
$$

而：

$$
\hat{t} = yX\frac{1}{x}
$$

所以由定理 14.1：

$$
\begin{aligned}
Var(\hat{t}) &= Var(yX\frac{1}{x}) \\
&= (yX)^2 Var(\frac{1}{x}) \\
&\approx (yX)^2\left(\frac{-1}{E^2(x)}\right)^2 Var(x) \\
&= \frac{(yX)^2}{E^4(x)}\frac{yX}{t}\frac{(t-y)(t-X)}{t(t-1)} \\
&= \frac{(yX)^2}{E^3(x)}\frac{(t-y)(t-X)}{t(t-1)}
\end{aligned}
$$

用 x 替代 $E(x)$（相当于是一次简单随机抽样，利用无偏性），然后考虑 t 较大时的近似，最后还剩一个 t，用 $\hat{t}$ 带入进行计算，即可得到：

$$
\begin{aligned}
\widehat{Var}(\hat{t}) &= \frac{(yX)^2}{x^3}\frac{(t-y)(t-X)}{t(t-1)} \\
&\approx \frac{(yX)^2}{x^3}\frac{(t-y)(t-X)}{t^2} \\
&= \frac{(yX)^2}{x^3}\left(1-\frac{X}{t}\right)\left(1-\frac{y}{t}\right) \\
&\approx \frac{Xy(X-x)(y-x)}{x^3}
\end{aligned}
$$

□

极端情况下的修正

在极端情况下，x 可能为 0 或很小，那么 $\widehat{Var}(\hat{t})$ 就会无限大，此时作如下修正（即不带入 $\hat{t}$，而是代入 $\tilde{t}$）：

$$\tilde{t} = \frac{(X+1)(y+1)}{x+1} - 1$$
$$\widehat{Var}(\tilde{t}) = \frac{(X+1)(y+1)(y-x)(X-x)}{(x+1)^2(x+2)}$$

20.2.2 区间估计

正态近似求置信区间

由点估计方差公式，易得如下估计的总体总数地置信区间：

$$\hat{t} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var}(\hat{t})}, \quad \tilde{t} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var}(\tilde{t})}$$

正态近似置信区间可能存在的问题

正态近似置信区间可能会存在：置信区间左端点小于两次捕捉到的总数的现象，这显然是不合理的。

Pearsonχ^2 检验求置信区间

由标记重捕法使用条件，第一次被捕到和第二次被捕到这两件事情是独立的，由此可构建如下的列联表：

	第二次捕获: 是	第二次捕获: 否
第一次捕获：是	a	b
第一次捕获：否	c	d

表 20.1: 标记重捕法的列联表示意图

在这个表里，a, c, b 显然都是已知的，只有 d 是未知的。可以通过给 d 赋值的方式，去检验列联表行列变量之间是否独立（参考 section 26.4.1），选择合适的 d 值（即让独立性检验结果显著的 d 值）作为置信区间。

似然比检验

由样本可计算出 $\hat{t}$，然后可以构建如下假设：

$$H_0 : \theta = \hat{t} \quad H_1 : \theta = \theta_A$$

进行似然比检验（参考 section 26.5）。置信区间为拒绝零假设的 θ_A 构成的区间，即比 $\hat{t}$ 更适合作为模型参数的 θ_A 构成置信区间。

bootstrap 求置信区间

在第二个样本中进行 bootstrap，有放回的抽取 y 个样本，计算每个样本对总体总数的估计值 $\hat{t}$，重复 N 次。将 N 个 $\hat{t}$ 从小到大排序，在此基础上取分位点即产生置信区间，

代码

以上四种方法的代码如下：

```
tag_recapture_CI <- function(a, b, c, d, alpha = 0.05,
   method = c("normal", "chisq", "fisher", "likelihood", "bootstrap"),
   x.correct = FALSE, N = 1000, seed = 42) {
  # Ensure the 'method' parameter is valid
  method <- match.arg(method)

  if (method == "chisq") {
    # Pearson's Chi-squared test
    p.values <- sapply(d, function(d_i) {
      chisq.test(matrix(c(a, b, c, d_i), nrow = 2, byrow = TRUE),
                 correct = FALSE)$p.value
    })
    valid_d <- d[p.values > alpha]
    if (length(valid_d) == 0) {
      stop("No values satisfy the p-value > alpha condition.")
    }
    return(sum(c(a, b, c)) + range(valid_d))

  } else if (method == "fisher"){
    # Fisher's exact test
    p.values <- sapply(d, function(d_i) {
      fisher.test(matrix(c(a, b, c, d_i), nrow = 2, byrow =
      ↪  TRUE))$p.value
    })
    valid_d <- d[p.values > alpha]
    if (length(valid_d) == 0) {
      stop("No values satisfy the p-value > alpha condition.")
    }
    return(sum(c(a, b, c)) + range(valid_d))

  } else if (method == "normal") {
```

```r
    # Normal approximation method
    X <- a + b
    y <- a + c
    x <- a
    if (x.correct) {
      t_hat <- (X + 1) * (y + 1) / (x + 1) - 1
      V_hat <- ((X + 1) * (y + 1) * (y - x) * (X - x)) / ((x + 1)^2 * (x + 2))
    } else {
      t_hat <- y * X / x
      V_hat <- y * X * (y - x) * (X - x) / x^3
    }
    CI_lower <- t_hat - qnorm(1 - alpha / 2) * sqrt(V_hat)
    CI_upper <- t_hat + qnorm(1 - alpha / 2) * sqrt(V_hat)
    return(c(CI_lower, CI_upper))

  } else if (method == "bootstrap") {
    # Bootstrap method
    set.seed(seed)
    sample.frame <- c(rep(1, a), rep(0, c)) # Construct sample frame
    bootstrap_estimates <- replicate(N, {
      sampled <- sample(sample.frame, a + c, replace = TRUE)
      x_boot <- sum(sampled)
      (a + b) * (a + c) / x_boot
    })
    CI <- quantile(bootstrap_estimates, probs = c(alpha / 2, 1 - alpha / 2))
    return(floor(CI))

  } else if (method == "likelihood") {
    # Likelihood method
    t_hat <- (a + b) * (a + c) / a
    ll_max <- dhyper(a, a + b, t_hat - (a + b), a + c, log = TRUE)
    ll <- sapply(d, function(d_i) {
      dhyper(a, a + b, d_i, a + c, log = TRUE)
    })
    valid_d <- d[2 * (ll_max - ll) < qchisq(1 - alpha, df = 1)]
    if (length(valid_d) == 0) {
```

```
      stop("No values satisfy the likelihood condition.")
    }
    return(a + b + range(valid_d))
  }
}
```

Chapter 21

分层抽样

分层抽样与分类型辅助变量息息相关。其核心为：

把目标群体分为 H 个亚群体 (stratum)。亚群体之间不重叠，它们构成整个群体（每个抽样单元属于且只属于某个亚群体）。在每个亚群体中通过概率抽样的方法进行独立抽样，然后汇集信息进行群体估计。

当亚群体内的单元值趋于一致时，分层抽样有意义。

为什么要使用分层抽样

分层抽样相比于 SRS 具有如下优势：

1. 分层抽样可以避免因为不同类型的样本对研究结果会产生显著差异从而导致的严重样本选择偏倚。

2. 分层抽样过程有可能更易于管理，同时可以降低成本。

3. 分层抽样不仅可以估计群体的特征，还可以估计亚群体特征。

4. 样本数相同的情况下，分层抽样通常比 SRS 更加精确。当亚群体内的单元值趋于一致时，该结论尤其正确。

分层随机抽样基本设置

1. 必须知道每个 $N_h,\ h = 1, 2, \ldots, H$。

2. 在每一个层里面独立地使用 SRS。

公式	含义
$\tau_h = \sum_{j=1}^{N_h} Y_{hj}$	第 h 层的总量
$\tau = \sum_{h=1}^{H} \tau_{Y_h}$	总体总量
$\mu_h = \frac{\sum_{j=1}^{N_h} Y_{hj}}{N_h}$	第 h 层的均值
$\mu = \frac{\sum_{h=1}^{H}\sum_{j=1}^{N_h} Y_{hj}}{N}$	总体均值
$\sigma_h^2 = \frac{\sum_{j=1}^{N_h}\left(Y_{hj}-\mu_h\right)^2}{N_h-1}$	第 h 层的方差
$\sigma^2 = \frac{\sum_{h=1}^{H}\sum_{j=1}^{N_h}\left(Y_{hj}-\mu\right)^2}{N-1}$	总体方差

表 21.1: 分层抽样部分计算公式

21.1 参数估计

21.1.1 亚群体特征的估计

因为分层随机抽样在亚群体中为简单随机抽样，由简单随机抽样的估计公式即有如下公式：

$$\hat{\mu}_h = \frac{1}{n_h}\sum_{j=1}^{n_h} y_{hj}$$

$$\hat{\tau}_h = \frac{N_h}{n_h}\sum_{j=1}^{n_h} y_{hj} = N_h\hat{\mu}_h$$

$$\hat{\sigma^2}_h = s_h^2 = \frac{1}{n_h-1}\sum_{j=1}^{n_h}(y_{hj}-\hat{\mu}_h)^2$$

21.1.2 总体总量 $\hat{\tau}$ 的估计

计算公式

$$\hat{\tau}_{str} = \sum_{h=1}^{H}\hat{\tau}_h = \sum_{h=1}^{H} N_h\bar{y}_h$$

抽样权重形式

$$\hat{\tau}_{str} = \sum_{h=1}^{H} N_h\bar{y}_h = \sum_{h=1}^{H}\frac{N_h}{n_h}\sum_{j=1}^{n_h} y_{hj} = \sum_{h=1}^{H}\sum_{j=1}^{n_h}\frac{N_h}{n_h}y_{hj} = \sum_{h=1}^{H}\sum_{j=1}^{n_h} w_{hj}y_{hj}$$

21.1.3 总体均值 $\hat{\mu}$ 的估计

计算公式

$$\hat{\mu}_{str} = \frac{\hat{\tau}_{str}}{N} = \frac{1}{N}\sum_{h=1}^{H} N_h \bar{y}_h$$

抽样权重形式

只需注意到 $N = \sum\limits_{h=1}^{H}\sum\limits_{j=1}^{n_h} w_{hj}$：

$$\hat{\mu}_{str} = \frac{\sum\limits_{h=1}^{H}\sum\limits_{j=1}^{n_h} w_{hj} y_{hj}}{\sum\limits_{h=1}^{H}\sum\limits_{j=1}^{n_h} w_{hj}}$$

21.1.4 估计的性质

无偏性

无偏性是显然的：在每一层里面使用的是简单随机抽样，而简单随机抽样的估计量是无偏的，总和也自然是无偏的。

方差

由各层样本之间的独立性以及每层中的抽样实际是 SRS，立即可得如下分层随机抽样估计量的方差公式：

$$Var(\hat{\tau}_{str}) = \sum_{h=1}^{H} N_h^2 \left(1 - \frac{n_h}{N_h}\right)\frac{\sigma_h^2}{n_h}$$

$$\widehat{Var}(\hat{\tau}_{str}) = \sum_{h=1}^{H} N_h^2 \left(1 - \frac{n_h}{N_h}\right)\frac{s_h^2}{n_h}$$

$$Var(\hat{\mu}_{str}) = \sum_{h=1}^{H} \left(\frac{N_h}{N}\right)^2 \left(1 - \frac{n_h}{N_h}\right)\frac{\sigma_h^2}{n_h}$$

$$\widehat{Var}(\hat{\mu}_{str}) = \sum_{h=1}^{H} \left(\frac{N_h}{N}\right)^2 \left(1 - \frac{n_h}{N_h}\right)\frac{s_h^2}{n_h}$$

其中：

$$\sigma_h^2 = \frac{1}{N_h - 1}\sum_{j=1}^{N_h}(Y_{hj} - \mu_h)^2$$
$$s_h^2 = \frac{1}{N_h - 1}\sum_{j=1}^{n_h}(y_{hj} - \bar{y}_h)^2$$

置信区间

$$\hat{\mu}_{str} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var}(\hat{\mu}_{str})},\ \hat{\tau}_{str} \pm u_{1-\frac{\alpha}{2}}\sqrt{\widehat{Var})(\hat{\tau}_{str})}$$

自由度问题

当使用 t 置信区间的时候，如果各层之间方差是齐的，那么自由度即为 $n - H$。如果方差不齐，则使用 Satterwaithe approximation 来估计自由度：

$$Dof = \left(\sum_{h=1}^{H} a_h s_h^2\right)^2 \div \sum_{h=1}^{H}\frac{(a_h s_h^2)^2}{(n_h - 1)}$$

其中：

$$a_h = \frac{N_h(N_h - n_h)}{n_h}$$

21.1.5 群体比例问题

$$\hat{p}_{str} = \sum_{h=1}^{H}\frac{N_h}{N}\hat{p}_h$$
$$\widehat{Var}(\hat{p}_{str}) = \sum_{h=1}^{H}\left(\frac{N_h}{N}\right)^2\left(1 - \frac{n_h}{N_h}\right)\frac{\hat{p}_h(1 - \hat{p}_h)}{n - 1}$$

21.2 估计方法思考

在分层抽样中，如果使用如下公式估计 μ：

$$\tilde{\mu}_{str} = \frac{\sum\limits_{h=1}^{H}\sum\limits_{j=1}^{n_h} y_{hj}}{n}$$

均值

讨论阳性率问题。

该方法的总体均值为：

$$
\begin{aligned}
E(\tilde{\mu}_{str}) &= E\left(\frac{\sum_{h=1}^{H}\sum_{j=1}^{n_h} y_{hj}}{n}\right) \\
&= \frac{1}{n}\sum_{h=1}^{H} E\left(\sum_{j=1}^{N_h} Y_{hj} Z_{hj}\right) \\
&= \frac{1}{n}\sum_{h=1}^{H}\sum_{j=1}^{N_h} Y_{hj} E(Z_{hj}) \\
&= \frac{1}{n}\sum_{h=1}^{H} E(Z_{hj}) \sum_{j=1}^{N_h} Y_{hj} \\
&= \frac{1}{n}\sum_{h=1}^{H} \frac{n_h}{N_h} N_h p_h \\
&= \frac{1}{n}\sum_{h=1}^{H} n_h p_h
\end{aligned}
$$

而真实的总体均值为：

$$
\mu = \frac{t}{N} = \frac{1}{N}\sum_{h=1}^{H} N_h p_h
$$

如果想要无偏，则显然需要满足：

$$
\frac{n_h}{N_h} = \frac{n}{N}
$$

21.3 分配原则

分层随机抽样要考虑两个问题：

1. 如何定义层？
2. 每个层里面样本量是多少？

21.3.1 比例分配

比例分配 (proportional allocation)是指在分层抽样中令 $\pi_{hj} = \frac{n}{N} = \frac{n_h}{N_h}$，$h = 1, 2, \ldots, H$，$j = 1, 2, \ldots, N_h$。这种分配方式不会出现极端情况，即样本几乎都出自某一层的现象。

比例分配与 SRS 的比较

可以注意到此时所有样本的入样概率都一样。

由总体均值、总体总量估计量的计算公式可知：比例分配与 SRS 对于总体均值、总体总量估计的期望是一样的，即估计量的期望是一样的。但是两种方式对于总体均值、总体总量估计的方差不一样。在 n 相同的情况下，$Var(\tilde{\mu}_{str})$，$Var(\tilde{\tau}_{str})$ 通常比 $Var(\hat{\mu}_{srs})$，$Var(\hat{\tau}_{str})$ 小。

证明. 从方差分析的角度去分析。因为两种估计方式中总体总量的估计都是总体均值估计的 N 倍，所以只需证明总体均值的情况即可。 回头补方差分析

由 $\dfrac{n_h}{N_h} = \dfrac{n}{N}$ 可得：

$$
\begin{aligned}
Var(\tilde{\tau}_{str}) &= \sum_{h=1}^{H} N_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{\sigma_h^2}{n_h} \\
&= \sum_{h=1}^{H} N_h \left(1 - \frac{n}{N}\right) \frac{n}{N} \sigma_h^2 \\
&= \left(1 - \frac{n}{N}\right) \frac{1}{N} \sum_{h=1}^{H} N_h \sigma_h^2
\end{aligned}
$$

从理论角度看待 SSe，即计算总体而非样本的 SSe，可得到：

$$
SSe = \sum_{h=1}^{H} \sum_{j=1}^{N_h} (Y_{hj} - \mu_h)^2 = \sum_{h=1}^{H} (N_h - 1)\sigma_h^2
$$

所以：

$$
Var(\tilde{\tau}_{str}) = \left(1 - \frac{n}{N}\right) \frac{1}{N} \sum_{h=1}^{H} N_h \sigma_h^2 = \left(1 - \frac{n}{N}\right) \frac{1}{N} \left(SSe + \sum_{h=1}^{H} \sigma_h^2\right)
$$

而：

$$
\begin{aligned}
Var(\hat{\tau}_{srs}) &= N^2\left(1-\frac{n}{N}\right)\frac{\sigma^2}{n} \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{SST}{N-1} \\
&= \frac{N^2}{n(N-1)}\left(1-\frac{n}{N}\right)(SSA+SSe) \\
&= \frac{N^2}{n(N-1)}\left(1-\frac{n}{N}\right)SSA+\left(1-\frac{n}{N}\right)\frac{N}{n}\left(\frac{N}{N-1}SSe\right) \\
&= \frac{N^2}{n(N-1)}\left(1-\frac{n}{N}\right)SSA+\left(1-\frac{n}{N}\right)\frac{N}{n}\left(SSe+\frac{1}{N-1}SSe\right) \\
&= \frac{N^2}{n(N-1)}\left(1-\frac{n}{N}\right)SSA+\left(1-\frac{n}{N}\right)\frac{N}{n}\left(SSe+\sum_{h=1}^{H}\frac{N_h-1}{N-1}\sigma_h^2\right) \\
&= \frac{N^2}{n(N-1)}\left(1-\frac{n}{N}\right)SSA+\left(1-\frac{n}{N}\right)\frac{N}{n}\left(SSe+\sum_{h=1}^{H}\left(\frac{N-1}{N-1}-\frac{N-N_h}{N-1}\right)\sigma_h^2\right) \\
&= \frac{N^2}{n(N-1)}\left(1-\frac{n}{N}\right)SSA+\left(1-\frac{n}{N}\right)\frac{N}{n}\left(SSe+\sum_{h=1}^{H}\sigma_h^2\right)+\left(1-\frac{n}{N}\right)\frac{N}{n}\left(\sum_{h=1}^{H}\left(-\frac{N-N_h}{N-1}\right)\sigma_h^2\right) \\
&= Var(\tilde{\tau}_{str})+\frac{N^2}{n(N-1)}\left(1-\frac{n}{N}\right)\left[SSA-\sum_{h=1}^{H}\left(1-\frac{N_h}{N}\right)\sigma_h^2\right]
\end{aligned}
$$

由上式可以看出，如果比例分配估计量的方差比 SRS 估计量的方差大，则需要：

$$
SSA<\sum_{h=1}^{H}\left(1-\frac{N_h}{N}\right)\sigma_h^2
$$

而这种情况在实践中几乎见不到。 □

从以上推导中也可以看出，组间差异越大，即 SSA 越大，比例分配估计量的方差比 SRS 估计量的方差小得越多，也即精确得更多。而如果每一个层中的方差很大，即 σ_h^2 很大，有可能会使比例分配估计量的方差大于 SRS 估计量的方差，所以在选择分层的时候，要使层内差异小。综上，层间差异大、层内差异小时，比例分配下的分层随机抽样比 SRS 效果更好。

21.3.2 最优分配

在考虑分配方式的时候有如下三点主要因素：

1. 每层中的个体总数 N_h。
2. 层内差异 σ_h^2。
3. 在每个层内抽样的平均成本 c_h。

显然，比例分配没有考虑第二点和第三点。

成本一致最小化方差

当不同层之间抽样成本一致的时候，可以最小化估计量方差。可以将问题转化为：

$$\min f(\overrightarrow{n}) = Var(\hat{\tau}_{str}) = \sum_{h=1}^{H} N_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{\sigma_h^2}{n_h}$$
$$s.t. \quad \sum_{h=1}^{H} n_h = n$$

可得最佳分配 (optimal allocation)方案为：

$$n_k = \frac{nN_k\sigma_k}{\sum\limits_{h=1}^{H} N_h\sigma_h}, \quad k = 1, 2, \ldots, H$$

证明. 使用 Lagrange 乘子法求解。引入 Lagrange 乘子 λ 即有：

$$f(\overrightarrow{n}) = \sum_{h=1}^{H} N_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{\sigma_h^2}{n_h}$$
$$g(\overrightarrow{n}) = \sum_{h=1}^{H} n_h - n$$
$$h(\overrightarrow{n}) = f(\overrightarrow{n}) + \lambda g(\overrightarrow{n})$$

对 f 求偏导可得：

$$\begin{aligned}\frac{\partial f}{\partial n_h} &= -\frac{N_h^2\sigma_h^2}{N_h n_h} - \left(1 - \frac{n_h}{N_h}\right)\frac{N_k^2\sigma_h^2}{n_k^2} \\ &= -\frac{N_h\sigma_h^2}{n_h} - \frac{N_h^2\sigma_h^2}{n_h^2} + \frac{N_h\sigma_h^2}{n_h} \\ &= -\frac{N_h^2\sigma_h^2}{n_h^2}\end{aligned}$$

所以：

$$\nabla f(\overrightarrow{n}) = (-\frac{N_1^2\sigma_1^2}{n_1^2}, -\frac{N_2^2\sigma_2^2}{n_2^2}, \ldots, -\frac{N_H^2\sigma_H^2}{n_H^2})$$
$$\nabla g(\overrightarrow{n}) = (1, 1, \ldots, 1)$$

当 f 取最小值时有：

$$\frac{\partial h(\overrightarrow{n})}{\partial \overrightarrow{n}} = (-\frac{N_1^2\sigma_1^2}{n_1^2} + \lambda, -\frac{N_2^2\sigma_2^2}{n_2^2} + \lambda, \ldots, -\frac{N_H^2\sigma_H^2}{n_H^2} + \lambda) = (0, 0, \ldots, 0)$$
$$\sum_{h=1}^{H} n_h = n$$

解得：

$$n_h = \frac{N_h\sigma_h}{\sqrt{\lambda}}, \quad h = 1, 2, \ldots, H$$

此时：

$$n=\sum_{h=1}^{H} n_h=\frac{\sum\limits_{h=1}^{H} N_h\sigma_h}{\sqrt{\lambda}}$$

于是：

$$\sqrt{\lambda}=\frac{\sum\limits_{h=1}^{H} N_h\sigma_h}{n}$$

所以：

$$n_k=\frac{nN_k\sigma_k}{\sum\limits_{h=1}^{H} N_h\sigma_h},\quad k=1,2,\ldots,H$$

□

成本不一致最小化方差

如果不同层之间抽样成本不一致，且总抽样成本为：

$$c=c_0+\sum_{h=1}^{H} c_h n_h$$

可以将问题转化为：

$$\min f(\overrightarrow{n})=Var(\hat{\tau}_{str})=\sum_{h=1}^{H} N_h^2\left(1-\frac{n_h}{N_h}\right)\frac{\sigma_h^2}{n_h}$$

$$s.t.\quad c-c_0-\sum_{h=1}^{H} c_h n_h=0$$

则最佳分配方案为：

$$n_k=\frac{(c-c_0)N_k\sigma_k}{\sum\limits_{h=1}^{H} N_h\sigma_h\sqrt{c_h}}\frac{1}{\sqrt{c_k}},\quad k=1,2,\ldots,H$$

从上式中可看出，需要在个数多或方差大得层中分配更多的个体（方差大需要更多的个体来获得有代表性的样本），在成本高的层中分配较少的个体。

固定方差最小化成本

如果不同层之间抽样成本不一致，且总抽样成本为：

$$c=c_0+\sum_{h=1}^{H} c_h n_h$$

此时如果固定方差最小化成本，则最佳分配方案为：

$$n_k=n\frac{\frac{N_k\sigma_k}{\sqrt{c_k}}}{\sum\limits_{h=1}^{H}\frac{N_h\sigma_h}{\sqrt{c_h}}},\quad k=1,2,\ldots,H$$

若计算出来 $n_k>N_k$，则令 $n_k=N_k$。

21.4 后分层

当使用了 SRS 后发现获取的样本比较极端时（比如研究人群体重，获得的样本中 90% 都是男性），此时使用后分层 (poststratification)，即先进行 SRS，然后将获得的样本分层。

21.4.1 参数估计

总体均值 μ 的估计

$$\hat{\mu}_{poststr} = \sum_{h=1}^{H} \frac{N_h}{N} \bar{y}_h$$

$$Var(\hat{\mu}_{poststr}) = E[Var(\hat{\mu}_{str}|\overrightarrow{n})] \approx \left(1 - \frac{n}{N}\right) \frac{1}{n} \sum_{h=1}^{H} \frac{N_h}{N} \sigma_h^2 + \left(\frac{N-n}{N-1}\right) \frac{1}{n^2} \sum_{h=1}^{H} \left(1 - \frac{N_h}{N}\right) \sigma_h^2$$

下证明：(1) 后分层估计量 $\hat{\mu}_{poststr}$ 是无偏估计；(2) 如上后分层方差公式正确。

证明. (1) 后分层估计量的计算公式本质和分层随机抽样一样，因此是无偏的。

(2) 由方差分解公式：

$$Var(\hat{\mu}_{poststr}) = Var(E[\hat{\mu}_{str}|\overrightarrow{n}]) + E[Var(\hat{\mu}_{str}|\overrightarrow{n})]$$

而：

$$\begin{aligned}
E[\hat{\mu}_{str}|\overrightarrow{n}] &= E\left(\sum_{h=1}^{H} \sum_{j=1}^{N_h} \frac{Y_{hj} Z_{hj}}{n}\right) \\
&= \sum_{h=1}^{H} \sum_{j=1}^{N_h} \frac{Y_{hj}}{n} E(Z_{hj}) \\
&= \sum_{h=1}^{H} \sum_{j=1}^{N_h} \frac{Y_{hj} n_h}{n N_h} \\
&= \sum_{h=1}^{H} \frac{n_h}{n} \sum_{j=1}^{N_h} \frac{Y_{hj}}{N_h} \\
&= \sum_{h=1}^{H} \frac{n_h}{n} \mu_h
\end{aligned}$$

可以看出上式是一个定值，所以：

$$Var(E[\hat{\mu}_{str}|\overrightarrow{n}]) = 0$$

于是：

$$
\begin{aligned}
Var(\hat{\mu}_{poststr}) &= E[Var(\hat{\mu}_{str}|\overrightarrow{n})] \\
&= E\left[\sum_{h=1}^{H}\left(\frac{N_h}{N}\right)^2\left(1-\frac{n_h}{N_h}\right)\frac{\sigma_h^2}{n_h}\right] \\
&= \sum_{h=1}^{H}\left(\frac{N_h}{N}\right)^2\sigma_h^2\left[E\left(\frac{1}{n_h}\right)-\frac{1}{N_h}\right]
\end{aligned}
$$

由定理 14.1，利用泰勒展开，令 $E(n_h)=\mu$，即有：

$$
\begin{aligned}
E\left(\frac{1}{n_h}\right) &\approx E\left[\frac{1}{\mu}-\frac{1}{\mu^2}(n_h-\mu)+\frac{2}{\mu^3}\frac{(n_h-\mu)^2}{2!}\right] \\
&= \frac{1}{\mu}+\frac{1}{\mu^3}Var(n_h)
\end{aligned}
$$

由后分层原理，显然可以得到：

$$
n_h \sim \text{Hyper}(n, N_h, N)
$$

$$
E(n_h)=\frac{nN_h}{N},\ Var(n_h)=\frac{nN_h(N-n)(N-N_h)}{N^2(N-1)}
$$

于是：

$$
E\left(\frac{1}{n_h}\right)=\frac{N}{nN_h}+\left(\frac{N}{nN_h}\right)^2\left(1-\frac{N_h}{N}\right)\frac{N-n}{N-1}
$$

将上式代入 $Var(\hat{\mu}_{poststr})$ 即可得到：

$$
Var(\hat{\mu}_{poststr}) \approx \left(1-\frac{n}{N}\right)\frac{1}{n}\sum_{h=1}^{H}\frac{N_h}{N}\sigma_h^2+\left(\frac{N-n}{N-1}\right)\frac{1}{n^2}\sum_{h=1}^{H}\left(1-\frac{N_h}{N}\right)\sigma_h^2 \qquad \square
$$

21.5 样本容量

忽略 FPC

当 $\frac{n_h}{N_h}$，$h=1,2,\ldots,H$ 小的时候，忽略层内的 FPC，令：

$$
Var(\hat{\mu}_{str})=\frac{1}{n}\sum_{h=1}^{H}\left(\frac{N_h}{N}\right)^2\frac{n}{n_h}\sigma_h^2=\frac{v}{n}
$$

则 MOE 为 $u\sqrt{\frac{v}{n}}$，可得：

$$
n=\frac{u^2v}{d^2}
$$

不忽略 FPC

如果 $\frac{n_h}{N_h}$，$h=1,2,\ldots,H$ 较大，则考虑层内的 FPC 或使用 Monte Carlo 算法。

Chapter 22

整群抽样

整群抽样 (cluster sampling)不同于分层抽样的地方是它并不选取辅助变量。整群抽样的精确度有可能低于 SRS 的精确度，因为初级抽样单元 (primary sampling units, psus)与辅助变量有一定的相似性，样本可能不具备代表性，而呈现出样本内的相关性。但是整群抽样会让抽样更方便，单位价格上能获取的信息量更大。在整群抽样中，总体中的个体的元素 ssu 只有在它属于的 psu 被选中时才会有可能被包含在样本中抽样单位是 psu，观察单位是 ssu 只讨论一阶整群抽样，即一旦 psu 被选中，该 psu 中的 ssu 全部被选中

1. 有些时候构建抽样框架可能很困难或根本做不到

2. 目标群体在地理上分布广泛，调查成本太高

分层随机抽样中，$Var(\hat{\mu}_Y)$ 在群内差异小群间差异大的情况下较小，整群抽样中，方差在群内差异大群间差异小的情况下较小，在实践中只能通过扩大群的个数来提高精确度

icc intra-cluster correlation

符号		说明
n		抽样群数
N		总群数
M_i	$i=1,2,\ldots,N$	psu 中的 ssu 个数
M		所有 ssu 的个数
μ_i	$i=1,2,\ldots,N$	psu 中的均值
μ		总体均值
τ_i		psu 中的总量
τ		总体总量
$\sigma_i^2=\sum_{j=1}^{M_i}\frac{(y_{ij}-\mu_{Y_i})^2}{M_i-1}$	$i=1,2,\ldots,N$	psu 中的方差
$\sigma_{psu}^2=\frac{1}{N-1}\sum_{i=1}^{N}\left(\tau_i-\frac{\tau}{N}\right)^2$		psu 间的方差
$\sigma^2=\sum_{i=1}^{N}\sum_{j=1}^{M_i}\frac{(y_{ij}-\mu)^2}{M-1}$		总体方差

表 22.1: 符号说明表

$$\hat{\tau}=\frac{N}{n}\sum_{i=1}^{n}\tau_i$$

$$\widehat{Var}(\hat{\tau})=N^2\left(1-\frac{n}{N}\right)\frac{s_\tau^2}{n}=N(N-n)\frac{s_t^2}{n}$$

$$s_t^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(\tau_i-\frac{\hat{\tau}}{N}\right)$$

$$\widehat{Var}(\frac{\hat{\tau}}{N})$$

$$\hat{\mu}=\frac{\hat{\tau}}{M}$$

$$\widehat{Var}(\hat{\mu})=\frac{1}{M^2}\widehat{Var}(\hat{\tau})=\frac{1}{M^2}N^2\left(1-\frac{n}{N}\right)\frac{s_\tau^2}{n}$$

$$w_{ij}=\frac{N}{n}$$

$$\mu=\frac{1}{M}\sum_{i=1}^{N}\sum_{j=1}^{M_i}=\frac{\sum_{i=1}^{N}\tau_i}{\sum_{i=1}^{N}M_i}=\frac{\tau}{M}=B$$

$$\hat{\mu}_r=\frac{\hat{\tau}}{\hat{M}}=\frac{\frac{N}{n}\sum_{i=1}^{n}\tau_i}{\frac{N}{n}\sum_{i=1}^{n}M_i}$$

第八部分

非参数统计学

Chapter 23

单样本位置检验

23.1 广义符号检验

目的

给定某样本，检验给定值 q_0 与总体的 π 分位点 Q_π 之间的关系。

适用条件

总体是连续型的。离散型分位点的定义会导致下述统计量不服从对应的二项分布。

原理

记一组样本中大于 q_0 的单元的个数为 s^+，小于 q_0 的单元的个数为 s^-。若零假设成立（即 q_0 确实为总体的 π 分位点），则从总体中任取一个元素，它小于 q_0 的概率应为 π，那么对于任意一组样本来讲，应有 $K \sim \text{Binom}(s^+ + s^-, \pi)$，其中 K 为 s^- 背后的随机变量。

零假设

$H_0 : Q_\pi = q_0$

大样本近似

当 n 较大时，可认为 $Z \sim N(0,1)$，其中 $Z = \dfrac{K - n\pi}{\sqrt{n\pi(1-\pi)}}$，其中 n 为样本中不等于 q_0 的单元的个数，由此可在求 p 值时近似计算标准正态分布的累积概率值。

注意事项

需要去除样本中值为 q_0 的单元，这部分单元对推断没有帮助。

备择假设	p 值	解释
$H_1: Q_\pi > q_0$	$P_{H_0}(K \leqslant s^-)$	在零假设下，二项分布变量小于当前样本 s^- 的概率太小，说明 s^- 太小应变大，即分位点的值应比 N 大
$H_1: Q_\pi < q_0$	$P_{H_0}(K \geqslant s^-)$	略
$H_1: Q_\pi \neq q_0$	$2\min\{P_{H_0}(K \leqslant s^-), P_{H_0}(K \geqslant s^-)\}$	略

表 23.1: 对 $H_0: Q_\pi = q_0$ 的检验

尚存疑惑

为什么 p 值是这样的呢？

代码

```
sign.test <- function(x, q0, pi, exact = FALSE,
                      alternative = c("two.sided", "greater", "less")) {
  alternative <- match.arg(alternative)
  s_pos <- sum(x > q0)
  STATISTIC <- sum(x < q0)
  n <- s_pos + STATISTIC
  STATISTIC <- setNames(STATISTIC, "s_neg")
  hypothesis_message <- switch(alternative,
                               "greater" = paste("Q0 >", pi),
                               "less" = paste("Q0 <", pi),
                               "two.sided" = paste("Q0 !=", pi))
  if (exact) {
    METHOD <- "Sign Test (Exact)"
    p.value <- switch(alternative,
                      "greater" = pbinom(q = STATISTIC, size = n, prob = pi),
                      "less" = pbinom(q = STATISTIC-1, size = n, prob = pi, lower.tail = FALSE),
                      "two.sided" = 2 * min(pbinom(q = STATISTIC-1, size = n, prob = pi, lower.tail = FALSE),
                                            pbinom(q = STATISTIC, size = n, prob = pi)))
```

```
  } else {
    METHOD <- "Sign Test (Approximate)"
    z_score <- (STATISTIC - n * pi) / sqrt(n * pi * (1 - pi))
    p.value <- switch(alternative,
                      "greater" = pnorm(z_score, lower.tail = TRUE),
                      "less" = pnorm(z_score, lower.tail = FALSE),
                      "two.sided" = 2 * min(pnorm(z_score), 1 -
                      ↪  pnorm(z_score)))
  }

  RVAL <- list(statistic = STATISTIC, p.value = p.value,
               data.name = deparse(substitute(x)),
               method = METHOD, alternative = hypothesis_message)
  class(RVAL) <- "htest"
  RVAL
}
```

23.2 Wilcoxon 符号秩检验

目的

给定某样本，检验给定值 M_0 与总体的中位数 M 之间的关系。

适用条件

总体分布是连续且对称的。连续是为了避免样本中出现重复值影响秩分配，对称则是秩推断成立的必要条件，见下文23.2。

符号秩的计算

设样本中每个单元的取值为 X_i，$i = 1, 2, \ldots, n$。

1. 对 $i = 1, 2, \ldots, n$，计算 $d_i = |X_i - M_0|$。
2. 对 d_i 进行排序，找出它们的秩 R_i。
3. 计算 $W^+ = \sum\limits_{i \in \{i: X_i - M_0 > 0\}} R_i$，$W^- = \sum\limits_{i \in \{i: X_i - M_0 < 0\}} R_i$。

原理

由于总体是对称的，那么对于任意一个元素，首先它出现在 M_0 两边的可能性是相等的，其次它出现在 M_0 两边对称位置的可能性是相等的，由此在零假设成立的条件下，W^+

和 W^- 应相差不大，且二者满足关系：$W^+ + W^- = \frac{n(n+1)}{2}$，因此，当其中之一很小时，应怀疑零假设。若想对 p 值精确求解，见。

在概率论里完
Wilcoxon 秩统
的分布相关理论
后链接过来

零假设

$H_0 : M = M_0$

备择假设	统计量 W	p 值
$H_1 : M > M_0$	W^-	$P(W \leqslant w)$
$H_1 : M < M_0$	W^+	$P(W \leqslant w)$
$H_1 : M \neq M_0$	$\min\{W^-, W^+\}$	$2P(W \leqslant w)$

表 23.2: Wilcoxon 符号秩检验

大样本近似

可求出 Wilcoxon 符号秩检验统计量的期望和方差分别为：

$$E(W) = \frac{n(n+1)}{4} \qquad Var(W) = \frac{n(n+1)(2n+1)}{24}$$

当 n 较大时，由中心极限定理，可认为 $Z \sim N(0,1)$，其中 $Z = \dfrac{W - E(W)}{\sqrt{Var(W)}}$，由此可在求 p 值时近似计算标准正态分布的累积分布值。

打结

若数据中含有相同的数字，称之为打结的情况。结的个数为重复出现的数值的个数，结中数值的秩为它们升序排序后位置的平均值。如果结多了，大样本近似公式就不准，要进行修正，同时，如果数据中有结则必须使用大样本近似。修正后的公式为：

$$Z = \frac{W - E(W)}{\sqrt{Var(W) - \frac{\sum_{i=1}^{g}(\tau_i^3 - \tau_i)}{48}}} \sim N(0,1)$$

举例：对于数据 $\{2, 2, 5, 8, 8.8, 1, 1, 1, 1\}$，一共有 3 个结，$\tau_1 = 2$（两个 2），$\tau_2 = 3$（三个 8），$\tau_3 = 4$（四个 1）。称 τ 为结统计量。

代码

```
wilcox.test(x, alternative = c("two.sided", "less", "greater"), mu = M0,
↪  exact = NULL, correct = TRUE)
```

23.3 中位数的点估计与置信区间

适用条件

总体分布是连续且对称的。

中位数点估计公式

我们称 $\{\frac{X_i+X_j}{2},\ i \leqslant j\}$ 为 Walsh 平均，然后使用 Walsh 平均的中位数估计总体的中位数，该统计量称为 Hodges-Lehmann 估计量（简称 HT 估计量）。

$$\hat{\theta} = \text{median}\{\frac{X_i + X_j}{2},\ i \leqslant j\}$$

中位数区间估计原理

注意到如下关系：

$$W^+ = \left|\{\frac{X_i + X_j}{2} > M_0,\ i \leqslant j\}\right|$$

该关系也有关于 W^- 的对称版本。对 Walsh 平均从小到大排序，记为 $W_{(1)}, W_{(2)}, \ldots, W_{(N)}, N = \frac{n(n+1)}{2}$。因为想要取两个 Walsh 平均构成一个中位数的区间估计，那么就要去掉左端和右端部分的 Walsh 平均，而 Walsh 平均的个数是与符号秩统计量 W 是相关的，左端去掉的 Walsh 平均的个数可以看作 W^- 的实现值，右端去掉的 Walsh 平均的个数可以看作 W^+ 的实现值，那么就给予了区间估计成立的概率值。

因此，给出中位数 M 的 $(1-\alpha)$ 置信区间为：

$$(W_{k+1}, W_{N-k}),\ k\text{满足}P(W^- \leqslant k) \leqslant \frac{\alpha}{2}\text{与}P(W^- \leqslant k+1) > \frac{\alpha}{2}$$

注意到上式利用了 W^- 与 W^+ 的对称性。

在大样本下，可以近似得到：

$$k \approx \frac{n(n+1)}{4} - Z_{\frac{\alpha}{2}}\sqrt{\frac{n(n+1)(2n+1)}{24}}$$

为什么要用 Walsh 平均

Walsh 平均可以增大样本数量，如果就用原样本去估计置信区间，在样本数较小的情况下，置信区间会变得很大，不够精确。

代码

```
wilcox.test(x, exact = NULL, correct = TRUE, conf.int = FALSE, conf.level
↪  = 0.95))
```

23.4 符号检验与 Wilcoxon 符号秩检验的比较

在数据满足 Wilcoxon 符号秩检验的适用条件时，由于 Wilcoxon 符号秩检验不仅利用了符号信息，也利用了距离信息，因此会更准确。

Chapter 24

两样本位置检验

24.1 目的

通过检验样本中位数的一致性来判断样本的差异性。中位数是某种意义上的“平均”。

24.2 Brown-Mood 中位数检验

目的

检验两个样本 X 和 Y 的中位数 M_X, M_Y 是否相同。

原理

记样本 X 与 Y 分别为 $X_1, X_2, \ldots, X_m$, $Y_1, Y_2, \ldots, Y_n$。将两样本混合求得混合后的中位数 M_{XY}。若两样本中位数相同，则混合后的中位数应也等于二者的中位数，那么两个样本中大于 M_{XY} 的单元的个数应该大致一样。可构建如下表格：

	X 样本	Y 样本	总和
单元大于 M_{XY} 的个数	a	b	p
单元小于 M_{XY} 的个数	c	d	q
总和	m	n	N

表 24.1: $2*2$ 列联表矩阵

令 A 表示表中 a 背后的随机变量，在 m、n、p 固定的情况下，A 服从超几何分布 $\mathrm{H}(p, m, N)$（在四个边际和中任意三个固定的情况下，都有 $2*2$ 列联表中的一个值其背后的随机变量服从超几何分布），有如下概率：

$$P(A=k)=\frac{\binom{m}{k}\binom{n}{p-k}}{\binom{N}{p}}$$

若 A 过大或过小，考虑到此时 p 是固定的，那么 X 样本中大于 M_{XY} 单元的个数离 Y 样本中大于 M_{XY} 单元的个数就会很远，就应怀疑零假设。

零假设

$H_0 : M_X = M_Y$

备择假设	p 值
$H_1 : M_X > M_Y$	$P(A \geqslant a)$
$H_1 : M_X < M_Y$	$P(A \leqslant a)$
$H_1 : M_X \neq M_Y$	$2\min\{P(A \geqslant a), P(A \leqslant a)\}$

表 24.2: 对 $H_0 : M_X = M_Y$ 的检验

大样本近似

由超几何分布的期望与方差，在大样本情况下可认为有如下关系：

$$Z = \frac{A - \frac{pm}{N}}{\sqrt{\frac{pm(N-p)(N-m)}{N^3}}} \sim N(0,1)$$

对于双边假设检验，在大样本情况下，可选取检验统计量与 p 值如下：

$$K = \frac{(2a-m)^2(m+n)}{mn} \sim \chi^2(1),\ p = P(K \geqslant k)$$

注意事项

若有和 M_{XY} 值相同的单元，可将其去除，也可将其归于任何一类使得检验变得保守一点。

代码

以下代码需要输入 x 满足一定的格式：数据是两列，第一列为观测值，第二列用 $1, 2$ 来表示其属于 X 或 Y 样本，1 表示属于 X 样本。以下代码也提供了样本中有和 M_{XY} 值相同的单元情况下的处理方案，omit 表示去除与 M_{XY} 值相同的单元，less 表示将其归于小于 M_{XY} 值的一类，greater 表示将其归于大于 M_{XY} 值值的一类。

```
brown.mood.test <- functions(data,
      alternative = c("two.sided", "less", "greater"),
      ties.method = c("omit", "less", "greater")){
  M_AB <- median(data[,1])
  switch(ties.method,
         omit = {data <- data[data[, 1] != M_AB,]},
```

```
        less = {data[data[, 1] == M_AB, 1] = M_AB - 1},
        greater = {data[data[, 1] == M_AB, 1] = M_AB + 1})

  C <- matrix(nr = 2, nc = 2)
  C[1, 1] <- sum(data[data[, 2] == 1, 1] > M_AB)
  C[1, 2] <- sum(data[data[, 2] == 2, 1] > M_AB)
  C[2, 1] <- sum(data[data[, 2] == 1, 1] < M_AB)
  C[2, 2] <- sum(data[data[, 2] == 2, 1] < M_AB)

  fisher.test(C, alt=alternative, conf.int = FALSE)
}
```

24.3 Wilcoxon 秩和检验

目的

检验两个样本 X 和 Y 的中位数 M_X, M_Y 是否相同。

适用条件

需要两总体的分布有类似形状，但并不需要对称。

Wilcoxon 秩和统计量

记样本 X 与 Y 分别为 $X_1, X_2, \ldots, X_m$, $Y_1, Y_2, \ldots, Y_n$。把两个样本混合起来并从小到大排序，令 R_{X_i} 和 R_{Y_j} 分别表示单元 X_i、单元 Y_i 在混合样本中的秩，则称

$$W_X = \sum_{i=1}^{m} R_{X_i},\ W_Y = \sum_{j=1}^{n} R_{Y_j}$$

为 Wilcoxon 秩和统计量。

在零假设下，令 R_i 表示 Y 中第 i 个样本在混合后的秩，可得如下性质：

$$P(R_i = k)\frac{1}{N},\ k = 1, 2, \ldots, N;\ i = 1, 2, \ldots, n;$$

$$P(R_i = k,\ R_j = l) = \begin{cases} \frac{1}{N(N-1)} & k \neq l; \\ 0 & k = l. \end{cases}$$

$$E(R_i) = \frac{N+1}{2},\ Var(R_i) = \frac{N^2-1}{12},\ Cov(R_i,\ R_j) = -\frac{N+1}{12}(i \neq j)$$

$$E(W_Y) = \frac{n(N+1)}{2},\ Var(W_Y) = \frac{mn(N+1)}{12}$$

原理

若零假设成立，在两总体分布有类似形状时 W_X 与 W_Y 应比较接近，当其中之一很大或很小时，应怀疑零假设。

零假设

$H_0 : M_X = M_Y$

备择假设	统计量 K	p 值
$H_1 : M_X > M_Y$	W_Y	$P(K \leqslant k)$
$H_1 : M_X < M_Y$	W_X	$P(K \leqslant k)$
$H_1 : M_X \neq M_Y$	$\min\{W_X, W_Y\}$	$2P(K \leqslant k)$

表 24.3: Wilcoxon 秩和检验

大样本近似

由 W_Y 的期望与方差，在大样本下可认为：

$$Z = \frac{W_Y - E(W_Y)}{\sqrt{Var(W_Y)}} \sim N(0,1) \tag{24.1}$$

若存在打结的情况，只能使用大样本近似，且应对正态近似公式进行修正（其中 τ 为结统计量）：

$$Z = \frac{W_Y - E(W_Y)}{\sqrt{Var(W_Y) - \frac{mn(\sum_{i=1}^{g}\tau_i^3 - \sum_{i=1}^{g}\tau_i)}{12(m+n)(m+n-1)}}} \sim N(0,1) \tag{24.2}$$

代码

```
wilcox.test(x, y, alternative = c("two.sided", "less", "greater"), exact
↪  = NULL, correct = TRUE)
```

24.4 Brown-Mood 中位数检验与 Wilcoxon 秩和检验的比较

在数据满足 Wilcoxon 秩和检验的适用条件时，由于 Wilcoxon 符号秩检验不仅利用了符号信息，也利用了距离信息，因此会更准确。

24.5 成对数据差异性检验

目的： 检验成对数据间是否有显著差异。

适用条件:

1. 每一对数据来自可比较的对象。
2. 每一对数据彼此之间是独立的。。

24.5.1 连续型数据

原理

记两组观测值分别为 $X_1, X_2, \ldots, X_n$, $Y_1, Y_2, \ldots, Y_n$。对应元素作差，则检验退化为单样本中位数检验。令 M_D 表示 $X_i - Y_i$ 的中位数，则有以下检验类型:

零假设	备择假设
$H_0 : M_D = M_0$	$H_0 : M_D > M_0$
$H_0 : M_D = M_0$	$H_0 : M_D < M_0$
$H_0 : M_D = M_0$	$H_0 : M_D \neq M_0$

表 24.4: 检验类型

代码

下述 sign.test 的代码参考第193页。mu 值的都是想要检验的二者之间的差异值，wilcox.test 可以给出一定置信度下二者差异值的点估计与区间估计。

```
sign.test(x-y, mu, 0.5, exact = FALSE, alternative = c("two.sided", "less", "greater"), )
wilcox.test(x, y, alternative = c("two.sided", "less", "greater"), mu = 0, paired = TRUE, exact = NULL, correct = TRUE, conf.int = FALSE, conf.level = 0.95)
```

24.5.2 01 型数据的 McNemar 检验

假设

H_0 : 无显著差异; H_1 : 有显著差异

原理

记两组观测值分别为 $X_1, X_2, \ldots, X_n$, $Y_1, Y_2, \ldots, Y_n$。记:

$$n_X = |\{i : X_i = 1,\ Y_i = 0\}|,\ n_Y = |\{i : Y_i = 1,\ X_i = 0\}|$$

McNemar 检验统计量为：

$$K = \frac{(n_X - n_Y)^2}{n_X + n_Y}$$

在零假设成立的条件下该统计量近似服从 $\chi^2(1)$，而在大样本的情况下，它的平方根近似服从标准正态分布。如果有差异，那么统计量的值应该是偏大的，因此只考虑上侧的单侧检验问题，有如下 p 值：

$$p = F_{\chi^2}(K \geqslant k)$$

代码

没搞懂这里的连
性修正是个什么
况

```
mcnemar(x, y, correct=TRUE)
```

Chapter 25

多样本位置检验

25.1 目的

成试验设计之
把多样本位置检
方差分析部分
起来

利用样本中各响应值的位置信息，判断各水平间是否存在差异或某种趋势。

25.2 本章各方法的简单总结

1. 所有方法都要求各水平的总体分布之间是相似的，仅仅是位置参数可能有些差异。
2. Kruskal-Wallis 与 Friedman、Durbin 对称，都是检验各水平响应值的位置参数是否一致（即各水平在该响应值下是否有差异）。Kruskal 是在各水平不相关的情况下使用的，Freidman 是在完全区组设计下、各水平之间由于区组问题不独立时使用的，而 Durbin 是在不完全区组设计下、各区组之间独立时使用的。同时 Kruskal-Wallis、Durbin 要求数据是连续型的，Friedman 则无此类要求。
3. Jonckheere-Terpstra 与 page 对称，都是检验各水平响应值的位置参数是否有顺序关系，Jonckheere-Terpstra 是在各水平不相关的情况下使用的，page 是在完全区组设计下、各水平之间由于区组问题不独立时使用的。同时 Jonckheere-Terpstra 要求数据是连续型的，page 则无此类要求。
4. Cochran 与 Friedman 对应，Cochran 是完全区组设计、二元响应情况下检验各水平是否存在差异的方法。
5. Friedman 与下一章 Kendall 检验是一致的。Kendall 一般用在判断评估者的主观评估是否一致，而 Friedman 则是客观的判断水平之间是否有差异。

25.3 Kruskal-Wallis 检验

适用条件

各响应值在水平间和水平内是独立的，水平之间分布是相似的，数据是连续型的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x - \theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

将所有水平的响应值混合后排序，得到每一个响应值对应于所有数据的秩，类似于方差分析中 MSA 的构成，若水平间的秩和差异大，则应怀疑零假设。由此构建以下 Kruskal-Wallis 统计量（其中 $\bar{R}_i$ 表示第 i 个水平秩的平均值，$\bar{R}$ 表示所有响应值秩的平均值）：

$$H = \frac{12}{N(N+1)} \sum_{i=1}^{k} n_i(\bar{R}_i - \bar{R})^2 = \frac{12}{N(N+1)} \sum_{i=1}^{k} \frac{R_i^2}{n_i} - 3(N+1)$$

如果备择假设成立，那么统计量的值应该是偏大的，因此只考虑上侧的单侧检验问题。

若想求精确结果，需要满足数据中不存在结（即数据中不存在相同的数值），对每种秩分配计算对应的 H 值，便能得到此时统计量 H 的分布。

大样本近似

在大样本的情况下，若零假设成立，有如下近似分布：

$$H \sim \chi^2_{(k-1)}$$

打结

若存在打结的情况，将 H 作以下修正，然后利用大样本近似公式进行计算：

$$H_C = \frac{H}{1 - \sum_{i=1}^{g} (\tau_i^3 - \tau_i)/(N^3 - N)}$$

代码

这是 R 语言 stats 包中的函数，只提供大样本近似，并且不包含连续性修正。x 表示各水平的 response 值，g 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个包含所有水平响应值的列表，各水平之间分隔开。

```
kruskal.test(x, g)
```

以下是自编代码，x 表示各水平的 response 值，y 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个数据框，第一列是 response 值，第二列是 factor 标签。提供精确检验、大样本近似、连续性修正与打结校正功能。精确检验需要 gtools 包，同时测试了一下一个水平 8 个数据一共 24 个数据 permutation 就要占到 14 个 G 的内存以上，慎用精确检验。

```r
kruskal_wallis.test <- function(x, y = NULL, exact = FALSE, correct = FALSE) {
  if (is.data.frame(x) && ncol(x) == 2) {
    DNAME <- deparse(substitute(x))
    y <- x[, 2]
    x <- x[, 1]
  } else if (is.vector(x)) {
    if (is.null(y))
      stop("Error: x must have two columns or y is provided.")
    if (length(y) != length(x))
      stop("Error: x and y must have the same length.")
    DNAME <- paste(deparse(substitute(x)), "and", deparse(substitute(y)))
  } else {
    stop("Error: x must be a data frame with 2 columns or a vector.")
  }
  METHOD <- "Kruskal-Wallis test"
  TIES <- table(x)
  if (any(TIES > 1)) {
    ties <- TRUE
  } else {ties <- FALSE}
  unique_y <- sort(unique(y))
  rank_x <- rank(x)
  R_i <- sapply(unique_y, function(i) sum(rank_x[y == i]))
  n_i <- sapply(unique_y, function(i) sum(y == i))
  N <- length(x)
  STATISTIC <- setNames((12 / (N * (N + 1)) * sum(R_i^2 / n_i) - 3 * (N + 1))
                        / (1 - sum(TIES^3 - TIES) / (N^3 - N)), "H")
  if (!exact || ties) {
    df <- length(unique_y) - 1
    if (!correct) {
      p_value <- pchisq(STATISTIC, df = df, lower.tail = FALSE)
    } else {
      METHOD <- paste(METHOD, "with continuity correction")
      p_value <- pchisq(STATISTIC - 0.5, df = df, lower.tail = FALSE)
    }
  } else {
```

```
    H.cal <- function(rank_x, y) {
      R_i <- sapply(unique_y, function(i) sum(rank_x[y == i]))
      (12 / (N * (N + 1)) * sum(R_i^2 / n_i) - 3 * (N + 1))
    }
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    all_permutations <- permutations(N, N)
    Hs <- sapply(1:nrow(all_permutations), function(i) {
      H.cal(all_permutations[i, ], y)
    })
    p_value <- mean(Hs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

25.4 Jonckheere-Terpstra 检验

目的

检验水平的位置参数是否呈现出上升趋势，若想检验是否呈现出下降趋势，改变水平顺序就行了。

适用条件

各响应值在水平间和水平内是独立的，水平之间分布是相似的，数据是连续型的。这里与 Kruskal-Wallis 检验的条件是一样的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x - \theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$$

原理

假设一共有 k 个水平，每个水平中有 n_i 个响应值 $(i=1,2,\ldots,k)$，响应值用 X_{ij} 表示 $(i=1,2,\ldots,k,\ j=1,2,\ldots,n_i)$，由此构建以下 JT 统计量 (J)：

$$U_{ij}=|X_{ia}<X_{jb},\ a=1,2,\ldots,n_i,\ b=1,2,\ldots,n_j|$$
$$J=\sum_{i<j}U_{ij}$$

在备择假设成立的情况下，某个水平中的观测值会比后面水平中的观测值小，水平间的 U_{ij} 会比较大，J 也会比较大。因此在 J 比较大的时候，有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

若想求精确检验的结果，需要满足数据中没有结（即所有数据中没有相同的数值），然后对每一种秩分配情况计算 J 的值（秩的大小关系便反映了数据之间的大小关系），即可得到 J 的精确分布。

大样本近似

在 $\min\limits_i n_i\to+\infty$ 时，有以下近似公式：

$$Z=\frac{J-(N^2-\sum\limits_{i=1}^{k})/4}{\sqrt{[N^2(2N+3)-\sum\limits_{i=1}^{k}n_i^2(2n_i+3)]/72}}\sim N(0,\ 1)$$

打结

当数据中存在相同数值时，要进行修正：

$$U_{ij}=|X_{ia}<X_{jb},\ a=1,2,\ldots,n_i,\ b=1,2,\ldots,n_j|+$$
$$\frac{1}{2}|X_{ia}=X_{jb},\ a=1,2,\ldots,n_i,\ b=1,2,\ldots,n_j|$$
$$J=\sum_{i<j}U_{ij}$$

代码

x 表示各水平的 response 值，y 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个数据框，第一列是 response 值，第二列是 factor 标签。提供精确检验、大样本近似、连续性修正与打结校正功能。精确检验需要 gtools 包，同时测试了一下一个水平 8 个数据一共 24 个数据 permutation 就要占到 14 个 G 的内存以上，慎用精确检验。

```
JT.test <- function(x, y = NULL, exact = FALSE, correct = FALSE) {
  if (is.data.frame(x) && ncol(x) == 2) {
```

```
    DNAME <- deparse(substitute(x))
    y <- x[, 2]
    x <- x[, 1]
  } else if (is.vector(x)) {
    if (is.null(y))
      stop("Error: x must have two columns or y is provided.")
    if (length(y) != length(x))
      stop("Error: x and y must have the same length.")
    DNAME <- paste(deparse(substitute(x)), "and", deparse(substitute(y)))
  } else {
    stop("Error: x must be a data frame with 2 columns or a vector.")
  }
  J.cal <- function(x, y, k) {
    U <- 0
    for (i in 1:(k - 1)) {
      for (j in (i + 1):k) {
        xi <- x[y==i]
        xj <- x[y==j]
        ties <- sum(outer(xi, xj, "==") * 1)
        U <- U + sum(outer(xi, xj, "<") * 1) + ties / 2
      }
    }
    U
  }
  METHOD <- "Jonckheere-Terpstra test"
  k <- max(y)
  U <- 0
  for (i in 1:(k - 1)) {
    for (j in (i + 1):k) {
      xi <- x[y==i]
      xj <- x[y==j]
      ties <- sum(outer(xi, xj, "==") * 1)
      if (ties > 0) {exact <- FALSE}
      U <- U + sum(outer(xi, xj, "<") * 1) + ties / 2
    }
  }
  STATISTIC <- setNames(U, "J")
  if (!exact) {
```

```
    ni <- table(y)
    N <- sum(ni)
    Z <- (STATISTIC - (N^2 - sum(ni^2)) / 4) / sqrt((N^2 * (2 * N + 3) -
    ↪  sum(ni^2 * (2 * ni + 3))) / 72)
    if (!correct) {
      p_value <- pnorm(Z, lower.tail = FALSE)
    } else {
      p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    n <- length(x)
    all_permutations <- permutations(n, n)
    JTs <- sapply(1:nrow(all_permutations), function(i) {
      J.cal(all_permutations[i, ], y, k)
    })
    p_value <- mean(JTs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

25.5 Friedman 秩和检验

适用条件

各水平间并不独立（因为还有区组的影响），采用完全区组设计，水平之间分布是相似的，连续型与离散型数据都可以。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x - \theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

假设有 k 个水平、b 个区组。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum\limits_{j=1}^{b} R_{ij}$，$i = 1, 2, \ldots, k$，定义如下 Friedman 统计量:

$$Q = \frac{12}{bk(k+1)} \sum_{i=1}^{k} (R_i - \frac{b(k+1)}{2})^2 = \frac{12}{bk(k+1)} \sum_{i=1}^{k} R_i^2 - 3b(k+1)$$

易证 $\frac{b(k+1)}{2} = \bar{R}_i$（只需注意此时秩是针对区组内而言）。在零假设成立的情况下，各水平之间的秩和与均值相比不应相差过大，也就是 Q 值不应太大，若 Q 值过大，则有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

大样本近似

在大样本的情况下（$b \to +\infty$），若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(k-1)}$$

打结

在某个区组存在结的时候，利用下式进行修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$Q_C = \frac{Q}{1-C},\ C = \frac{\sum\limits_{i,j}(\tau_{ij}^3 - \tau_{ij})}{bk(k^2-1)}$$

成对数据的比较

类似于邓肯多重比较法，有时需要比较某两个水平之间是否存在差异，那么在大样本的情况下，如果零假设为：i 水平与 j 水平之间没有差异，那么如果下式成立（其中 α 是检验的显著性水平）：

$$\left| R_i - R_j > Z_{\frac{\alpha^*}{2}} \sqrt{b(k+1)k/6} \right|$$
$$\alpha^* = \frac{\alpha}{k(k-1)/2}$$

则可拒绝零假设。可以看出这是一个很保守的检验，α^* 其实是做了多重假设检验的校正。

记得以后要写多
假设检验的校正
题

代码

以下是自编代码，提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

```r
friedman.test <- function(x, factor = NULL, block = NULL,
                          exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  Q.call <- function(ranks, factors) {
    R_i <- tapply(ranks, factors, sum)
    12 / (b * k * (k + 1)) * sum(R_i^2) - 3 * b * (k + 1)
  }
  METHOD <- "Friedman rank sum test"
  k <- length(unique(factor))
  b <- length(unique(block))
  rank <- ave(response, block, FUN = rank)
  STATISTIC <- setNames(Q.call(rank, factor), "Q")
  TIES <- unlist(tapply(response, block, table))
  if (any(sapply(TIES, function(x) any(x > 1)))) {
    ties <- TRUE
  } else {ties <- FALSE}
  if (!exact || ties) {
    Qc <- STATISTIC / (1 - sum(TIES^3 - TIES) / (b * k * (k^2 - 1)))
```

```
      if (!correct) {
        p_value <- pchisq(Qc, k - 1, lower.tail = FALSE)
      } else {
        p_value <- pchisq(Qc - 0.5, k - 1, lower.tail = FALSE)
        METHOD <- paste(METHOD, "with continuity correction")
      }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    possible_ranks <- permutations(k, k)
    all_combinations <- permutations(nrow(possible_ranks), b,
    ↪  repeats.allowed = TRUE)
    Qs <- sapply(1:nrow(all_combinations), function(i) {
      b_combs <- possible_ranks[all_combinations[i, ], ]
      rank_i <- as.vector(b_combs)
      Q.call(rank_i, factor)
    })
    p_value <- mean(Qs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

25.6 Page 检验

目的

检验水平的位置参数是否呈现出上升趋势，若想检验是否呈现出下降趋势，改变水平顺序就行了。

适用条件

各水平间并不独立（因为还有区组的影响），采用完全区组设计，水平之间分布是相似的，离散型数据与连续型数据都可以。

假设

假设 k 个水平有分布函数 $F_i(x)=F(x-\theta_i)$, $i=1,2,\ldots,k$，则检验假设可写为：

$$H_0:\theta_1=\theta_2=\cdots=\theta_n \Leftrightarrow H_1:\theta_1\leqslant\theta_2\leqslant\cdots\leqslant\theta_n$$

原理

假设有 k 个水平、b 个区组。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i=\sum\limits_{j=1}^{b}R_{ij}$, $i=1,2,\ldots,k$，定义如下 Page 统计量：

$$L=\sum_{i=1}^{k}iR_i$$

如果备择假设是正确的，那么对 R_i 进行加权求和可以对统计量起到一个放大的作用，那么 L 就会很大。因此在 L 比较大的时候，有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

若想求精确检验的结果，需要满足数据中没有结（即每个区组中都没有相同的数值），然后对每一种秩分配情况计算 L 的值（秩的大小关系便反映了数据之间的大小关系），即可得到 L 的精确分布。

大样本近似

在大样本的情况下（$b\to+\infty$），有如下正态近似：

$$Z=\frac{L-\mu_L}{\sigma_L}\sim N(0,\ 1)$$
$$\mu_L=\frac{bk(k+1)^2}{4},\ \sigma_L^2=\frac{b(k^3-k)^2}{144(k-1)}$$

打结

若存在打结的情况，需要对正态近似的 σ_L^2 作如下修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$\sigma_L^2=k(k^2-1)\frac{bk(k^2-1)-\sum_i\sum_j(\tau_{ij}^3-\tau_{ij})}{144(k-1)}$$

对区组、水平进行重复时的 page 检验

在区组和水平之间不存在交互作用，并且所有 $(i,\ j)$ 位置的重复数都相同时（假设都是 n），有如下正态近似（也考虑了到打结的修正）：

$$Z = \frac{L - \mu_L}{\sigma_L} \sim N(0,\ 1)$$
$$\mu_L = \frac{nbk(k+1)(nk+1)}{4}$$
$$\sigma_L^2 = nk(k^2-1)\frac{nbk(n^2k^2-1) - \sum_i \sum_j (\tau_{ij}^3 - \tau_{ij})}{144(nk-1)}$$

代码

以下是自编代码，提供重复、精确计算、大样本近似、连续性修正与打结校正功能。当对区组与水平进行重复时，x 必须是一个数据框，每一列是一次重复的结果，也必须传入 factor 与 block，此时只提供大样本近似。当不进行重复时，x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。请注意，检验顺序与输入的 factor 顺序是一致的，建议对照二维表**逐行**输入（行是水平，检验顺序即为行的顺序，列是区组）。如果出现打结的情况，结统计量按照计算公式进行计算，L 统计量的秩部分取结的平均秩（例：数据为 1、1、3、4，有重复值 1，则秩为 1.5、1.5、3、4）。

```
page.test <- function(x, factor = NULL, block = NULL,
                      exact = FALSE, correct = FALSE,
                      repeated = FALSE) {
  if (repeated) {
    if (exact) {
      stop("Error: exact cannot be TRUE when repeated is TRUE.")
    }
    if (!is.data.frame(x) || ncol(x) == 1) {
      stop("Error: x must be a data frame with more than one column when repeated is TRUE.")
    }
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when repeated is TRUE.")
    }
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    if (is.data.frame(x)) {
```

```
      if (ncol(x) == 3) {
        response <- x[[1]]
        factor <- x[[2]]
        block <- x[[3]]
        DNAME <- deparse(substitute(x))
      }
    } else if (is.vector(x)) {
      if (is.null(factor) || is.null(block)) {
        stop("Error: factor and block must be provided when x is a vector.")
      }
      response <- x
      DNAME <- paste(deparse(substitute(x)), ", ",
                     deparse(substitute(factor)), " and ",
                     deparse(substitute(block)), sep = "")
    } else {
      stop("Error: x must be either a data frame with three columns or a vector.")
    }
  }
  L.call <- function(ranks, factors, num_fac) {
    R_i <- tapply(ranks, factors, sum)
    sum(seq_len(num_fac) * R_i)
  }
  compute_z <- function(statistic, k, b, repeat_n, ties){
    mu <- repeat_n * b * k * (k + 1)^2 / 4
    sigma2 <- repeat_n * k * (k^2 - 1) *
      (repeat_n * b * k * (repeat_n^2 * k^2 - 1) - sum(ties^3 - ties)) /
      (144 * (repeat_n * k - 1))
    (statistic - mu) / sqrt(sigma2)
  }
  METHOD <- "Page test"
  k <- length(unique(factor))
  b <- length(unique(block))
  if (repeated) {
    repeat_n <- ncol(x)
    Ls <- sapply(1:repeat_n, function(repeat_idx) {
      response <- x[[repeat_idx]]
```

```
      rank <- ave(response, block, FUN = rank)
      L.call(rank, factor, k)
    })
    STATISTIC <- setNames(sum(Ls), "L")
    TIES <- unlist(sapply(1:repeat_n, function(repeat_idx) {
      unlist(tapply(x[[repeat_idx]], block, table))
    }))
    Z <- compute_z(STATISTIC, k, b, repeat_n, TIES)
    if (!correct) {
      p_value <- pnorm(Z, lower.tail = FALSE)
    } else {
      p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    rank <- ave(response, block, FUN = rank)
    STATISTIC <- setNames(L.call(rank, factor, k), "L")
    TIES <- unlist(tapply(response, block, table))
    if (any(sapply(TIES, function(x) any(x > 1)))) {
      ties <- TRUE
    } else {ties <- FALSE}
    if (!exact || ties) {
      Z <- compute_z(STATISTIC, k, b, 1, TIES)
      if (!correct) {
        p_value <- pnorm(Z, lower.tail = FALSE)
      } else {
        p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
        METHOD <- paste(METHOD, "with continuity correction")
      }
    } else {
      METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
      library(gtools)
      possible_ranks <- permutations(k, k)
      all_combinations <- permutations(nrow(possible_ranks), b,
      ↪  repeats.allowed = TRUE)
      Ls <- sapply(1:nrow(all_combinations), function(i) {
        b_combs <- possible_ranks[all_combinations[i, ], ]
        rank_i <- as.vector(b_combs)
```

```
        L.call(rank_i, factor, k)
      })
      p_value <- mean(Ls >= STATISTIC)
    }
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

25.7 Cochran 检验

目的

检验完全区组设计、二元响应情况下，各水平之间是否存在差异。

适用条件

完全区组设计，二元响应。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i),\ i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

假设有 k 个水平、b 个区组。

令 L_j 表示第 j 个区组中为 1 的数目的总和，N_i 表示第 i 个水平中为 1 的数目的总和，即 $L_j = \sum\limits_{i=1}^{k} x_{ij},\ j = 1, 2,\ b,\ N_i = \sum\limits_{j=1}^{b} x_{ij},\ i = 1, 2,\ k$。

在零假设成立的情况下，各水平之间无差异，那么对于每个 j 而言，L_j 个 1 在所有水平中出现的概率是相同的，这个概率依赖于具体的 L_j。由此定义如下 Cochran 统计量：

$$Q = \frac{k(k-1)\sum\limits_{i=1}^{k}(N_i - \bar{N})^2}{kN - \sum\limits_{j=1}^{b} L_j^2} = \frac{k(k-1)\sum\limits_{i=1}^{k} N_i^2 - (k-1)N^2}{kN - \sum\limits_{j=1}^{b} L_j^2}$$

其中 $\bar{N} = \dfrac{1}{k}\sum\limits_{i=1}^{k} N_i,\ N = \sum\limits_{i=1}^{k} N_i$。易证，若 $L_j = 0$ 或 $L_j = k$，那么这个区组的数据可以删除，对 Q 值没有影响（与前面的原理是相合的）。

若想进行精确检验

需要找论文，Patil(1975)，同需要看统计量的导过程，为什么检验

大样本近似

在大样本的情况下（$b \to +\infty$），若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(k-1)}$$

代码

以下是自编代码，需要传入一个数据框，行为水平列为区组。提供大样本近似与连续性修正。

现在只提供了大本近似，回头看文和原理记得补

```
cochran.test <- function(x, exact = FALSE, correct = FALSE) {
  if (!is.data.frame(x)) {
    stop("Error: x must be a data frame.")
  }
  DNAME <- deparse(substitute(x))
  METHOD <- "Cochran test"
  Ni <- apply(x, 1, sum)
  Lj <- apply(x, 2, sum)
  N <- sum(Ni)
  k <- nrow(x)
  STATISTIC <- (k * (k-1) * sum(Ni^2) - (k - 1) * N^2) / (k * N -
  ↪  sum(Lj^2))
  STATISTIC <- setNames(STATISTIC, "Q")
  if (!exact) {
    if (!correct){
      p_value <- pchisq(STATISTIC, k - 1, lower.tail = FALSE)
    } else {
      p_value <- pchisq(STATISTIC - 0.5, k - 1, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    # exact test
  }

  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
```

```
  RVAL
}
```

25.8 Durbin 检验

适用条件

不完全区组设计，水平之间分布是相似的，数据是连续型的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

会看看这里平不平衡的不完组设计有没有区别

假设有 k 个水平、b 个区组，每个区组中含 t 个处理，每个处理出现在 r 个区组中。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum\limits_j R_{ij}$, $i = 1, 2, \ldots, k$，定义如下 Durbin 统计量:

$$D = \frac{12(k-1)}{rk(t^2-1)} \sum_{i=1}^{k} (R_i - \frac{r(t+1)}{2})^2 = \frac{12(k-1)}{rk(t^2-1)} \sum_{i=1}^{k} R_i^2 - \frac{3r(k-1)(t+1)}{t-1}$$

在零假设成立的情况下，各水平之间的秩和与均值相比不应相差过大，也就是 D 值不应太大，若 D 值过大，则有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。同时，可以看出 Durbin 统计量在完全区组设计 ($t = k$, $r = b$) 的时候和 Friedman 统计量是完全一样的。

大样本近似

在大样本的情况下（$r \to +\infty$），若零假设成立，有如下近似分布：

$$D \sim \chi^2_{(k-1)}$$

在某个区组存在结的时候，利用下式进行修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$D_C = \frac{(k-1)\sum_{i=1}^{k}(R_i - \frac{r(t+1)}{2})^2}{A - C}$$

$$A = \sum_i \sum_j R_{ij}^2, \ C = \frac{bt(t+1)^2}{4}$$

代码

以下是自编代码，会检查输入的数据是否满足不完全区组设计的平衡性。提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

代码现在是只考虑平衡的

```
durbin.test <- function(x, factor = NULL, block = NULL,
                        exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  num_r <- table(factor)
  num_t <- table(block)
  if (length(unique(num_r)) != 1) {
    stop("Error: The design is not balanced.
         Each treatment must appear in the same number of blocks.")
  }
  if (length(unique(num_t)) != 1) {
    stop("Error: The design is not balanced.
         Each block must contain the same number of treatments.")
  }
```

```
D.call <- function(ranks, factors) {
  R_i <- tapply(ranks, factors, sum)
  12 * (k - 1) / (r * k * (t^2 - 1)) * sum(R_i^2) -
    3 * r * (k - 1) * (t + 1) / (t - 1)
}
METHOD <- "Friedman rank sum test"
k <- length(unique(factor))
b <- length(unique(block))
r <- as.numeric(num_r[1])
t <- as.numeric(num_t[1])
rank <- ave(response, block, FUN = rank)
STATISTIC <- setNames(D.call(rank, factor), "D")
TIES <- unlist(tapply(response, block, table))
if (any(sapply(TIES, function(x) any(x > 1)))) {
  ties <- TRUE
} else {ties <- FALSE}
if (!exact || ties) {
  Dc <- (k - 1) * sum((tapply(rank, factor, sum) - r * (t + 1) / 2)^2) /
    (sum(rank^2) - b * t * (t + 1)^2 / 4)
  if (!correct) {
    p_value <- pchisq(Dc, k - 1, lower.tail = FALSE)
  } else {
    p_value <- pchisq(Dc - 0.5, k - 1, lower.tail = FALSE)
    METHOD <- paste(METHOD, "with continuity correction")
  }
} else {
  METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
  library(gtools)
  possible_ranks <- permutations(t, t)
  all_combinations <- permutations(nrow(possible_ranks), b, repeats.allowed = TRUE)
  Ds <- sapply(1:nrow(all_combinations), function(i) {
    b_combs <- possible_ranks[all_combinations[i, ], ]
    rank_i <- as.vector(b_combs)
    D.call(rank_i, factor)
  })
  p_value <- mean(Ds >= STATISTIC)
```

```
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

Chapter 26

Something else

26.1 Cox-Stuart 趋势检验

目的

查看某组数据是否有递增、递减的趋势。

检验原理

把样本分成前后两段，若样本大小为奇数，则去除最中间的单元。把前后两段相同位置的元素组成对子，以每个对子两个元素差的正负性衡量增减。

$$x_1, x_2, x_3, \cdots, x_n$$

$$\text{对子：}(x_i, x_{i+c}),\ c = \begin{cases} n/2 & n \equiv 0 \mod 2 \\ (n+1)/2 & n \not\equiv 0 \mod 2 \end{cases}$$

$$D_i = x_i - x_{i+c}$$

$$\text{令} s^+ = |\{D_i : D_i > 0\}|,\ s^- = |\{D_i : D_i < 0\}|$$

若数据无趋势，s^- 与 s^+ 应服从 Binom$(s^+ + s^-, 0.5)$，则检验退化为符号检验。以下 p 值计算与广义符号检验略有差异，这是因为 p 取 0.5 时二项分布是对称分布。

检验的数学语言（与表 26.1 对应）

假设独立观测值序列 $X_i \sim F(x - \theta_i),\ i = 1, 2, \ldots, n$:

1. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$
2. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \geqslant \theta_2 \geqslant \cdots \geqslant \theta_n$
3. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$ 或 $\theta_1 \geqslant \theta_2 \geqslant \cdots \geqslant \theta_n$

备择假设	统计量 K	p 值
H_1 : 有增长趋势	s^+	$P(K \leqslant k)$
H_1 : 有减少趋势	s^-	$P(K \leqslant k)$
H_1 : 有趋势	$\min\{s^+, s^-\}$	$2P(K \leqslant k)$

表 26.1: Cox-stuart 趋势检验

代码

```
Cox_Stuart <- function(y) {
    n <- length(y)
    c <- ifelse(n %% 2 == 0, n / 2, (n + 1) / 2)
    D <- y[(c + 1):n] - y[1:c]
    s_neg <- sum(D < 0)
    s_pos <- sum(D > 0)
    s <- min(s_neg, s_pos)
    text <- ifelse(s_pos - s_neg > 0, "Increasing with", "Decreasing
    ↪ with")
    cat(text, 'p_value =', pbinom(s, c, 0.5))
}
```

26.2 游程检验

目的

检验一组数据是否是随机出现的。

适用条件

数据的顺序有意义且是离散的，若不离散，可以中位数为间隔，利用符号函数将数据转换为二元数据。

游程的定义

游程是来自于同一总体的样本所构成的一个或一个以上相同符号连续出现的片段。例：对于数据

$$0000110111000$$

在这组数据中，一共有 5 个游程（3 个 0 游程，2 个 1 游程）。

游程数的分布

证明

令 R 表示游程数，可以证明：

$$P(R=2k)=\frac{2\binom{m-1}{k-1}\binom{n-1}{k-1}}{\binom{N}{n}}$$

$$P(R=2k+1)=\frac{\binom{m-1}{k-1}\binom{n-1}{k}+\binom{m-1}{k}\binom{n-1}{k-1}}{\binom{N}{n}}$$

$$E(R)=\frac{2mn}{m+1}+1 \quad Var(R)=\frac{2mn(2mn-m-n)}{(m+n)^2(m+n-1)}$$

游程检验原理

若数据是随机的，那么游程数不应过多也不应过少，若过多，则呈现出混合倾向，若过少，则呈现出聚集倾向。

备择假设	统计量 K	p 值
H_1 : 数据有聚集趋势	R	$P(K\leqslant k)$
H_1 : 数据有混合趋势	R	$P(K\geqslant k)$
H_1 : 数据有趋势	R	$2\min P(K\leqslant k),\ P(K\geqslant k)$

表 26.2: 随机性的游程检验

代码

tseries 包中的 runs.test

需要注意，该函数只提供大样本近似，并且输入值必须转换为因子，同时，要去除经过符号函数转换后值为 0 的数据。

```
library(tseries)
# median <- median(x)
# x <- factor(sign(x[x != median]-median))
runs.test(x, alternative = c("two.sided", "less", "greater"))
```

自编版

```
runs.test <- function(x, alternative = c("two.sided", "less", "greater"),
↪  exact = TRUE, correct = FALSE) {

  alternative <- match.arg(alternative)
  DNAME <- deparse1(substitute(x))
```

```r
METHOD <- "Runs test"

# Calculate runs
runs <- sum(diff(x) != 0) + 1

# Calculate sample sizes
N <- length(x)
n <- sum(x)  # Number of 1s in x
m <- N - n  # Number of 0s in x

# Functions for cumulative probability
pruns <- function(runs, m, n, lower.tail = TRUE){
  p <- 0
  if (lower.tail){
    for (i in 1:runs){
      if (i %% 2 == 0){
        k <- i / 2
        p <- p + 2 * choose(m - 1, k - 1) *
          choose(n - 1, k - 1) /
          choose(m + n, n)
      }else{
        k <- (i - 1) / 2
        p <- p + (choose(m - 1, k - 1) * choose(n - 1, k) +
                    choose(m - 1, k) * choose(n - 1, k - 1)) /
          choose(m + n, n)
      }
    }
  }else{
    for (i in (runs + 1):(m+n)){
      if (i %% 2 == 0){
        k <- i / 2
        p <- p + 2 * choose(m - 1, k - 1) *
          choose(n - 1, k - 1) /
          choose(m + n, n)
      }else{
        k <- (i - 1) / 2
        p <- p + (choose(m - 1, k - 1) * choose(n - 1, k) +
                    choose(m - 1, k) * choose(n - 1, k - 1)) /
```

```
            choose(m + n, n)
        }
      }
    }
    return(p)
  }

  if (exact){
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    # Exact p-value calculation
    p.value <- switch(alternative,
                      two.sided = 2 * min(pruns(runs, m, n),
                                          pruns(runs - 1, m, n,
                                          ↪  lower.tail = FALSE)),
                      less = pruns(runs, m, n),
                      greater = pruns(runs, m, n, lower.tail = FALSE))
  }else{
    # Normal approximation
    E_R <- (2 * m * n) / N + 1
    Var_R <- (2 * m * n * (2 * m * n - N)) / (N^2 * (N - 1))
    z <- (runs - E_R) / sqrt(Var_R)

    if (correct){
      METHOD <- paste(METHOD, "with continuity correction")
      # Apply continuity correction
      z <- runs - E_R
      CORRECTION <- switch(alternative,
                           two.sided = sign(z) * 0.5,
                           greater = 0.5,
                           less = -0.5)
      z <- (z - CORRECTION) / sqrt(Var_R)
      # p-value using normal approximation
      p.value <- switch(alternative,
                        two.sided =  2 * min(pnorm(z),
                                             pnorm(z, lower.tail =
                                             ↪  FALSE)),
                        less = pnorm(z),
                        greater = pnorm(z, lower.tail = FALSE))
```

```
    }else{
      p.value <- switch(alternative,
                        two.sided =  2 * min(pnorm(z),
                                             pnorm(z, lower.tail =
                                             ↪  FALSE)),
                        less = pnorm(z),
                        greater = pnorm(z, lower.tail = FALSE))
    }
  }

  alternative <- switch(alternative,
                        two.sided = "The data lacks randomness.",
                        less = "The data has a tendency to cluster.",
                        greater = "The data has a tendency to mix.")

  # Create output in htest format
  RVAL <- list(statistics = setNames(runs, "runs"),
               alternative = alternative, method = METHOD,
               data.name = DNAME, p.value = p.value)
  class(RVAL) <- "htest"
  RVAL
}

# median <- median(x)
# x <- na.omit(ifelse(x > median, 1, ifelse(x < median, 0, NA)))
runs.test(x, alternative = "two.sided",
          exact = TRUE, correct = FALSE)
```

26.3 分类评分结果一致性判断

26.3.1 Cohen's Kappa 系数

根本没懂原理

评判标准

1. < 0.4 一致性很差
2. $0.4 - 0.6$ 中度一致
3. $0.6 - 0.8$ 具有较高的一致性

4. > 0.8 具有极高的一致性

代码

```
library(psych)
cohen.kappa(x)
```

26.3.2 Kendall 协同系数检验

目的

检验 b 次对 k 个个体的评估是随机的（不相关的）还是一致的。

适用条件

完全区组设计，离散型数据（打分，排序），主观性的数据一般使用 Kendall 检验。

假设

$$H_0: \text{这些评估是不相关的或是随机的},\ H_1: \text{这些评估是一致的}$$

原理

这里其实是把 b 个评估者看作是区组，把被评分的个体看作了水平。所有的计算和 Friedman 秩和检验一样（参考第211页），只是 Kendall 协同系数 W 要在 Friedman 统计量 Q 的基础上再除 $b(k-1)$（大样本近似与打结的情况都可参考 Friedman 秩和检验）。

料看 Kendall
结是否和
man 一致

为什么这么做呢？我们想看的是对个体的评估是否是随机的，那么如果是随机的，各个体获得的评分总秩和应该是较相近的。其实还是看各水平之间是否有差异，但并不是它们本身的差异，而是在被评估者打分以后，在打分上是否呈现出各水平的差异。其实我们在这里是默认个体之间是有差异的，如果评估结果有差异那么就不随机，评估结果没有差异那就是随机的评估。

代码

以下是自编代码，提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

```
kendall.test <- function(x, factor = NULL, block = NULL,
                         exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
```

```
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  W.call <- function(ranks, factors) {
    R_i <- tapply(ranks, factors, sum)
    (12 / (b * k * (k + 1)) * sum(R_i^2) - 3 * b * (k + 1)) / (b * (k - 1))
  }
  METHOD <- "Kendall test"
  k <- length(unique(factor))
  b <- length(unique(block))
  rank <- ave(response, block, FUN = rank)
  STATISTIC <- setNames(W.call(rank, factor), "W")
  TIES <- unlist(tapply(response, block, table))
  if (any(sapply(TIES, function(x) any(x > 1)))) {exact = FALSE}
  if (!exact) {
    Wc <- STATISTIC / (1 - sum(TIES^3 - TIES) / (b * k * (k^2 - 1)))
    if (!correct) {
      p_value <- pchisq(Wc * b * (k - 1), k - 1, lower.tail = FALSE)
    } else {
      p_value <- pchisq(Wc * b * (k - 1) - 0.5, k - 1, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
```

```
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    possible_ranks <- permutations(k, k)
    all_combinations <- permutations(nrow(possible_ranks), b,
    ↪  repeats.allowed = TRUE)
    Ws <- sapply(1:nrow(all_combinations), function(i) {
      b_combs <- possible_ranks[all_combinations[i, ], ]
      rank_i <- as.vector(b_combs)
      W.call(rank_i, factor)
    })
    p_value <- mean(Ws >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

26.4 列联表独立性问题

检验列联表的行列变量之间是否是独立的。

假设

$$H_0: \text{行变量与列变量是独立的} \Leftrightarrow H_1: \text{行变量与列变量是相关的}$$

26.4.1 Pearson 近似检验

原理

假设行变量有 r 个取值，列变量有 c 个取值，列联表中频数记为 n_{ij}，$i = 1, 2, \ldots, r$，$j = 1, 2, \ldots, c$，行频数总和 $n_{i\cdot} = \sum_j n_{ij}$，列频数总和 $n_{\cdot j} = \sum_i n_{ij}$，频数总和 $n = \sum_{i,j} n_{ij}$，列联表中第 ij 个格子的理论频数为 E_{ij}，行变量取第 i 个值的概率为 $p_{i\cdot}$，列变量取第 j 个值的概率为 $p_{\cdot j}$，一个观测值被分配到列联表中第 ij 个格子的理论概率为 p_{ij}。

概率论把独立接到这里来

若行变量与列变量独立，由随机变量的独立性，有：

$$p_{ij} = p_{i\cdot} p_{\cdot j},\ E_{ij} = p_{\cdot j} n_{i\cdot}$$

但由于 $p_{\cdot j}$ 是理论值无法预知，用 $\frac{n_{\cdot j}}{n}$ 来代替，那么 $E_{ij} = \hat{p_{\cdot j}} n_{i\cdot} = \frac{n_{i\cdot} n_{\cdot j}}{n}$。由此构建以下 Pearson$\chi^2$ 统计量：

$$Q = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

如果零假设不成立，那么 n_{ij} 与 E_{ij} 的值相差就会比较大，统计量的值也会偏大。若统计量的值过大，则有里有怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

大样本近似

在大样本的情况下，若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(r-1)(c-1)}$$

26.4.2 低维列联表的 Fisher 精确检验

假定五个边际频数都是固定的，在零假设成立的情况下，这个具体的列联表出现的条件概率（给定边际频数的情况下，因此是条件概率）只依赖于四个频数中的任意一个，且该概率满足超几何分布：

$$P = \frac{\binom{n_{1\cdot}}{n_{11}}\binom{n_{2\cdot}}{n_{21}}}{\binom{n}{n_{\cdot 1}}}$$

	B1	B2	总和
A1	n_{11}	n_{12}	$n_{1\cdot}$
A2	n_{21}	n_{22}	$n_{2\cdot}$
总和	$n_{\cdot 1}$	$n_{\cdot 2}$	n

表 26.3: 二维列联表

若零假设成立，那么任何一个关于 n_{ij} 的尾概率 $P(n_{ij} \leqslant a)$, $P(n_{ij} \geqslant b)$, $1 - P(a < n_{ij} < b)$ 都不应该太小或太大。若尾概率太小或太大，则有理由怀疑零假设。由此可以看出这里其实是涉及备择假设的方向问题的，可以单侧也可以双侧。

有机会看看单侧
实际意义，不懂
么会考虑单侧

代码

Pearson 近似检验

直接将列联表矩阵输入以下函数即可。

```
chisq.test(x)
```

Fisher 精确检验

直接将列联表矩阵输入以下函数即可。

```
fisher.test(x, alternative="two.sided")
```

26.5 似然比检验

目的

有两个对未知分布 F 参数 θ 的点估计 θ_1 和 θ_2，需要去判断哪个估计更好。

假设

$$H_0 : \theta = \theta_1 \quad H_1 : \theta = \theta_2$$

原理

令 L 表示最大似然函数，则检验统计量为：

$$\lambda = \frac{L(X|\theta_1)}{L(X|\theta_2)}$$

如果 λ 偏小，则说明在 θ_2 下样本出现的概率更大，那么就应该拒绝零假设。当样本量 n 足够大时，有：

$$-2\ln\lambda \sim \chi_p^2, \quad p = dim(\Theta_0 \cup \Theta_1) - dim(\Theta_0)$$

Chapter 27

单调关联性

写完概率论把
Pearson 线性相
数链接过来。

单调关联性 (association) 与单调相关性 (correlation) 是否是同一个东西呢？

它们并不一样。单调关联性仅从秩的角度来衡量两个变量是否同增同减或一增一减，单调相关性除了增减性以外，还要求增减之间存在线性关系，即一个变量增大或减小一个单位，另一个变量是否会固定地增大或减小某个单位的数值。考虑语言习惯问题，本章仍使用相关性来称呼关联性。

27.1 单调关联性的零假设与备择假设

$$H_0: X\text{和}Y\text{不相关}, \begin{cases} H_1: X\text{和}Y\text{正相关} \\ H_1: X\text{和}Y\text{负相关} \\ H_1: X\text{和}Y\text{相关} \end{cases}$$

27.2 本章各方法的简单总结

1. Spearman 秩相关检验与 Kendall 秩相关检验中的 τ_a 都可以用作连续变量的相关性检验。

2. Kendell's τ_b 与 τ_c 都可以用作有序分类变量的相关性检验，但在列联表行列数目 r 和 c 差别较大时，使用 τ_c 更合适。

3. Goodman-Kruskal's τ 检验针对分类有序变量。

4. Somers' d 检验针对分类有序变量，与前面几种方法的不同是：前几种方法的两个变量 X 和 Y 是对称的，而 Somers' 检验把其中一个变量看作自变量，另一个看作因变量，它可以度量自变量对因变量的影响。

27.3 Spearman 秩关联检验

原理

记 x_i 在 X 样本中的秩为 R_i，y_i 在 Y 样本中的秩为 S_i，$d_i^2 = (R_i - S_i)^2$，$\bar{R} = E(R) = \frac{1}{n}\sum_{i=1}^n R_i$，$barS = E(S) = \frac{1}{n}\sum_{i=1}^n S_i$。

显然，若很多 d_i^2 很大，那么两个变量之间可能是负相关；若很多 d_i^2 很小，那么两个变量之间可能是正相关。类似 Pearson 相关系数，定义以下 Spearman 检验统计量：

$$r_s = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2 \sum_{i=1}^n (S_i - \bar{S})^2}} = 1 - \frac{6\sum_{i=1}^n d_i^2}{n(n^2-1)}$$

由 Cauchy 不等式，显然有 $-1 \leqslant r_s \leqslant 1$。

在样本不大且没有结的时候，可以使用精确检验：固定 R_i 从小到大，此时 S_i 的排序情况共有 $n!$ 种可能，对每一种可能计算 r_s，即可得到 r_s 的精确分布。

大样本的情况

大样本时没有近似分布，采用 Monte Carlo 模拟，固定随机数种子，随机抽取 m 个 S_i 可能的排序情况，对这 m 个情况计算 r_s 值，得到近似的分布。

打结

若 X 或 Y 样本中存在相同的数据，则称之为打结的情况。记 u_j，$j = 1, 2, \ldots, p$ 和 v_j，$j = 1, 2, \ldots, q$ 分别为 X 和 Y 样本中结统计量的值，记：

$$U = \sum_{j=1}^p (u_j^3 - u_j),\ V = \sum_{j=1}^q (v_j^3 - v_j)$$

则此时修正过的 Spearman 检验统计量定义为：

$$r_s = \frac{n(n^2-1) - 6\sum_{i=1}^n (R_i - S_i)^2 - 6(U+V)}{\sqrt{[n(n^2-1) - 12U]\,[n(n^2-1) - 12V]}}$$

在样本量比较大时，有：

$$Z = r_s\sqrt{n-1} \sim N(0,\ 1)$$

有结的时候没有精确分布，只能使用上式的大样本近似。

代码

```
cor.test(x, y,
alternative = c("two.sided", "less", "greater"),
method = "spearman"
exact = NULL, continuity = FALSE)
```

27.4 Kendall τ 关联检验

协同

对于样本 $X_i, Y_i,\ i=1,2,\ldots,n$，从中任取两对作积 $(X_i-X_j)(Y_i-Y_j)$，若乘积大于 0，则称对子 $(X_i,\ Y_i)$ 和 $(X_j,\ Y_j)$ 是协同的 (concordant)，它们具有相同的倾向，若乘积小于 0，则称对子是不协同的 (disconcordant)，它们有相反的倾向。令：

$$\Psi(X_i,X_j,Y_i,Y_j)=\begin{cases}1, & (X_i-X_j)(Y_i-Y_j)>0\\ 0, & (X_i-X_j)(Y_i-Y_j)=0\\ -1, & (X_i-X_j)(Y_i-Y_j)<0\end{cases}$$

原理

定义 Kendall τ 相关系数为：

$$\tau_a=\frac{2}{n(n-1)}\sum_{1\leqslant i<j\leqslant n}\Psi(X_i,X_j,Y_i,Y_j)=\frac{K}{\binom{n}{2}}=\frac{n_c-n_d}{\binom{n}{2}}$$

其中 n_c 表示协同的对子的数目，而 n_d 表示不协同的对子的数目。

由定义可以看出，τ_a 取值在 $-1\sim 1$ 之间，τ_a 越大，协同的对子数目越多，两个变量越有可能正相关；τ_a 越小，不协同的对子数目越多，两个变量越有可能负相关。

在计算时，可以把成对数据 $(X_i,\ Y_i)$ 按第一个变量从小到大排序，然后就可以只用 Y_i 的大小关系或者秩来计算 n_c 和 n_d 了。

在样本量不太大并且没有结的时候，可以按如下方法求精确检验结果：把成对数据 $(X_i,\ Y_i)$ 按第一个变量从小到大排序，此时 Y_i 的排序情况共有 $n!$ 种可能，对每一种可能计算 τ_a，即可得到 τ_a 的精确分布。

大样本近似

在零假设成立的情况下，当 $n\to+\infty$ 时，有如下近似分布：

$$Z=K\sqrt{\frac{18}{n(n-1)(2n+5)}}\sim N(0,\ 1)$$

打结

若 X 或 Y 样本中存在相同的数据，则称之为打结的情况。记 $u_i,\ i=1,2,\ldots,p$ 和 $v_i,\ i=1,2,\ldots,q$ 分别为 X 和 Y 样本中结统计量的值，此时有如下修正后的检验统计量：

$$\tau_b=\frac{n_c-n_d}{\sqrt{\left[\frac{n(n-1)}{2}-\sum_i u_i(u_i-1)/2\right]\left[\frac{n(n-1)}{2}-\sum_i v_i(v_i-1)/2\right]}}$$

有结的时候没有精确分布，只能使用下式的大样本近似：

$$Z = \frac{n_c - n_d}{\sqrt{[n(n-1)(2n+5) - t_u - t_v]/18 + t_1 + t_2}} \sim N(0,\ 1)$$

$$t_u = \sum_i u_i(u_i - 1)(2u_i + 5)$$

$$t_v = \sum_i v_i(v_i - 1)(2v_i + 5)$$

$$t_1 = \frac{1}{2n(n-1)} \sum_i u_i(u_i - 1) \sum_j v_j(v_j - 1)$$

$$t_2 = \frac{1}{9n(n-1)(n-2)} \sum_i u_i(u_i - 1)(u_i - 2) \sum_j v_j(v_j - 1)(v_j - 2)$$

有序分类变量情况下的 τ_c

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i = 1, 2, \ldots, r,\ j = 1, 2, \ldots, c$ 为列联表中的对应元素，则 Kendall's τ_c 的定义和其渐进均方差为：

$$\tau_c = \frac{2q(n_c - n_d)}{n^2(q-1)}$$

$$\text{ASE} = \frac{2q}{(q-1)n^2} \sqrt{\sum_{ij} n_{ij}(C_{ij} - D_{ij})^2 - 4(n_c - n_d)^2/n}$$

$$q = \min(r, c)$$

$$C_{ij} = \sum_{i'>i} \sum_{j'>j} n_{i'j'} + \sum_{i'<i} \sum_{j'<j} n_{i'j'}$$

$$D_{ij} = \sum_{i'>i} \sum_{j'<j} n_{i'j'} + \sum_{i'<i} \sum_{j'>j} n_{i'j'}$$

其取值范围也在 $-1 \sim 1$ 之间，同时有如下大样本近似：

$$\frac{\tau_c}{\text{ASE}} \sim N(0,\ 1)$$

代码

```
cor.test(x, y,
alternative = c("two.sided", "less", "greater"),
method = "kendall"
exact = NULL, continuity = FALSE)
```

27.5 Goodman-Kruskal's γ 关联检验

原理

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i=1,2,\ldots,r,\ j=1,2,\ldots,c$ 为列联表中的对应元素，则 Goodman-Kruskal 关联检验统计量 G（也是相关系数的一个点估计）的定义和其近似分布为：

$$G=\frac{n_c-n_d}{n_c+n_d}$$

$$\frac{G}{Var(G)}\sim N(0,\ 1)$$

$$Var(G)\approx\frac{16}{(P+Q)^4}\sum_{i,j}n_{ij}(PC_{ij}-QD_{ij})^2$$

$$P=2n_c,\ Q=2n_d$$

$$C_{ij}=\sum_{i'>i}\sum_{j'>j}n_{i'j'}+\sum_{i'<i}\sum_{j'<j}n_{i'j'},\ D_{ij}=\sum_{i'>i}\sum_{j'<j}n_{i'j'}+\sum_{i'<i}\sum_{j'>j}n_{i'j'}$$

代码

```
library(DescTools)
GoodmanKruskalGamma(x, y, )
```

27.6 Sumers' d 关联检验

原理

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i=1,2,\ldots,r,\ j=1,2,\ldots,c$ 为列联表中的对应元素。

Somers 定义了 $d(C|R)$ 与 $d(R|C)$，前者将行变量 X 看作自变量，后者把列变量 Y 看作自变量，下面仅介绍 $d(C|R)$，$d(R|C)$ 的情况只需要把列联表转置即可得到相应的结果。$d(C|R)$ 的定义及其渐近均方差为：

$$d(C|R)=\frac{2(n_c-n_d)}{n(n-1)-\sum_i^r R_i(R_i-1)}=\frac{P-Q}{D_r}$$

$$\text{ASE}=\frac{2}{D_r^2}\sqrt{\sum_{i,j}n_{ij}\left[D_r(C_{ij}-D_{ij})-(P-Q)(n-R_i)\right]^2}$$

$$R_i=\sum_{j=1}^{c}n_{ij},\ D_r=n^2-\sum_{i}^{r}R_i^2$$

$$P=2n_c,\ Q=2n_d$$

$$C_{ij}=\sum_{i'>i}\sum_{j'>j}n_{i'j'}+\sum_{i'<i}\sum_{j'<j}n_{i'j'},\ D_{ij}=\sum_{i'>i}\sum_{j'<j}n_{i'j'}+\sum_{i'<i}\sum_{j'>j}n_{i'j'}$$

在大样本情况下有如下近似：

$$\frac{d(C|R)}{\text{ASE}}\sim N(0,\ 1)$$

附录

.1 R 语言函数详解

.1.1 wilcox.test

部分参数解释

1. digits.rank：若为有限值，则在计算秩的时候对数据取小数点后 digits.rank 位进行计算。

后记