你永远不知道一个强迫症能干出什么事情

倪兴程 [1]

2024 年 10 月 18 日

[1]Email: 19975022383@163.com

Todo list

需要再考虑一下是不是 SRS 和 SRSWR 都是这样的 19
在概率论里完善 Wilcoxon 秩统计量的分布相关理论，然后链接过来 31
没搞懂这里的连续性修正是个什么情况 39
在完成试验设计之后，把多样本位置检验与方差分析部分结合起来 40
记得以后要写多重假设检验的校正问题 47
需要找论文，Patil(1975)，同时需要看统计量的推导过程，为什么单侧检验 55
现在只提供了大样本近似，回头看完论文和原理记得补 55
有机会看看这里平衡与不平衡的不完全区组设计有没有什么区别 56
代码现在是只考虑平衡的 57
有空证明 62
根本没懂原理 65
查资料看 Kendall 的打结是否和 Friedman 一致 66
写完概率论把独立性链接到这里来 68
有机会看看单侧的实际意义，不懂为什么会考虑单侧 69
写完概率论把 Pearson 线性相关系数链接过来。 71

前言

其实这个想法在我大二之初准备全国大学生数学建模竞赛的时候就已经产生。第一次打数模国赛时整篇论文的编排工作由组内成员负责，当时我并不了解 LaTeX 的语法与使用，但由于 IGEM 校园选拔赛要求每位申请数模组的同学提交一篇自己独立完成的数学建模论文，我便开始学习 LaTeX。

本科阶段我曾学习大量数学专业课程，从基础的数学分析、高等代数到后来的随机过程、实变函数与泛函分析。我曾苦于寻找合适的教材（请允许我吐槽一下国内的本科教材，北大版高等代数与华东师大版数学分析简直不是人能看得下去的东西），感谢知乎、csdn 等处各位同学、学长学姐们的分享，我才得以接触到一些适合我的教材。以数学分析为例，我主要以北京大学张筑生教授编写的《数学分析新讲》为学习教材，以苏州大学谢惠民、恽自求等教授编写的《数学分析习题课讲义》为习题册进行查漏补缺，同时也曾阅读复旦大学陈纪修教授、北京大学伍胜健教授编写的《数学分析》，对清华大学于品教授的讲义也曾匆匆一瞥，这些教材都可以称为是国内顶尖的数学分析教材了。可是每本书都有每本书自己的特点，对于任何一本书，以上所列的其他书籍都对其有着一定的补充，曾考虑使用 marginnote 软件将这些书籍整理成一些思维导图，但思来想去还是觉得不如自己动手重新编撰为一本属于自己的教材。首先，思维导图只能援引原著内容，难以进行个性化表述，即使可以，操作与使用起来都有一定的复杂性与不便性；其次，倘若重新整理，内容编排上可按我的个人习惯以及思维过程进行调整，也可引入适当高阶课程中的知识进行更高观点的阐释，不同课程中的交叉部分也很容易集中叙述；同时，LaTeX 的交叉引用（点击即跳转）的功能也十分吸引我；最后，自己编一本书，倘若确实质量不错，也可上传至 Github 或个人主页供后来者一阅。

曾想过在 Bilibili 上录播自己在 SRT 阶段学习到的机器学习、深度学习及生物信息学知识作为分享，同时也可作为自己复习的一手资料，也曾想过利用 csdn、知乎这两个平台发布自己整理的笔记，但终究没有付诸实践，略有遗憾，但我现在做的本科阶段知识的整理，我一定会完成它。

本书打算整理我本科所学的所有数学类课程知识，将伴随着我个人的考研复习进度逐步完成，预计耗时一年半。

倪兴程

2024 年 10 月 18 日于南京农业大学教四楼 B409

目录

前言 ii

第一部分　分析学 1

第一章　数列极限 2

1.1　数列极限的定义 2

第二章　函数极限 4

第二部分　概率论 5

第三章　大数定律与中心极限定理 6

3.1　连续性校正 6

3.1.1　使用原因 6

3.1.2　具体方法 7

第三部分　统计学 8

第四章　正态分布与三大抽样分布 9

4.1　多维正态分布 9

4.1.1　多维正态分布的定义 9

4.1.2　多维正态分布的性质 10

第四部分　试验设计 12

第五章　试验设计基本概念 13

第五部分　抽样调查 14

符号说明 15

第六章 抽样调查基本概念 **16**
6.1 抽样调查的目的 16
6.2 目标群体、源群体、研究群体 16
6.3 抽样设计 17
6.4 抽样框架 17
6.5 抽样调查随机性的来源 18
6.5.1 基于模型的方法 18
6.5.2 基于设计的方法 18

第七章 概率抽样 **19**
7.1 概率抽样概述 19
7.1.1 样本概率 19
7.1.2 入样概率与抽样权重 19
7.2 简单随机抽样 19
7.2.1 特征 19
7.2.2 SRS 中 Z 的相关性质 20
7.2.3 SRS 总体均值 μ 的估计 20
7.2.4 SRS 总体总数 τ 的估计 21
7.2.5 SRS 总体方差 σ^2 的估计 22
7.2.6 SRSWR 中 Q 的相关性质 23
7.2.7 SRSWR 总体总数 τ 的估计 23
7.2.8 SRS 阳性率问题 24
7.2.9 样本容量的选择 25
7.2.10 简单随机抽样适用条件 26

第六部分 非参数统计学 **27**

第八章 单样本位置检验 **28**
8.1 广义符号检验 28
8.1.1 具体方法 28
8.1.2 代码 29
8.2 Wilcoxon 符号秩检验 30
8.2.1 具体方法 30
8.2.2 代码 31
8.3 中位数的点估计与置信区间 32
8.3.1 具体方法 32
8.3.2 代码 32
8.4 符号检验与 Wilcoxon 符号秩检验的比较 33

第九章 两样本位置检验 **34**
9.1 目的 34
9.2 Brown-Mood 中位数检验 34
9.2.1 具体方法 34
9.2.2 代码 35
9.3 Wilcoxon 秩和检验 36
9.3.1 具体方法 36
9.3.2 代码 37
9.4 Brown-Mood 中位数检验与 Wilcoxon 秩和检验的比较 37
9.5 成对数据差异性检验 37
9.5.1 连续型数据 38
9.5.2 01 型数据的 McNemar 检验 38

第十章 多样本位置检验 **40**
10.1 目的 40
10.2 本章各方法的简单总结 40
10.3 Kruskal-Wallis 检验 41
10.3.1 具体方法 41
10.3.2 代码 41
10.4 Jonckheere-Terpstra 检验 43
10.4.1 具体方法 43
10.4.2 代码 44
10.5 Friedman 秩和检验 46
10.5.1 具体方法 46
10.5.2 代码 48
10.6 Page 检验 49
10.6.1 具体方法 49
10.6.2 代码 51
10.7 Cochran 检验 54
10.7.1 具体方法 54
10.7.2 代码 55
10.8 Durbin 检验 56
10.8.1 具体方法 56
10.8.2 代码 57

第十一章 Something else **60**
11.1 Cox-Stuart 趋势检验 60
11.1.1 具体方法 60
11.1.2 代码 61

11.2 游程检验 61
11.2.1 具体方法 61
11.2.2 代码 62
11.3 分类评分结果一致性判断 65
11.3.1 Cohen's Kappa 系数 65
11.3.2 Kendall 协同系数检验 66
11.4 列联表独立性问题 68
11.4.1 目的 68
11.4.2 Pearson 近似检验 68
11.4.3 低维列联表的 Fisher 精确检验 69
11.4.4 代码 69

第十二章 单调关联性 71

12.1 单调关联性的零假设与备择假设 71
12.2 本章各方法的简单总结 71
12.3 Spearman 秩关联检验 72
12.3.1 具体方法 72
12.3.2 代码 72
12.4 Kendall τ 关联检验 73
12.4.1 具体方法 73
12.4.2 代码 74
12.5 Goodman-Kruskal's γ 关联检验 75
12.5.1 原理 75
12.5.2 代码 75
12.6 Sumers' d 关联检验 75
12.6.1 原理 75

附录 77

.1 R 语言函数详解 77
.1.1 wilcox.test 77

后记 78

第一部分

分析学

Chapter 1

数列极限

1.1 数列极限的定义

实数序列有界序列收敛序列的定义（包含无穷大，并区分 R 中收敛还是包含扩充的 R 中收敛），几何解释，在这里定义发散序列

收敛序列的证明方法：定义法（放大），夹逼定理（有穷与无穷），单调收敛原理（有界情况用到了收敛序列的有界性，无界情况则无穷，把两个都包含进去），柯西收敛原理（用到了波尔查诺-魏尔斯特拉斯，，需要先说明基本序列以及基本序列的有界性）（使用时常取 n 与 n+p，最终还是需要把 p 放缩掉）

收敛序列的性质：极限的唯一性（无穷与有穷），有界性（有界收敛），四则运算与绝对值（右端的式子有意义，分为两方面，一方面是极限存在，另一方面是极限的那些数值做的计算有意义），收敛序列与不等式的关系

子列的定义，收敛序列子列必有极限且极限相同且唯一

闭区间套原理（用到了单调收敛原理，至于 c 的唯一性可以用上下确界的唯一性得到），波尔查诺-魏尔斯特拉斯定理（有界序列必有子列有极限，用到了闭区间套）

函数极限的序列式定义与柯西式定义，两种定义的等价性。（这里考虑极限值与极限点的有穷与无穷）

函数极限的证明方法：定义法，夹逼定理（序列式易证，有穷与无穷），有穷极限时的收敛原理

函数极限的性质：极限的唯一性（序列式易证），有界性（极限有界，柯西式易证），四则运算与绝对值（序列式可以直接得到有穷与无穷下的所有结果），收敛函数与不等式的关系（柯西式定义），复合函数求极限（序列式与柯西式都易证）

函数的单侧极限，极限存在与单侧极限的关系，单调函数的单侧极限总是存在的

函数的连续性与单侧连续的定义，一类与二类间断点。

闭区间上连续函数的性质：介值定理（闭区间套与连续函数交换映射与极限顺序），区间上有界（闭区间套和函数极限的有界性），最值定理（其实是上下确界，利用上下确界的定义以及有界序列必有收敛子列），一致连续（构造序列反证，利用连续函数定义与有界序列必有收敛子列。同时还有序列式表述的一致连续性以及两个表述之间的等价性)

乘积或商时等价因式的替换（和极限的四则运算一样，要求右侧有意义并且存在对应的极限关系）

导数的定义。单侧导数，单侧导数与导数存在的关系。导数的运算法则：加减（函数四则运算证明），乘除（加一减一），复合函数求导（引入微分表示的不变性），反函数求导（注意反函数的单调性导致分母不会为 0），隐函数求导（注意这里用了反函数，对某个隐函数是有要求的）（同时还要注意直接求导法），对数求导法，高阶导数莱布尼茨公式。常见函数的导函数。

可微的定义，一元函数可导与可微的充要关系，一元函数可微与连续的关系。微分的定义，函数运算后的微分（导数乘 dx）。

极值点的判断：极值点定义（函数需要有定义，此处需要有内点的定义）引入无穷小增量公式（微分），费马定理（极值点的必要条件，此处引入临界点的定义，最值的搜索定理）引入有限增量公式（罗尔中值定理：闭区间函数必有最大值和最小值，最值必然也是极值，由费马定理推出导数为 0；拉格朗日中值定理：作辅助函数变为罗尔定理的形式），函数递增与严格递增的充要条件，极值点的第一充分条件（不要求可导，但要求连续），极值点的第二充分条件（比第一充分条件严格，也是从第一推导来的）

原函数的定义，原函数的表示形式，不定积分，函数线性运算后的不定积分不定积分的求法：换元积分法（微分形式不便性，分第一和第二），分步积分法（函数积的微分），有理函数的积分

Chapter 2

函数极限

第二部分

概率论

Chapter 3

大数定律与中心极限定理

3.1 连续性校正

3.1.1 使用原因

由中心极限定理，独立同分布的随机变量序列 $X_i,\ i = 1, 2 \ldots, n$ 的和 $\sum\limits_{i=1}^{n} X_i$ 将在随机变量个数 $n \to +\infty$ 时服从正态分布，因此，在某些情况下，我们可以利用正态分布 CDF(Cumulative Distribution Function) 值来近似一些难以计算的离散型随机变量 (Discrete Variable) 的 CDF 值。

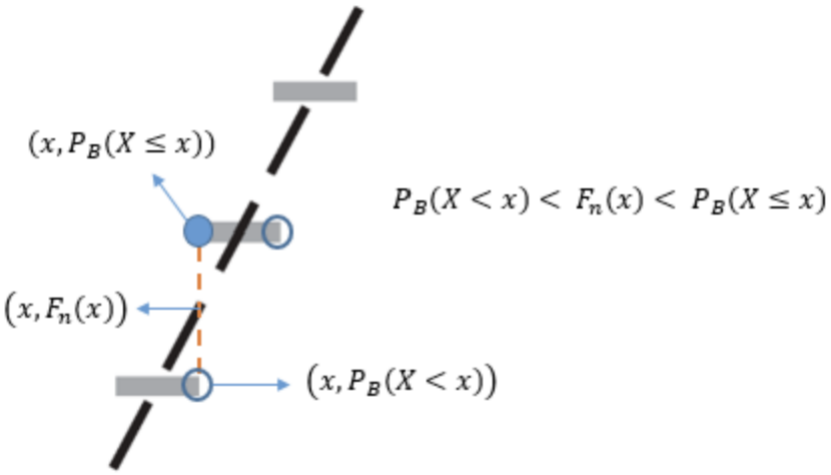

图 3.1: 连续型、离散型随机变量 CDF 图

对于离散型随机变量，常出现 $P(X < x) \neq P(X \leqslant x)$，而对于连续型随机变量 (Continuous Variable)，二者的值是相等的，因此，CDF 值的近似将出现以下问题：

1. 使用正态分布 CDF 值近似 $P(X \leqslant x)$ 时近似值偏小。

2. 使用正态分布 CDF 值近似 $P(X < x)$ 时近似值偏大。

而我们会想要得到一个一致的近似，即对于以上两个近似，结果总是一致地偏大或偏小，这样利于分析。

3.1.2 具体方法

- 根据近似的分布选择一个 $\alpha \in (-1, 1)$，一般选择 $\pm\frac{1}{2}$。
- 使用正态分布 CDF 值 $F(\frac{x+\alpha-\mu}{\sigma})$ 近似 $P(X < x)$ 与 $P(X \leqslant x)$。

第三部分

统计学

Chapter 4

正态分布与三大抽样分布

4.1 多维正态分布

4.1.1 多维正态分布的定义

若一个随机向量满足以下概率密度函数：

$$f(\mathbf{X}) = \frac{1}{(2\pi)^{\frac{n}{2}}(\det\boldsymbol{\Sigma})^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{X}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{X}-\boldsymbol{\mu})}$$

则称其为一个正态随机向量，记作 $\mathbf{X} \sim \mathrm{N}(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$。其中 $\mathbf{X} = (x_1, x_2, \ldots, x_n)' \in \mathbf{R}^n$，$\boldsymbol{\mu} = (\mu_1, \mu_2, \ldots, \mu_n)'$，$\boldsymbol{\Sigma}$ 是一个 n 维矩阵。我们仅讨论 $\boldsymbol{\Sigma}$ 是正定非退化矩阵的情况。下面我们证明概率密度函数中的两个参数 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 分别是正态随机向量的均值向量与协方差阵。

证明. 令：

$$\mathbf{Y} = \boldsymbol{\Sigma}^{-\frac{1}{2}}(\mathbf{X} - \boldsymbol{\mu})$$

则有 $\mathbf{X} = \boldsymbol{\Sigma}^{\frac{1}{2}}\mathbf{Y} + \boldsymbol{\mu}$，由求随机变量函数的分布中的变量变换法可知[1]：

$$g(\mathbf{Y}) = f(\boldsymbol{\Sigma}^{\frac{1}{2}}\mathbf{Y} + \boldsymbol{\mu})|\mathbf{J}|$$

其中 $\mathbf{J}$ 为变换的 Jacobi 行列式：

$$\mathbf{J} = \begin{vmatrix} \dfrac{\partial x_1}{\partial y_1} & \cdots & \dfrac{\partial x_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial x_n}{\partial y_1} & \cdots & \dfrac{\partial x_n}{\partial y_n} \end{vmatrix} = det(\boldsymbol{\Sigma}^{\frac{1}{2}}) = (det\boldsymbol{\Sigma})^{\frac{1}{2}}$$

[1]这是由于 $\mathbf{X}$ 到 $\mathbf{Y}$ 的变换是一个线性变换，线性变换让 $\mathbf{X}$ 关于 $\mathbf{Y}$ 有连续偏导数，同时这个线性变换可逆，满足变量变换法的两大条件。

那么 $\mathbf{Y}$ 为：

$$\begin{aligned} g(\mathbf{Y}) &= \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}\mathbf{Y}'\mathbf{Y}} \\ &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}} e^{-\frac{y_i^2}{2}} \\ &= \prod_{i=1}^{n} f(y_i) \end{aligned}$$

可见 $y_i \sim \mathrm{N}(0,\ 1)$。同时，$\mathbf{Y}$ 的 n 个分量的联合密度等于每个分量密度函数的乘积，于是 $\mathbf{Y}$ 的各个分量相互独立，再结合 $\mathbf{Y}$ 与 $\mathbf{X}$ 的关系，有：

$$E(\mathbf{Y}) = \mathbf{0},\ Cov(\mathbf{Y}) = \mathbf{I}$$

$$E(\mathbf{X}) = \boldsymbol{\mu},\ Cov(\mathbf{X}) = \boldsymbol{\Sigma}$$

□

4.1.2 多维正态分布的性质

定理 4.1. 设 $\mathbf{X} \sim N(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$，且 $\mathbf{X}$、$\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 有如下分块形式：

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \\ \vdots \\ \mathbf{X}_a \end{pmatrix},\ \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \\ \vdots \\ \boldsymbol{\mu}_a \end{pmatrix},\ \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_1 & \mathbf{0} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_2 & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \ddots & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \boldsymbol{\Sigma}_a \end{pmatrix}$$

则有 $\mathbf{X}_i \sim N(\boldsymbol{\mu}_i,\ \boldsymbol{\Sigma}_i)$ 且相互独立。

证明. 显然此时有：

$$\det\boldsymbol{\Sigma} = \prod_{i=1}^{a} \det\boldsymbol{\Sigma}_i$$

$$(\mathbf{X}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{X}-\boldsymbol{\mu}) = \prod_{i=1}^{a} (\mathbf{X}_i-\boldsymbol{\mu}_i)'\boldsymbol{\Sigma}_i^{-1}(\mathbf{X}_i-\boldsymbol{\mu}_i)$$

□

定理 4.2. 设 $\mathbf{X} \sim N(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$，$\mathbf{A}$ 为 n 阶非随机可逆矩阵，$\mathbf{b}$ 为 n 维列向量，记 $\mathbf{Y} = \mathbf{AX}+\mathbf{b}$，则有：

$$\mathbf{Y} \sim N(\mathbf{AX}+\mathbf{b},\ \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$$

证明. 与证明 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 是多维正态随机变量 X 的均值与协方差矩阵一样，利用变量变换法求随机变量函数的分布。 □

定理 4.3. 设 $\mathbf{X} \sim N(\boldsymbol{\mu},\ \boldsymbol{\Sigma})$，且 $\mathbf{X}$、$\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 有如下分块形式：

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \\ \vdots \\ \mathbf{X}_a \end{pmatrix},\ \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \\ \vdots \\ \boldsymbol{\mu}_a \end{pmatrix},\ \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} & \cdots & \boldsymbol{\Sigma}_{1a} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} & \cdots & \boldsymbol{\Sigma}_{2a} \\ \vdots & \vdots & \ddots & \vdots \\ \boldsymbol{\Sigma}_{a1} & \boldsymbol{\Sigma}_{a2} & \cdots & \boldsymbol{\Sigma}_{aa} \end{pmatrix}$$

则有 $\mathbf{X}_i \sim N(\boldsymbol{\mu}_i,\ \boldsymbol{\Sigma}_{ii})$。

证明. 存在一个线性变换让其变成Equation 4.1中的形式。取：

$$\mathbf{A} = \begin{pmatrix} \mathbf{\Sigma}_{11} & \mathbf{\Sigma}_{12} & \cdots & \mathbf{\Sigma}_{1i} & \cdots & \mathbf{\Sigma}_{1a} \\ \vdots & \vdots & & \vdots & & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{I_{ii}} & \cdots & \mathbf{0} \end{pmatrix} \tag{4.1}$$

□

第四部分

试验设计

Chapter 5

试验设计基本概念

1. 响应变量 (response)：衡量实验结果好坏的指标。
    - 定量响应变量。
    - 定性响应变量。
2. 因子 (factor)：影响响应变量的因素。
3. 水平：试验中因子所处的各个状态称之为因子的水平。
4. 效应模型：

第五部分

抽样调查

符号说明

符号	说明
Y_k	总体中单元的取值
y_k	样本中单元的取值
N	总体单元个数
n	样本单元个数
$p(s)$	样本概率
π_k	单元的入样概率
w_k	单元的抽样权重
τ	总体均值
σ^2	总体方差
μ	样本均值
s^2	样本方差
Z_i	单元是否入样的示性变量
Q_i	单元在样本中出现的次数
p	阳性率

表 5.1: 符号说明表

Chapter 6

抽样调查基本概念

6.1 抽样调查的目的

抽样调查最直接的主要任务，就是根据测得的样本数量指标 $\{y_1, y_2, \ldots, y_n\}$，对总体 $\{Y_1, Y_2, \ldots, Y_N\}$ 的一些数字特征进行估计。如估计：

1. 总体均值$\mu = \frac{1}{N}\sum_{i=1}^{N} Y_i$, 总体总数$\tau = \sum_{i=1}^{N} Y_i$。

2. [1]总体方差$\sigma^2 = \frac{1}{N-1}\sum_{i=1}^{N}(Y_i - \overline{Y})^2$。

3. 总体中满足某一特征的单元所占比例 p。

4. 总体分布的分位数。

6.2 目标群体、源群体、研究群体

- 目标群体：研究者希望对其进行描述或推断的群体。

- 源群体：研究者实际用于选择样本的群体，通常是目标群体的一个子集或一个接近目标群体的群体。

- 研究群体：抽样后的样本

[1]这里指的是有限总体的方差，我们在抽样调查中认为有限总体也相当于一个样本，以样本方差公式计算其方差。在有放回与无限总体的情况下，分母取 N

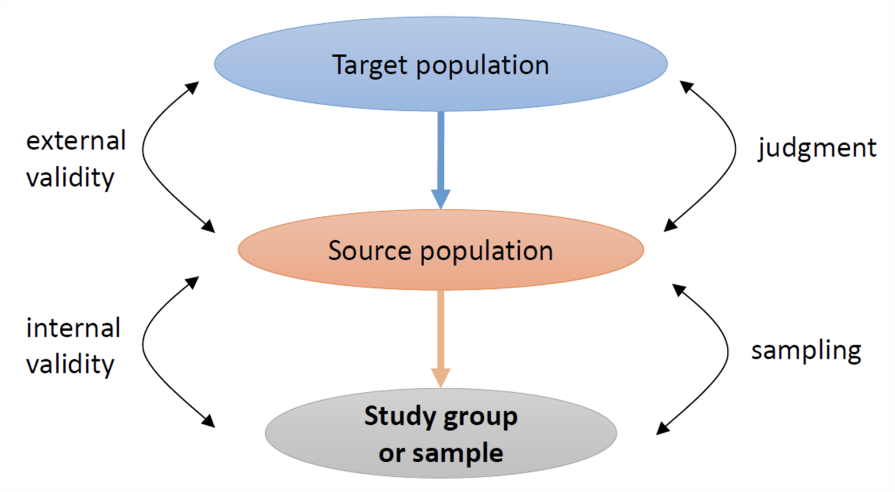

图 6.1: 群体

6.3 抽样设计

$$
\text{抽样设计}\begin{cases}\text{概率抽样}\begin{cases}\text{简单随机抽样}\\ \text{分层抽样}\\ \text{整群抽样}\end{cases}\\ \text{非概率抽样}\begin{cases}\text{方便抽样}\\ \text{雪球抽样}\\ \text{判断抽样}\end{cases}\end{cases}
$$

- 概率抽样样本是随机产生的，非概率抽样样本不是随机产生的。
- 非概率抽样无法判断样本是否具备代表性，也就无法确定抽样误差。但在一定程度上可以说明总体的特征。
- 方便抽样是选择最容易获得的样本作为研究对象。
- 雪球抽样是先选择一个较小的样本，再让这个样本中的单元去提供一些样本。
- 判断抽样是研究人员从总体中选择自己认为最能代表总体的个体。

6.4 抽样框架

对可以选择作为样本的群体单位列出的名册或排序编号，用以确定总体的抽样范围和结构。

6.5 抽样调查随机性的来源

6.5.1 基于模型的方法

绝大多数统计学课程是基于模型的 (model-based approch)，它将总体看作是背后随机变量的实现，随机性来源于随机变量的取值。

6.5.2 基于设计的方法

抽样调查是基于设计的 (design-based approch)，它将总体中单元的数值看作为定值，而随机性来源于是否抽到总体中的单元。

Chapter 7

概率抽样

7.1 概率抽样概述

7.1.1 样本概率

记一个可能的样本为 s，记在抽样设计下出现这个样本的概率[1]为 $p(s)$，应有 $\sum_s p(s) = 1$。

7.1.2 入样概率与抽样权重

对于任意单元 Y_k，该单元的入样概率 π_k 记为 $\sum_{Y_k \in s} p(s)$，该单元的抽样权重 w_k 定义为 $\frac{1}{\pi_k}$，表示该单元可以代表总体里的多少个单元。

7.2 简单随机抽样

简单随机抽样分为不放回 (simple random sampling, SRS) 与有放回 (simple random sampling with replacement, SRSWR) 两种。我们通常更喜欢不放回抽样，因为同一个单元出现多次并不能提供额外的信息，同时有放回抽样会导致估计量的方差更大。

7.2.1 特征

简单随机抽样意味着每个样本出现的概率是一样的，即 $p(s)$ 一致，那么每个单元的入样概率也是一致的（样本出现概率一致时每个单元的入样概率服从古典概型）。

需要再考虑一下是不是 SRS SRSWR 都是这

[1]样本出现的概率未必是等可能的。

7.2.2 SRS 中 Z 的相关性质

$$
\begin{aligned}
E(Z_i) &= \frac{n}{N} \\
Var(Z_i) &= \frac{n}{N}\left(1-\frac{n}{N}\right) \\
Cov(Z_i, Z_j) &= \frac{-n}{N(N-1)}\left(1-\frac{n}{N}\right)
\end{aligned}
$$

证明. 每个单元被抽到的概率为：

$$
\pi_k = \frac{\binom{N-1}{n-1}}{\binom{N}{n}} = \frac{n}{N}
$$

由此可知单元示性变量的期望：

$$
E(Z_i) = 1 \times P(Z_i = 1) = 1 \times \pi_i = \frac{n}{N}
$$

注意到 $E(Z_i^2) = 0 \times P(Z_i^2 = 0) + 1 \times P(Z_i^2 = 1) = P(Z_i = 1) = E(Z_i)$，

$$
\begin{aligned}
Var(Z_i) &= E(Z_i^2) - E^2(Z_i) \\
&= E(Z_i)\left(1 - E(Z_i)\right) \\
&= \frac{n}{N}\left(1-\frac{n}{N}\right)
\end{aligned}
$$

注意到 $E(Z_iZ_j) = P(Z_i = 1,\ Z_j = 1)$，

$$
\begin{aligned}
Cov(Z_i, Z_j) &= E(Z_iZ_j) - E(Z_i)E(Z_j) \\
&= \frac{\binom{N-2}{n-2}}{\binom{N}{n}} - E^2(Z_i) \\
&= \frac{-n}{N(N-1)}\left(1-\frac{n}{N}\right)
\end{aligned}
$$

□

7.2.3 SRS 总体均值 μ 的估计

点估计及点估计的性质

$$
\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} y_i = \frac{1}{n}\sum_{i=1}^{N} Y_i Z_i
$$

$$
E(\hat{\mu}) = \mu,\ Var(\hat{\mu}) = \frac{1}{n}\left(1-\frac{n}{N}\right)\sigma^2
$$

$$
\widehat{Var(\hat{\mu})} = \frac{1}{n}\left(1-\frac{n}{N}\right)s^2 \text{是关于} Var(\hat{\mu}) \text{的无偏估计。}
$$

其中方差的计算见下文总体总数方差的推导，由方差的性质即可推导出总体均值的方差。[2]

[2] $\left(1-\frac{n}{N}\right)$ 被称之为有限群体校正分数 (finite population correction fraction, FPC)，有放回抽样或 N 远大于 n 时不需要 FPC。

区间估计

$$\frac{\mu-\hat{\mu}}{\sqrt{Var(\hat{\mu})}} \sim \mathrm{N}(0,\ 1)$$
$$\frac{\mu-\hat{\mu}}{\sqrt{\widehat{Var(\hat{\mu})}}} \sim t_{n-1}$$

因此置信度为 $(1-\alpha)$ 的双侧置信区间为：

$$\hat{\mu} \pm t_{1-\frac{\alpha}{2}} \times \sqrt{\widehat{Var(\hat{\mu})}}$$

7.2.4 SRS 总体总数 τ 的估计

利用样本平均值进行估计

$$\hat{\tau} = N\hat{\mu} = \frac{N}{n}\sum_{i=1}^{n} y_i = \frac{N}{n}\sum_{i=1}^{N} Y_i Z_i$$
$$E(\hat{\tau}) = \tau$$

Horvitz-Thompson 估计量（HT 估计量）

点估计及其性质

$$\hat{\tau} = \sum_{i=1}^{n} w_i y_i = \sum_{i=1}^{N} w_i Y_i Z_i$$
$$E(\hat{\tau}) = \tau,\ Var(\hat{\tau}) = \frac{N^2}{n}\left(1-\frac{n}{N}\right)\sigma^2$$
$$\widehat{Var(\hat{\tau})} = \frac{N^2}{n}\left(1-\frac{n}{N}\right)s^2$$

区间估计

$$\frac{\tau-\hat{\tau}}{\sqrt{Var(\hat{\tau})}} \sim \mathrm{N}(0,\ 1)$$
$$\frac{\tau-\hat{\tau}}{\sqrt{\widehat{Var(\hat{\tau})}}} \sim t_{n-1}$$

因此置信度为 $(1-\alpha)$ 的双侧置信区间为：

$$\hat{\tau} \pm t_{1-\frac{\alpha}{2}} \times \sqrt{\widehat{Var(\hat{\tau})}}$$

下给出点估计估计量方差公式的证明。

证明.

$$
\begin{aligned}
Var(\hat{\tau}) &= Var\left(\sum_{i=1}^{N} w_i Y_i Z_i\right) \\
&= \sum_{i=1}^{N} Var(w_i Y_i Z_i) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} Cov(w_i Y_i Z_i, w_j Y_j Z_j) \\
&= \sum_{i=1}^{N} w_i^2 Y_i^2 Var(Z_i) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} w_i Y_i w_j Y_j Cov(Z_i, Z_j)
\end{aligned}
$$

注意到 $w_i = \frac{N}{n}$：

$$
\begin{aligned}
Var(\hat{\tau}) &= \sum_{i=1}^{N} w_i^2 Y_i^2 Var(Z_i) + 2\sum_{i=1}^{N}\sum_{j=i+1}^{N} w_i Y_i w_j Y_j Cov(Z_i, Z_j) \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\sum_{i=1}^{N}\left[(N-1)Y_i^2 - \sum_{j=i+1}^{N} 2Y_iY_j\right] \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left[\sum_{i=1}^{N}(N-1)Y_i^2 - \sum_{i=1}^{N}\sum_{j=i+1}^{N} 2Y_iY_j\right] \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left[\sum_{i=1}^{N}(N-1)Y_i^2 - (\sum_{i=1}^{N} Y_i)^2 + \sum_{i=1}^{N} Y_i^2\right] \\
&= \frac{N}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left[N\sum_{i=1}^{N} Y_i^2 - (\sum_{i=1}^{N} Y_i)^2\right] \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left(\sum_{i=1}^{N} Y_i^2 - N\mu^2\right) \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left(\sum_{i=1}^{N} Y_i^2 - 2N\mu^2 + N\mu^2\right) \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\left(\sum_{i=1}^{N} Y_i^2 - 2\mu\sum_{i=1}^{N} Y_i + N\mu^2\right) \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\frac{1}{N-1}\sum_{i=1}^{N}(Y_i-\mu)^2 \\
&= \frac{N^2}{n}\left(1-\frac{n}{N}\right)\sigma^2
\end{aligned}
$$

□

7.2.5 SRS 总体方差 σ^2 的估计

利用样本方差进行估计

$$
\hat{\sigma^2} = s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(y_i-\overline{y})^2 = \frac{1}{n-1}\sum_{i=1}^{N}(Y_i-\hat{\mu})^2 Z_i
$$

7.2.6 SRSWR 中 Q 的相关性质

$$\overrightarrow{Q} \sim \text{Multi}\left(n,\ \overbrace{\left(\frac{1}{N},\ \frac{1}{N},\ldots,\frac{1}{N}\right)}^{\text{N 个 } \frac{1}{N}}\right)$$

$$Q_i \sim \text{Binom}(n,\ \frac{1}{N})$$

$$E(Q_i) = \frac{n}{N},\ Var(Q_i) = \frac{n}{N}(1-\frac{n}{N})$$

$$Cov(Q_i,\ Q_j) = -\frac{n}{N^2}$$

证明. 由多项分布性质：多项分布随机变量的一维边际分布是二项分布，因此上第二、三式成立。下证第四式，将 Q_i 分解为独立二项分布随机变量的和，有：

$$\begin{aligned}
Cov(Q_i,\ Q_j) &= Cov\left(\sum_{k=1}^{n} I_i(k),\ \sum_{l=1}^{n} I_j(l)\right) \\
&= \sum_{k=1}^{n}\sum_{l=1}^{n} Cov(I_i(k),\ I_j(l)) \\
&= \sum_{k=l} Cov(I_i(k),\ I_j(l)) + \sum_{k\neq l} Cov(I_i(k),\ I_j(l))
\end{aligned}$$

由二项分布随机变量的独立性，后一项为 0：

$$\begin{aligned}
Cov(Q_i,\ Q_j) &= \sum_{k=1}^{n} Cov(I_i(k),\ I_j(k)) \\
&= \sum_{k=1}^{n} [E(I_i(k)I_j(k)) - E(I_i(k))E(I_j(k))]
\end{aligned}$$

同一次伯努利实验中不可能出现两个结果，前一项为 0：

$$\begin{aligned}
Cov(Q_i,\ Q_j) &= -\sum_{k=1}^{n} E(I_i(k))E(I_j(k)) \\
&= -np_ip_j \\
&= -\frac{n}{N^2}
\end{aligned}$$

□

7.2.7 SRSWR 总体总数 τ 的估计

$$\hat{\tau} = \frac{N}{n}\sum_{i=1}^{N} Y_iQ_i$$

$$E(\hat{\tau}) = \tau,\ ,Var(\hat{\tau}) = \frac{N^2}{n}\sigma^2$$

证明.

$$
\begin{aligned}
Var(\hat{\tau}) &= Var\left(\frac{N}{n}\sum_{i=1}^{N} Q_i Y_i\right) \\
&= \frac{N^2}{n^2}\left[\sum_{i=1}^{N} Y_i^2 Var(Q_i) + 2\sum_{i=1}^{N}\sum_{j=i}^{N} Y_i Y_j Cov(Q_i, Q_j)\right] \\
&= \frac{N^2}{n^2}\left[\sum_{i=1}^{N} Y_i^2 \frac{n}{N}\left(1-\frac{1}{N}\right) + 2\sum_{i=1}^{N}\sum_{j=i}^{N} Y_i Y_j \frac{-n}{N^2}\right] \\
&= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2\left(1-\frac{1}{N}\right) - \frac{1}{N}\sum_{i=1}^{N}\sum_{j=i}^{N} 2Y_i Y_j\right]
\end{aligned}
$$

此处使用平方和公式（该技巧常用）：

$$
\begin{aligned}
Var(\hat{\tau}) &= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2\left(1-\frac{1}{N}\right) - \frac{1}{N}\left((\sum_{i=1}^{N} Y_i)^2 - \sum_{i=1}^{N} Y_i^2\right)\right] \\
&= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2 - \frac{1}{N}(\sum_{i=1}^{N} Y_i)^2\right]
\end{aligned}
$$

此处使用 $N\mu^2$ 并进行加减凑项（该技巧常用）：

$$
\begin{aligned}
Var(\hat{\tau}) &= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2 - N\mu^2\right] \\
&= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2 - 2N\mu^2 + N\mu^2\right]
\end{aligned}
$$

此处使用 $N\mu = \sum_{i=1}^{N} Y_i$（该技巧常用）：

$$
\begin{aligned}
Var(\hat{\tau}) &= \frac{N}{n}\left[\sum_{i=1}^{N} Y_i^2 - 2\mu\sum_{i=1}^{N} Y_i + N\mu^2\right] \\
&= \frac{N}{n}\sum_{i=1}^{N}(Y_i-\mu)^2 \\
&= \frac{N^2}{n}\sigma^2
\end{aligned}
$$

□

7.2.8 SRS 阳性率问题

阳性率问题是前述问题的一种特殊形式，Y_i 只能在 0 和 1 中取值。因此阳性率 p 即为总体均值 μ。

总体均值 p 的估计

点估计

$$\hat{p} = \frac{1}{n}\sum_{i=1}^{n} y_i = \frac{1}{n}\sum_{i=1}^{N} Y_i Z_i$$
$$E(\hat{p}) = p,\ Var(\hat{p}) = \frac{1}{n}\left(1 - \frac{n}{N}\right)\sigma^2$$
$$\widehat{Var(\hat{p})} = \frac{1}{n}\left(1 - \frac{n}{N}\right)s^2$$

区间估计 仅考虑大样本正态近似，同时由于 $Var(\hat{p})$ 的计算中涉及未知参数 σ^2，以 $\widehat{Var(\hat{p})}$ 代替，由此得到下列计算公式：

$$\hat{p} \pm z_{1-\frac{\alpha}{2}}\sqrt{\left(1 - \frac{n}{N}\right)\frac{\hat{p}(1-\hat{p})}{n-1}}$$

需要注意上述计算公式需要满足 $n\hat{p} \geqslant 5$ 和 $n(1-\hat{p}) \geqslant 5$。

总体方差 σ^2 的估计

$$\hat{\sigma^2} = s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \overline{y})^2 = \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \hat{p})^2 = \frac{n}{n-1}\hat{p}(1-\hat{p})$$

总体方差 σ^2 与总体均值 p 的关系

由于 $Y_i^2 = Y_i$，可得：

$$\sigma^2 = \frac{1}{N-1}\sum_{i=1}^{N}(Y_i - p)^2 = \frac{N}{N-1}p(1-p)$$

7.2.9 样本容量的选择

抽样分布的方差决定置信区间的长度，样本量增大的时候抽样分布的方差减小，置信区间变窄。

误差幅度 MOE

margin of error

但是会面临总体方差未知的情况（样本最大值与最小值大概是 4 个标准差，4 个标准差大概是 95

用均值去考虑而不从总体，因为总体还会涉及到 N^2，而对于无穷总体是无法进行计算的。

百分比问题两步法不能用，与理论公式不等

估计百分比的时候，如果想要求样本量，会涉及到百分比的真实值：方法一，有根据的推测，历史数据；方法二，保守估计，p=0.5

7.2.10 简单随机抽样适用条件

1. 可使用的额外信息较少。

2. 研究多元关系，没有特别特殊的理由使用别的抽样方法。

第六部分

非参数统计学

Chapter 8

单样本位置检验

8.1 广义符号检验

8.1.1 具体方法

目的

给定某样本，检验给定值 q_0 与总体的 π 分位点 Q_π 之间的关系。

适用条件

总体是连续型的。离散型分位点的定义会导致下述统计量不服从对应的二项分布。

原理

记一组样本中大于 q_0 的单元的个数为 s^+，小于 q_0 的单元的个数为 s^-。若零假设成立（即 q_0 确实为总体的 π 分位点），则从总体中任取一个元素，它小于 q_0 的概率应为 π，那么对于任意一组样本来讲，应有 $K \sim \mathrm{Binom}(s^+ + s^-, \pi)$，其中 K 为 s^- 背后的随机变量。

零假设

$H_0 : Q_\pi = q_0$

大样本近似

当 n 较大时，可认为 $Z \sim \mathrm{N}(0,1)$，其中 $Z = \dfrac{K - n\pi}{\sqrt{n\pi(1-\pi)}}$，其中 n 为样本中不等于 q_0 的单元的个数，由此可在求 p 值时近似计算标准正态分布的累积概率值。

注意事项

需要去除样本中值为 q_0 的单元，这部分单元对推断没有帮助。

备择假设	p 值	解释
$H_1: Q_\pi > q_0$	$P_{H_0}(K \leqslant s^-)$	在零假设下，二项分布变量小于当前样本 s^- 的概率太小，说明 s^- 太小应变大，即分位点的值应比原假设大
$H_1: Q_\pi < q_0$	$P_{H_0}(K \geqslant s^-)$	略
$H_1: Q_\pi \neq q_0$	$2\min\{P_{H_0}(K \leqslant s^-), P_{H_0}(K \geqslant s^-)\}$	略

表 8.1: 对 $H_0: Q_\pi = q_0$ 的检验

尚存疑惑

为什么 p 值是这样的呢？

8.1.2 代码

```
sign.test <- function(x, q0, pi, exact = FALSE,
                      alternative = c("two.sided", "greater", "less")) {
  alternative <- match.arg(alternative)
  s_pos <- sum(x > q0)
  STATISTIC <- sum(x < q0)
  n <- s_pos + STATISTIC
  STATISTIC <- setNames(STATISTIC, "s_neg")
  hypothesis_message <- switch(alternative,
                               "greater" = paste("Q0 >", pi),
                               "less" = paste("Q0 <", pi),
                               "two.sided" = paste("Q0 !=", pi))
  if (exact) {
    METHOD <- "Sign Test (Exact)"
    p.value <- switch(alternative,
                      "greater" = pbinom(q = STATISTIC, size = n, prob = pi),
                      "less" = pbinom(q = STATISTIC-1, size = n, prob = pi, lower.tail = FALSE),
                      "two.sided" = 2 * min(pbinom(q = STATISTIC-1, size = n, prob = pi, lower.tail = FALSE),
                                            pbinom(q = STATISTIC, size = n, prob = pi)))
```

```
  } else {
    METHOD <- "Sign Test (Approximate)"
    z_score <- (STATISTIC - n * pi) / sqrt(n * pi * (1 - pi))
    p.value <- switch(alternative,
                      "greater" = pnorm(z_score, lower.tail = TRUE),
                      "less" = pnorm(z_score, lower.tail = FALSE),
                      "two.sided" = 2 * min(pnorm(z_score), 1 -
                      ↪  pnorm(z_score)))
  }

  RVAL <- list(statistic = STATISTIC, p.value = p.value,
               data.name = deparse(substitute(x)),
               method = METHOD, alternative = hypothesis_message)
  class(RVAL) <- "htest"
  RVAL
}
```

8.2 Wilcoxon 符号秩检验

8.2.1 具体方法

目的

给定某样本，检验给定值 M_0 与总体的中位数 M 之间的关系。

适用条件

总体分布是连续且对称的。连续是为了避免样本中出现重复值影响秩分配，对称则是秩推断成立的必要条件，见下文8.2.1。

符号秩的计算

设样本中每个单元的取值为 X_i，$i = 1, 2, \ldots, n$。

1. 对 $i = 1, 2, \ldots, n$，计算 $d_i = |X_i - M_0|$。

2. 对 d_i 进行排序，找出它们的秩 R_i。

3. 计算 $W^+ = \sum\limits_{i \in \{i: X_i - M_0 > 0\}} R_i$, $W^- = \sum\limits_{i \in \{i: X_i - M_0 < 0\}} R_i$。

原理

由于总体是对称的，那么对于任意一个元素，首先它出现在 M_0 两边的可能性是相等的，其次它出现在 M_0 两边对称位置的可能性是相等的，由此在零假设成立的条件下，W^+ 和 W^- 应相差不大，且二者满足关系：$W^+ + W^- = \frac{n(n+1)}{2}$，因此，当其中之一很小时，应怀疑零假设。若想对 p 值精确求解，见。

在概率论里完
Wilcoxon 秩统
的分布相关理论
后链接过来

零假设

$H_0 : M = M_0$

备择假设	统计量 W	p 值
$H_1 : M > M_0$	W^-	$P(W \leqslant w)$
$H_1 : M < M_0$	W^+	$P(W \leqslant w)$
$H_1 : M \neq M_0$	$\min\{W^-, W^+\}$	$2P(W \leqslant w)$

表 8.2: Wilcoxon 符号秩检验

大样本近似

可求出 Wilcoxon 符号秩检验统计量的期望和方差分别为：

$$E(W) = \frac{n(n+1)}{4} \qquad Var(W) = \frac{n(n+1)(2n+1)}{24}$$

当 n 较大时，由中心极限定理，可认为 $Z \sim \mathrm{N}(0,1)$，其中 $Z = \dfrac{W - E(W)}{\sqrt{Var(W)}}$，由此可在求 p 值时近似计算标准正态分布的累积分布值。

打结

若数据中含有相同的数字，称之为打结的情况。结的个数为重复出现的数值的个数，结中数值的秩为它们升序排序后位置的平均值。如果结多了，大样本近似公式就不准，要进行修正，同时，如果数据中有结则必须使用大样本近似。修正后的公式为：

$$Z = \frac{W - E(W)}{\sqrt{Var(W) - \frac{\sum_{i=1}^{g}(\tau_i^3 - \tau_i)}{48}}} \sim \mathrm{N}(0,1)$$

举例：对于数据 $\{2, 2, 5, 8, 8.8, 1, 1, 1, 1\}$，一共有 3 个结，$\tau_1 = 2$（两个 2），$\tau_2 = 3$（三个 8），$\tau_3 = 4$（四个 1）。称 τ 为结统计量。

8.2.2 代码

```
wilcox.test(x, alternative = c("two.sided", "less", "greater"), mu = M0,
↪  exact = NULL, correct = TRUE)
```

8.3 中位数的点估计与置信区间

8.3.1 具体方法

适用条件

总体分布是连续且对称的。

中位数点估计公式

我们称 $\{\frac{X_i+X_j}{2},\ i \leqslant j\}$ 为 Walsh 平均，然后使用 Walsh 平均的中位数估计总体的中位数，该统计量称为 Hodges-Lehmann 估计量（简称 HT 估计量）。

$$\hat{\theta} = \text{median}\{\frac{X_i + X_j}{2},\ i \leqslant j\}$$

中位数区间估计原理

注意到如下关系：

$$W^+ = \left|\{\frac{X_i + X_j}{2} > M_0,\ i \leqslant j\}\right|$$

该关系也有关于 W^- 的对称版本。对 Walsh 平均从小到大排序，记为 $W_{(1)}, W_{(2)}, \ldots, W_{(N)}, N = \frac{n(n+1)}{2}$。因为想要取两个 Walsh 平均构成一个中位数的区间估计，那么就要去掉左端和右端部分的 Walsh 平均，而 Walsh 平均的个数是与符号秩统计量 W 是相关的，左端去掉的 Walsh 平均的个数可以看作 W^- 的实现值，右端去掉的 Walsh 平均的个数可以看作 W^+ 的实现值，那么就给予了区间估计成立的概率值。

因此，给出中位数 M 的 $(1-\alpha)$ 置信区间为：

$$(W_{k+1}, W_{N-k}),\ k\text{满足}P(W^- \leqslant k) \leqslant \frac{\alpha}{2}\text{与}P(W^- \leqslant k+1) > \frac{\alpha}{2}$$

注意到上式利用了 W^- 与 W^+ 的对称性。

在大样本下，可以近似得到：

$$k \approx \frac{n(n+1)}{4} - Z_{\frac{\alpha}{2}}\sqrt{\frac{n(n+1)(2n+1)}{24}}$$

为什么要用 Walsh 平均

Walsh 平均可以增大样本数量，如果就用原样本去估计置信区间，在样本数较小的情况下，置信区间会变得很大，不够精确。

8.3.2 代码

```
wilcox.test(x, exact = NULL, correct = TRUE, conf.int = FALSE, conf.level
↪  = 0.95))
```

8.4 符号检验与 Wilcoxon 符号秩检验的比较

在数据满足 Wilcoxon 符号秩检验的适用条件时，由于 Wilcoxon 符号秩检验不仅利用了符号信息，也利用了距离信息，因此会更准确。

Chapter 9

两样本位置检验

9.1 目的

通过检验样本中位数的一致性来判断样本的差异性。中位数是某种意义上的“平均”。

9.2 Brown-Mood 中位数检验

9.2.1 具体方法

目的

检验两个样本 X 和 Y 的中位数 M_X, M_Y 是否相同。

原理

记样本 X 与 Y 分别为 $X_1, X_2, \ldots, X_m$, $Y_1, Y_2, \ldots, Y_n$。将两样本混合求得混合后的中位数 M_{XY}。若两样本中位数相同，则混合后的中位数应也等于二者的中位数，那么两个样本中大于 M_{XY} 的单元的个数应该大致一样。可构建如下表格：

	X 样本	Y 样本	总和
单元大于 M_{XY} 的个数	a	b	p
单元小于 M_{XY} 的个数	c	d	q
总和	m	n	N

表 9.1: $2*2$ 列联表矩阵

令 A 表示表中 a 背后的随机变量，在 m、n、p 固定的情况下，A 服从超几何分布 $\mathrm{H}(p, m, N)$（在四个边际和中任意三个固定的情况下，都有 $2*2$ 列联表中的一个值其背后的随机变量服从超几何分布），有如下概率：

$$P(A=k) = \frac{\binom{m}{k}\binom{n}{p-k}}{\binom{N}{p}}$$

若 A 过大或过小，考虑到此时 p 是固定的，那么 X 样本中大于 M_{XY} 单元的个数离 Y 样本中大于 M_{XY} 单元的个数就会很远，就应怀疑零假设。

零假设

$H_0 : M_X = M_Y$

备择假设	p 值
$H_1 : M_X > M_Y$	$P(A \geqslant a)$
$H_1 : M_X < M_Y$	$P(A \leqslant a)$
$H_1 : M_X \neq M_Y$	$2\min\{P(A \geqslant a), P(A \leqslant a)\}$

表 9.2: 对 $H_0 : M_X = M_Y$ 的检验

大样本近似

由超几何分布的期望与方差，在大样本情况下可认为有如下关系：

$$Z = \frac{A - \frac{pm}{N}}{\sqrt{\frac{pm(N-p)(N-m)}{N^3}}} \sim \mathrm{N}(0,1)$$

对于双边假设检验，在大样本情况下，可选取检验统计量与 p 值如下：

$$K = \frac{(2a-m)^2(m+n)}{mn} \sim \chi^2(1),\ p = P(K \geqslant k)$$

注意事项

若有和 M_{XY} 值相同的单元，可将其去除，也可将其归于任何一类使得检验变得保守一点。

9.2.2 代码

以下代码需要输入 x 满足一定的格式：数据是两列，第一列为观测值，第二列用 $1, 2$ 来表示其属于 X 或 Y 样本，1 表示属于 X 样本。以下代码也提供了样本中有和 M_{XY} 值相同的单元情况下的处理方案，omit 表示去除与 M_{XY} 值相同的单元，less 表示将其归于小于 M_{XY} 值的一类，greater 表示将其归于大于 M_{XY} 值值的一类。

```
brown.mood.test <- functions(data,
      alternative = c("two.sided", "less", "greater"),
      ties.method = c("omit", "less", "greater")){
  M_AB <- median(data[,1])
  switch(ties.method,
         omit = {data <- data[data[, 1] != M_AB,]},
```

```
        less = {data[data[, 1] == M_AB, 1] = M_AB - 1},
        greater = {data[data[, 1] == M_AB, 1] = M_AB + 1})

  C <- matrix(nr = 2, nc = 2)
  C[1, 1] <- sum(data[data[, 2] == 1, 1] > M_AB)
  C[1, 2] <- sum(data[data[, 2] == 2, 1] > M_AB)
  C[2, 1] <- sum(data[data[, 2] == 1, 1] < M_AB)
  C[2, 2] <- sum(data[data[, 2] == 2, 1] < M_AB)

  fisher.test(C, alt=alternative, conf.int = FALSE)
}
```

9.3 Wilcoxon 秩和检验

9.3.1 具体方法

目的

检验两个样本 X 和 Y 的中位数 M_X, M_Y 是否相同。

适用条件

需要两总体的分布有类似形状，但并不需要对称。

Wilcoxon 秩和统计量

记样本 X 与 Y 分别为 $X_1, X_2, \ldots, X_m$, $Y_1, Y_2, \ldots, Y_n$。把两个样本混合起来并从小到大排序，令 R_{X_i} 和 R_{Y_j} 分别表示单元 X_i、单元 Y_i 在混合样本中的秩，则称

$$W_X = \sum_{i=1}^{m} R_{X_i},\ W_Y = \sum_{j=1}^{n} R_{Y_j}$$

为 Wilcoxon 秩和统计量。

在零假设下，令 R_i 表示 Y 中第 i 个样本在混合后的秩，可得如下性质：

$$P(R_i = k)\frac{1}{N},\ k = 1, 2, \ldots, N;\ i = 1, 2, \ldots, n;$$

$$P(R_i = k,\ R_j = l) = \begin{cases} \frac{1}{N(N-1)} & k \neq l; \\ 0 & k = l. \end{cases}$$

$$E(R_i) = \frac{N+1}{2},\ Var(R_i) = \frac{N^2-1}{12},\ Cov(R_i,\ R_j) = -\frac{N+1}{12}(i \neq j)$$

$$E(W_Y) = \frac{n(N+1)}{2},\ Var(W_Y) = \frac{mn(N+1)}{12}$$

原理

若零假设成立，在两总体分布有类似形状时 W_X 与 W_Y 应比较接近，当其中之一很大或很小时，应怀疑零假设。

零假设

$H_0 : M_X = M_Y$

备择假设	统计量 K	p 值
$H_1 : M_X > M_Y$	W_Y	$P(K \leqslant k)$
$H_1 : M_X < M_Y$	W_X	$P(K \leqslant k)$
$H_1 : M_X \neq M_Y$	$\min\{W_X, W_Y\}$	$2P(K \leqslant k)$

表 9.3: Wilcoxon 秩和检验

大样本近似

由 W_Y 的期望与方差，在大样本下可认为：

$$Z = \frac{W_Y - E(W_Y)}{\sqrt{Var(W_Y)}} \sim \mathrm{N}(0,1) \tag{9.1}$$

若存在打结的情况，只能使用大样本近似，且应对正态近似公式进行修正（其中 τ 为结统计量）：

$$Z = \frac{W_Y - E(W_Y)}{\sqrt{Var(W_Y) - \frac{mn(\sum_{i=1}^{g} \tau_i^3 - \sum_{i=1}^{g} \tau_i)}{12(m+n)(m+n-1)}}} \sim \mathrm{N}(0,1) \tag{9.2}$$

9.3.2 代码

```
wilcox.test(x, y, alternative = c("two.sided", "less", "greater"), exact
↪  = NULL, correct = TRUE)
```

9.4 Brown-Mood 中位数检验与 Wilcoxon 秩和检验的比较

在数据满足 Wilcoxon 秩和检验的适用条件时，由于 Wilcoxon 符号秩检验不仅利用了符号信息，也利用了距离信息，因此会更准确。

9.5 成对数据差异性检验

目的： 检验成对数据间是否有显著差异。

适用条件:

1. 每一对数据来自可比较的对象。
2. 每一对数据彼此之间是独立的。。

9.5.1 连续型数据

原理

记两组观测值分别为 $X_1, X_2, \ldots, X_n$, $Y_1, Y_2, \ldots, Y_n$。对应元素作差，则检验退化为单样本中位数检验。令 M_D 表示 $X_i - Y_i$ 的中位数，则有以下检验类型:

零假设	备择假设
$H_0 : M_D = M_0$	$H_0 : M_D > M_0$
$H_0 : M_D = M_0$	$H_0 : M_D < M_0$
$H_0 : M_D = M_0$	$H_0 : M_D \neq M_0$

表 9.4: 检验类型

代码

下述 sign.test 的代码参考第29页。mu 值的都是想要检验的二者之间的差异值，wilcox.test 可以给出一定置信度下二者差异值的点估计与区间估计。

```
sign.test(x-y, mu, 0.5, exact = FALSE, alternative = c("two.sided", "less", "greater"), )
wilcox.test(x, y, alternative = c("two.sided", "less", "greater"), mu = 0, paired = TRUE, exact = NULL, correct = TRUE, conf.int = FALSE, conf.level = 0.95)
```

9.5.2 01 型数据的 McNemar 检验

假设

H_0 : 无显著差异; H_1 : 有显著差异

原理

记两组观测值分别为 $X_1, X_2, \ldots, X_n$, $Y_1, Y_2, \ldots, Y_n$。记:

$$n_X = |\{i : X_i = 1,\ Y_i = 0\}|,\ n_Y = |\{i : Y_i = 1,\ X_i = 0\}|$$

McNemar 检验统计量为：

$$K = \frac{(n_X - n_Y)^2}{n_X + n_Y}$$

在零假设成立的条件下该统计量近似服从 $\chi^2(1)$，而在大样本的情况下，它的平方根近似服从标准正态分布。如果有差异，那么统计量的值应该是偏大的，因此只考虑上侧的单侧检验问题，有如下 p 值：

$$p = F_{\chi^2}(K \geqslant k)$$

代码

没搞懂这里的连
性修正是个什么
况

```
mcnemar(x, y, correct=TRUE)
```

Chapter 10

多样本位置检验

10.1 目的

成试验设计之把多样本位置检方差分析部分起来

利用样本中各响应值的位置信息，判断各水平间是否存在差异或某种趋势。

10.2 本章各方法的简单总结

1. 所有方法都要求各水平的总体分布之间是相似的，仅仅是位置参数可能有些差异。

2. Kruskal-Wallis 与 Friedman、Durbin 对称，都是检验各水平响应值的位置参数是否一致（即各水平在该响应值下是否有差异）。Kruskal 是在各水平不相关的情况下使用的，Freidman 是在完全区组设计下、各水平之间由于区组问题不独立时使用的，而 Durbin 是在不完全区组设计下、各区组之间独立时使用的。同时 Kruskal-Wallis、Durbin 要求数据是连续型的，Friedman 则无此类要求。

3. Jonckheere-Terpstra 与 page 对称，都是检验各水平响应值的位置参数是否有顺序关系，Jonckheere-Terpstra 是在各水平不相关的情况下使用的，page 是在完全区组设计下、各水平之间由于区组问题不独立时使用的。同时 Jonckheere-Terpstra 要求数据是连续型的，page 则无此类要求。

4. Cochran 与 Friedman 对应，Cochran 是完全区组设计、二元响应情况下检验各水平是否存在差异的方法。

5. Friedman 与下一章 Kendall 检验是一致的。Kendall 一般用在判断评估者的主观评估是否一致，而 Friedman 则是客观的判断水平之间是否有差异。

10.3 Kruskal-Wallis 检验

10.3.1 具体方法

适用条件

各响应值在水平间和水平内是独立的，水平之间分布是相似的，数据是连续型的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x - \theta_i),\ i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

将所有水平的响应值混合后排序，得到每一个响应值对应于所有数据的秩，类似于方差分析中 MSA 的构成，若水平间的秩和差异大，则应怀疑零假设。由此构建以下 Kruskal-Wallis 统计量（其中 $\bar{R}_i$ 表示第 i 个水平秩的平均值，$\bar{R}$ 表示所有响应值秩的平均值）：

$$H = \frac{12}{N(N+1)} \sum_{i=1}^{k} n_i (\bar{R}_i - \bar{R})^2 = \frac{12}{N(N+1)} \sum_{i=1}^{k} \frac{R_i^2}{n_i} - 3(N+1)$$

如果备择假设成立，那么统计量的值应该是偏大的，因此只考虑上侧的单侧检验问题。

若想求精确结果，需要满足数据中不存在结（即数据中不存在相同的数值），对每种秩分配计算对应的 H 值，便能得到此时统计量 H 的分布。

大样本近似

在大样本的情况下，若零假设成立，有如下近似分布：

$$H \sim \chi^2_{(k-1)}$$

打结

若存在打结的情况，将 H 作以下修正，然后利用大样本近似公式进行计算：

$$H_C = \frac{H}{1 - \sum\limits_{i=1}^{g} (\tau_i^3 - \tau_i)/(N^3 - N)}$$

10.3.2 代码

这是 R 语言 stats 包中的函数，只提供大样本近似，并且不包含连续性修正。x 表示各水平的 response 值，g 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个包含所有水平响应值的列表，各水平之间分隔开。

```r
kruskal.test(x, g)
```

以下是自编代码，x 表示各水平的 response 值，y 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个数据框，第一列是 response 值，第二列是 factor 标签。提供精确检验、大样本近似、连续性修正与打结校正功能。精确检验需要 gtools 包，同时测试了一下一个水平 8 个数据一共 24 个数据 permutation 就要占到 14 个 G 的内存以上，慎用精确检验。

```r
kruskal_wallis.test <- function(x, y = NULL, exact = FALSE, correct = FALSE) {
  if (is.data.frame(x) && ncol(x) == 2) {
    DNAME <- deparse(substitute(x))
    y <- x[, 2]
    x <- x[, 1]
  } else if (is.vector(x)) {
    if (is.null(y))
      stop("Error: x must have two columns or y is provided.")
    if (length(y) != length(x))
      stop("Error: x and y must have the same length.")
    DNAME <- paste(deparse(substitute(x)), "and", deparse(substitute(y)))
  } else {
    stop("Error: x must be a data frame with 2 columns or a vector.")
  }
  METHOD <- "Kruskal-Wallis test"
  TIES <- table(x)
  if (any(TIES > 1)) {
    ties <- TRUE
  } else {ties <- FALSE}
  unique_y <- sort(unique(y))
  rank_x <- rank(x)
  R_i <- sapply(unique_y, function(i) sum(rank_x[y == i]))
  n_i <- sapply(unique_y, function(i) sum(y == i))
  N <- length(x)
  STATISTIC <- setNames((12 / (N * (N + 1)) * sum(R_i^2 / n_i) - 3 * (N + 1))
                        / (1 - sum(TIES^3 - TIES) / (N^3 - N)), "H")
  if (!exact || ties) {
    df <- length(unique_y) - 1
    if (!correct) {
```

```
      p_value <- pchisq(STATISTIC, df = df, lower.tail = FALSE)
    } else {
      METHOD <- paste(METHOD, "with continuity correction")
      p_value <- pchisq(STATISTIC - 0.5, df = df, lower.tail = FALSE)
    }
  } else {
    H.cal <- function(rank_x, y) {
      R_i <- sapply(unique_y, function(i) sum(rank_x[y == i]))
      (12 / (N * (N + 1)) * sum(R_i^2 / n_i) - 3 * (N + 1))
    }
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    all_permutations <- permutations(N, N)
    Hs <- sapply(1:nrow(all_permutations), function(i) {
      H.cal(all_permutations[i, ], y)
    })
    p_value <- mean(Hs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

10.4 Jonckheere-Terpstra 检验

10.4.1 具体方法

目的

检验水平的位置参数是否呈现出上升趋势，若想检验是否呈现出下降趋势，改变水平顺序就行了。

适用条件

各响应值在水平间和水平内是独立的，水平之间分布是相似的，数据是连续型的。这里与 Kruskal-Wallis 检验的条件是一样的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i),\ i=1,2,\ldots,k$，则检验假设可写为：

$$H_0: \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1: \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$$

原理

假设一共有 k 个水平，每个水平中有 n_i 个响应值 $(i=1,2,\ldots,k)$，响应值用 X_{ij} 表示 $(i=1,2,\ldots,k,\ j=1,2,\ldots,n_i)$，由此构建以下 JT 统计量 (J)：

$$U_{ij} = |X_{ia} < X_{jb},\ a=1,2,\ldots,n_i,\ b=1,2,\ldots,n_j|$$
$$J = \sum_{i<j} U_{ij}$$

在备择假设成立的情况下，某个水平中的观测值会比后面水平中的观测值小，水平间的 U_{ij} 会比较大，J 也会比较大。因此在 J 比较大的时候，有理由怀疑原假设。由此可看出这里只考虑上侧的单侧检验问题。

若想求精确检验的结果，需要满足数据中没有结（即所有数据中没有相同的数值），然后对每一种秩分配情况计算 J 的值（秩的大小关系便反映了数据之间的大小关系），即可得到 J 的精确分布。

大样本近似

在 $\min\limits_i n_i \to +\infty$ 时，有以下近似公式：

$$Z = \frac{J - (N^2 - \sum\limits_{i=1}^{k})/4}{\sqrt{[N^2(2N+3) - \sum\limits_{i=1}^{k} n_i^2(2n_i+3)]/72}} \sim \mathrm{N}(0,\ 1)$$

打结

当数据中存在相同数值时，要进行修正：

$$U_{ij} = |X_{ia} < X_{jb},\ a=1,2,\ldots,n_i,\ b=1,2,\ldots,n_j| + \frac{1}{2}|X_{ia} = X_{jb},\ a=1,2,\ldots,n_i,\ b=1,2,\ldots,n_j|$$
$$J = \sum_{i<j} U_{ij}$$

10.4.2 代码

x 表示各水平的 response 值，y 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个数据框，第一列是 response 值，第二列是 factor 标签。提供精确检验、大样本近似、连

续性修正与打结校正功能。精确检验需要 gtools 包，同时测试了一下一个水平 8 个数据一共 24 个数据 permutation 就要占到 14 个 G 的内存以上，慎用精确检验。

```
JT.test <- function(x, y = NULL, exact = FALSE, correct = FALSE) {
  if (is.data.frame(x) && ncol(x) == 2) {
    DNAME <- deparse(substitute(x))
    y <- x[, 2]
    x <- x[, 1]
  } else if (is.vector(x)) {
    if (is.null(y))
      stop("Error: x must have two columns or y is provided.")
    if (length(y) != length(x))
      stop("Error: x and y must have the same length.")
    DNAME <- paste(deparse(substitute(x)), "and", deparse(substitute(y)))
  } else {
    stop("Error: x must be a data frame with 2 columns or a vector.")
  }
  J.cal <- function(x, y, k) {
    U <- 0
    for (i in 1:(k - 1)) {
      for (j in (i + 1):k) {
        xi <- x[y==i]
        xj <- x[y==j]
        ties <- sum(outer(xi, xj, "==") * 1)
        U <- U + sum(outer(xi, xj, "<") * 1) + ties / 2
      }
    }
    U
  }
  METHOD <- "Jonckheere-Terpstra test"
  k <- max(y)
  U <- 0
  for (i in 1:(k - 1)) {
    for (j in (i + 1):k) {
      xi <- x[y==i]
      xj <- x[y==j]
      ties <- sum(outer(xi, xj, "==") * 1)
      if (ties > 0) {exact <- FALSE}
      U <- U + sum(outer(xi, xj, "<") * 1) + ties / 2
```

```
    }
  }
  STATISTIC <- setNames(U, "J")
  if (!exact) {
    ni <- table(y)
    N <- sum(ni)
    Z <- (STATISTIC - (N^2 - sum(ni^2)) / 4) / sqrt((N^2 * (2 * N + 3) -
    ↪  sum(ni^2 * (2 * ni + 3))) / 72)
    if (!correct) {
      p_value <- pnorm(Z, lower.tail = FALSE)
    } else {
      p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    n <- length(x)
    all_permutations <- permutations(n, n)
    JTs <- sapply(1:nrow(all_permutations), function(i) {
      J.cal(all_permutations[i, ], y, k)
    })
    p_value <- mean(JTs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

10.5 Friedman 秩和检验

10.5.1 具体方法

适用条件

各水平间并不独立（因为还有区组的影响），采用完全区组设计，水平之间分布是相似的，连续型与离散型数据都可以。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i),\ i=1,2,\ldots,k$，则检验假设可写为：

$$H_0: \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1: \text{至少有一个等号不成立}$$

原理

假设有 k 个水平、b 个区组。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum\limits_{j=1}^{b} R_{ij},\ i=1,2,\ldots,k$，定义如下 Friedman 统计量:

$$Q = \frac{12}{bk(k+1)}\sum_{i=1}^{k}(R_i - \frac{b(k+1)}{2})^2 = \frac{12}{bk(k+1)}\sum_{i=1}^{k}R_i^2 - 3b(k+1)$$

易证 $\frac{b(k+1)}{2} = \bar{R}_i$（只需注意此时秩是针对区组内而言）。在零假设成立的情况下，各水平之间的秩和与均值相比不应相差过大，也就是 Q 值不应太大，若 Q 值过大，则有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

大样本近似

在大样本的情况下（$b \to +\infty$），若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(k-1)}$$

打结

在某个区组存在结的时候，利用下式进行修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$Q_C = \frac{Q}{1-C},\ C = \frac{\sum\limits_{i,\,j}(\tau_{ij}^3 - \tau_{ij})}{bk(k^2-1)}$$

成对数据的比较

类似于邓肯多重比较法，有时需要比较某两个水平之间是否存在差异，那么在大样本的情况下，如果零假设为：i 水平与 j 水平之间没有差异，那么如果下式成立（其中 α 是检验的显著性水平）：

$$\left|R_i - R_j > Z_{\frac{\alpha^*}{2}}\sqrt{b(k+1)k/6}\right|$$
$$\alpha^* = \frac{\alpha}{k(k-1)/2}$$

则可拒绝零假设。可以看出这是一个很保守的检验，α^* 其实是做了多重假设检验的校正。

记得以后要写多
假设检验的校正
题

10.5.2 代码

以下是自编代码，提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

```
friedman.test <- function(x, factor = NULL, block = NULL,
                          exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  Q.call <- function(ranks, factors) {
    R_i <- tapply(ranks, factors, sum)
    12 / (b * k * (k + 1)) * sum(R_i^2) - 3 * b * (k + 1)
  }
  METHOD <- "Friedman rank sum test"
  k <- length(unique(factor))
  b <- length(unique(block))
  rank <- ave(response, block, FUN = rank)
  STATISTIC <- setNames(Q.call(rank, factor), "Q")
  TIES <- unlist(tapply(response, block, table))
  if (any(sapply(TIES, function(x) any(x > 1)))) {
```

```
    ties <- TRUE
  } else {ties <- FALSE}
  if (!exact || ties) {
    Qc <- STATISTIC / (1 - sum(TIES^3 - TIES) / (b * k * (k^2 - 1)))
      if (!correct) {
        p_value <- pchisq(Qc, k - 1, lower.tail = FALSE)
      } else {
        p_value <- pchisq(Qc - 0.5, k - 1, lower.tail = FALSE)
        METHOD <- paste(METHOD, "with continuity correction")
      }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    possible_ranks <- permutations(k, k)
    all_combinations <- permutations(nrow(possible_ranks), b,
    ↪  repeats.allowed = TRUE)
    Qs <- sapply(1:nrow(all_combinations), function(i) {
      b_combs <- possible_ranks[all_combinations[i, ], ]
      rank_i <- as.vector(b_combs)
      Q.call(rank_i, factor)
    })
    p_value <- mean(Qs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

10.6 Page 检验

10.6.1 具体方法

目的

检验水平的位置参数是否呈现出上升趋势，若想检验是否呈现出下降趋势，改变水平顺序就行了。

适用条件

各水平间并不独立（因为还有区组的影响），采用完全区组设计，水平之间分布是相似的，离散型数据与连续型数据都可以。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i),\ i=1,2,\ldots,k$，则检验假设可写为：

$$H_0: \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1: \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$$

原理

假设有 k 个水平、b 个区组。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum\limits_{j=1}^{b} R_{ij},\ i=1,2,\ldots,k$，定义如下 Page 统计量：

$$L = \sum_{i=1}^{k} iR_i$$

如果备择假设是正确的，那么对 R_i 进行加权求和可以对统计量起到一个放大的作用，那么 L 就会很大。因此在 L 比较大的时候，有理由怀疑原假设。由此可看出这里只考虑上侧的单侧检验问题。

若想求精确检验的结果，需要满足数据中没有结（即每个区组中都没有相同的数值），然后对每一种秩分配情况计算 L 的值（秩的大小关系便反映了数据之间的大小关系），即可得到 L 的精确分布。

大样本近似

在大样本的情况下（$b \to +\infty$），有如下正态近似：

$$Z = \frac{L-\mu_L}{\sigma_L} \sim \mathrm{N}(0,\ 1)$$
$$\mu_L = \frac{bk(k+1)^2}{4},\ \sigma_L^2 = \frac{b(k^3-k)^2}{144(k-1)}$$

打结

若存在打结的情况，需要对正态近似的 σ_L^2 作如下修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$\sigma_L^2 = k(k^2-1)\frac{bk(k^2-1) - \sum_i \sum_j (\tau_{ij}^3 - \tau_{ij})}{144(k-1)}$$

对区组、水平进行重复时的 page 检验

在区组和水平之间不存在交互作用，并且所有 $(i,\ j)$ 位置的重复数都相同时（假设都是 n），有如下正态近似（也考虑了到打结的修正）：

$$Z = \frac{L - \mu_L}{\sigma_L} \sim \mathrm{N}(0,\ 1)$$
$$\mu_L = \frac{nbk(k+1)(nk+1)}{4}$$
$$\sigma_L^2 = nk(k^2-1)\frac{nbk(n^2k^2-1) - \sum_i \sum_j (\tau_{ij}^3 - \tau_{ij})}{144(nk-1)}$$

10.6.2 代码

以下是自编代码，提供重复、精确计算、大样本近似、连续性修正与打结校正功能。当对区组与水平进行重复时，x 必须是一个数据框，每一列是一次重复的结果，也必须传入 factor 与 block，此时只提供大样本近似。当不进行重复时，x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。请注意，检验顺序与输入的 factor 顺序是一致的，建议对照二维表**逐行**输入（行是水平，检验顺序即为行的顺序，列是区组）。如果出现打结的情况，结统计量按照计算公式进行计算，L 统计量的秩部分取结的平均秩（例：数据为 1、1、3、4，有重复值 1，则秩为 1.5、1.5、3、4）。

```r
page.test <- function(x, factor = NULL, block = NULL,
                      exact = FALSE, correct = FALSE,
                      repeated = FALSE) {
  if (repeated) {
    if (exact) {
      stop("Error: exact cannot be TRUE when repeated is TRUE.")
    }
    if (!is.data.frame(x) || ncol(x) == 1) {
      stop("Error: x must be a data frame with more than one column when repeated is TRUE.")
    }
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when repeated is TRUE.")
    }
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    if (is.data.frame(x)) {
```

```
      if (ncol(x) == 3) {
        response <- x[[1]]
        factor <- x[[2]]
        block <- x[[3]]
        DNAME <- deparse(substitute(x))
      }
    } else if (is.vector(x)) {
      if (is.null(factor) || is.null(block)) {
        stop("Error: factor and block must be provided when x is a vector.")
      }
      response <- x
      DNAME <- paste(deparse(substitute(x)), ", ",
                     deparse(substitute(factor)), " and ",
                     deparse(substitute(block)), sep = "")
    } else {
      stop("Error: x must be either a data frame with three columns or a vector.")
    }
  }
  L.call <- function(ranks, factors, num_fac) {
    R_i <- tapply(ranks, factors, sum)
    sum(seq_len(num_fac) * R_i)
  }
  compute_z <- function(statistic, k, b, repeat_n, ties){
    mu <- repeat_n * b * k * (k + 1)^2 / 4
    sigma2 <- repeat_n * k * (k^2 - 1) *
      (repeat_n * b * k * (repeat_n^2 * k^2 - 1) - sum(ties^3 - ties)) /
      (144 * (repeat_n * k - 1))
    (statistic - mu) / sqrt(sigma2)
  }
  METHOD <- "Page test"
  k <- length(unique(factor))
  b <- length(unique(block))
  if (repeated) {
    repeat_n <- ncol(x)
    Ls <- sapply(1:repeat_n, function(repeat_idx) {
      response <- x[[repeat_idx]]
```

```
      rank <- ave(response, block, FUN = rank)
      L.call(rank, factor, k)
    })
    STATISTIC <- setNames(sum(Ls), "L")
    TIES <- unlist(sapply(1:repeat_n, function(repeat_idx) {
      unlist(tapply(x[[repeat_idx]], block, table))
    }))
    Z <- compute_z(STATISTIC, k, b, repeat_n, TIES)
    if (!correct) {
      p_value <- pnorm(Z, lower.tail = FALSE)
    } else {
      p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    rank <- ave(response, block, FUN = rank)
    STATISTIC <- setNames(L.call(rank, factor, k), "L")
    TIES <- unlist(tapply(response, block, table))
    if (any(sapply(TIES, function(x) any(x > 1)))) {
      ties <- TRUE
    } else {ties <- FALSE}
    if (!exact || ties) {
      Z <- compute_z(STATISTIC, k, b, 1, TIES)
      if (!correct) {
        p_value <- pnorm(Z, lower.tail = FALSE)
      } else {
        p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
        METHOD <- paste(METHOD, "with continuity correction")
      }
    } else {
      METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
      library(gtools)
      possible_ranks <- permutations(k, k)
      all_combinations <- permutations(nrow(possible_ranks), b,
      ↪  repeats.allowed = TRUE)
      Ls <- sapply(1:nrow(all_combinations), function(i) {
        b_combs <- possible_ranks[all_combinations[i, ], ]
        rank_i <- as.vector(b_combs)
```

```
        L.call(rank_i, factor, k)
      })
      p_value <- mean(Ls >= STATISTIC)
    }
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

10.7 Cochran 检验

10.7.1 具体方法

目的

检验完全区组设计、二元响应情况下，各水平之间是否存在差异。

适用条件

完全区组设计，二元响应。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i),\ i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

假设有 k 个水平、b 个区组。

令 L_j 表示第 j 个区组中为 1 的数目的总和，N_i 表示第 i 个水平中为 1 的数目的总和，即 $L_j = \sum\limits_{i=1}^{k} x_{ij},\ j = 1, 2,\ b,\ N_i = \sum\limits_{j=1}^{b} x_{ij},\ i = 1, 2,\ k$。

在零假设成立的情况下，各水平之间无差异，那么对于每个 j 而言，L_j 个 1 在所有水平中出现的概率是相同的，这个概率依赖于具体的 L_j。由此定义如下 Cochran 统计量：

$$Q = \frac{k(k-1)\sum\limits_{i=1}^{k}(N_i - \bar{N})^2}{kN - \sum\limits_{j=1}^{b} L_j^2} = \frac{k(k-1)\sum\limits_{i=1}^{k} N_i^2 - (k-1)N^2}{kN - \sum\limits_{j=1}^{b} L_j^2}$$

其中 $\bar{N} = \frac{1}{k}\sum_{i=1}^{k} N_i$，$N = \sum_{i=1}^{k} N_i$。易证，若 $L_j = 0$ 或 $L_j = k$，那么这个区组的数据可以删除，对 Q 值没有影响（与前面的原理是相合的）。

若想进行精确检验

需要找论文，Patil(1975)，同需要看统计量的导过程，为什么检验

大样本近似

在大样本的情况下（$b \to +\infty$），若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(k-1)}$$

10.7.2 代码

现在只提供了大本近似，回头看文和原理记得补

以下是自编代码，需要传入一个数据框，行为水平列为区组。提供大样本近似与连续性修正。

```
cochran.test <- function(x, exact = FALSE, correct = FALSE) {
  if (!is.data.frame(x)) {
    stop("Error: x must be a data frame.")
  }
  DNAME <- deparse(substitute(x))
  METHOD <- "Cochran test"
  Ni <- apply(x, 1, sum)
  Lj <- apply(x, 2, sum)
  N <- sum(Ni)
  k <- nrow(x)
  STATISTIC <- (k * (k-1) * sum(Ni^2) - (k - 1) * N^2) / (k * N -
  ↪  sum(Lj^2))
  STATISTIC <- setNames(STATISTIC, "Q")
  if (!exact) {
    if (!correct){
      p_value <- pchisq(STATISTIC, k - 1, lower.tail = FALSE)
    } else {
      p_value <- pchisq(STATISTIC - 0.5, k - 1, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    # exact test
  }

```

```
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

10.8 Durbin 检验

10.8.1 具体方法

适用条件

不完全区组设计，水平之间分布是相似的，数据是连续型的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x - \theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

会看看这里平不平衡的不完组设计有没有区别

假设有 k 个水平、b 个区组，每个区组中含 t 个处理，每个处理出现在 r 个区组中。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum_j R_{ij}$, $i = 1, 2, \ldots, k$，定义如下 Durbin 统计量:

$$D = \frac{12(k-1)}{rk(t^2-1)} \sum_{i=1}^{k} (R_i - \frac{r(t+1)}{2})^2 = \frac{12(k-1)}{rk(t^2-1)} \sum_{i=1}^{k} R_i^2 - \frac{3r(k-1)(t+1)}{t-1}$$

在零假设成立的情况下，各水平之间的秩和与均值相比不应相差过大，也就是 D 值不应太大，若 D 值过大，则有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。同时，可以看出 Durbin 统计量在完全区组设计 ($t = k$, $r = b$) 的时候和 Friedman 统计量是完全一样的。

大样本近似

在大样本的情况下（$r \to +\infty$），若零假设成立，有如下近似分布：

$$D \sim \chi^2_{(k-1)}$$

在某个区组存在结的时候，利用下式进行修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$D_C = \frac{(k-1)\sum_{i=1}^{k}(R_i - \frac{r(t+1)}{2})^2}{A-C}$$
$$A = \sum_i \sum_j R_{ij}^2,\ C = \frac{bt(t+1)^2}{4}$$

10.8.2 代码

以下是自编代码，会检查输入的数据是否满足不完全区组设计的平衡性。提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

代码现在是只
平衡的

```
durbin.test <- function(x, factor = NULL, block = NULL,
                        exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  num_r <- table(factor)
  num_t <- table(block)
  if (length(unique(num_r)) != 1) {
    stop("Error: The design is not balanced.
```

```
        Each treatment must appear in the same number of blocks.")
  }
  if (length(unique(num_t)) != 1) {
    stop("Error: The design is not balanced.
        Each block must contain the same number of treatments.")
  }
  D.call <- function(ranks, factors) {
    R_i <- tapply(ranks, factors, sum)
    12 * (k - 1) / (r * k * (t^2 - 1)) * sum(R_i^2) -
      3 * r * (k - 1) * (t + 1) / (t - 1)
  }
  METHOD <- "Friedman rank sum test"
  k <- length(unique(factor))
  b <- length(unique(block))
  r <- as.numeric(num_r[1])
  t <- as.numeric(num_t[1])
  rank <- ave(response, block, FUN = rank)
  STATISTIC <- setNames(D.call(rank, factor), "D")
  TIES <- unlist(tapply(response, block, table))
  if (any(sapply(TIES, function(x) any(x > 1)))) {
    ties <- TRUE
  } else {ties <- FALSE}
  if (!exact || ties) {
    Dc <- (k - 1) * sum((tapply(rank, factor, sum) - r * (t + 1) / 2)^2)
    ↪ /
      (sum(rank^2) - b * t * (t + 1)^2 / 4)
    if (!correct) {
      p_value <- pchisq(Dc, k - 1, lower.tail = FALSE)
    } else {
      p_value <- pchisq(Dc - 0.5, k - 1, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    possible_ranks <- permutations(t, t)
    all_combinations <- permutations(nrow(possible_ranks), b,
    ↪ repeats.allowed = TRUE)
```

```
    Ds <- sapply(1:nrow(all_combinations), function(i) {
      b_combs <- possible_ranks[all_combinations[i, ], ]
      rank_i <- as.vector(b_combs)
      D.call(rank_i, factor)
    })
    p_value <- mean(Ds >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

Chapter 11

Something else

11.1 Cox-Stuart 趋势检验

11.1.1 具体方法

目的

查看某组数据是否有递增、递减的趋势。

检验原理

把样本分成前后两段，若样本大小为奇数，则去除最中间的单元。把前后两段相同位置的元素组成对子，以每个对子两个元素差的正负性衡量增减。

$$x_1, x_2, x_3, \cdots, x_n$$

$$\text{对子：}(x_i, x_{i+c}),\ c = \begin{cases} n/2 & n \equiv 0 \mod 2 \\ (n+1)/2 & n \not\equiv 0 \mod 2 \end{cases}$$

$$D_i = x_i - x_{i+c}$$

$$\text{令} s^+ = |\{D_i : D_i > 0\}|,\ s^- = |\{D_i : D_i < 0\}|$$

若数据无趋势，s^- 与 s^+ 应服从 Binom$(s^+ + s^-, 0.5)$，则检验退化为符号检验。以下 p 值计算与广义符号检验略有差异，这是因为 p 取 0.5 时二项分布是对称分布。

检验的数学语言（与表 11.1 对应）

假设独立观测值序列 $X_i \sim F(x - \theta_i),\ i = 1, 2, \ldots, n$:

1. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$
2. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \geqslant \theta_2 \geqslant \cdots \geqslant \theta_n$
3. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$ 或 $\theta_1 \geqslant \theta_2 \geqslant \cdots \geqslant \theta_n$

备择假设	统计量 K	p 值
H_1 : 有增长趋势	s^+	$P(K \leqslant k)$
H_1 : 有减少趋势	s^-	$P(K \leqslant k)$
H_1 : 有趋势	$\min\{s^+, s^-\}$	$2P(K \leqslant k)$

表 11.1: Cox-stuart 趋势检验

11.1.2 代码

```
Cox_Stuart <- function(y) {
    n <- length(y)
    c <- ifelse(n %% 2 == 0, n / 2, (n + 1) / 2)
    D <- y[(c + 1):n] - y[1:c]
    s_neg <- sum(D < 0)
    s_pos <- sum(D > 0)
    s <- min(s_neg, s_pos)
    text <- ifelse(s_pos - s_neg > 0, "Increasing with", "Decreasing
    ↪ with")
    cat(text, 'p_value =', pbinom(s, c, 0.5))
}
```

11.2 游程检验

11.2.1 具体方法

目的

检验一组数据是否是随机出现的。

适用条件

数据的顺序有意义且是离散的，若不离散，可以中位数为间隔，利用符号函数将数据转换为二元数据。

游程的定义

游程是来自于同一总体的样本所构成的一个或一个以上相同符号连续出现的片段。例：对于数据

$$0000110111000$$

在这组数据中，一共有 5 个游程（3 个 0 游程，2 个 1 游程）。

游程数的分布

证明

令 R 表示游程数，可以证明：

$$P(R=2k)=\frac{2\binom{m-1}{k-1}\binom{n-1}{k-1}}{\binom{N}{n}}$$
$$P(R=2k+1)=\frac{\binom{m-1}{k-1}\binom{n-1}{k}+\binom{m-1}{k}\binom{n-1}{k-1}}{\binom{N}{n}}$$
$$E(R)=\frac{2mn}{m+1}+1 \quad Var(R)=\frac{2mn(2mn-m-n)}{(m+n)^2(m+n-1)}$$

游程检验原理

若数据是随机的，那么游程数不应过多也不应过少，若过多，则呈现出混合倾向，若过少，则呈现出聚集倾向。

备择假设	统计量 K	p 值
H_1 : 数据有聚集趋势	R	$P(K\leqslant k)$
H_1 : 数据有混合趋势	R	$P(K\geqslant k)$
H_1 : 数据有趋势	R	$2\min P(K\leqslant k),\ P(K\geqslant k)$

表 11.2: 随机性的游程检验

11.2.2 代码

tseries 包中的 runs.test

需要注意，该函数只提供大样本近似，并且输入值必须转换为因子，同时，要去除经过符号函数转换后值为 0 的数据。

```
library(tseries)
# median <- median(x)
# x <- factor(sign(x[x != median]-median))
runs.test(x, alternative = c("two.sided", "less", "greater"))
```

自编版

```
runs.test <- function(x, alternative = c("two.sided", "less", "greater"),
↪  exact = TRUE, correct = FALSE) {

  alternative <- match.arg(alternative)
  DNAME <- deparse1(substitute(x))
```

```r
METHOD <- "Runs test"

# Calculate runs
runs <- sum(diff(x) != 0) + 1

# Calculate sample sizes
N <- length(x)
n <- sum(x)  # Number of 1s in x
m <- N - n  # Number of 0s in x

# Functions for cumulative probability
pruns <- function(runs, m, n, lower.tail = TRUE){
  p <- 0
  if (lower.tail){
    for (i in 1:runs){
      if (i %% 2 == 0){
        k <- i / 2
        p <- p + 2 * choose(m - 1, k - 1) *
          choose(n - 1, k - 1) /
          choose(m + n, n)
      }else{
        k <- (i - 1) / 2
        p <- p + (choose(m - 1, k - 1) * choose(n - 1, k) +
                    choose(m - 1, k) * choose(n - 1, k - 1)) /
          choose(m + n, n)
      }
    }
  }else{
    for (i in (runs + 1):(m+n)){
      if (i %% 2 == 0){
        k <- i / 2
        p <- p + 2 * choose(m - 1, k - 1) *
          choose(n - 1, k - 1) /
          choose(m + n, n)
      }else{
        k <- (i - 1) / 2
        p <- p + (choose(m - 1, k - 1) * choose(n - 1, k) +
                    choose(m - 1, k) * choose(n - 1, k - 1)) /
```

```
            choose(m + n, n)
        }
      }
    }
    return(p)
  }

  if (exact){
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    # Exact p-value calculation
    p.value <- switch(alternative,
                      two.sided = 2 * min(pruns(runs, m, n),
                                          pruns(runs - 1, m, n,
                                          ↪  lower.tail = FALSE)),
                      less = pruns(runs, m, n),
                      greater = pruns(runs, m, n, lower.tail = FALSE))
  }else{
    # Normal approximation
    E_R <- (2 * m * n) / N + 1
    Var_R <- (2 * m * n * (2 * m * n - N)) / (N^2 * (N - 1))
    z <- (runs - E_R) / sqrt(Var_R)

    if (correct){
      METHOD <- paste(METHOD, "with continuity correction")
      # Apply continuity correction
      z <- runs - E_R
      CORRECTION <- switch(alternative,
                           two.sided = sign(z) * 0.5,
                           greater = 0.5,
                           less = -0.5)
      z <- (z - CORRECTION) / sqrt(Var_R)
      # p-value using normal approximation
      p.value <- switch(alternative,
                        two.sided =  2 * min(pnorm(z),
                                             pnorm(z, lower.tail =
                                             ↪  FALSE)),
                        less = pnorm(z),
                        greater = pnorm(z, lower.tail = FALSE))
```

```
    }else{
      p.value <- switch(alternative,
                        two.sided =  2 * min(pnorm(z),
                                             pnorm(z, lower.tail =
                                             ↪  FALSE)),
                        less = pnorm(z),
                        greater = pnorm(z, lower.tail = FALSE))
    }
  }

  alternative <- switch(alternative,
                        two.sided = "The data lacks randomness.",
                        less = "The data has a tendency to cluster.",
                        greater = "The data has a tendency to mix.")

  # Create output in htest format
  RVAL <- list(statistics = setNames(runs, "runs"),
               alternative = alternative, method = METHOD,
               data.name = DNAME, p.value = p.value)
  class(RVAL) <- "htest"
  RVAL
}

# median <- median(x)
# x <- na.omit(ifelse(x > median, 1, ifelse(x < median, 0, NA)))
runs.test(x, alternative = "two.sided",
          exact = TRUE, correct = FALSE)
```

11.3 分类评分结果一致性判断

11.3.1 Cohen's Kappa 系数

根本没懂原理

评判标准

1. < 0.4 一致性很差
2. $0.4 - 0.6$ 中度一致
3. $0.6 - 0.8$ 具有较高的一致性

4. > 0.8 具有极高的一致性

代码

```
library(psych)
cohen.kappa(x)
```

11.3.2 Kendall 协同系数检验

目的

检验 b 次对 k 个个体的评估是随机的（不相关的）还是一致的。

适用条件

完全区组设计，离散型数据（打分，排序），主观性的数据一般使用 Kendall 检验。

假设

$$H_0: \text{这些评估是不相关的或是随机的},\ H_1: \text{这些评估是一致的}$$

原理

这里其实是把 b 个评估者看作是区组，把被评分的个体看作了水平。所有的计算和 Friedman 秩和检验一样（参考第47页），只是 Kendall 协同系数 W 要在 Friedman 统计量 Q 的基础上再除 $b(k-1)$（大样本近似与打结的情况都可参考 Friedman 秩和检验）。

料看 Kendall
结是否和
man 一致

为什么这么做呢？我们想看的是对个体的评估是否是随机的，那么如果是随机的，各个体获得的评分总秩和应该是较相近的。其实还是看各水平之间是否有差异，但并不是它们本身的差异，而是在被评估者打分以后，在打分上是否呈现出各水平的差异。其实我们在这里是默认个体之间是有差异的，如果评估结果有差异那么就不随机，评估结果没有差异那就是随机的评估。

代码

以下是自编代码，提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

```
kendall.test <- function(x, factor = NULL, block = NULL,
                         exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
```

```
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  W.call <- function(ranks, factors) {
    R_i <- tapply(ranks, factors, sum)
    (12 / (b * k * (k + 1)) * sum(R_i^2) - 3 * b * (k + 1)) / (b * (k - 1))
  }
  METHOD <- "Kendall test"
  k <- length(unique(factor))
  b <- length(unique(block))
  rank <- ave(response, block, FUN = rank)
  STATISTIC <- setNames(W.call(rank, factor), "W")
  TIES <- unlist(tapply(response, block, table))
  if (any(sapply(TIES, function(x) any(x > 1)))) {exact = FALSE}
  if (!exact) {
    Wc <- STATISTIC / (1 - sum(TIES^3 - TIES) / (b * k * (k^2 - 1)))
    if (!correct) {
      p_value <- pchisq(Wc * b * (k - 1), k - 1, lower.tail = FALSE)
    } else {
      p_value <- pchisq(Wc * b * (k - 1) - 0.5, k - 1, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
```

```
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    possible_ranks <- permutations(k, k)
    all_combinations <- permutations(nrow(possible_ranks), b,
    ↪  repeats.allowed = TRUE)
    Ws <- sapply(1:nrow(all_combinations), function(i) {
      b_combs <- possible_ranks[all_combinations[i, ], ]
      rank_i <- as.vector(b_combs)
      W.call(rank_i, factor)
    })
    p_value <- mean(Ws >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

11.4 列联表独立性问题

11.4.1 目的

检验列联表的行列变量之间是否是独立的。

假设

$$H_0: \text{行变量与列变量是独立的} \Leftrightarrow H_1: \text{行变量与列变量是相关的}$$

11.4.2 Pearson 近似检验

原理

假设行变量有 r 个取值，列变量有 c 个取值，列联表中频数记为 n_{ij}，$i = 1, 2, \ldots, r$，$j = 1, 2, \ldots, c$，行频数总和 $n_{i\cdot} = \sum_j n_{ij}$，列频数总和 $n_{\cdot j} = \sum_i n_{ij}$，频数总和 $n = \sum_{i,j} n_{ij}$，列联表中第 ij 个格子的理论频数为 E_{ij}，行变量取第 i 个值的概率为 $p_{i\cdot}$，列变量取第 j 个值的概率为 $p_{\cdot j}$，一个观测值被分配到列联表中第 ij 个格子的理论概率为 p_{ij}。

概率论把独立
接到这里来

若行变量与列变量独立，由随机变量的独立性，有：

$$p_{ij} = p_{i\cdot}p_{\cdot j},\ E_{ij} = p_{\cdot j}n_{i\cdot}$$

但由于 $p_{\cdot j}$ 是理论值无法预知，用 $\frac{n_{\cdot j}}{n}$ 来代替，那么 $E_{ij} = \hat{p_{\cdot j}}n_{i\cdot} = \frac{n_{i\cdot}n_{\cdot j}}{n}$。由此构建以下 Pearson$\chi^2$ 统计量：

$$Q = \sum_{i=1}^{r}\sum_{j=1}^{c}\frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

如果零假设不成立，那么 n_{ij} 与 E_{ij} 的值相差就会比较大，统计量的值也会偏大。若统计量的值过大，则有里有怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

大样本近似

在大样本的情况下，若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(r-1)(c-1)}$$

11.4.3 低维列联表的 Fisher 精确检验

假定五个边际频数都是固定的，在零假设成立的情况下，这个具体的列联表出现的条件概率（给定边际频数的情况下，因此是条件概率）只依赖于四个频数中的任意一个，且该概率满足超几何分布：

$$P = \frac{\binom{n_{1\cdot}}{n_{11}}\binom{n_{2\cdot}}{n_{21}}}{\binom{n}{n_{\cdot 1}}}$$

	B1	B2	总和
A1	n_{11}	n_{12}	$n_{1\cdot}$
A2	n_{21}	n_{22}	$n_{2\cdot}$
总和	$n_{\cdot 1}$	$n_{\cdot 2}$	n

表 11.3: 二维列联表

若零假设成立，那么任何一个关于 n_{ij} 的尾概率 $P(n_{ij} \leqslant a)$, $P(n_{ij} \geqslant b)$, $1 - P(a < n_{ij} < b)$ 都不应该太小或太大。若尾概率太小或太大，则有理由怀疑零假设。由此可以看出这里其实是涉及备择假设的方向问题的，可以单侧也可以双侧。

有机会看看单侧
实际意义，不懂
么会考虑单侧

11.4.4 代码

Pearson 近似检验

直接将列联表矩阵输入以下函数即可。

```
chisq.test(x)
```

Fisher 精确检验

直接将列联表矩阵输入以下函数即可。

```
fisher.test(x, alternative="two.sided")
```

Chapter 12

单调关联性

写完概率论把
Pearson 线性相
数链接过来。

单调关联性 (association) 与单调相关性 (correlation) 是否是同一个东西呢？

它们并不一样。单调关联性仅从秩的角度来衡量两个变量是否同增同减或一增一减，单调相关性除了增减性以外，还要求增减之间存在线性关系，即一个变量增大或减小一个单位，另一个变量是否会固定地增大或减小某个单位的数值。考虑语言习惯问题，本章仍使用相关性来称呼关联性。

12.1 单调关联性的零假设与备择假设

$$H_0: X\text{和}Y\text{不相关}, \begin{cases} H_1: X\text{和}Y\text{正相关} \\ H_1: X\text{和}Y\text{负相关} \\ H_1: X\text{和}Y\text{相关} \end{cases}$$

12.2 本章各方法的简单总结

1. Spearman 秩相关检验与 Kendall 秩相关检验中的 τ_a 都可以用作连续变量的相关性检验。

2. Kendell's τ_b 与 τ_c 都可以用作有序分类变量的相关性检验，但在列联表行列数目 r 和 c 差别较大时，使用 τ_c 更合适。

3. Goodman-Kruskal's τ 检验针对分类有序变量。

4. Somers' d 检验针对分类有序变量，与前面几种方法的不同是：前几种方法的两个变量 X 和 Y 是对称的，而 Somers' 检验把其中一个变量看作自变量，另一个看作因变量，它可以度量自变量对因变量的影响。

12.3 Spearman 秩关联检验

12.3.1 具体方法

原理

记 x_i 在 X 样本中的秩为 R_i，y_i 在 Y 样本中的秩为 S_i，$d_i^2 = (R_i - S_i)^2$，$\bar{R} = E(R) = \frac{1}{n}\sum_{i=1}^n R_i$，$barS = E(S) = \frac{1}{n}\sum_{i=1}^n S_i$。

显然，若很多 d_i^2 很大，那么两个变量之间可能是负相关；若很多 d_i^2 很小，那么两个变量之间可能是正相关。类似 Pearson 相关系数，定义以下 Spearman 检验统计量：

$$r_s = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2 \sum_{i=1}^n (S_i - \bar{S})^2}} = 1 - \frac{6\sum_{i=1}^n d_i^2}{n(n^2-1)}$$

由 Cauchy 不等式，显然有 $-1 \leqslant r_s \leqslant 1$。

在样本不大且没有结的时候，可以使用精确检验：固定 R_i 从小到大，此时 S_i 的排序情况共有 $n!$ 种可能，对每一种可能计算 r_s，即可得到 r_s 的精确分布。

大样本的情况

大样本时没有近似分布，采用 Monte Carlo 模拟，固定随机数种子，随机抽取 m 个 S_i 可能的排序情况，对这 m 个情况计算 r_s 值，得到近似的分布。

打结

若 X 或 Y 样本中存在相同的数据，则称之为打结的情况。记 u_j，$j = 1, 2, \ldots, p$ 和 v_j，$j = 1, 2, \ldots, q$ 分别为 X 和 Y 样本中结统计量的值，记：

$$U = \sum_{j=1}^p (u_j^3 - u_j),\ V = \sum_{j=1}^q (v_j^3 - v_j)$$

则此时修正过的 Spearman 检验统计量定义为：

$$r_s = \frac{n(n^2-1) - 6\sum_{i=1}^n (R_i - S_i)^2 - 6(U+V)}{\sqrt{[n(n^2-1) - 12U]\,[n(n^2-1) - 12V]}}$$

在样本量比较大时，有：

$$Z = r_s\sqrt{n-1} \sim \mathrm{N}(0,\ 1)$$

有结的时候没有精确分布，只能使用上式的大样本近似。

12.3.2 代码

```r
cor.test(x, y,
alternative = c("two.sided", "less", "greater"),
method = "spearman"
exact = NULL, continuity = FALSE)
```

12.4 Kendall τ 关联检验

12.4.1 具体方法

协同

对于样本 $X_i, Y_i,\ i=1,2,\ldots,n$，从中任取两对作积 $(X_i-X_j)(Y_i-Y_j)$，若乘积大于 0，则称对子 $(X_i,\ Y_i)$ 和 $(X_j,\ Y_j)$ 是协同的 (concordant)，它们具有相同的倾向，若乘积小于 0，则称对子是不协同的 (disconcordant)，它们有相反的倾向。令：

$$\Psi(X_i,X_j,Y_i,Y_j)=\begin{cases}1, & (X_i-X_j)(Y_i-Y_j)>0\\ 0, & (X_i-X_j)(Y_i-Y_j)=0\\ -1, & (X_i-X_j)(Y_i-Y_j)<0\end{cases}$$

原理

定义 Kendall τ 相关系数为：

$$\tau_a=\frac{2}{n(n-1)}\sum_{1\leqslant i<j\leqslant n}\Psi(X_i,X_j,Y_i,Y_j)=\frac{K}{\binom{n}{2}}=\frac{n_c-n_d}{\binom{n}{2}}$$

其中 n_c 表示协同的对子的数目，而 n_d 表示不协同的对子的数目。

由定义可以看出，τ_a 取值在 $-1\sim 1$ 之间，τ_a 越大，协同的对子数目越多，两个变量越有可能正相关；τ_a 越小，不协同的对子数目越多，两个变量越有可能负相关。

在计算时，可以把成对数据 $(X_i,\ Y_i)$ 按第一个变量从小到大排序，然后就可以只用 Y_i 的大小关系或者秩来计算 n_c 和 n_d 了。

在样本量不太大并且没有结的时候，可以按如下方法求精确检验结果：把成对数据 $(X_i,\ Y_i)$ 按第一个变量从小到大排序，此时 Y_i 的排序情况共有 $n!$ 种可能，对每一种可能计算 τ_a，即可得到 τ_a 的精确分布。

大样本近似

在零假设成立的情况下，当 $n\to+\infty$ 时，有如下近似分布：

$$Z=K\sqrt{\frac{18}{n(n-1)(2n+5)}}\sim \mathrm{N}(0,\ 1)$$

打结

若 X 或 Y 样本中存在相同的数据，则称之为打结的情况。记 $u_i,\ i=1,2,\ldots,p$ 和 $v_i,\ i=1,2,\ldots,q$ 分别为 X 和 Y 样本中结统计量的值，此时有如下修正后的检验统计量：

$$\tau_b=\frac{n_c-n_d}{\sqrt{\left[\frac{n(n-1)}{2}-\sum_i u_i(u_i-1)/2\right]\left[\frac{n(n-1)}{2}-\sum_i v_i(v_i-1)/2\right]}}$$

有结的时候没有精确分布，只能使用下式的大样本近似：

$$
\begin{aligned}
Z &= \frac{n_c - n_d}{\sqrt{\left[n(n-1)(2n+5) - t_u - t_v\right]/18 + t_1 + t_2}} \sim \mathrm{N}(0,\ 1) \\
t_u &= \sum_i u_i(u_i - 1)(2u_i + 5) \\
t_v &= \sum_i v_i(v_i - 1)(2v_i + 5) \\
t_1 &= \frac{1}{2n(n-1)} \sum_i u_i(u_i - 1) \sum_j v_j(v_j - 1) \\
t_2 &= \frac{1}{9n(n-1)(n-2)} \sum_i u_i(u_i - 1)(u_i - 2) \sum_j v_j(v_j - 1)(v_j - 2)
\end{aligned}
$$

有序分类变量情况下的 τ_c

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i = 1, 2, \ldots, r,\ j = 1, 2, \ldots, c$ 为列联表中的对应元素，则 Kendall's τ_c 的定义和其渐进均方差为：

$$
\begin{aligned}
\tau_c &= \frac{2q(n_c - n_d)}{n^2(q-1)} \\
\mathrm{ASE} &= \frac{2q}{(q-1)n^2} \sqrt{\sum_{ij} n_{ij}(C_{ij} - D_{ij})^2 - 4(n_c - n_d)^2/n} \\
q &= \min(r, c) \\
C_{ij} &= \sum_{i'>i} \sum_{j'>j} n_{i'j'} + \sum_{i'<i} \sum_{j'<j} n_{i'j'} \\
D_{ij} &= \sum_{i'>i} \sum_{j'<j} n_{i'j'} + \sum_{i'<i} \sum_{j'>j} n_{i'j'}
\end{aligned}
$$

其取值范围也在 $-1 \sim 1$ 之间，同时有如下大样本近似：

$$
\frac{\tau_c}{\mathrm{ASE}} \sim \mathrm{N}(0,\ 1)
$$

12.4.2 代码

```
cor.test(x, y,
alternative = c("two.sided", "less", "greater"),
method = "kendall"
exact = NULL, continuity = FALSE)
```

12.5 Goodman-Kruskal's γ 关联检验

12.5.1 原理

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i=1,2,\ldots,r,\ j=1,2,\ldots,c$ 为列联表中的对应元素，则 Goodman-Kruskal 关联检验统计量 G（也是相关系数的一个点估计）的定义和其近似分布为：

$$G=\frac{n_c-n_d}{n_c+n_d}$$

$$\frac{G}{Var(G)}\sim \mathrm{N}(0,\ 1)$$

$$Var(G)\approx\frac{16}{(P+Q)^4}\sum_{i,j}n_{ij}(PC_{ij}-QD_{ij})^2$$

$$P=2n_c,\ Q=2n_d$$

$$C_{ij}=\sum_{i'>i}\sum_{j'>j}n_{i'j'}+\sum_{i'<i}\sum_{j'<j}n_{i'j'},\ D_{ij}=\sum_{i'>i}\sum_{j'<j}n_{i'j'}+\sum_{i'<i}\sum_{j'>j}n_{i'j'}$$

12.5.2 代码

```
library(DescTools)
GoodmanKruskalGamma(x, y, )
```

12.6 Sumers' d 关联检验

12.6.1 原理

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i=1,2,\ldots,r,\ j=1,2,\ldots,c$ 为列联表中的对应元素。

Somers 定义了 $d(C|R)$ 与 $d(R|C)$，前者将行变量 X 看作自变量，后者把列变量 Y 看作自变量，下面仅介绍 $d(C|R)$，$d(R|C)$ 的情况只需要把列联表转置即可得到相应的结果。$d(C|R)$ 的定义及其渐近均方差为：

$$d(C|R)=\frac{2(n_c-n_d)}{n(n-1)-\sum_i^r R_i(R_i-1)}=\frac{P-Q}{D_r}$$

$$\mathrm{ASE}=\frac{2}{D_r^2}\sqrt{\sum_{i,j}n_{ij}\left[D_r(C_{ij}-D_{ij})-(P-Q)(n-R_i)\right]^2}$$

$$R_i=\sum_{j=1}^{c}n_{ij},\ D_r=n^2-\sum_{i}^{r}R_i^2$$

$$P=2n_c,\ Q=2n_d$$

$$C_{ij}=\sum_{i'>i}\sum_{j'>j}n_{i'j'}+\sum_{i'<i}\sum_{j'<j}n_{i'j'},\ D_{ij}=\sum_{i'>i}\sum_{j'<j}n_{i'j'}+\sum_{i'<i}\sum_{j'>j}n_{i'j'}$$

在大样本情况下有如下近似：

$$\frac{d(C|R)}{\mathrm{ASE}} \sim \mathrm{N}(0,\ 1)$$

附录

.1 R 语言函数详解

.1.1 wilcox.test

部分参数解释

1. digits.rank：若为有限值，则在计算秩的时候对数据取小数点后 digits.rank 位进行计算。

后记