你永远不知道一个强迫症能干出什么事情

倪兴程 [1]

2024 年 10 月 18 日

[1]Email: 19975022383@163.com

Todo list

在概率论里完善 Wilcoxon 秩统计量的分布相关理论，然后链接过来 8
没搞懂这里的连续性修正是个什么情况 16
在完成试验设计之后，把多样本位置检验与方差分析部分结合起来 17
记得以后要写多重假设检验的校正问题 24
需要找论文，Patil(1975)，同时需要看统计量的推导过程，为什么单侧检验 32
现在只提供了大样本近似，回头看完论文和原理记得补 32
有机会看看这里平衡与不平衡的不完全区组设计有没有什么区别 33
代码现在是只考虑平衡的 34
有空证明 39
根本没懂原理 42
查资料看 Kendall 的打结是否和 Friedman 一致 43
写完概率论把独立性链接到这里来 45
有机会看看单侧的实际意义，不懂为什么会考虑单侧 46
写完概率论把 Pearson 线性相关系数链接过来。 48

前言

其实这个想法在我大二之初准备全国大学生数学建模竞赛的时候就已经产生。第一次打数模国赛时整篇论文的编排工作由组内成员负责，当时我并不了解 LaTeX 的语法与使用，但由于 IGEM 校园选拔赛要求每位申请数模组的同学提交一篇自己独立完成的数学建模论文，我便开始学习 LaTeX。

本科阶段我曾学习大量数学专业课程，从基础的数学分析、高等代数到后来的随机过程、实变函数与泛函分析。我曾苦于寻找合适的教材（请允许我吐槽一下国内的本科教材，北大版高等代数与华东师大版数学分析简直不是人能看得下去的东西），感谢知乎、csdn 等处各位同学、学长学姐们的分享，我才得以接触到一些适合我的教材。以数学分析为例，我主要以北京大学张筑生教授编写的《数学分析新讲》为学习教材，以苏州大学谢惠民、恽自求等教授编写的《数学分析习题课讲义》为习题册进行查漏补缺，同时也曾阅读复旦大学陈纪修教授、北京大学伍胜健教授编写的《数学分析》，对清华大学于品教授的讲义也曾匆匆一瞥，这些教材都可以称为是国内顶尖的数学分析教材了。可是每本书都有每本书自己的特点，对于任何一本书，以上所列的其他书籍都对其有着一定的补充，曾考虑使用 marginnote 软件将这些书籍整理成一些思维导图，但思来想去还是觉得不如自己动手重新编撰为一本属于自己的教材。首先，思维导图只能援引原著内容，难以进行个性化表述，即使可以，操作与使用起来都有一定的复杂性与不便性；其次，倘若重新整理，内容编排上可按我的个人习惯以及思维过程进行调整，也可引入适当高阶课程中的知识进行更高观点的阐释，不同课程中的交叉部分也很容易集中叙述；同时，LaTeX 的交叉引用（点击即跳转）的功能也十分吸引我；最后，自己编一本书，倘若确实质量不错，也可上传至 Github 或个人主页供后来者一阅。

曾想过在 Bilibili 上录播自己在 SRT 阶段学习到的机器学习、深度学习及生物信息学知识作为分享，同时也可作为自己复习的一手资料，也曾想过利用 csdn、知乎这两个平台发布自己整理的笔记，但终究没有付诸实践，略有遗憾，但我现在做的本科阶段知识的整理，我一定会完成它。

本书打算整理我本科所学的所有数学类课程知识，将伴随着我个人的考研复习进度逐步完成，预计耗时一年半。

倪兴程

2024 年 10 月 18 日于南京农业大学教四楼 B409

目录

前言 ii

第一部分　概率论 1

第一章　大数定律与中心极限定理 2
1.1　连续性校正 2
1.1.1　使用原因 2
1.1.2　具体方法 3

第二部分　非参数统计学 4

第二章　单样本位置检验 5
2.1　广义符号检验 5
2.2　Wilcoxon 符号秩检验 7
2.3　中位数的点估计与置信区间 9
2.4　符号检验与 Wilcoxon 符号秩检验的比较 10

第三章　两样本位置检验 11
3.1　目的 11
3.2　Brown-Mood 中位数检验 11
3.3　Wilcoxon 秩和检验 13
3.4　Brown-Mood 中位数检验与 Wilcoxon 秩和检验的比较 14
3.5　成对数据差异性检验 14
3.5.1　连续型数据 15
3.5.2　01 型数据的 McNemar 检验 15

第四章　多样本位置检验 17
4.1　目的 17
4.2　本章各方法的简单总结 17
4.3　Kruskal-Wallis 检验 17

4.4 Jonckheere-Terpstra 检验 20
4.5 Friedman 秩和检验 23
4.6 Page 检验 26
4.7 Cochran 检验 31
4.8 Durbin 检验 33

第五章 Something else **37**
5.1 Cox-Stuart 趋势检验 37
5.2 游程检验 38
5.3 分类评分结果一致性判断 42
5.3.1 Cohen's Kappa 系数 42
5.3.2 Kendall 协同系数检验 43
5.4 列联表独立性问题 45
5.4.1 Pearson 近似检验 45
5.4.2 低维列联表的 Fisher 精确检验 46
5.5 似然比检验 47

第六章 单调关联性 **48**
6.1 单调关联性的零假设与备择假设 48
6.2 本章各方法的简单总结 48
6.3 Spearman 秩关联检验 49
6.4 Kendall τ 关联检验 50
6.5 Goodman-Kruskal's γ 关联检验 51
6.6 Sumers' d 关联检验 52

附录 **53**
.1 数域 53
.2 等价关系 53
.3 矩阵 55
.3.1 Kronecker 乘积 55
.3.2 迹 55

后记 **56**

第一部分

概率论

Chapter 1

大数定律与中心极限定理

1.1 连续性校正

1.1.1 使用原因

由中心极限定理，独立同分布的随机变量序列 $X_i,\ i = 1, 2 \ldots, n$ 的和 $\sum\limits_{i=1}^{n} X_i$ 将在随机变量个数 $n \to +\infty$ 时服从正态分布，因此，在某些情况下，我们可以利用正态分布 CDF(Cumulative Distribution Function) 值来近似一些难以计算的离散型随机变量 (Discrete Variable) 的 CDF 值。

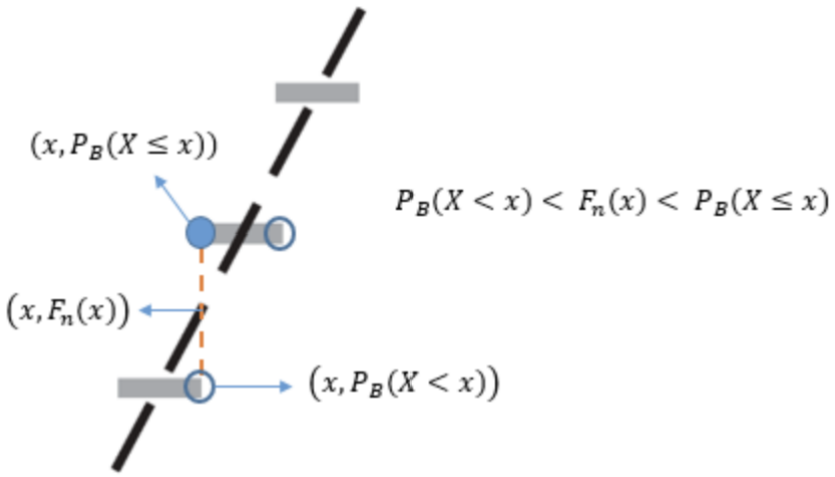

图 1.1: 连续型、离散型随机变量 CDF 图

对于离散型随机变量，常出现 $P(X < x) \neq P(X \leqslant x)$，而对于连续型随机变量 (Continuous Variable)，二者的值是相等的，因此，CDF 值的近似将出现以下问题：

1. 使用正态分布 CDF 值近似 $P(X \leqslant x)$ 时近似值偏小。
2. 使用正态分布 CDF 值近似 $P(X < x)$ 时近似值偏大。

而我们会想要得到一个一致的近似，即对于以上两个近似，结果总是一致地偏大或偏小，这样利于分析。

1.1.2 具体方法

- 根据近似的分布选择一个 $\alpha \in (-1, 1)$，一般选择 $\pm\frac{1}{2}$。
- 使用正态分布 CDF 值 $F(\frac{x+\alpha-\mu}{\sigma})$ 近似 $P(X < x)$ 与 $P(X \leqslant x)$。

第二部分

非参数统计学

Chapter 2

单样本位置检验

2.1 广义符号检验

目的

给定某样本，检验给定值 q_0 与总体的 π 分位点 Q_π 之间的关系。

适用条件

总体是连续型的。离散型分位点的定义会导致下述统计量不服从对应的二项分布。

原理

记一组样本中大于 q_0 的单元的个数为 s^+，小于 q_0 的单元的个数为 s^-。若零假设成立（即 q_0 确实为总体的 π 分位点），则从总体中任取一个元素，它小于 q_0 的概率应为 π，那么对于任意一组样本来讲，应有 $K \sim \text{Binom}(s^+ + s^-, \pi)$，其中 K 为 s^- 背后的随机变量。

零假设

$H_0 : Q_\pi = q_0$

大样本近似

当 n 较大时，可认为 $Z \sim N(0,1)$，其中 $Z = \dfrac{K - n\pi}{\sqrt{n\pi(1-\pi)}}$，其中 n 为样本中不等于 q_0 的单元的个数，由此可在求 p 值时近似计算标准正态分布的累积概率值。

注意事项

需要去除样本中值为 q_0 的单元，这部分单元对推断没有帮助。

备择假设	p 值	解释
$H_1: Q_\pi > q_0$	$P_{H_0}(K \leqslant s^-)$	在零假设下，二项分布变量小于当前样本 s^- 的概率太小，说明 s^- 太小应变大，即分位点的值应比 N 大
$H_1: Q_\pi < q_0$	$P_{H_0}(K \geqslant s^-)$	略
$H_1: Q_\pi \neq q_0$	$2\min\{P_{H_0}(K \leqslant s^-), P_{H_0}(K \geqslant s^-)\}$	略

表 2.1: 对 $H_0: Q_\pi = q_0$ 的检验

尚存疑惑

为什么 p 值是这样的呢？

代码

```
sign.test <- function(x, q0, pi, exact = FALSE,
                      alternative = c("two.sided", "greater", "less")) {
  alternative <- match.arg(alternative)
  s_pos <- sum(x > q0)
  STATISTIC <- sum(x < q0)
  n <- s_pos + STATISTIC
  STATISTIC <- setNames(STATISTIC, "s_neg")
  hypothesis_message <- switch(alternative,
                               "greater" = paste("Q0 >", pi),
                               "less" = paste("Q0 <", pi),
                               "two.sided" = paste("Q0 !=", pi))
  if (exact) {
    METHOD <- "Sign Test (Exact)"
    p.value <- switch(alternative,
                      "greater" = pbinom(q = STATISTIC, size = n, prob = pi),
                      "less" = pbinom(q = STATISTIC-1, size = n, prob = pi, lower.tail = FALSE),
                      "two.sided" = 2 * min(pbinom(q = STATISTIC-1, size = n, prob = pi, lower.tail = FALSE),
                                            pbinom(q = STATISTIC, size = n, prob = pi)))
```

```
  } else {
    METHOD <- "Sign Test (Approximate)"
    z_score <- (STATISTIC - n * pi) / sqrt(n * pi * (1 - pi))
    p.value <- switch(alternative,
                      "greater" = pnorm(z_score, lower.tail = TRUE),
                      "less" = pnorm(z_score, lower.tail = FALSE),
                      "two.sided" = 2 * min(pnorm(z_score), 1 -
                      ↪  pnorm(z_score)))
  }

  RVAL <- list(statistic = STATISTIC, p.value = p.value,
               data.name = deparse(substitute(x)),
               method = METHOD, alternative = hypothesis_message)
  class(RVAL) <- "htest"
  RVAL
}
```

2.2 Wilcoxon 符号秩检验

目的

给定某样本，检验给定值 M_0 与总体的中位数 M 之间的关系。

适用条件

总体分布是连续且对称的。连续是为了避免样本中出现重复值影响秩分配，对称则是秩推断成立的必要条件，见下文2.2。

符号秩的计算

设样本中每个单元的取值为 X_i，$i = 1, 2, \ldots, n$。

1. 对 $i = 1, 2, \ldots, n$，计算 $d_i = |X_i - M_0|$。
2. 对 d_i 进行排序，找出它们的秩 R_i。
3. 计算 $W^+ = \sum\limits_{i \in \{i: X_i - M_0 > 0\}} R_i$, $W^- = \sum\limits_{i \in \{i: X_i - M_0 < 0\}} R_i$。

原理

由于总体是对称的，那么对于任意一个元素，首先它出现在 M_0 两边的可能性是相等的，其次它出现在 M_0 两边对称位置的可能性是相等的，由此在零假设成立的条件下，W^+

和 W^- 应相差不大，且二者满足关系：$W^+ + W^- = \frac{n(n+1)}{2}$，因此，当其中之一很小时，应怀疑零假设。若想对 p 值精确求解，见。

在概率论里完善 Wilcoxon 秩统计量的分布相关理论，然后链接过来

零假设

$H_0 : M = M_0$

备择假设	统计量 W	p 值
$H_1 : M > M_0$	W^-	$P(W \leqslant w)$
$H_1 : M < M_0$	W^+	$P(W \leqslant w)$
$H_1 : M \neq M_0$	$\min\{W^-, W^+\}$	$2P(W \leqslant w)$

表 2.2: Wilcoxon 符号秩检验

大样本近似

可求出 Wilcoxon 符号秩检验统计量的期望和方差分别为：

$$E(W) = \frac{n(n+1)}{4} \qquad Var(W) = \frac{n(n+1)(2n+1)}{24}$$

当 n 较大时，由中心极限定理，可认为 $Z \sim N(0,1)$，其中 $Z = \dfrac{W - E(W)}{\sqrt{Var(W)}}$，由此可在求 p 值时近似计算标准正态分布的累积分布值。

打结

若数据中含有相同的数字，称之为打结的情况。结的个数为重复出现的数值的个数，结中数值的秩为它们升序排序后位置的平均值。如果结多了，大样本近似公式就不准，要进行修正，同时，如果数据中有结则必须使用大样本近似。修正后的公式为：

$$Z = \frac{W - E(W)}{\sqrt{Var(W) - \frac{\sum_{i=1}^{g}(\tau_i^3 - \tau_i)}{48}}} \sim N(0,1)$$

举例：对于数据 $\{2, 2, 5, 8, 8.8, 1, 1, 1, 1\}$，一共有 3 个结，$\tau_1 = 2$（两个 2），$\tau_2 = 3$（三个 8），$\tau_3 = 4$（四个 1）。称 τ 为结统计量。

代码

```
wilcox.test(x, alternative = c("two.sided", "less", "greater"), mu = M0,
↪  exact = NULL, correct = TRUE)
```

2.3 中位数的点估计与置信区间

适用条件

总体分布是连续且对称的。

中位数点估计公式

我们称 $\{\frac{X_i+X_j}{2},\ i \leqslant j\}$ 为 Walsh 平均，然后使用 Walsh 平均的中位数估计总体的中位数，该统计量称为 Hodges-Lehmann 估计量（简称 HT 估计量）。

$$\hat{\theta} = \text{median}\{\frac{X_i + X_j}{2},\ i \leqslant j\}$$

中位数区间估计原理

注意到如下关系：

$$W^+ = \left|\{\frac{X_i + X_j}{2} > M_0,\ i \leqslant j\}\right|$$

该关系也有关于 W^- 的对称版本。对 Walsh 平均从小到大排序，记为 $W_{(1)}, W_{(2)}, \ldots, W_{(N)}, N = \frac{n(n+1)}{2}$。因为想要取两个 Walsh 平均构成一个中位数的区间估计，那么就要去掉左端和右端部分的 Walsh 平均，而 Walsh 平均的个数是与符号秩统计量 W 是相关的，左端去掉的 Walsh 平均的个数可以看作 W^- 的实现值，右端去掉的 Walsh 平均的个数可以看作 W^+ 的实现值，那么就给予了区间估计成立的概率值。

因此，给出中位数 M 的 $(1-\alpha)$ 置信区间为：

$$(W_{k+1}, W_{N-k}),\ k\text{满足}P(W^- \leqslant k) \leqslant \frac{\alpha}{2}\text{与}P(W^- \leqslant k+1) > \frac{\alpha}{2}$$

注意到上式利用了 W^- 与 W^+ 的对称性。

在大样本下，可以近似得到：

$$k \approx \frac{n(n+1)}{4} - Z_{\frac{\alpha}{2}}\sqrt{\frac{n(n+1)(2n+1)}{24}}$$

为什么要用 Walsh 平均

Walsh 平均可以增大样本数量，如果就用原样本去估计置信区间，在样本数较小的情况下，置信区间会变得很大，不够精确。

代码

```
wilcox.test(x, exact = NULL, correct = TRUE, conf.int = FALSE, conf.level
↪  = 0.95))
```

2.4 符号检验与 Wilcoxon 符号秩检验的比较

在数据满足 Wilcoxon 符号秩检验的适用条件时，由于 Wilcoxon 符号秩检验不仅利用了符号信息，也利用了距离信息，因此会更准确。

Chapter 3

两样本位置检验

3.1 目的

通过检验样本中位数的一致性来判断样本的差异性。中位数是某种意义上的“平均”。

3.2 Brown-Mood 中位数检验

目的

检验两个样本 X 和 Y 的中位数 M_X, M_Y 是否相同。

原理

记样本 X 与 Y 分别为 $X_1, X_2, \ldots, X_m$, $Y_1, Y_2, \ldots, Y_n$。将两样本混合求得混合后的中位数 M_{XY}。若两样本中位数相同，则混合后的中位数应也等于二者的中位数，那么两个样本中大于 M_{XY} 的单元的个数应该大致一样。可构建如下表格：

	X 样本	Y 样本	总和
单元大于 M_{XY} 的个数	a	b	p
单元小于 M_{XY} 的个数	c	d	q
总和	m	n	N

表 3.1: $2*2$ 列联表矩阵

令 A 表示表中 a 背后的随机变量，在 m、n、p 固定的情况下，A 服从超几何分布 $\mathrm{H}(p, m, N)$（在四个边际和中任意三个固定的情况下，都有 $2*2$ 列联表中的一个值其背后的随机变量服从超几何分布），有如下概率：

$$P(A=k) = \frac{\binom{m}{k}\binom{n}{p-k}}{\binom{N}{p}}$$

若 A 过大或过小，考虑到此时 p 是固定的，那么 X 样本中大于 M_{XY} 单元的个数离 Y 样本中大于 M_{XY} 单元的个数就会很远，就应怀疑零假设。

零假设

$H_0 : M_X = M_Y$

备择假设	p 值
$H_1 : M_X > M_Y$	$P(A \geqslant a)$
$H_1 : M_X < M_Y$	$P(A \leqslant a)$
$H_1 : M_X \neq M_Y$	$2\min\{P(A \geqslant a), P(A \leqslant a)\}$

表 3.2: 对 $H_0 : M_X = M_Y$ 的检验

大样本近似

由超几何分布的期望与方差，在大样本情况下可认为有如下关系：

$$Z = \frac{A - \frac{pm}{N}}{\sqrt{\frac{pm(N-p)(N-m)}{N^3}}} \sim N(0,1)$$

对于双边假设检验，在大样本情况下，可选取检验统计量与 p 值如下：

$$K = \frac{(2a-m)^2(m+n)}{mn} \sim \chi^2(1),\ p = P(K \geqslant k)$$

注意事项

若有和 M_{XY} 值相同的单元，可将其去除，也可将其归于任何一类使得检验变得保守一点。

代码

以下代码需要输入 x 满足一定的格式：数据是两列，第一列为观测值，第二列用 $1, 2$ 来表示其属于 X 或 Y 样本，1 表示属于 X 样本。以下代码也提供了样本中有和 M_{XY} 值相同的单元情况下的处理方案，omit 表示去除与 M_{XY} 值相同的单元，less 表示将其归于小于 M_{XY} 值的一类，greater 表示将其归于大于 M_{XY} 值值的一类。

```
brown.mood.test <- functions(data,
      alternative = c("two.sided", "less", "greater"),
      ties.method = c("omit", "less", "greater")){
  M_AB <- median(data[,1])
  switch(ties.method,
         omit = {data <- data[data[, 1] != M_AB,]},
```

```
        less = {data[data[, 1] == M_AB, 1] = M_AB - 1},
        greater = {data[data[, 1] == M_AB, 1] = M_AB + 1})

  C <- matrix(nr = 2, nc = 2)
  C[1, 1] <- sum(data[data[, 2] == 1, 1] > M_AB)
  C[1, 2] <- sum(data[data[, 2] == 2, 1] > M_AB)
  C[2, 1] <- sum(data[data[, 2] == 1, 1] < M_AB)
  C[2, 2] <- sum(data[data[, 2] == 2, 1] < M_AB)

  fisher.test(C, alt=alternative, conf.int = FALSE)
}
```

3.3 Wilcoxon 秩和检验

目的

检验两个样本 X 和 Y 的中位数 M_X, M_Y 是否相同。

适用条件

需要两总体的分布有类似形状，但并不需要对称。

Wilcoxon 秩和统计量

记样本 X 与 Y 分别为 $X_1, X_2, \ldots, X_m$, $Y_1, Y_2, \ldots, Y_n$。把两个样本混合起来并从小到大排序，令 R_{X_i} 和 R_{Y_j} 分别表示单元 X_i、单元 Y_i 在混合样本中的秩，则称

$$W_X = \sum_{i=1}^{m} R_{X_i},\ W_Y = \sum_{j=1}^{n} R_{Y_j}$$

为 Wilcoxon 秩和统计量。

在零假设下，令 R_i 表示 Y 中第 i 个样本在混合后的秩，可得如下性质：

$$P(R_i = k)\frac{1}{N},\ k = 1, 2, \ldots, N;\ i = 1, 2, \ldots, n;$$

$$P(R_i = k,\ R_j = l) = \begin{cases} \frac{1}{N(N-1)} & k \neq l; \\ 0 & k = l. \end{cases}$$

$$E(R_i) = \frac{N+1}{2},\ Var(R_i) = \frac{N^2-1}{12},\ Cov(R_i,\ R_j) = -\frac{N+1}{12}(i \neq j)$$

$$E(W_Y) = \frac{n(N+1)}{2},\ Var(W_Y) = \frac{mn(N+1)}{12}$$

原理

若零假设成立，在两总体分布有类似形状时 W_X 与 W_Y 应比较接近，当其中之一很大或很小时，应怀疑零假设。

零假设

$H_0 : M_X = M_Y$

备择假设	统计量 K	p 值
$H_1 : M_X > M_Y$	W_Y	$P(K \leqslant k)$
$H_1 : M_X < M_Y$	W_X	$P(K \leqslant k)$
$H_1 : M_X \neq M_Y$	$\min\{W_X, W_Y\}$	$2P(K \leqslant k)$

表 3.3: Wilcoxon 秩和检验

大样本近似

由 W_Y 的期望与方差，在大样本下可认为：

$$Z = \frac{W_Y - E(W_Y)}{\sqrt{Var(W_Y)}} \sim N(0,1) \tag{3.1}$$

若存在打结的情况，只能使用大样本近似，且应对正态近似公式进行修正（其中 τ 为结统计量）：

$$Z = \frac{W_Y - E(W_Y)}{\sqrt{Var(W_Y) - \frac{mn(\sum_{i=1}^{g}\tau_i^3 - \sum_{i=1}^{g}\tau_i)}{12(m+n)(m+n-1)}}} \sim N(0,1) \tag{3.2}$$

代码

```
wilcox.test(x, y, alternative = c("two.sided", "less", "greater"), exact
↪  = NULL, correct = TRUE)
```

3.4 Brown-Mood 中位数检验与 Wilcoxon 秩和检验的比较

在数据满足 Wilcoxon 秩和检验的适用条件时，由于 Wilcoxon 符号秩检验不仅利用了符号信息，也利用了距离信息，因此会更准确。

3.5 成对数据差异性检验

目的： 检验成对数据间是否有显著差异。

适用条件:

1. 每一对数据来自可比较的对象。
2. 每一对数据彼此之间是独立的。。

3.5.1 连续型数据

原理

记两组观测值分别为 $X_1, X_2, \ldots, X_n$, $Y_1, Y_2, \ldots, Y_n$。对应元素作差，则检验退化为单样本中位数检验。令 M_D 表示 $X_i - Y_i$ 的中位数，则有以下检验类型:

零假设	备择假设
$H_0 : M_D = M_0$	$H_0 : M_D > M_0$
$H_0 : M_D = M_0$	$H_0 : M_D < M_0$
$H_0 : M_D = M_0$	$H_0 : M_D \neq M_0$

表 3.4: 检验类型

代码

下述 sign.test 的代码参考第6页。mu 值的都是想要检验的二者之间的差异值，wilcox.test 可以给出一定置信度下二者差异值的点估计与区间估计。

```
sign.test(x-y, mu, 0.5, exact = FALSE, alternative = c("two.sided", "less", "greater"), )
wilcox.test(x, y, alternative = c("two.sided", "less", "greater"), mu = 0, paired = TRUE, exact = NULL, correct = TRUE, conf.int = FALSE, conf.level = 0.95)
```

3.5.2 01 型数据的 McNemar 检验

假设

H_0 : 无显著差异; H_1 : 有显著差异

原理

记两组观测值分别为 $X_1, X_2, \ldots, X_n$, $Y_1, Y_2, \ldots, Y_n$。记:

$$n_X = |\{i : X_i = 1,\ Y_i = 0\}|,\ n_Y = |\{i : Y_i = 1,\ X_i = 0\}|$$

McNemar 检验统计量为：

$$K = \frac{(n_X - n_Y)^2}{n_X + n_Y}$$

在零假设成立的条件下该统计量近似服从 $\chi^2(1)$，而在大样本的情况下，它的平方根近似服从标准正态分布。如果有差异，那么统计量的值应该是偏大的，因此只考虑上侧的单侧检验问题，有如下 p 值：

$$p = F_{\chi^2}(K \geqslant k)$$

没搞懂这里的连续性修正是个什么情况

代码

```
mcnemar(x, y, correct=TRUE)
```

Chapter 4

多样本位置检验

4.1 目的

利用样本中各响应值的位置信息，判断各水平间是否存在差异或某种趋势。

在完成试验设计之后，把多样本位置检验与方差分析部分结合起来

4.2 本章各方法的简单总结

1. 所有方法都要求各水平的总体分布之间是相似的，仅仅是位置参数可能有些差异。
2. Kruskal-Wallis 与 Friedman、Durbin 对称，都是检验各水平响应值的位置参数是否一致（即各水平在该响应值下是否有差异）。Kruskal 是在各水平不相关的情况下使用的，Freidman 是在完全区组设计下、各水平之间由于区组问题不独立时使用的，而 Durbin 是在不完全区组设计下、各区组之间独立时使用的。同时 Kruskal-Wallis、Durbin 要求数据是连续型的，Friedman 则无此类要求。
3. Jonckheere-Terpstra 与 page 对称，都是检验各水平响应值的位置参数是否有顺序关系，Jonckheere-Terpstra 是在各水平不相关的情况下使用的，page 是在完全区组设计下、各水平之间由于区组问题不独立时使用的。同时 Jonckheere-Terpstra 要求数据是连续型的，page 则无此类要求。
4. Cochran 与 Friedman 对应，Cochran 是完全区组设计、二元响应情况下检验各水平是否存在差异的方法。
5. Friedman 与下一章 Kendall 检验是一致的。Kendall 一般用在判断评估者的主观评估是否一致，而 Friedman 则是客观的判断水平之间是否有差异。

4.3 Kruskal-Wallis 检验

适用条件

各响应值在水平间和水平内是独立的，水平之间分布是相似的，数据是连续型的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

将所有水平的响应值混合后排序，得到每一个响应值对应于所有数据的秩，类似于方差分析中 MSA 的构成，若水平间的秩和差异大，则应怀疑零假设。由此构建以下 Kruskal-Wallis 统计量（其中 $\bar{R}_i$ 表示第 i 个水平秩的平均值，$\bar{R}$ 表示所有响应值秩的平均值）：

$$H = \frac{12}{N(N+1)} \sum_{i=1}^{k} n_i(\bar{R}_i - \bar{R})^2 = \frac{12}{N(N+1)} \sum_{i=1}^{k} \frac{R_i^2}{n_i} - 3(N+1)$$

如果备择假设成立，那么统计量的值应该是偏大的，因此只考虑上侧的单侧检验问题。

若想求精确结果，需要满足数据中不存在结（即数据中不存在相同的数值），对每种秩分配计算对应的 H 值，便能得到此时统计量 H 的分布。

大样本近似

在大样本的情况下，若零假设成立，有如下近似分布：

$$H \sim \chi^2_{(k-1)}$$

打结

若存在打结的情况，将 H 作以下修正，然后利用大样本近似公式进行计算：

$$H_C = \frac{H}{1 - \sum\limits_{i=1}^{g} (\tau_i^3 - \tau_i)/(N^3 - N)}$$

代码

这是 R 语言 stats 包中的函数，只提供大样本近似，并且不包含连续性修正。x 表示各水平的 response 值，g 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个包含所有水平响应值的列表，各水平之间分隔开。

```
kruskal.test(x, g)
```

以下是自编代码，x 表示各水平的 response 值，y 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个数据框，第一列是 response 值，第二列是 factor 标签。提供精确检验、大样本近似、连续性修正与打结校正功能。精确检验需要 gtools 包，同时测试了一下一个水平 8 个数据一共 24 个数据 permutation 就要占到 14 个 G 的内存以上，慎用精确检验。

```r
kruskal_wallis.test <- function(x, y = NULL, exact = FALSE, correct = FALSE) {
  if (is.data.frame(x) && ncol(x) == 2) {
    DNAME <- deparse(substitute(x))
    y <- x[, 2]
    x <- x[, 1]
  } else if (is.vector(x)) {
    if (is.null(y))
      stop("Error: x must have two columns or y is provided.")
    if (length(y) != length(x))
      stop("Error: x and y must have the same length.")
    DNAME <- paste(deparse(substitute(x)), "and", deparse(substitute(y)))
  } else {
    stop("Error: x must be a data frame with 2 columns or a vector.")
  }
  METHOD <- "Kruskal-Wallis test"
  TIES <- table(x)
  if (any(TIES > 1)) {
    ties <- TRUE
  } else {ties <- FALSE}
  unique_y <- sort(unique(y))
  rank_x <- rank(x)
  R_i <- sapply(unique_y, function(i) sum(rank_x[y == i]))
  n_i <- sapply(unique_y, function(i) sum(y == i))
  N <- length(x)
  STATISTIC <- setNames((12 / (N * (N + 1)) * sum(R_i^2 / n_i) - 3 * (N + 1))
                        / (1 - sum(TIES^3 - TIES) / (N^3 - N)), "H")
  if (!exact || ties) {
    df <- length(unique_y) - 1
    if (!correct) {
      p_value <- pchisq(STATISTIC, df = df, lower.tail = FALSE)
    } else {
      METHOD <- paste(METHOD, "with continuity correction")
      p_value <- pchisq(STATISTIC - 0.5, df = df, lower.tail = FALSE)
    }
  } else {
```

```
    H.cal <- function(rank_x, y) {
      R_i <- sapply(unique_y, function(i) sum(rank_x[y == i]))
      (12 / (N * (N + 1)) * sum(R_i^2 / n_i) - 3 * (N + 1))
    }
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    all_permutations <- permutations(N, N)
    Hs <- sapply(1:nrow(all_permutations), function(i) {
      H.cal(all_permutations[i, ], y)
    })
    p_value <- mean(Hs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

4.4 Jonckheere-Terpstra 检验

目的

检验水平的位置参数是否呈现出上升趋势，若想检验是否呈现出下降趋势，改变水平顺序就行了。

适用条件

各响应值在水平间和水平内是独立的，水平之间分布是相似的，数据是连续型的。这里与 Kruskal-Wallis 检验的条件是一样的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x - \theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$$

原理

假设一共有 k 个水平，每个水平中有 n_i 个响应值 $(i = 1, 2, \ldots, k)$，响应值用 X_{ij} 表示 $(i = 1, 2, \ldots, k,\ j = 1, 2, \ldots, n_i)$，由此构建以下 JT 统计量 (J)：

$$U_{ij} = |X_{ia} < X_{jb},\ a = 1, 2, \ldots, n_i,\ b = 1, 2, \ldots, n_j|$$
$$J = \sum_{i<j} U_{ij}$$

在备择假设成立的情况下，某个水平中的观测值会比后面水平中的观测值小，水平间的 U_{ij} 会比较大，J 也会比较大。因此在 J 比较大的时候，有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

若想求精确检验的结果，需要满足数据中没有结（即所有数据中没有相同的数值），然后对每一种秩分配情况计算 J 的值（秩的大小关系便反映了数据之间的大小关系），即可得到 J 的精确分布。

大样本近似

在 $\min\limits_i n_i \to +\infty$ 时，有以下近似公式：

$$Z = \frac{J - (N^2 - \sum\limits_{i=1}^{k})/4}{\sqrt{[N^2(2N+3) - \sum\limits_{i=1}^{k} n_i^2(2n_i+3)]/72}} \sim N(0,\ 1)$$

打结

当数据中存在相同数值时，要进行修正：

$$U_{ij} = |X_{ia} < X_{jb},\ a = 1, 2, \ldots, n_i,\ b = 1, 2, \ldots, n_j| + \frac{1}{2}|X_{ia} = X_{jb},\ a = 1, 2, \ldots, n_i,\ b = 1, 2, \ldots, n_j|$$
$$J = \sum_{i<j} U_{ij}$$

代码

x 表示各水平的 response 值，y 对应于 factor 标签。也可以只传入 x，此时 x 需要是一个数据框，第一列是 response 值，第二列是 factor 标签。提供精确检验、大样本近似、连续性修正与打结校正功能。精确检验需要 gtools 包，同时测试了一下一个水平 8 个数据一共 24 个数据 permutation 就要占到 14 个 G 的内存以上，慎用精确检验。

```
JT.test <- function(x, y = NULL, exact = FALSE, correct = FALSE) {
  if (is.data.frame(x) && ncol(x) == 2) {
```

```
    DNAME <- deparse(substitute(x))
    y <- x[, 2]
    x <- x[, 1]
  } else if (is.vector(x)) {
    if (is.null(y))
      stop("Error: x must have two columns or y is provided.")
    if (length(y) != length(x))
      stop("Error: x and y must have the same length.")
    DNAME <- paste(deparse(substitute(x)), "and", deparse(substitute(y)))
  } else {
    stop("Error: x must be a data frame with 2 columns or a vector.")
  }
  J.cal <- function(x, y, k) {
    U <- 0
    for (i in 1:(k - 1)) {
      for (j in (i + 1):k) {
        xi <- x[y==i]
        xj <- x[y==j]
        ties <- sum(outer(xi, xj, "==") * 1)
        U <- U + sum(outer(xi, xj, "<") * 1) + ties / 2
      }
    }
    U
  }
  METHOD <- "Jonckheere-Terpstra test"
  k <- max(y)
  U <- 0
  for (i in 1:(k - 1)) {
    for (j in (i + 1):k) {
      xi <- x[y==i]
      xj <- x[y==j]
      ties <- sum(outer(xi, xj, "==") * 1)
      if (ties > 0) {exact <- FALSE}
      U <- U + sum(outer(xi, xj, "<") * 1) + ties / 2
    }
  }
  STATISTIC <- setNames(U, "J")
  if (!exact) {
```

```
    ni <- table(y)
    N <- sum(ni)
    Z <- (STATISTIC - (N^2 - sum(ni^2)) / 4) / sqrt((N^2 * (2 * N + 3) -
    ↪  sum(ni^2 * (2 * ni + 3))) / 72)
    if (!correct) {
      p_value <- pnorm(Z, lower.tail = FALSE)
    } else {
      p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    n <- length(x)
    all_permutations <- permutations(n, n)
    JTs <- sapply(1:nrow(all_permutations), function(i) {
      J.cal(all_permutations[i, ], y, k)
    })
    p_value <- mean(JTs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

4.5 Friedman 秩和检验

适用条件

各水平间并不独立（因为还有区组的影响），采用完全区组设计，水平之间分布是相似的，连续型与离散型数据都可以。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x - \theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

假设有 k 个水平、b 个区组。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum\limits_{j=1}^{b} R_{ij}$，$i = 1, 2, \ldots, k$，定义如下 Friedman 统计量:

$$Q = \frac{12}{bk(k+1)} \sum_{i=1}^{k} (R_i - \frac{b(k+1)}{2})^2 = \frac{12}{bk(k+1)} \sum_{i=1}^{k} R_i^2 - 3b(k+1)$$

易证 $\frac{b(k+1)}{2} = \bar{R}_i$（只需注意此时秩是针对区组内而言）。在零假设成立的情况下，各水平之间的秩和与均值相比不应相差过大，也就是 Q 值不应太大，若 Q 值过大，则有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

大样本近似

在大样本的情况下（$b \to +\infty$），若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(k-1)}$$

打结

在某个区组存在结的时候，利用下式进行修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$Q_C = \frac{Q}{1-C},\ C = \frac{\sum\limits_{i,j}(\tau_{ij}^3 - \tau_{ij})}{bk(k^2-1)}$$

成对数据的比较

类似于邓肯多重比较法，有时需要比较某两个水平之间是否存在差异，那么在大样本的情况下，如果零假设为：i 水平与 j 水平之间没有差异，那么如果下式成立（其中 α 是检验的显著性水平）：

$$\left| R_i - R_j > Z_{\frac{\alpha^*}{2}} \sqrt{b(k+1)k/6} \right|$$
$$\alpha^* = \frac{\alpha}{k(k-1)/2}$$

则可拒绝零假设。可以看出这是一个很保守的检验，α^* 其实是做了多重假设检验的校正。

记得以后要写多重假设检验的校正问题

代码

以下是自编代码，提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

```r
friedman.test <- function(x, factor = NULL, block = NULL,
                          exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  Q.call <- function(ranks, factors) {
    R_i <- tapply(ranks, factors, sum)
    12 / (b * k * (k + 1)) * sum(R_i^2) - 3 * b * (k + 1)
  }
  METHOD <- "Friedman rank sum test"
  k <- length(unique(factor))
  b <- length(unique(block))
  rank <- ave(response, block, FUN = rank)
  STATISTIC <- setNames(Q.call(rank, factor), "Q")
  TIES <- unlist(tapply(response, block, table))
  if (any(sapply(TIES, function(x) any(x > 1)))) {
    ties <- TRUE
  } else {ties <- FALSE}
  if (!exact || ties) {
    Qc <- STATISTIC / (1 - sum(TIES^3 - TIES) / (b * k * (k^2 - 1)))
```

```
      if (!correct) {
        p_value <- pchisq(Qc, k - 1, lower.tail = FALSE)
      } else {
        p_value <- pchisq(Qc - 0.5, k - 1, lower.tail = FALSE)
        METHOD <- paste(METHOD, "with continuity correction")
      }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    possible_ranks <- permutations(k, k)
    all_combinations <- permutations(nrow(possible_ranks), b,
    ↪  repeats.allowed = TRUE)
    Qs <- sapply(1:nrow(all_combinations), function(i) {
      b_combs <- possible_ranks[all_combinations[i, ], ]
      rank_i <- as.vector(b_combs)
      Q.call(rank_i, factor)
    })
    p_value <- mean(Qs >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

4.6 Page 检验

目的

检验水平的位置参数是否呈现出上升趋势，若想检验是否呈现出下降趋势，改变水平顺序就行了。

适用条件

各水平间并不独立（因为还有区组的影响），采用完全区组设计，水平之间分布是相似的，离散型数据与连续型数据都可以。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$$

原理

假设有 k 个水平、b 个区组。

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum\limits_{j=1}^{b} R_{ij}$, $i = 1, 2, \ldots, k$，定义如下 Page 统计量：

$$L = \sum_{i=1}^{k} iR_i$$

如果备择假设是正确的，那么对 R_i 进行加权求和可以对统计量起到一个放大的作用，那么 L 就会很大。因此在 L 比较大的时候，有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

若想求精确检验的结果，需要满足数据中没有结（即每个区组中都没有相同的数值），然后对每一种秩分配情况计算 L 的值（秩的大小关系便反映了数据之间的大小关系），即可得到 L 的精确分布。

大样本近似

在大样本的情况下（$b \to +\infty$），有如下正态近似：

$$Z = \frac{L - \mu_L}{\sigma_L} \sim N(0,\ 1)$$
$$\mu_L = \frac{bk(k+1)^2}{4},\ \sigma_L^2 = \frac{b(k^3-k)^2}{144(k-1)}$$

打结

若存在打结的情况，需要对正态近似的 σ_L^2 作如下修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$\sigma_L^2 = k(k^2-1)\frac{bk(k^2-1) - \sum_i \sum_j (\tau_{ij}^3 - \tau_{ij})}{144(k-1)}$$

对区组、水平进行重复时的 page 检验

在区组和水平之间不存在交互作用，并且所有 $(i,\ j)$ 位置的重复数都相同时（假设都是 n），有如下正态近似（也考虑了到打结的修正）：

$$Z = \frac{L - \mu_L}{\sigma_L} \sim N(0,\ 1)$$
$$\mu_L = \frac{nbk(k+1)(nk+1)}{4}$$
$$\sigma_L^2 = nk(k^2-1)\frac{nbk(n^2k^2-1) - \sum_i \sum_j (\tau_{ij}^3 - \tau_{ij})}{144(nk-1)}$$

代码

以下是自编代码，提供重复、精确计算、大样本近似、连续性修正与打结校正功能。当对区组与水平进行重复时，x 必须是一个数据框，每一列是一次重复的结果，也必须传入 factor 与 block，此时只提供大样本近似。当不进行重复时，x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。请注意，检验顺序与输入的 factor 顺序是一致的，建议对照二维表**逐行**输入（行是水平，检验顺序即为行的顺序，列是区组）。如果出现打结的情况，结统计量按照计算公式进行计算，L 统计量的秩部分取结的平均秩（例：数据为 1、1、3、4，有重复值 1，则秩为 1.5、1.5、3、4）。

```r
page.test <- function(x, factor = NULL, block = NULL,
                      exact = FALSE, correct = FALSE,
                      repeated = FALSE) {
  if (repeated) {
    if (exact) {
      stop("Error: exact cannot be TRUE when repeated is TRUE.")
    }
    if (!is.data.frame(x) || ncol(x) == 1) {
      stop("Error: x must be a data frame with more than one column when repeated is TRUE.")
    }
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when repeated is TRUE.")
    }
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    if (is.data.frame(x)) {
```

```
      if (ncol(x) == 3) {
        response <- x[[1]]
        factor <- x[[2]]
        block <- x[[3]]
        DNAME <- deparse(substitute(x))
      }
    } else if (is.vector(x)) {
      if (is.null(factor) || is.null(block)) {
        stop("Error: factor and block must be provided when x is a vector.")
      }
      response <- x
      DNAME <- paste(deparse(substitute(x)), ", ",
                     deparse(substitute(factor)), " and ",
                     deparse(substitute(block)), sep = "")
    } else {
      stop("Error: x must be either a data frame with three columns or a vector.")
    }
  }
  L.call <- function(ranks, factors, num_fac) {
    R_i <- tapply(ranks, factors, sum)
    sum(seq_len(num_fac) * R_i)
  }
  compute_z <- function(statistic, k, b, repeat_n, ties){
    mu <- repeat_n * b * k * (k + 1)^2 / 4
    sigma2 <- repeat_n * k * (k^2 - 1) *
      (repeat_n * b * k * (repeat_n^2 * k^2 - 1) - sum(ties^3 - ties)) /
      (144 * (repeat_n * k - 1))
    (statistic - mu) / sqrt(sigma2)
  }
  METHOD <- "Page test"
  k <- length(unique(factor))
  b <- length(unique(block))
  if (repeated) {
    repeat_n <- ncol(x)
    Ls <- sapply(1:repeat_n, function(repeat_idx) {
      response <- x[[repeat_idx]]
```

```
      rank <- ave(response, block, FUN = rank)
      L.call(rank, factor, k)
    })
    STATISTIC <- setNames(sum(Ls), "L")
    TIES <- unlist(sapply(1:repeat_n, function(repeat_idx) {
      unlist(tapply(x[[repeat_idx]], block, table))
    }))
    Z <- compute_z(STATISTIC, k, b, repeat_n, TIES)
    if (!correct) {
      p_value <- pnorm(Z, lower.tail = FALSE)
    } else {
      p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    rank <- ave(response, block, FUN = rank)
    STATISTIC <- setNames(L.call(rank, factor, k), "L")
    TIES <- unlist(tapply(response, block, table))
    if (any(sapply(TIES, function(x) any(x > 1)))) {
      ties <- TRUE
    } else {ties <- FALSE}
    if (!exact || ties) {
      Z <- compute_z(STATISTIC, k, b, 1, TIES)
      if (!correct) {
        p_value <- pnorm(Z, lower.tail = FALSE)
      } else {
        p_value <- pnorm(Z - 0.5, lower.tail = FALSE)
        METHOD <- paste(METHOD, "with continuity correction")
      }
    } else {
      METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
      library(gtools)
      possible_ranks <- permutations(k, k)
      all_combinations <- permutations(nrow(possible_ranks), b,
      ↪  repeats.allowed = TRUE)
      Ls <- sapply(1:nrow(all_combinations), function(i) {
        b_combs <- possible_ranks[all_combinations[i, ], ]
        rank_i <- as.vector(b_combs)
```

```
        L.call(rank_i, factor, k)
      })
      p_value <- mean(Ls >= STATISTIC)
    }
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

4.7 Cochran 检验

目的

检验完全区组设计、二元响应情况下，各水平之间是否存在差异。

适用条件

完全区组设计，二元响应。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i),\ i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

假设有 k 个水平、b 个区组。

令 L_j 表示第 j 个区组中为 1 的数目的总和，N_i 表示第 i 个水平中为 1 的数目的总和，即 $L_j = \sum\limits_{i=1}^{k} x_{ij},\ j = 1, 2,\ b,\ N_i = \sum\limits_{j=1}^{b} x_{ij},\ i = 1, 2,\ k$。

在零假设成立的情况下，各水平之间无差异，那么对于每个 j 而言，L_j 个 1 在所有水平中出现的概率是相同的，这个概率依赖于具体的 L_j。由此定义如下 Cochran 统计量：

$$Q = \frac{k(k-1)\sum\limits_{i=1}^{k}(N_i - \bar{N})^2}{kN - \sum\limits_{j=1}^{b} L_j^2} = \frac{k(k-1)\sum\limits_{i=1}^{k} N_i^2 - (k-1)N^2}{kN - \sum\limits_{j=1}^{b} L_j^2}$$

其中 $\bar{N} = \frac{1}{k}\sum\limits_{i=1}^{k} N_i,\ N = \sum\limits_{i=1}^{k} N_i$。易证，若 $L_j = 0$ 或 $L_j = k$，那么这个区组的数据可以删除，对 Q 值没有影响（与前面的原理是相合的）。

需要找论文，Patil(1975)，同时需要看统计量的推导过程，为什么单侧检验

若想进行精确检验

大样本近似

在大样本的情况下（$b \to +\infty$），若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(k-1)}$$

代码

现在只提供了大样本近似，回头看完论文和原理记得补

以下是自编代码，需要传入一个数据框，行为水平列为区组。提供大样本近似与连续性修正。

```
cochran.test <- function(x, exact = FALSE, correct = FALSE) {
  if (!is.data.frame(x)) {
    stop("Error: x must be a data frame.")
  }
  DNAME <- deparse(substitute(x))
  METHOD <- "Cochran test"
  Ni <- apply(x, 1, sum)
  Lj <- apply(x, 2, sum)
  N <- sum(Ni)
  k <- nrow(x)
  STATISTIC <- (k * (k-1) * sum(Ni^2) - (k - 1) * N^2) / (k * N -
  ↪  sum(Lj^2))
  STATISTIC <- setNames(STATISTIC, "Q")
  if (!exact) {
    if (!correct){
      p_value <- pchisq(STATISTIC, k - 1, lower.tail = FALSE)
    } else {
      p_value <- pchisq(STATISTIC - 0.5, k - 1, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    # exact test
  }

  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
```

```
  RVAL
}
```

4.8 Durbin 检验

适用条件

不完全区组设计，水平之间分布是相似的，数据是连续型的。

假设

假设 k 个水平有分布函数 $F_i(x) = F(x-\theta_i)$, $i = 1, 2, \ldots, k$，则检验假设可写为：

$$H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \text{至少有一个等号不成立}$$

原理

假设有 k 个水平、b 个区组，每个区组中含 t 个处理，每个处理出现在 r 个区组中。

有机会看看这里平衡与不平衡的不完全区组设计有没有什么区别

因为各区组之间是有影响的，无法把各响应值混在一起排序。选择在各个区组内计算所有响应值的秩，R_{ij} 表示在第 j 个区组中水平 i 的秩，$R_i = \sum\limits_j R_{ij}$, $i = 1, 2, \ldots, k$，定义如下 Durbin 统计量:

$$D = \frac{12(k-1)}{rk(t^2-1)} \sum_{i=1}^{k} (R_i - \frac{r(t+1)}{2})^2 = \frac{12(k-1)}{rk(t^2-1)} \sum_{i=1}^{k} R_i^2 - \frac{3r(k-1)(t+1)}{t-1}$$

在零假设成立的情况下，各水平之间的秩和与均值相比不应相差过大，也就是 D 值不应太大，若 D 值过大，则有理由怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。同时，可以看出 Durbin 统计量在完全区组设计 ($t = k$, $r = b$) 的时候和 Friedman 统计量是完全一样的。

大样本近似

在大样本的情况下（$r \to +\infty$），若零假设成立，有如下近似分布：

$$D \sim \chi^2_{(k-1)}$$

在某个区组存在结的时候，利用下式进行修正（其中 τ_{ij} 表示第 j 个区组的第 i 个结统计量）：

$$D_C = \frac{(k-1)\sum_{i=1}^{k}(R_i - \frac{r(t+1)}{2})^2}{A - C}$$

$$A = \sum_i \sum_j R_{ij}^2, \ C = \frac{bt(t+1)^2}{4}$$

代码

代码现在是只考虑平衡的

以下是自编代码，会检查输入的数据是否满足不完全区组设计的平衡性。提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

```
durbin.test <- function(x, factor = NULL, block = NULL,
                        exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  num_r <- table(factor)
  num_t <- table(block)
  if (length(unique(num_r)) != 1) {
    stop("Error: The design is not balanced.
         Each treatment must appear in the same number of blocks.")
  }
  if (length(unique(num_t)) != 1) {
    stop("Error: The design is not balanced.
         Each block must contain the same number of treatments.")
  }
```

```r
D.call <- function(ranks, factors) {
  R_i <- tapply(ranks, factors, sum)
  12 * (k - 1) / (r * k * (t^2 - 1)) * sum(R_i^2) -
    3 * r * (k - 1) * (t + 1) / (t - 1)
}
METHOD <- "Friedman rank sum test"
k <- length(unique(factor))
b <- length(unique(block))
r <- as.numeric(num_r[1])
t <- as.numeric(num_t[1])
rank <- ave(response, block, FUN = rank)
STATISTIC <- setNames(D.call(rank, factor), "D")
TIES <- unlist(tapply(response, block, table))
if (any(sapply(TIES, function(x) any(x > 1)))) {
  ties <- TRUE
} else {ties <- FALSE}
if (!exact || ties) {
  Dc <- (k - 1) * sum((tapply(rank, factor, sum) - r * (t + 1) / 2)^2) /
    (sum(rank^2) - b * t * (t + 1)^2 / 4)
  if (!correct) {
    p_value <- pchisq(Dc, k - 1, lower.tail = FALSE)
  } else {
    p_value <- pchisq(Dc - 0.5, k - 1, lower.tail = FALSE)
    METHOD <- paste(METHOD, "with continuity correction")
  }
} else {
  METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
  library(gtools)
  possible_ranks <- permutations(t, t)
  all_combinations <- permutations(nrow(possible_ranks), b, repeats.allowed = TRUE)
  Ds <- sapply(1:nrow(all_combinations), function(i) {
    b_combs <- possible_ranks[all_combinations[i, ], ]
    rank_i <- as.vector(b_combs)
    D.call(rank_i, factor)
  })
  p_value <- mean(Ds >= STATISTIC)
```

```
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

Chapter 5

Something else

5.1 Cox-Stuart 趋势检验

目的

查看某组数据是否有递增、递减的趋势。

检验原理

把样本分成前后两段，若样本大小为奇数，则去除最中间的单元。把前后两段相同位置的元素组成对子，以每个对子两个元素差的正负性衡量增减。

$$x_1, x_2, x_3, \cdots, x_n$$

$$\text{对子：}(x_i, x_{i+c}),\ c = \begin{cases} n/2 & n \equiv 0 \mod 2 \\ (n+1)/2 & n \not\equiv 0 \mod 2 \end{cases}$$

$$D_i = x_i - x_{i+c}$$

$$\text{令} s^+ = |\{D_i : D_i > 0\}|,\ s^- = |\{D_i : D_i < 0\}|$$

若数据无趋势，s^- 与 s^+ 应服从 Binom$(s^+ + s^-, 0.5)$，则检验退化为符号检验。以下 p 值计算与广义符号检验略有差异，这是因为 p 取 0.5 时二项分布是对称分布。

检验的数学语言（与表 5.1 对应）

假设独立观测值序列 $X_i \sim F(x - \theta_i),\ i = 1, 2, \ldots, n$:

1. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$
2. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \geqslant \theta_2 \geqslant \cdots \geqslant \theta_n$
3. $H_0 : \theta_1 = \theta_2 = \cdots = \theta_n \Leftrightarrow H_1 : \theta_1 \leqslant \theta_2 \leqslant \cdots \leqslant \theta_n$ 或 $\theta_1 \geqslant \theta_2 \geqslant \cdots \geqslant \theta_n$

备择假设	统计量 K	p 值
H_1 : 有增长趋势	s^+	$P(K \leqslant k)$
H_1 : 有减少趋势	s^-	$P(K \leqslant k)$
H_1 : 有趋势	$\min\{s^+, s^-\}$	$2P(K \leqslant k)$

表 5.1: Cox-stuart 趋势检验

代码

```
Cox_Stuart <- function(y) {
    n <- length(y)
    c <- ifelse(n %% 2 == 0, n / 2, (n + 1) / 2)
    D <- y[(c + 1):n] - y[1:c]
    s_neg <- sum(D < 0)
    s_pos <- sum(D > 0)
    s <- min(s_neg, s_pos)
    text <- ifelse(s_pos - s_neg > 0, "Increasing with", "Decreasing
    ↪ with")
    cat(text, 'p_value =', pbinom(s, c, 0.5))
}
```

5.2 游程检验

目的

检验一组数据是否是随机出现的。

适用条件

数据的顺序有意义且是离散的，若不离散，可以中位数为间隔，利用符号函数将数据转换为二元数据。

游程的定义

游程是来自于同一总体的样本所构成的一个或一个以上相同符号连续出现的片段。例：对于数据

$$0000110111000$$

在这组数据中，一共有 5 个游程（3 个 0 游程，2 个 1 游程）。

游程数的分布

令 R 表示游程数，可以证明：

有空证明

$$P(R=2k)=\frac{2\binom{m-1}{k-1}\binom{n-1}{k-1}}{\binom{N}{n}}$$

$$P(R=2k+1)=\frac{\binom{m-1}{k-1}\binom{n-1}{k}+\binom{m-1}{k}\binom{n-1}{k-1}}{\binom{N}{n}}$$

$$E(R)=\frac{2mn}{m+1}+1 \quad Var(R)=\frac{2mn(2mn-m-n)}{(m+n)^2(m+n-1)}$$

游程检验原理

若数据是随机的，那么游程数不应过多也不应过少，若过多，则呈现出混合倾向，若过少，则呈现出聚集倾向。

备择假设	统计量 K	p 值
H_1 : 数据有聚集趋势	R	$P(K\leqslant k)$
H_1 : 数据有混合趋势	R	$P(K\geqslant k)$
H_1 : 数据有趋势	R	$2\min P(K\leqslant k),\ P(K\geqslant k)$

表 5.2: 随机性的游程检验

代码

tseries 包中的 runs.test

需要注意，该函数只提供大样本近似，并且输入值必须转换为因子，同时，要去除经过符号函数转换后值为 0 的数据。

```
library(tseries)
# median <- median(x)
# x <- factor(sign(x[x != median]-median))
runs.test(x, alternative = c("two.sided", "less", "greater"))
```

自编版

```
runs.test <- function(x, alternative = c("two.sided", "less", "greater"),
↪  exact = TRUE, correct = FALSE) {

  alternative <- match.arg(alternative)
  DNAME <- deparse1(substitute(x))
```

```
METHOD <- "Runs test"

# Calculate runs
runs <- sum(diff(x) != 0) + 1

# Calculate sample sizes
N <- length(x)
n <- sum(x)  # Number of 1s in x
m <- N - n  # Number of 0s in x

# Functions for cumulative probability
pruns <- function(runs, m, n, lower.tail = TRUE){
  p <- 0
  if (lower.tail){
    for (i in 1:runs){
      if (i %% 2 == 0){
        k <- i / 2
        p <- p + 2 * choose(m - 1, k - 1) *
          choose(n - 1, k - 1) /
          choose(m + n, n)
      }else{
        k <- (i - 1) / 2
        p <- p + (choose(m - 1, k - 1) * choose(n - 1, k) +
                    choose(m - 1, k) * choose(n - 1, k - 1)) /
          choose(m + n, n)
      }
    }
  }else{
    for (i in (runs + 1):(m+n)){
      if (i %% 2 == 0){
        k <- i / 2
        p <- p + 2 * choose(m - 1, k - 1) *
          choose(n - 1, k - 1) /
          choose(m + n, n)
      }else{
        k <- (i - 1) / 2
        p <- p + (choose(m - 1, k - 1) * choose(n - 1, k) +
                    choose(m - 1, k) * choose(n - 1, k - 1)) /
```

```
            choose(m + n, n)
        }
      }
    }
    return(p)
  }

  if (exact){
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    # Exact p-value calculation
    p.value <- switch(alternative,
                      two.sided = 2 * min(pruns(runs, m, n),
                                          pruns(runs - 1, m, n,
                                          ↪  lower.tail = FALSE)),
                      less = pruns(runs, m, n),
                      greater = pruns(runs, m, n, lower.tail = FALSE))
  }else{
    # Normal approximation
    E_R <- (2 * m * n) / N + 1
    Var_R <- (2 * m * n * (2 * m * n - N)) / (N^2 * (N - 1))
    z <- (runs - E_R) / sqrt(Var_R)

    if (correct){
      METHOD <- paste(METHOD, "with continuity correction")
      # Apply continuity correction
      z <- runs - E_R
      CORRECTION <- switch(alternative,
                           two.sided = sign(z) * 0.5,
                           greater = 0.5,
                           less = -0.5)
      z <- (z - CORRECTION) / sqrt(Var_R)
      # p-value using normal approximation
      p.value <- switch(alternative,
                        two.sided =  2 * min(pnorm(z),
                                             pnorm(z, lower.tail =
                                             ↪  FALSE)),
                        less = pnorm(z),
                        greater = pnorm(z, lower.tail = FALSE))
```

```
    }else{
      p.value <- switch(alternative,
                        two.sided =  2 * min(pnorm(z),
                                             pnorm(z, lower.tail =
                                             ↪  FALSE)),
                        less = pnorm(z),
                        greater = pnorm(z, lower.tail = FALSE))
    }
  }

  alternative <- switch(alternative,
                        two.sided = "The data lacks randomness.",
                        less = "The data has a tendency to cluster.",
                        greater = "The data has a tendency to mix.")

  # Create output in htest format
  RVAL <- list(statistics = setNames(runs, "runs"),
               alternative = alternative, method = METHOD,
               data.name = DNAME, p.value = p.value)
  class(RVAL) <- "htest"
  RVAL
}

# median <- median(x)
# x <- na.omit(ifelse(x > median, 1, ifelse(x < median, 0, NA)))
runs.test(x, alternative = "two.sided",
          exact = TRUE, correct = FALSE)
```

5.3 分类评分结果一致性判断

根本没懂原理

5.3.1 Cohen's Kappa 系数

评判标准

1. < 0.4 一致性很差
2. $0.4 - 0.6$ 中度一致
3. $0.6 - 0.8$ 具有较高的一致性

4. > 0.8 具有极高的一致性

代码

```
library(psych)
cohen.kappa(x)
```

5.3.2 Kendall 协同系数检验

目的

检验 b 次对 k 个个体的评估是随机的（不相关的）还是一致的。

适用条件

完全区组设计，离散型数据（打分，排序），主观性的数据一般使用 Kendall 检验。

假设

$$H_0: \text{这些评估是不相关的或是随机的}, \ H_1: \text{这些评估是一致的}$$

原理

这里其实是把 b 个评估者看作是区组，把被评分的个体看作了水平。所有的计算和 Friedman 秩和检验一样（参考第24页），只是 Kendall 协同系数 W 要在 Friedman 统计量 Q 的基础上再除 $b(k-1)$（大样本近似与打结的情况都可参考 Friedman 秩和检验）。

查资料看 Kendall 的打结是否和 Friedman 一致

为什么这么做呢？我们想看的是对个体的评估是否是随机的，那么如果是随机的，各个体获得的评分总秩和应该是较相近的。其实还是看各水平之间是否有差异，但并不是它们本身的差异，而是在被评估者打分以后，在打分上是否呈现出各水平的差异。其实我们在这里是默认个体之间是有差异的，如果评估结果有差异那么就不随机，评估结果没有差异那就是随机的评估。

代码

以下是自编代码，提供精确计算、大样本近似、连续性修正与打结校正功能。x 可以是一个三列的数据框，第一列表示 response 值，第二列表示 factor，第三列表示 block。x 也可以是一个向量，表示 response，此时必须传入 factor 和 block。

```
kendall.test <- function(x, factor = NULL, block = NULL,
                         exact = FALSE, correct = FALSE) {
  if (is.data.frame(x)) {
    if (ncol(x) == 3) {
```

```
      response <- x[[1]]
      factor <- x[[2]]
      block <- x[[3]]
      DNAME <- deparse(substitute(x))
    }
  } else if (is.vector(x)) {
    if (is.null(factor) || is.null(block)) {
      stop("Error: factor and block must be provided when x is a vector.")
    }
    response <- x
    DNAME <- paste(deparse(substitute(x)), ", ",
                   deparse(substitute(factor)), " and ",
                   deparse(substitute(block)), sep = "")
  } else {
    stop("Error: x must be either a data frame with three columns or a vector.")
  }
  W.call <- function(ranks, factors) {
    R_i <- tapply(ranks, factors, sum)
    (12 / (b * k * (k + 1)) * sum(R_i^2) - 3 * b * (k + 1)) / (b * (k - 1))
  }
  METHOD <- "Kendall test"
  k <- length(unique(factor))
  b <- length(unique(block))
  rank <- ave(response, block, FUN = rank)
  STATISTIC <- setNames(W.call(rank, factor), "W")
  TIES <- unlist(tapply(response, block, table))
  if (any(sapply(TIES, function(x) any(x > 1)))) {exact = FALSE}
  if (!exact) {
    Wc <- STATISTIC / (1 - sum(TIES^3 - TIES) / (b * k * (k^2 - 1)))
    if (!correct) {
      p_value <- pchisq(Wc * b * (k - 1), k - 1, lower.tail = FALSE)
    } else {
      p_value <- pchisq(Wc * b * (k - 1) - 0.5, k - 1, lower.tail = FALSE)
      METHOD <- paste(METHOD, "with continuity correction")
```

```
    }
  } else {
    METHOD <- sub("test", "exact test", METHOD, fixed = TRUE)
    library(gtools)
    possible_ranks <- permutations(k, k)
    all_combinations <- permutations(nrow(possible_ranks), b,
    ↪  repeats.allowed = TRUE)
    Ws <- sapply(1:nrow(all_combinations), function(i) {
      b_combs <- possible_ranks[all_combinations[i, ], ]
      rank_i <- as.vector(b_combs)
      W.call(rank_i, factor)
    })
    p_value <- mean(Ws >= STATISTIC)
  }
  RVAL <- list(statistic = STATISTIC, p.value = p_value,
               method = METHOD, data.name = DNAME)
  class(RVAL) <- "htest"
  RVAL
}
```

5.4 列联表独立性问题

检验列联表的行列变量之间是否是独立的。

假设

$$H_0: \text{行变量与列变量是独立的} \Leftrightarrow H_1: \text{行变量与列变量是相关的}$$

5.4.1 Pearson 近似检验

原理

假设行变量有 r 个取值，列变量有 c 个取值，列联表中频数记为 n_{ij}，$i = 1, 2, \ldots, r$，$j = 1, 2, \ldots, c$，行频数总和 $n_{i\cdot} = \sum_j n_{ij}$，列频数总和 $n_{\cdot j} = \sum_i n_{ij}$，频数总和 $n = \sum_{i,j} n_{ij}$，列联表中第 ij 个格子的理论频数为 E_{ij}，行变量取第 i 个值的概率为 $p_{i\cdot}$，列变量取第 j 个值的概率为 $p_{\cdot j}$，一个观测值被分配到列联表中第 ij 个格子的理论概率为 p_{ij}。

写完概率论把独立性链接到这里来

若行变量与列变量独立，由随机变量的独立性，有：

$$p_{ij} = p_{i\cdot} p_{\cdot j},\ E_{ij} = p_{\cdot j} n_{i\cdot}$$

但由于 $p_{\cdot j}$ 是理论值无法预知，用 $\frac{n_{\cdot j}}{n}$ 来代替，那么 $E_{ij} = \hat{p_{\cdot j}} n_{i\cdot} = \frac{n_{i\cdot} n_{\cdot j}}{n}$。由此构建以下 Pearson$\chi^2$ 统计量：

$$Q = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

如果零假设不成立，那么 n_{ij} 与 E_{ij} 的值相差就会比较大，统计量的值也会偏大。若统计量的值过大，则有里有怀疑零假设。由此可看出这里只考虑上侧的单侧检验问题。

大样本近似

在大样本的情况下，若零假设成立，有如下近似分布：

$$Q \sim \chi^2_{(r-1)(c-1)}$$

5.4.2 低维列联表的 Fisher 精确检验

假定五个边际频数都是固定的，在零假设成立的情况下，这个具体的列联表出现的条件概率（给定边际频数的情况下，因此是条件概率）只依赖于四个频数中的任意一个，且该概率满足超几何分布：

$$P = \frac{\binom{n_{1\cdot}}{n_{11}}\binom{n_{2\cdot}}{n_{21}}}{\binom{n}{n_{\cdot 1}}}$$

	B1	B2	总和
A1	n_{11}	n_{12}	$n_{1\cdot}$
A2	n_{21}	n_{22}	$n_{2\cdot}$
总和	$n_{\cdot 1}$	$n_{\cdot 2}$	n

表 5.3: 二维列联表

若零假设成立，那么任何一个关于 n_{ij} 的尾概率 $P(n_{ij} \leqslant a)$, $P(n_{ij} \geqslant b)$, $1 - P(a < n_{ij} < b)$ 都不应该太小或太大。若尾概率太小或太大，则有理由怀疑零假设。由此可以看出这里其实是涉及备择假设的方向问题的，可以单侧也可以双侧。

有机会看看单侧的实际意义，不懂为什么会考虑单侧

代码

Pearson 近似检验

直接将列联表矩阵输入以下函数即可。

```
chisq.test(x)
```

Fisher 精确检验

直接将列联表矩阵输入以下函数即可。

```
fisher.test(x, alternative="two.sided")
```

5.5 似然比检验

目的

有两个对未知分布 F 参数 θ 的点估计 θ_1 和 θ_2，需要去判断哪个估计更好。

假设

$$H_0 : \theta = \theta_1 \quad H_1 : \theta = \theta_2$$

原理

令 L 表示最大似然函数，则检验统计量为：

$$\lambda = \frac{L(X|\theta_1)}{L(X|\theta_2)}$$

如果 λ 偏小，则说明在 θ_2 下样本出现的概率更大，那么就应该拒绝零假设。当样本量 n 足够大时，有：

$$-2\ln\lambda \sim \chi_p^2, \quad p = dim(\Theta_0 \cup \Theta_1) - dim(\Theta_0)$$

Chapter 6

单调关联性

写完概率论把 Pearson 线性相关系数链接过来。

单调关联性 (association) 与单调相关性 (correlation) 是否是同一个东西呢？

它们并不一样。单调关联性仅从秩的角度来衡量两个变量是否同增同减或一增一减，单调相关性除了增减性以外，还要求增减之间存在线性关系，即一个变量增大或减小一个单位，另一个变量是否会固定地增大或减小某个单位的数值。考虑语言习惯问题，本章仍使用相关性来称呼关联性。

6.1 单调关联性的零假设与备择假设

$$H_0: X\text{和}Y\text{不相关}, \begin{cases} H_1: X\text{和}Y\text{正相关} \\ H_1: X\text{和}Y\text{负相关} \\ H_1: X\text{和}Y\text{相关} \end{cases}$$

6.2 本章各方法的简单总结

1. Spearman 秩相关检验与 Kendall 秩相关检验中的 τ_a 都可以用作连续变量的相关性检验。

2. Kendell's τ_b 与 τ_c 都可以用作有序分类变量的相关性检验，但在列联表行列数目 r 和 c 差别较大时，使用 τ_c 更合适。

3. Goodman-Kruskal's τ 检验针对分类有序变量。

4. Somers' d 检验针对分类有序变量，与前面几种方法的不同是：前几种方法的两个变量 X 和 Y 是对称的，而 Somers' 检验把其中一个变量看作自变量，另一个看作因变量，它可以度量自变量对因变量的影响。

6.3 Spearman 秩关联检验

原理

记 x_i 在 X 样本中的秩为 R_i，y_i 在 Y 样本中的秩为 S_i，$d_i^2 = (R_i - S_i)^2$，$\bar{R} = E(R) = \frac{1}{n}\sum_{i=1}^n R_i$，$barS = E(S) = \frac{1}{n}\sum_{i=1}^n S_i$。

显然，若很多 d_i^2 很大，那么两个变量之间可能是负相关；若很多 d_i^2 很小，那么两个变量之间可能是正相关。类似 Pearson 相关系数，定义以下 Spearman 检验统计量：

$$r_s = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2 \sum_{i=1}^n (S_i - \bar{S})^2}} = 1 - \frac{6\sum_{i=1}^n d_i^2}{n(n^2-1)}$$

由 Cauchy 不等式，显然有 $-1 \leqslant r_s \leqslant 1$。

在样本不大且没有结的时候，可以使用精确检验：固定 R_i 从小到大，此时 S_i 的排序情况共有 $n!$ 种可能，对每一种可能计算 r_s，即可得到 r_s 的精确分布。

大样本的情况

大样本时没有近似分布，采用 Monte Carlo 模拟，固定随机数种子，随机抽取 m 个 S_i 可能的排序情况，对这 m 个情况计算 r_s 值，得到近似的分布。

打结

若 X 或 Y 样本中存在相同的数据，则称之为打结的情况。记 u_j，$j = 1, 2, \ldots, p$ 和 v_j，$j = 1, 2, \ldots, q$ 分别为 X 和 Y 样本中结统计量的值，记：

$$U = \sum_{j=1}^p (u_j^3 - u_j),\ V = \sum_{j=1}^q (v_j^3 - v_j)$$

则此时修正过的 Spearman 检验统计量定义为：

$$r_s = \frac{n(n^2-1) - 6\sum_{i=1}^n (R_i - S_i)^2 - 6(U+V)}{\sqrt{[n(n^2-1) - 12U]\,[n(n^2-1) - 12V]}}$$

在样本量比较大时，有：

$$Z = r_s\sqrt{n-1} \sim N(0,\ 1)$$

有结的时候没有精确分布，只能使用上式的大样本近似。

代码

```
cor.test(x, y,
alternative = c("two.sided", "less", "greater"),
method = "spearman"
exact = NULL, continuity = FALSE)
```

6.4 Kendall τ 关联检验

协同

对于样本 $X_i, Y_i,\ i=1,2,\ldots,n$，从中任取两对作积 $(X_i-X_j)(Y_i-Y_j)$，若乘积大于 0，则称对子 $(X_i,\ Y_i)$ 和 $(X_j,\ Y_j)$ 是协同的 (concordant)，它们具有相同的倾向，若乘积小于 0，则称对子是不协同的 (disconcordant)，它们有相反的倾向。令：

$$\Psi(X_i,X_j,Y_i,Y_j)=\begin{cases}1, & (X_i-X_j)(Y_i-Y_j)>0\\ 0, & (X_i-X_j)(Y_i-Y_j)=0\\ -1, & (X_i-X_j)(Y_i-Y_j)<0\end{cases}$$

原理

定义 Kendall τ 相关系数为：

$$\tau_a=\frac{2}{n(n-1)}\sum_{1\leqslant i<j\leqslant n}\Psi(X_i,X_j,Y_i,Y_j)=\frac{K}{\binom{n}{2}}=\frac{n_c-n_d}{\binom{n}{2}}$$

其中 n_c 表示协同的对子的数目，而 n_d 表示不协同的对子的数目。

由定义可以看出，τ_a 取值在 $-1\sim 1$ 之间，τ_a 越大，协同的对子数目越多，两个变量越有可能正相关；τ_a 越小，不协同的对子数目越多，两个变量越有可能负相关。

在计算时，可以把成对数据 $(X_i,\ Y_i)$ 按第一个变量从小到大排序，然后就可以只用 Y_i 的大小关系或者秩来计算 n_c 和 n_d 了。

在样本量不太大并且没有结的时候，可以按如下方法求精确检验结果：把成对数据 $(X_i,\ Y_i)$ 按第一个变量从小到大排序，此时 Y_i 的排序情况共有 $n!$ 种可能，对每一种可能计算 τ_a，即可得到 τ_a 的精确分布。

大样本近似

在零假设成立的情况下，当 $n\to+\infty$ 时，有如下近似分布：

$$Z=K\sqrt{\frac{18}{n(n-1)(2n+5)}}\sim N(0,\ 1)$$

打结

若 X 或 Y 样本中存在相同的数据，则称之为打结的情况。记 $u_i,\ i=1,2,\ldots,p$ 和 $v_i,\ i=1,2,\ldots,q$ 分别为 X 和 Y 样本中结统计量的值，此时有如下修正后的检验统计量：

$$\tau_b=\frac{n_c-n_d}{\sqrt{\left[\frac{n(n-1)}{2}-\sum_i u_i(u_i-1)/2\right]\left[\frac{n(n-1)}{2}-\sum_i v_i(v_i-1)/2\right]}}$$

有结的时候没有精确分布，只能使用下式的大样本近似：

$$Z = \frac{n_c - n_d}{\sqrt{[n(n-1)(2n+5) - t_u - t_v]/18 + t_1 + t_2}} \sim N(0,\ 1)$$

$$t_u = \sum_i u_i(u_i - 1)(2u_i + 5)$$

$$t_v = \sum_i v_i(v_i - 1)(2v_i + 5)$$

$$t_1 = \frac{1}{2n(n-1)} \sum_i u_i(u_i - 1) \sum_j v_j(v_j - 1)$$

$$t_2 = \frac{1}{9n(n-1)(n-2)} \sum_i u_i(u_i - 1)(u_i - 2) \sum_j v_j(v_j - 1)(v_j - 2)$$

有序分类变量情况下的 τ_c

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i = 1, 2, \ldots, r,\ j = 1, 2, \ldots, c$ 为列联表中的对应元素，则 Kendall's τ_c 的定义和其渐进均方差为：

$$\tau_c = \frac{2q(n_c - n_d)}{n^2(q-1)}$$

$$\text{ASE} = \frac{2q}{(q-1)n^2} \sqrt{\sum_{ij} n_{ij}(C_{ij} - D_{ij})^2 - 4(n_c - n_d)^2/n}$$

$$q = \min(r, c)$$

$$C_{ij} = \sum_{i'>i} \sum_{j'>j} n_{i'j'} + \sum_{i'<i} \sum_{j'<j} n_{i'j'}$$

$$D_{ij} = \sum_{i'>i} \sum_{j'<j} n_{i'j'} + \sum_{i'<i} \sum_{j'>j} n_{i'j'}$$

其取值范围也在 $-1 \sim 1$ 之间，同时有如下大样本近似：

$$\frac{\tau_c}{\text{ASE}} \sim N(0,\ 1)$$

代码

```
cor.test(x, y,
alternative = c("two.sided", "less", "greater"),
method = "kendall"
exact = NULL, continuity = FALSE)
```

6.5 Goodman-Kruskal's γ 关联检验

原理

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i=1,2,\ldots,r,\ j=1,2,\ldots,c$ 为列联表中的对应元素，则 Goodman-Kruskal 关联检验统计量 G（也是相关系数的一个点估计）的定义和其近似分布为：

$$G=\frac{n_c-n_d}{n_c+n_d}$$

$$\frac{G}{Var(G)}\sim N(0,\ 1)$$

$$Var(G)\approx\frac{16}{(P+Q)^4}\sum_{i,j}n_{ij}(PC_{ij}-QD_{ij})^2$$

$$P=2n_c,\ Q=2n_d$$

$$C_{ij}=\sum_{i'>i}\sum_{j'>j}n_{i'j'}+\sum_{i'<i}\sum_{j'<j}n_{i'j'},\ D_{ij}=\sum_{i'>i}\sum_{j'<j}n_{i'j'}+\sum_{i'<i}\sum_{j'>j}n_{i'j'}$$

代码

```
library(DescTools)
GoodmanKruskalGamma(x, y, )
```

6.6 Sumers' d 关联检验

原理

假设 X 和 Y 是有序分类变量，分别由 r 个和 c 个有序水平，将观测数据的频数放入一个列联表中，令 $n_ij,\ i=1,2,\ldots,r,\ j=1,2,\ldots,c$ 为列联表中的对应元素。

Somers 定义了 $d(C|R)$ 与 $d(R|C)$，前者将行变量 X 看作自变量，后者把列变量 Y 看作自变量，下面仅介绍 $d(C|R)$，$d(R|C)$ 的情况只需要把列联表转置即可得到相应的结果。$d(C|R)$ 的定义及其渐近均方差为：

$$d(C|R)=\frac{2(n_c-n_d)}{n(n-1)-\sum_i^r R_i(R_i-1)}=\frac{P-Q}{D_r}$$

$$\text{ASE}=\frac{2}{D_r^2}\sqrt{\sum_{i,j}n_{ij}\left[D_r(C_{ij}-D_{ij})-(P-Q)(n-R_i)\right]^2}$$

$$R_i=\sum_{j=1}^{c}n_{ij},\ D_r=n^2-\sum_{i}^{r}R_i^2$$

$$P=2n_c,\ Q=2n_d$$

$$C_{ij}=\sum_{i'>i}\sum_{j'>j}n_{i'j'}+\sum_{i'<i}\sum_{j'<j}n_{i'j'},\ D_{ij}=\sum_{i'>i}\sum_{j'<j}n_{i'j'}+\sum_{i'<i}\sum_{j'>j}n_{i'j'}$$

在大样本情况下有如下近似：

$$\frac{d(C|R)}{\text{ASE}}\sim N(0,\ 1)$$

附录

.1 数域

定义 .1. 复数集的一个子集 K 如果满足：

1. $1 \in K$；
2. $a, b \in K \Rightarrow a \pm b, ab \in K$，$a, b \in K$ 且 $b \neq 0 \Rightarrow \dfrac{a}{b} \in K$。

则称 K 是一个数域 *(number filed)*。

定理 .1. 任意数域都包含有理数域。

证明. 任取数域 K，由数域的定义可得 $1 \in K$，那么根据数域对其内数加法与减法的封闭性，$\mathbb{Z} \subseteq K$。于是任意分数 $\frac{a}{b} \in K$, $b \neq 0$，即 $\mathbb{Q} \subseteq K$。 □

.2 等价关系

定义 .2. 对于任意两个非空集合 S, M，称：

$$\{(a, b) : a \in S,\ b \in M\}$$

为集合 S 与集合 M 的笛卡尔积 *(Cartesian product)*，记为 $S \times M$。其中两个元素 (a_1, b_1) 与 (a_2, b_2) 如果满足 $a_1 = a_2$, $b_1 = b_2$，则称二者相等，记作 $(a_1, b_1) = (a_2, b_2)$。

定义 .3. 设 S 是一个非空集合，把 $S \times S$ 的一个子集 W 叫作 S 上的一个二元关系 *(binary relation)*。如果 $(a, b) \in W$，则称 a 与 b 有 W 关系；如果 $(a, b) \notin W$，则称 a 与 b 没有 W 关系。当 a 与 b 有 W 关系时，记作 aWb，或 $a \sim b$。

定义 .4. 集合 S 上的一个二元关系 $\sim$ 如果具有如下性质：对 $\forall\, a, b, c \in S$，有：

1. $a \sim a$（反身性）；
2. $a \sim b \Rightarrow b \sim a$（对称性）；
3. $a \sim b,\ b \sim c \Rightarrow a \sim c$（传递性）。

那么称 $\sim$ 是集合 S 上的一个等价关系 *(equivalence relationship)*。

定义 .5. 设 $\sim$ 是集合 S 上的一个等价关系，$a \in S$，令：

$$\overline{a} \stackrel{\text{def}}{=} \{x \in S : x \sim a\}$$

称 $\overline{a}$ 是由 a 确定的等价类 *(equivalence class)*，称 a 是等价类 $\overline{a}$ 的一个代表。

性质. 等价类具有如下基本性质：

1. $a \in \overline{a}$;
2. $x \in \overline{a} \Leftrightarrow x \sim a$;
3. $x \sim y \Leftrightarrow \overline{x} = \overline{y}$。

证明. (1) 等价关系具有反身性。(2) 由等价类的定义可直接得出。

(3) **充分性**：因为 $x \in \overline{x}$ 且 $\overline{x} = \overline{y}$，所以 $x \in \overline{y}$，由 $\overline{y}$ 的定义，$x \sim y$。

必要性：任取 $a \in \overline{x}$，则 $a \sim x$。因为 $x \sim y$，由等价关系的传递性，$a \sim y$，即 $a \in \overline{y}$。由 a 的任意性，$\overline{x} \subseteq \overline{y}$。同理可证得 $\overline{y} \subseteq \overline{x}$，所以 $\overline{x} = \overline{y}$。 □

推论 .1. 用不同代表表示的等价类是一样的，即代表的选择与等价类本身无关。

证明. 由等价类基本性质 (3) 可直接得到。 □

定理 .2. 设 $\sim$ 是集合 S 上的一个等价关系。对 $\forall\, a, b \in S$，有 $\overline{a} = \overline{b}$ 或 $\overline{a} \cap \overline{b} = \varnothing$。

证明. 如果 $\overline{a} \neq \overline{b}$，假设此时 $\overline{a} \cap \overline{b} \neq \varnothing$，取 $c \in \overline{a} \cap \overline{b}$，则有 $c \sim a$ 且 $c \sim b$。由等价关系的对称性与传递性可得 $a \sim b$，根据等价类的基本性质 (3)，此时应有 $\overline{a} = \overline{b}$，矛盾，所以 $\overline{a} \cap \overline{b} = \varnothing$。 □

定义 .6. 如果集合 S 可以表示为一些非空子集的并集，且这些子集不相交，即：

$$\exists\, S_i \subseteq S,\ \bigcup_{i \in I} S_i = S,\ S_i \cap S_j = \varnothing,\ i \neq j,\ i, j \in I$$

其中 I 是指标集。称集合 $\{S_i : i \in I\}$ 是 S 的一个划分 *(partition)*，记作 $\pi(S)$。

定理 .3. 设 $\sim$ 是集合 S 上的一个等价关系，则所有等价类组成的集合是 S 的一个划分，记作 $\pi_{\sim}(S)$。

证明. 对 $\forall\, a_i \in S$，其中 i 是指标集，有 $a_i \in \overline{a_i}$，于是 $S = \bigcup_{i \in I} \overline{a_i}$。由定理 .2可得，若 $i \neq j$，$\overline{a_i} \cap \overline{a_j} = \varnothing$，从而所有等价类组成的集合是 S 的一个划分。 □

定义 .7. 设 $\sim$ 是集合 S 上的一个等价关系，所有等价类组成的集合称为 S 对于关系 $\sim$ 的商集 *(quotient set)*。

定义 .8. 设 $\sim$ 是集合 S 上的一个等价关系，一种量或者一种表达式如果对于同一个等价类里的元素是相等的，那么称这种量或表达式是一个**不变量**；恰好能完全绝对等价类的一组不变量称为**完全不变量**。

.3 矩阵

.3.1 Kronecker 乘积

定义 .9. 给定两个矩阵 $A \in \mathbb{R}^{m\times n}$ 和 $B \in \mathbb{R}^{p\times q}$，它们的 *Kronecker* 乘积 $A \otimes B$ 是一个大小为 $mp \times nq$ 的矩阵，定义为：

$$A \otimes B = \begin{pmatrix} a_{11}B & a_{12}B & \cdots & a_{1n}B \\ a_{21}B & a_{22}B & \cdots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \cdots & a_{mn}B \end{pmatrix}$$

其中 a_{ij} 是矩阵 A 的元素，而每个 $a_{ij}B$ 表示矩阵 B 乘以标量 a_{ij}。

.3.2 迹

定义 .10. 数域 K 上 n 阶矩阵 $A = (a_{ij})$ 的主对角线上的元素之和称为 A 的迹，记作 $\mathrm{tr}(A)$，即：

$$\mathrm{tr}(A) = \sum_{i=1}^{n} a_{ii}$$

性质. 设 $A, B \in M_n(K)$, $k \in K$，矩阵的迹具有如下性质：

1. $\mathrm{tr}(A+B) = \mathrm{tr}(A) + \mathrm{tr}(B)$；
2. $\mathrm{tr}(kA) = k\,\mathrm{tr}(A)$；
3. $\mathrm{tr}(AB) = \mathrm{tr}(BA)$。

证明. (1)(2) 是显然的；

(3) 显然：

$$\mathrm{tr}(AB) = \sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij}b_{ji} = \sum_{j=1}^{n}\sum_{i=1}^{n} b_{ji}a_{ij} = \mathrm{tr}(BA) \qquad \square$$

后记